



Universität
Bremen

Rangreduzierung in DMD mittels Marčenko–Pastur–Verteilung

Bachelorarbeit zur Erlangung des akademischen Grades
Bachelor of Science Technomathematik

Eingereicht von

Lennart Koliwer

koliwer1@uni-bremen.de

Gutachter:innen

Dr. Maxim Kirsebom

Prof. Dr. Anke Pohl

Fachbereich 3

Universität Bremen

SoSe 2026

5. Mai 2026

Inhaltsverzeichnis

1	Einleitung	1
2	Dynamic Mode Decomposition	5
2.1	Frobeniusnorm	5
2.2	Singulärwertzerlegung	6
2.3	Exact DMD	10
3	Marčenko–Pastur–Verteilung	13
3.1	Grundlagen	14
3.2	Marčenko–Pastur–Verteilung	16
3.3	Hilfsmittel für den Konvergenzbeweis	23
3.4	Konvergenzsatz und Beweis	27
	Literatur	37
	Eigenständigkeits- und Einverständniserklärung	40

1 Einleitung

Bei der Rangreduzierung handelt es sich um eine Methode, eine Matrix durch eine andere Matrix eines niedrigeren Ranges zu approximieren. Sie ist ein wichtiges Werkzeug im Umgang mit großen Datenmengen, welche als Matrix vorliegen, um den Rechenaufwand, der bei dem Verarbeiten der Daten aufkommt, zu minimieren.

Ein Beispiel, das wir in diesem Zusammenhang betrachten, ist der Dynamic Mode Decomposition Algorithmus, kurz DMD, aus dem Buch „Data-Driven Science and Engineering“ [4]. DMD ist ein datengetriebener Algorithmus, der ursprünglich im Forschungsgebiet der Strömungsdynamik entwickelt wurde. Grundsätzlich dient der Algorithmus der Analyse von Messdaten eines dynamischen Systems mittels Singulärwertzerlegung von großen Datenmatrizen. DMD kann anhand von Messdaten mehrerer Zeitpunkte die Dynamik eines Systems approximieren. Die Genauigkeit hängt unter anderem davon ab, wie viele Informationen in Form von Messdaten über das System zur Verfügung stehen und wie groß die Messfehler, also das Rauschen der Daten, sind. Dabei ist DMD gut im Erkennen von Mustern, wie im Falle der Strömungsdynamik zum Beispiel Verwirbelungen. Probleme treten jedoch auf, wenn man DMD außerhalb von Simulationen verwendet und echte Messungen analysieren will. Bei echten Messungen hat man immer ein Rauschen in den Daten, welches das Ergebnis verfälscht. Dadurch kommt es durch Fehlerfortpflanzung schnell zu größeren Ungenauigkeiten. Im Laufe der letzten Jahre wurden eine Vielzahl von Varianten des DMD Algorithmus entwickelt, um unterschiedliche Schwächen des Algorithmus auszugleichen.

Das klassische DMD benötigt Messdaten aus k Messungen in einheitlichen Zeitabständen. Für die ersten $k - 1$ Messungen werden die Daten zum Zeitpunkt i in die i -te Spalte einer Datenmatrix X eingetragen. Zusätzlich legen wir eine zweite Datenmatrix X' so an, dass wir in X die Messungen $(x_1, \dots, x_{k-1})$ und in X' die Messungen $(x_2, \dots, x_k)$ sammeln. Bei den Datenmatrizen handelt es sich um $p \times n$ Matrizen, wobei p die Dimension des Systems beziehungsweise die Anzahl der Messdaten zum i -ten Zeitpunkt und $n = k - 1$ die Anzahl der Messungen ist. In der Regel haben die Datenmatrizen deutlich mehr Zeilen als Spalten, also gilt $p \gg n$. Häufig sind die betrachteten Systeme hochgradig nicht-linear. Basierend auf, unter anderem, dem Satz von Hartman–Grobman können

wir auch nicht-lineare Systeme näherungsweise linear analysieren. Das Ziel von DMD ist es, einen linearen Operator A bzw. seine Spektralzerlegung zu finden, für den

$$X' \approx AX$$

so gut wie möglich gilt. Der Operator A muss diagonalisierbar sein. Der dafür am besten passende Operator A lässt sich durch

$$A = \arg \min_{A \in \text{GL}(p, \mathbb{R})} \|X' - AX\|_F = X'X^\dagger$$

bestimmen. Dabei sind $\|\cdot\|_F$ die Frobeniusnorm und $X^\dagger$ die Moore–Penrose–Inverse, welche wir in den Kapiteln 2.1 und 2.3 noch genauer beschreiben werden. Die Moore–Penrose–Inverse lässt sich dann mittels Singulärwertzerlegung (SWZ) der Datenmatrix X bestimmen. Die SWZ beschreiben wir in Kapitel 2.2 noch einmal genauer, liefern aber für einen ersten Überblick eine vereinfachte Beschreibung. Bei der SWZ finden wir für eine Matrix $X \in \mathbb{R}^{p \times n}$ zwei orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ und einer Diagonalmatrix $\hat{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_r)$ mit $r \leq \min(p, n)$ und $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U\Sigma V^\top \quad \text{mit} \quad \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Bei der Bestimmung von A wird der Rechenaufwand schnell zu groß, weshalb der DMD Algorithmus eine Dimensionsreduktion durchführt. Als Dimensionsreduktion bezeichnen wir eine Methode, bei der die Dimension einer Matrix, beispielsweise auf ihren Rang, reduziert wird. Damit kann man eine Spektralzerlegung von A machen, ohne A direkt zu benutzen. Durch die oben genannte Form der Datenmatrizen kann man direkt sehen, dass X maximal von Rang n sein kann. Es gibt also maximal $r \leq n$ Singulärwerte, die nicht null sind. Reduzieren wir also unser Σ aus der SWZ auf eine $r \times r$ große Matrix, also $\hat{\Sigma}$, und entfernen alle Spalten außer die ersten r von U und V , erhalten wir mit den reduzierten Matrizen U_r , Σ_r und V_r

$$X_r = U_r \Sigma_r V_r^\top = U_r \hat{\Sigma} V_r^\top.$$

Nach dem Eckart–Young–Theorem [4, S. 9] lässt sich durch

$$\|X_r\|_F^2 = \sum_{i=1}^r \sigma_i^2$$

zeigen, dass X_r die beste Rang r -Approximation von X bezüglich der Frobeniusnorm ist. Die Spektralzerlegung von A können wir damit über die kleinere Matrix

$$\tilde{A} = U_r^\top A U_r$$

bestimmen. Diese Methode der Dimensionsreduktion für SWZ ist als *ökonomische SWZ* bekannt.

Eine weitere Methode der Rangreduzierung, welche im Paper von Matan Gavish und David L. Donoho behandelt wird, ist das „singular value hard thresholding“ (SVHD) [5]. Dies ist eine Rangreduzierung für Datenmatrizen, in der alle Singulärwerte, die unter einem definierten Schwellenwert τ liegen, auf 0 gesetzt und die Dimensionen wie bei der ökonomischen SWZ angepasst werden. Gavish und Donoho definieren eine Rahmenstruktur, in der statt der Datenmatrix X eine Folge an Datenmatrizen $\{X_\eta\}_{\eta \in \mathbb{N}} \in \mathbb{K}^{p_\eta \times n_\eta}$ der Form

$$X_\eta := X_\eta^{\text{echt}} + \gamma X_\eta^{\text{rauschen}}$$

betrachtet wird, für die mit $\eta \rightarrow \infty$ die Dimensionen p_η und n_η gegen unendlich laufen. Dabei gilt für das Dimensions-Stichproben-Verhältnis $y = \frac{p_\eta}{n_\eta} \in (0, 1]$, dass es nicht divergiert. Zudem ist $\mathbb{K}$ je nach Anwendungsbereich $\mathbb{C}$ oder $\mathbb{R}$. Wir haben also X_η in einen echten Teil und einen durch $\gamma \in \mathbb{R}$ skalierten Fehleranteil aufgeteilt. Die Einträge der Fehlermatrix sind dabei unabhängig und identisch verteilte Zufallsvariablen mit Erwartungswert $\mathbb{E}(X_\eta^{\text{rauschen}}) = 0$ und Varianz $\text{Var}(X_\eta^{\text{rauschen}}) = 1$. Zusätzlich werden die Singulärwerte von X_η^{echt} fixiert. Sei also r der Rang von X^{echt} und $\sigma_1^{\text{echt}}, \dots, \sigma_r^{\text{echt}}$ ihre Singulärwerte, dann ist die Singulärwertzerlegung von X_η^{echt} für alle η von der Form

$$X_\eta^{\text{echt}} = U_\eta \text{diag}(\sigma_1^{\text{echt}}, \dots, \sigma_r^{\text{echt}}, 0, \dots, 0) V_\eta^\top \quad (1.1)$$

mit $U_\eta \in \mathbb{K}^{p_\eta \times p_\eta}$ und $V_\eta \in \mathbb{K}^{n_\eta \times n_\eta}$.

Gavish und Donoho haben numerisch herausgefunden, dass innerhalb der Rahmenstruktur für bekanntes Rauschen γ und bekanntem Dimensions-Stichproben-Verhältnis, der optimale Schwellenwert τ_* für Singulärwerte bei

$$\tau_* = \lambda_*(y) \gamma \sqrt{n_\eta} \quad \text{mit} \quad \lambda_*(y) := \sqrt{2(y+1) + \frac{8y}{(y+1) + \sqrt{y^2 + 14y + 1}}}$$

liegt. Bei quadratischen Matrizen ist $\lambda_* = \frac{4}{\sqrt{3}}$.

Wenn das Rauschen aber nicht bekannt ist, muss γ geschätzt werden. Das Ziel ist es also, einen Schwellenwert $\hat{\tau}_*$ zu finden, ab dem davon ausgegangen werden kann, dass

die Singulärwerte, die größer oder gleich diesem Schwellenwert sind, nur zu einem vernachlässigbaren Anteil aus Rauschen bestehen. Im Zusammenhang mit Singulärwerten von Zufallsmatrizen spielt die Marčenko–Pastur–Verteilung eine zentrale Rolle. Sie sagt aus, wie die quadrierten Singulärwerte von bestimmten Zufallsmatrizen verteilt sind. Für unbekanntes Rauschen haben Gavish und Donoho mit dem Median der Singulärwerte, notiert durch $\sigma_{\text{med},\eta}$, von X_η und dem Median der Marčenko–Pastur–Verteilung μ_y , den Rausch-Schätzer

$$\hat{\gamma}(X) := \frac{\sigma_{\text{med},\eta}}{\sqrt{n_\eta \mu_y}}$$

definiert. Der Median ist mit $a = (1 - \sqrt{y})^2$, $b = (1 + \sqrt{y})^2$ und $a \leq \mu_y \leq b$ so definiert, dass

$$\int_a^{\mu_y} \frac{1}{2\pi xy} \sqrt{(b-x)(x-a)} \, dx = \frac{1}{2}$$

gilt.

Mit $\hat{\gamma}$ haben Gavish und Donoho dann den Schwellenwert für Singulärwerte durch

$$\hat{\tau}_*(y, X) := \lambda_*(y) \hat{\gamma}(X) \sqrt{n_\eta} = \lambda_*(y) \frac{\sigma_{\text{med},\eta}}{\sqrt{\mu_y}}$$

definiert.

In dieser Arbeit konzentrieren wir uns zum einen auf den DMD Algorithmus und zum anderen auf die Herleitung der Marčenko–Pastur–Verteilung, da diese, wie gerade beschrieben, ein wesentlicher Bestandteil der Dimensionsreduktion ist.

2 Dynamic Mode Decomposition

In diesem Kapitel wollen wir genauer auf den DMD Algorithmus beziehungsweise die „exact DMD“ Variante eingehen.

Aus der Einleitung wissen wir, dass die Singulärwertzerlegung und die Frobeniusnorm wichtige Werkzeuge des Algorithmus sind, weshalb wir sie hier konkret definieren.

2.1 Frobeniusnorm

Definition 2.1 (Frobeniusnorm). Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix und x_{ij} mit $i \in \{1, \dots, p\}$, $j \in \{1, \dots, n\}$ ihre Einträge. Die *Frobeniusnorm* von X ist definiert durch

$$\|X\|_F := \sqrt{\sum_{i=1}^p \sum_{j=1}^n |x_{ij}|^2}.$$

Eine weitere Möglichkeit, die Frobeniusnorm zu definieren, ist über die Spur einer Matrix.

Lemma 2.2. Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix. Dann gilt

$$\|X\|_F = \sqrt{\text{tr}(X^H X)}.$$

Beweis. Sei x_i der i -te Spaltenvektor von X und $\bar{x}_{ij}$ das komplex Konjugierte von x_{ij} . Dann ist

$$\begin{aligned} X^H X &= \begin{pmatrix} x_1 & \cdots & x_n \end{pmatrix}^H \begin{pmatrix} x_1 & \cdots & x_n \end{pmatrix} \\ &= \begin{pmatrix} \langle x_1, x_1 \rangle & & * \\ & \ddots & \\ * & & \langle x_p, x_p \rangle \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^p \bar{x}_{1j} x_{1j} & & * \\ & \ddots & \\ * & & \sum_{j=1}^p \bar{x}_{nj} x_{nj} \end{pmatrix}. \end{aligned}$$

Mit $\bar{x}x = |x|^2$ erhalten wir

$$\operatorname{tr}(X^H X) = \sum_{i=1}^n \sum_{j=1}^p \bar{x}_{ij} x_{ij} = \sum_{i=1}^n \sum_{j=1}^p |x_{ij}|^2 = \|X\|_F^2. \quad (2.1)$$

□

Die Frobeniusnorm wird im weiteren Verlauf aufgrund ihrer Invarianz bezüglich unitärer Transformation verwendet, welche wir durch folgendes Lemma zeigen.

Lemma 2.3. Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix und $U \in \mathbb{C}^{p \times p}$ und $V \in \mathbb{C}^{n \times n}$ unitäre Matrizen. Dann gilt

1. $\|X\|_F = \|X^H\|_F$,
2. $\|UX\|_F = \|X\|_F$,
3. $\|XV\|_F = \|X\|_F$.

Beweis.

1. Aus Lemma 2.2 folgt

$$\|X\|_F^2 = \operatorname{tr}(X^H X) = \sum_{i=1}^n \sum_{j=1}^p \bar{x}_{ij} x_{ij} = \sum_{j=1}^p \sum_{i=1}^n \bar{x}_{ij} x_{ij} = \operatorname{tr}(X X^H) = \|X^H\|_F^2.$$

2. Es ist

$$\|UX\|_F^2 = \operatorname{tr}(X^H U^H U X) = \operatorname{tr}(X^H \mathbb{1} X) = \operatorname{tr}(X^H X) = \|X\|_F^2.$$

3. Mit 1. und 2. folgt

$$\|XV\|_F = \|V^H X^H\|_F = \|X^H\|_F = \|X\|_F. \quad \square$$

2.2 Singulärwertzerlegung

Satz 2.4 (Singulärwertzerlegung [7, S. 228]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix und $r := \operatorname{rang} X$ mit $r \leq \min(p, n)$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ und eine Diagonalmatrix $\hat{\Sigma} = \operatorname{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}$ mit $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U \Sigma V^T \quad \text{mit} \quad \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Wir nennen die Diagonalelemente von $\hat{\Sigma}$ Singulärwerte.

Der Beweis des Satzes 2.4 folgt später, da dafür noch die folgenden Lemmata benötigt werden. Wichtig zu erwähnen ist noch, dass unter den in Satz 2.4 genannten Voraussetzungen, $\hat{\Sigma}$ durch X eindeutig bestimmt ist [7, S. 229]. Die beiden orthogonalen Matrizen U und V hingegen sind nicht eindeutig.

Lemma 2.5. Seien $X \in \mathbb{R}^{p \times n}$ und $\sigma_i \in (0, \infty)$ die i -ten Singulärwerte von X mit den Voraussetzungen aus Satz 2.4. Seien weiter λ_i die Eigenwerte von $X^\top X$. Dann gilt

$$\sigma_i = \sqrt{\lambda_i}. \quad (2.2)$$

Beweis. Mit U und V aus Satz 2.4 wird durch

$$\begin{aligned} X^\top X &= (U \Sigma V^\top)^\top (U \Sigma V^\top) \\ &= V \Sigma^\top U^\top U \Sigma V^\top \\ &= V \Sigma^\top \Sigma V^\top \end{aligned}$$

deutlich, dass $X^\top X$ ähnlich zu $\Sigma^\top \Sigma$ ist. Also haben $X^\top X$ und $\Sigma^\top \Sigma$ auch die gleichen Eigenwerte. Damit sind auch die Wurzeln der Eigenwerte von $X^\top X$ gleich den Eigenwerten beziehungsweise Singulärwerten von Σ . $\square$

Lemma 2.6. Die aus der Singulärwertzerlegung in 2.4 entstehenden Singulärwerte sind invariant bezüglich der Transposition von X .

Beweis. Seien die Voraussetzungen aus Satz 2.4 gegeben, dann gilt

$$X^\top = (U \Sigma V^\top)^\top = V \Sigma^\top U^\top.$$

Da Σ nur auf der Hauptdiagonalen Einträge hat und sonst mit Nullen gefüllt ist, erhalten wir

$$\text{diag } \Sigma^\top = \{\sigma_1, \sigma_2, \dots, \sigma_m\} = \text{diag } \Sigma.$$

$\square$

Den Beweis von Satz 2.4 teilen wir auf. Wir betrachten dafür zum einen die Singulärwertzerlegung für den Fall, dass X vollen Rang besitzt, und zum anderen für den rangreduzierten Fall. Für den vollen Rang benutzen wir das folgende Lemma.

Lemma 2.7 ([7, S. 191]). Sei $X \in \mathbb{R}^{p \times p}$ eine symmetrische Matrix. Dann existiert eine orthogonale Matrix $U \in \mathbb{R}^{p \times p}$ und eine Diagonalmatrix $D \in \mathbb{R}^{p \times p}$ so, dass

$$U^\top XU = D$$

gilt.

Für den rangreduzierten Fall brauchen wir das folgende Lemma.

Lemma 2.8 ([7, S. 227]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix mit $\text{rang } X = r < n \leq p$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ sowie eine reguläre obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$ so, dass

$$U^\top XV = R \quad \text{mit} \quad R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt.

Für den Beweis der Singulärwertzerlegung, gehen wir durch Lemma 2.6 ohne Beschränkung der Allgemeinheit davon aus, dass $n < p$ gilt.

Beweis von Satz 2.4. Zunächst betrachten wir den Fall des vollen Ranges von X . Sei also der Rang von X durch $\text{rang } X = r = n$ gegeben. Bei vollem Rang ist $X^\top X \in \mathbb{R}^{n \times n}$ sowohl symmetrisch als auch positiv definit. Die Eigenwerte λ_i von $X^\top X$ sortieren wir nach ihrer Größe, also

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0.$$

Mit Lemma 2.7 finden wir ein orthogonales $V \in \mathbb{R}^{n \times n}$ so, dass

$$V^\top X^\top XV = D = \text{diag}(\lambda_1, \dots, \lambda_n) \in \mathbb{R}^{n \times n}.$$

Weiter definieren wir

$$\hat{\Sigma} := \text{diag}(\sigma_1, \dots, \sigma_n)$$

mit $\sigma_i := \sqrt{\lambda_i} \in (0, \infty)$, für $i = 1, \dots, n$, und setzen

$$\hat{U} := XV\hat{\Sigma}^{-1} \in \mathbb{R}^{p \times n}.$$

Jetzt kann man durch Umformung von

$$\begin{aligned}
\hat{U}^\top \hat{U} &= \hat{\Sigma}^{-\top} V^\top X^\top X V \hat{\Sigma}^{-1} \\
&= \hat{\Sigma}^{-1} D \hat{\Sigma}^{-1} \\
&= \hat{\Sigma}^{-1} \hat{\Sigma}^{-1} D \\
&= D^{-1} D \\
&= \mathbb{1}
\end{aligned}$$

die Orthonormalität der Spalten von $\hat{U}$ sehen.

Da $\hat{U}$ in $\mathbb{R}^{p \times n}$ liegt und aus orthonormalen Spaltenvektoren besteht, finden wir ein $Z \in \mathbb{R}^{p \times (p-n)}$, welches $\hat{U}$ so um $p - n$ orthonormale Spaltenvektoren ergänzt, dass

$$U = (\hat{U} \ Z) \in \mathbb{R}^{p \times p}$$

eine orthogonale Matrix ist. Es gilt also

$$\begin{aligned}
Z^\top X V \hat{\Sigma}^{-1} &= Z^\top \hat{U} \\
&= 0 \in \mathbb{R}^{(p-n) \times p}.
\end{aligned}$$

Da $\hat{\Sigma}^{-1} \hat{\Sigma} = \mathbb{1}$ ist, folgt auch direkt

$$Z^\top X V = 0.$$

Zusammengetragen haben wir dann

$$\begin{aligned}
U^\top X V &= \begin{pmatrix} \hat{U}^\top \\ Z^\top \end{pmatrix} X V = \begin{pmatrix} \hat{\Sigma}^{-1} V^\top X^\top X V \\ Z^\top X V \end{pmatrix} \\
&= \begin{pmatrix} \hat{\Sigma}^{-1} D \\ 0 \end{pmatrix} \\
&= \begin{pmatrix} \hat{\Sigma} \\ 0 \end{pmatrix},
\end{aligned}$$

womit wir den Fall des vollen Ranges bewiesen hätten.

Seien λ_i wie oben definiert wieder die Eigenwerte von $X^\top X$ und sei $X_r \in \mathbb{R}^{p \times n}$ eine Matrix mit $\text{rang } X_r = r < n$. Nach Lemma 2.8 gibt es zwei orthogonale Matrizen

$\tilde{U} \in \mathbb{R}^{p \times p}$ und $\tilde{V} \in \mathbb{R}^{n \times n}$, sowie eine obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$ so, dass

$$\tilde{U}^\top X_r \tilde{V} = R \text{ mit } R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Nach obigem Fall mit vollem Rang, wissen wir, dass es orthogonale Matrizen $U_r \in \mathbb{R}^{p \times p}$ und $V_r \in \mathbb{R}^{r \times r}$ mit

$$U_r^\top \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix} V_r = \begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{p \times r}$$

gibt. Dabei ist $\hat{\Sigma}_r := \text{diag}(\sigma_1, \dots, \sigma_r)$ mit $\sigma_i = \sqrt{\lambda_i}$. Im Folgenden erweitern wir

$$\begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{p \times r} \quad \text{zu} \quad \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} = \Sigma \in \mathbb{R}^{p \times n}$$

und finden eine orthogonale Fortsetzung für V_r zu

$$\bar{V}_r = \begin{pmatrix} V_r & 0 \\ 0 & \mathbb{1} \end{pmatrix} \in \mathbb{R}^{n \times n}.$$

Wenn wir uns jetzt die orthogonalen Matrizen

$$U := \tilde{U} U_r \in \mathbb{R}^{p \times p} \quad \text{und} \quad V := \tilde{V} \bar{V}_r \in \mathbb{R}^{n \times n}$$

definieren, erhalten wir durch

$$\begin{aligned} U^\top X_r V &= U_r^\top \tilde{U} X_r \tilde{V} \bar{V}_r \\ &= U_r^\top \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \bar{V}_r \\ &= \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} =: \Sigma \end{aligned}$$

eine erfolgreiche Zerlegung von X_r durch orthogonale Matrizen. □

2.3 Exact DMD

In der Einleitung haben wir grob den DMD Algorithmus erklärt. Wir gehen hier jetzt aber auf die „exact DMD“ Variante ein, da sie im Gegensatz zur ursprünglichen Vari-

ante keine einheitlichen Zeitabstände zwischen den Messungen erfordert. Dieses Kapitel beruht auf dem Buch „Data-Driven Science and Engineering“ [4].

Exact DMD erlaubt es uns, Daten über mehrere Messungen, die zeitlich unterschiedlich auseinanderliegen, zusammenzutragen. Zu jeder Messung gehört dann ein Datenpaar $\{x(t_i), x(t'_i)\}$ mit $i = 1, \dots, n$ und $t'_i = t_i + \Delta t$. Dabei ist x die Messung zum Zeitpunkt t_i beziehungsweise t'_i . Fügen wir die Datenpaare wie in (2.3) in zwei Matrizen $X, X' \in \mathbb{R}^{p \times n}$ ein, erhalten wir die Zustände des Systems zu n diskreten Zeitpunkten. Wir erhalten also

$$X = \begin{pmatrix} | & | & & | \\ x(t_1) & x(t_2) & \dots & x(t_n) \\ | & | & & | \end{pmatrix} \quad \text{und} \quad X' = \begin{pmatrix} | & | & & | \\ x(t'_1) & x(t'_2) & \dots & x(t'_n) \\ | & | & & | \end{pmatrix}. \quad (2.3)$$

Mit den Vorbereitungen abgeschlossen, gehen wir jetzt auf den Algorithmus ein.

Als Erstes bestimmen wir die Singulärwertzerlegung von X , also

$$X = U \Sigma V^\top.$$

Um den Rechenaufwand zu minimieren, finden wir eine geeignete Rangreduzierung. Wir finden also ein $r \in \mathbb{N}$ mit $r < n$ so, dass wir mit $U_r \in \mathbb{R}^{p \times r}$, $\Sigma_r \in \mathbb{R}^{r \times r}$ und $V_r \in \mathbb{R}^{n \times r}$

$$X \approx U_r \Sigma_r V_r^\top =: X_r$$

approximieren. Um den diagonalisierbaren, linearen Operator A zu finden, der

$$X' \approx AX$$

löst, benötigen wir die Pseudoinverse von X . Um eine eindeutige Inverse zu bekommen, benutzen wir die Moore–Penrose–Inverse aus dem folgenden Satz.

Satz 2.9 (Moore–Penrose–Inverse [7, S. 230]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix und $U, \hat{\Sigma}$ und V die Matrizen aus der Singulärwertzerlegung in Satz 2.4. Dann existiert genau eine Moore–Penrose–Inverse der Form

$$X^\dagger = V \begin{pmatrix} \hat{\Sigma}^{-1} & 0 \\ 0 & 0 \end{pmatrix} U^\top \in \mathbb{R}^{n \times p}.$$

Mit Satz 2.9 können wir A durch

$$A = X' V_r \Sigma_r^{-1} U_r^\top = X' X_r^\dagger$$

bestimmen. Das Ziel ist es, die Spektralzerlegung von A zu finden, damit wir analysieren können, wie sich das System mit der Zeit entwickelt. Da A aber eine $p \times p$ Matrix ist und p schnell sehr groß wird, können wir den Rechenaufwand minimieren, indem wir die Spektralzerlegung von einem $A_r \in \mathbb{R}^{r \times r}$ bestimmen, welches nur noch die für uns relevante Dimension r hat. Wir bestimmen A_r durch

$$\begin{aligned} A_r &= U_r^\top A U_r \\ &= U_r^\top X' X_r^\dagger U_r \\ &= U_r^\top X' V_r \Sigma_r^{-1}. \end{aligned} \tag{2.4}$$

Sei $W \in \mathbb{R}^{r \times r}$ die Matrix aus Eigenvektoren von A_r und $\Lambda \in \mathbb{R}^{r \times r}$ eine Diagonalmatrix, deren Einträge die Eigenwerte λ_i der zugehörigen Eigenvektoren von A_r sind, dann ist die Spektralzerlegung von A_r genau

$$A_r W = W \Lambda. \tag{2.5}$$

Sei $\Phi \in \mathbb{R}^{p \times p}$ die Matrix, deren Spalten die Eigenvektoren von A sind. Dann können wir Φ durch die reduzierten Eigenvektoren W mit

$$\Phi = X' V_r \Sigma_r^{-1} W$$

rekonstruieren.

Durch

$$\begin{aligned} A\Phi &= (X' V_r \Sigma_r^{-1} U_r^\top)(X' V_r \Sigma_r^{-1} W) \\ &\stackrel{(2.4)}{=} X' V_r \Sigma_r^{-1} A_r W \\ &\stackrel{(2.5)}{=} X' V_r \Sigma_r^{-1} W \Lambda \\ &= \Phi \Lambda \end{aligned}$$

können wir sehen, dass die Spalten von Φ auch die Eigenvektoren zu den Eigenwerten von A_r sind. Damit können wir also die Spektralzerlegung von A mit der Spektralzerlegung von A_r bestimmen.

3 Marčenko–Pastur–Verteilung

In Bezug auf die Rangreduzierung sind wir in der Einleitung auf das Paper von Gavish und Donoho eingegangen [5]. Wir erinnern uns an die gegebene Rahmenstruktur. Es galt für $\eta \rightarrow \infty$ und $X_\eta \in \mathbb{K}^{p_\eta \times n_\eta}$, dass das Dimensions-Stichproben-Verhältnis $y = \frac{p_\eta}{n_\eta} \in (0, 1]$ nicht divergiert. In dem Paper wird erwähnt, dass in

$$X_\eta := X_\eta^{\text{echt}} + \gamma X_\eta^{\text{rauschen}}$$

der durch $\frac{\sigma_{\text{med},\eta}}{\sqrt{n_\eta}}$ normierte Median der Singulärwerte von X_η fast sicher gegen den Median der Marčenko–Pastur–Verteilung μ_y konvergiert [5, S. 11]. Daraus ergibt sich dann, dass der Schwellenwert für die Dimensionsreduktion

$$\hat{\tau}_*(y, X) = \lambda_*(y) \frac{\sigma_{\text{med},\eta}}{\sqrt{\mu_y}}$$

fast sicher gegen

$$\lim_{\eta \rightarrow \infty} \lambda_*(y) \frac{\sigma_{\text{med},\eta}}{\sqrt{\mu_y}} \stackrel{\text{f.s.}}{=} \lambda_*(y) = \sqrt{2(y+1) + \frac{8y}{(y+1) + \sqrt{y^2 + 14y + 1}}}$$

konvergiert.

Um die Notation im Folgenden zu vereinfachen, bezeichnen wir die Rauschmatrix X_η^{rauschen} mit $\mathbf{X}_\eta$.

Die Marčenko–Pastur–Verteilung (kurz M-P-Verteilung) beschreibt die asymptotische Verteilung der Eigenwerte von großen Zufallsmatrizen der Form $\frac{1}{n_\eta} \mathbf{X}_\eta \mathbf{X}_\eta^H$. Die genauen Anforderungen an $\mathbf{X}_\eta$ stellen wir im kommenden Unterkapitel 3.1 vor. Eine Wahrscheinlichkeitsverteilung, die angibt, wie die Eigenwerte einer Matrix verteilt sind, ist die empirische Spektralverteilung.

Ziel dieses Kapitels ist es, die schwache Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung zu zeigen. Dieses Kapitel orientiert sich dabei an dem Buch „Spectral Analysis of Large Dimensional Random Matrices“ von Zhidong Bai und Jack W. Silverstein [3].

3.1 Grundlagen

Wir beginnen damit, die empirische Spektralverteilung konkret zu definieren.

Definition 3.1. [3, S. 4, 10] Sei B eine $p \times p$ hermitesche Matrix mit Eigenwerten λ_i und $i = 1, \dots, p$. Dann ist auf dem Ereignisraum $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $\mathcal{B}(\mathbb{R})$ als borelsche σ -Algebra durch

$$F^B(x) := \frac{1}{p} |A_x| \quad \text{mit } A_x := \{i \in \{1, \dots, p\} : \lambda_i \leq x\}$$

die *empirische Spektralverteilung* $F^B: \mathbb{R} \rightarrow [0, 1]$ definiert. Ihre *k-ten Momente* sind durch

$$\beta_k(B) = \int_{-\infty}^{\infty} x^k dF^B(x) = \frac{1}{p} \operatorname{tr}(B^k)$$

gegeben.

Die Konvergenz der empirischen Spektralverteilung betrachten wir in dem Sinne, dass wir analysieren, wie sich die Verteilung verhält, wenn wir eine Folge an Matrizen betrachten, deren Dimensionen p und n gegen unendlich laufen.

Definition 3.2. Sei $\mathbf{X}$ eine $p \times n$ Matrix, deren Elemente unabhängig und identisch verteilte komplexe Zufallsvariablen sind. Dabei sind ihre Erwartungswerte 0 und ihre Varianz bezeichnen wir mit σ^2 . Weiter sind $x_m = (x_{1m}, \dots, x_{pm})^\top$ und $\mathbf{X} = (x_1, \dots, x_n)$.

Für die Folge an Zufallsmatrizen $\{\mathbf{X}_\eta\}$ laufen also p und n so gegen unendlich, dass das Verhältnis

$$\lim_{\eta \rightarrow \infty} \frac{p_\eta}{n_\eta} = y$$

nicht divergiert.

Definition 3.3. Wir bezeichnen mit $\bar{x} = \frac{1}{n} \sum_{m=1}^n x_m$ die durch

$$S = \frac{1}{n} \sum_{m=1}^n (x_m - \bar{x})(x_m - \bar{x})^H \in \mathbb{R}^{p \times p} \quad (3.1)$$

gegebene Matrix S als *Stichproben-Kovarianzmatrix*.

Durch folgenden Satz können wir die Stichproben-Kovarianzmatrix noch weiter vereinfachen.

Satz 3.4 ([3, S. 503]). Seien $A, B \in \mathbb{C}^{p \times n}$, dann gilt

$$\left\| F^{AA^H} - F^{BB^H} \right\|_{\infty} \leq \frac{1}{p} \text{rang}(A - B).$$

Wir formen S zu

$$\begin{aligned} S &= \frac{1}{n} \sum_{m=1}^n (x_m - \bar{x})(x_m - \bar{x})^H \\ &= \frac{1}{n} \left(\sum_{m=1}^n x_m x_m^H - \sum_{m=1}^n x_m \bar{x}^H - \sum_{m=1}^n x_m^H \bar{x} + \sum_{m=1}^n \bar{x} \bar{x}^H \right) \\ &= \frac{1}{n} \left(\sum_{m=1}^n x_m x_m^H - n \bar{x} \bar{x}^H \right) \\ &= \frac{1}{n} \mathbf{X} \mathbf{X}^H - \bar{x} \bar{x}^H \end{aligned}$$

um und definieren $\mathbf{S}$ durch

$$\begin{aligned} \mathbf{S} &:= \frac{1}{n} \sum_{m=1}^n x_m x_m^H \\ &= \frac{1}{n} \mathbf{X} \mathbf{X}^H. \end{aligned} \tag{3.2}$$

Dann können wir mit Satz 3.4 durch

$$\begin{aligned} \|F^S - F^{\mathbf{S}}\|_{\infty} &\leq \frac{1}{p} \text{rang} \left(\frac{1}{\sqrt{n}} \mathbf{X} - \bar{x} \bar{x}^H - \frac{1}{\sqrt{n}} \mathbf{X} \right) \\ &= \frac{1}{p} \text{rang} (\bar{x} \bar{x}^H) \\ &= \frac{1}{p} \end{aligned}$$

zeigen, dass $\bar{x} \bar{x}^H$ keinen Einfluss auf die Konvergenz von F^S hat.

Bemerkung 3.5. Die Folgerung aus Satz 3.4 erlaubt es uns die vereinfachte Form $\mathbf{S}$ für die Stichproben-Kovarianzmatrix zu verwenden. Für den Konvergenzfall betrachten wir entsprechend

$$\mathbf{S}_{\eta} = \frac{1}{n} \mathbf{X}_{\eta} \mathbf{X}_{\eta}^H.$$

3.2 Marčenko–Pastur–Verteilung

Mit dem Verhältnis $y = \frac{p}{n}$ wird die Marčenko–Pastur–Verteilung durch das Wahrscheinlichkeitsmaß F_y auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ beschrieben. Für $y, \sigma^2 \in (0, \infty)$ und $x \in \mathbb{R}$ sind

$$a = \sigma^2 (1 - \sqrt{y})^2 \quad \text{und} \quad b = \sigma^2 (1 + \sqrt{y})^2 .$$

Die Dichtefunktion der Marčenko–Pastur–Verteilung ist dann durch

$$p_y(x) = \begin{cases} \frac{1}{2\pi xy\sigma^2} \sqrt{(b-x)(x-a)}, & \text{wenn } a \leq x \leq b \\ 0, & \text{sonst} \end{cases} \quad (3.3)$$

definiert, wobei sie mit $y > 1$ im Ursprung den Wert $1 - \frac{1}{y}$ annimmt. Die Verteilungsfunktion ergibt sich dann durch

$$F_y(t) = \int_a^t p_y(x) \, dx .$$

Wenn $\sigma^2 = 1$ ist, dann sprechen wir von der Standard-M-P-Verteilung. Die k -ten Momente der M-P-Verteilung sind durch

$$\beta_k(y, \sigma^2) := \int_a^b x^k p_y(x) \, dx \quad (3.4)$$

definiert. Wir können die Momente der M-P-Verteilung durch ihren Standardfall beschreiben, was wir im folgenden Lemma zeigen.

Lemma 3.6. Für alle $k \geq 1$ gilt

$$\beta_k(y, \sigma^2) = \sigma^{2k} \beta_k(y, 1) =: \beta_k .$$

Beweis. Nach (3.3) und (3.4) haben wir

$$\begin{aligned} \beta_k(y, \sigma^2) &= \int_a^b x^k p_y(x) \, dx \\ &= \int_{\sigma^2(1-\sqrt{y})^2}^{\sigma^2(1+\sqrt{y})^2} x^k \frac{1}{2\pi xy\sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - x)(x - \sigma^2(1-\sqrt{y})^2)} \, dx . \end{aligned}$$

Substituieren wir x mit $u\sigma^2$ erhalten wir

$$\begin{aligned}
\beta_k(y, \sigma^2) &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} (u\sigma^2)^k \frac{1}{2\pi u y \sigma^2} \sqrt{\left(\sigma^2(1+\sqrt{y})^2 - u\sigma^2\right) \left(u\sigma^2 - \sigma^2(1-\sqrt{y})^2\right)} du \\
&= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \sigma^{2k} \frac{1}{2\pi u y \sigma^2} \sqrt{\sigma^4 \left((1+\sqrt{y})^2 - u\right) \left(u - (1-\sqrt{y})^2\right)} du \\
&= \sigma^{2k} \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \frac{1}{2\pi u y} \sqrt{\left((1+\sqrt{y})^2 - u\right) \left(u - (1-\sqrt{y})^2\right)} du \\
&= \sigma^{2k} \beta_k(y, 1) .
\end{aligned}$$

Die Momente lassen sich also durch σ^{2k} skaliert über die Standard-M-P-Verteilung beschreiben. $\square$

Damit können wir zeigen, dass die Marčenko–Pastur–Verteilung eindeutig durch die Momente β_k bestimmt wird und wie die Momente explizit aussehen.

Lemma 3.7 (Carleman [3, S. 509]). Sei F eine Verteilungsfunktion und $\{\beta_k = \beta_k(F)\}_{k \in \mathbb{N}_0}$ die Folge ihrer Momente. Ist die *Carleman–Bedingung*

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} = \infty$$

erfüllt, dann wird die Verteilung F durch $\{\beta_k\}_{k \in \mathbb{N}_0}$ eindeutig bestimmt.

Lemma 3.8. Die Momente β_k der Marčenko–Pastur–Verteilung erfüllen die Carleman–Bedingung.

Beweis. Mit (3.3) und (3.4) können wir sehen, dass wir β_{2k} durch

$$\begin{aligned}
\beta_{2k} &= \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-x)(x-a)} dx \\
&\leq \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-a)(b-a)} dx \\
&= \frac{1}{2\pi y} \int_a^b x^{2k-1} (b-a) dx \\
&= \frac{1}{4k\pi y} (b^{2k} - a^{2k}) (b-a) \\
&= \frac{1}{k\pi\sqrt{y}} (b^{2k} - a^{2k}) \\
&\leq \frac{1}{k\pi\sqrt{y}} b^{2k} \\
&\leq b^{2k} = (1 + \sqrt{y})^{4k}
\end{aligned} \tag{3.5}$$

abschätzen können. Mit Lemma 3.7 und der Abschätzung (3.5) haben wir durch

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} \geq \sum_{k=1}^{\infty} (1 + \sqrt{y})^{-2} = \infty$$

die Carleman-Bedingung erfüllt. □

Damit haben wir gezeigt, dass die Marčenko–Pastur–Verteilung durch die Momente β_k eindeutig bestimmt ist. Die explizite Darstellung der Momente zeigen wir im folgenden Lemma.

Lemma 3.9. Die Momente k -ter Ordnung der Marčenko–Pastur–Verteilung haben die Form

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r. \tag{3.6}$$

Beweis. Nach (3.3) und (3.4) gilt

$$\beta_k = \frac{1}{2\pi y} \int_a^b x^{k-1} \sqrt{(b-x)(x-a)} dx.$$

Substituieren wir x mit $1 + y + z$ und setzen $(1 - \sqrt{y})^2$ für a und $(1 + \sqrt{y})^2$ für b ein,

erhalten wir

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{\left((1+\sqrt{y})^2 - 1 - y - z\right) \left(1+y+z - (1-\sqrt{y})^2\right)} dz \\ &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{4y - z^2} dz.\end{aligned}$$

Durch Einsetzen des binomischen Lehrsatzes lässt sich das Integral zu

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} z^\ell \sqrt{4y - z^2} dz \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-2\sqrt{y}}^{2\sqrt{y}} z^\ell \sqrt{4y - z^2} dz\end{aligned}$$

umformen. Um das Integral weiter zu vereinfachen, substituieren wir z mit $2\sqrt{y}u$ und erhalten

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-1}^1 2\sqrt{y} (2\sqrt{y}u)^\ell \sqrt{4y - 4yu^2} du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} (2\sqrt{y})^\ell 4y \int_{-1}^1 u^\ell \sqrt{1 - u^2} du.\end{aligned}$$

Hier ist unser Integrand ungerade, sofern ℓ ungerade ist. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen, ist das Integral für alle ungeraden ℓ gleich 0. Dadurch ist jeder zweite Summand 0. Wir lassen also die Summe bis zur Hälfte von $k-1$ laufen und summieren über 2ℓ statt über ℓ . Für den Fall, dass $k-1$ ungerade ist, runden wir ab, weil es dann nur $\frac{k-2}{2}$ Summanden gibt, die ungleich 0 sind. Wir haben also

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (2\sqrt{y})^{2\ell} 4y \int_{-1}^1 u^{2\ell} \sqrt{1 - u^2} du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \int_{-1}^1 u^{2\ell} \sqrt{1 - u^2} du.\end{aligned}$$

Da die Integralgrenzen symmetrisch um den Nullpunkt liegen und der Integrand gerade ist, können wir zweimal über das halbe Intervall integrieren. Zur Übersicht betrachten

wir vorerst nur noch das Integral und fügen später wieder alles zusammen. Folglich gilt

$$\int_{-1}^1 u^{2\ell} \sqrt{1-u^2} \, du = 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} \, du.$$

Wenn wir jetzt u mit $\sqrt{w}$ substituieren, erhalten wir ein Integral

$$\begin{aligned} 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} \, du &= \int_0^1 w^\ell \sqrt{1-w} \frac{1}{\sqrt{w}} \, dw \\ &= \int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} \, dw, \end{aligned}$$

das wir mittels Eulerscher Betafunktion lösen können. Die Eulersche Betafunktion ist durch

$$\int_0^1 t^{p-1} (1-t)^{q-1} \, dt = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

gegeben [2, S. 19]. Wir können also mit $p = \ell + \frac{1}{2}$ und $q = 1 + \frac{1}{2}$ das Integral durch die Gammafunktionen

$$\begin{aligned} \int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} \, dw &= \frac{\Gamma(\ell + \frac{1}{2})\Gamma(1 + \frac{1}{2})}{\Gamma(\ell + 2)} \\ &= \frac{1}{(\ell + 1)!} \left(\frac{(2\ell)! \sqrt{\pi}}{\ell! 4^\ell} \frac{2! \sqrt{\pi}}{4} \right) \\ &= \frac{1}{(\ell + 1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right) \end{aligned} \tag{3.7}$$

beschreiben. Nach Einsetzen von (3.7) in die wieder zusammengefügte Gleichung, erhalten wir

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right) \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{1}{2\pi y} \frac{(k-1)!}{(2\ell)!(k-1-2\ell)!} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right). \end{aligned}$$

Nach dem Kürzen der Brüche erhalten wir

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell (1+y)^{k-1-2\ell}.$$

Wenn wir den binomischen Lehrsatz mit

$$\begin{aligned}(1+y)^{k-1-2\ell} &= \sum_{s=0}^{k-1-2\ell} \binom{k-1-2\ell}{s} y^s \\ &= \sum_{s=0}^{k-1-2\ell} \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s\end{aligned}$$

einsetzen, haben wir

$$\begin{aligned}\beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!s!(k-1-2\ell-s)!} y^{\ell+s}.\end{aligned}$$

Jetzt wollen wir den Term wieder vereinfachen. Dafür setzen wir $s = r - \ell$, wodurch wir

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} y^r$$

erhalten und erweitern mit zwei Einsen, wodurch

$$\begin{aligned}\beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} \frac{r!}{r!} \frac{(k-r)!}{(k-r)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{r!(k-r)!} \frac{r!}{\ell!(r-\ell)!} \frac{(k-r)!}{(k-r-\ell-1)!(\ell+1)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \frac{k!}{r!(k-r)!} \frac{r!}{\ell!(r-\ell)!} \frac{(k-r)!}{(\ell+1)!(k-r-(\ell+1))!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r\end{aligned}$$

gilt. Für den nächsten Schritt müssen wir die Laufvariablen von 0 starten lassen. Momentan haben wir erst ein ℓ und ermitteln damit, inwieweit r eingeschränkt ist. Für ein

festes, aber beliebiges k liegen unsere Laufvariablen in

$$A = \left\{ (\ell, r) \in \mathbb{N}^2 \mid 0 \leq \ell \leq \left\lfloor \frac{k-1}{2} \right\rfloor, \ell \leq r \leq k-1-\ell \right\}.$$

Daraus wissen wir, dass

$$0 \leq \ell \quad \text{und} \quad r \leq k-1-\ell$$

gilt, woraus wir

$$\ell \leq k-1-r$$

folgern können. Damit erhalten wir

$$\begin{aligned} 0 \leq \ell \leq r \leq k-1-\ell \leq k-1 \\ \implies 0 \leq r \leq k-1, \quad 0 \leq \ell \leq \min(r, k-1-r). \end{aligned}$$

Folglich können wir die Summen äquivalent über

$$A = \{(\ell, r) \in \mathbb{N}^2 \mid 0 \leq r \leq k-1, 0 \leq \ell \leq \min(r, k-1-r)\} \quad (3.8)$$

laufen lassen.

Wir erhalten mit (3.8)

$$\begin{aligned} \beta_k &= \sum_{r=0}^{k-1} \sum_{\ell=0}^{\min(r, k-1-r)} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{\min(r, k-1-r)} \binom{r}{\ell} \binom{k-r}{\ell+1}. \end{aligned}$$

Das Minimum können wir noch weiter vereinfachen, da die Summanden gleich 0 sind, sobald $\ell > r$ oder $\ell > k-1-r$ ist. Wenn wir die Summe also bis r laufen lassen, ändern wir nichts am Ergebnis, wodurch wir den k -ten Moment schreiben können als

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^r \binom{r}{\ell} \binom{k-r}{\ell+1}.$$

An diesem Punkt müssen wir nur noch die innere Summe vereinfachen. Dafür machen

wir eine Indexverschiebung und formen die Binomialkoeffizienten um. Wir haben

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{\ell-1} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{r-(\ell-1)} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell}.
\end{aligned}$$

Hier nutzen wir die Vandermonde Identität [1, S. 16]. Diese ist durch

$$\sum_{\ddot{o}=0}^{\ddot{u}} \binom{n}{\ddot{o}} \binom{m}{\ddot{u}-\ddot{o}} = \binom{n+m}{\ddot{u}} \quad (3.9)$$

gegeben. Um die Vandermonde Identität nutzen zu können, lassen wir die Summe von $\ell = 0$ beginnen, da der zusätzliche Summand das Ergebnis nicht ändert. Mit der Identität (3.9) erhalten wir

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \frac{r+1}{r+1} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r.
\end{aligned}$$

□

3.3 Hilfsmittel für den Konvergenzbeweis

Im Beweis über die Konvergenz der empirischen Spektralverteilung benutzen wir Elemente aus der Graphentheorie und der Stochastik, die wir in diesem Kapitel einführen. Wir definieren eine Klasse von *gerichteten Graphen*, also Graphen, deren Kanten eine Richtung zugewiesen haben.

Gegeben ein Graph, bei dem die Knotenmenge in die Mengen *i*-Knoten und *j*-Knoten

unterteilt ist. Sei k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten mit der Gestalt $\mathbf{i} = \{i_1, \dots, i_k\}$ beziehungsweise $\mathbf{j} = \{j_1, \dots, j_k\}$. Den Knoten sind Werte zugewiesen. Dabei nehmen $\mathbf{i}$ -Knoten Werte in $\{0, \dots, p\}$ und $\mathbf{j}$ -Knoten Werte in $\{0, \dots, n\}$ an. Wenn unterschiedliche $\mathbf{i}/\mathbf{j}$ -Knoten den gleichen Wert annehmen, bezeichnen wir sie als *koinzident*.

Nun erstellen wir einen neuen Graphen, in dem koinzidente Knoten als *einen* Knoten mit mehreren Namen betrachtet werden.

Beispiel 3.10. Falls die Knoten i_2 und i_5 den gleichen Wert x annehmen, erhalten wir einen Knoten, welchen wir sowohl i_2 als auch i_5 nennen. Dies ist für die Definition der Kanten wichtig.

Die Kanten des neuen Graphen unterliegen den folgenden Regeln. Sie laufen von Knoten i_m zu j_m und von j_m zu i_{m+1} mit $m = 1, \dots, k$. Zusätzlich gibt es einen weiteren Knoten i_{k+1} , der den Graphen abschließt und für den $i_{k+1} = i_1$ gilt.

Beispiel 3.11. Wenn alle $\mathbf{i}$ -Knoten den Wert p und alle $\mathbf{j}$ -Knoten den Wert n annehmen, gibt es entsprechend $2k$ Kanten zwischen den zwei Knoten, da wir je k koinzidente $\mathbf{i}/\mathbf{j}$ -Knoten haben.

Sei $\hat{r}$ die Anzahl nicht koinzidenter $\mathbf{i}$ -Knoten, dann definieren wir $r := \hat{r} - 1$ und s als die Anzahl nicht koinzidenter $\mathbf{j}$ -Knoten. Da k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten ist, ist k auch die Anzahl an Kanten, die auf $\mathbf{i}$ -Knoten zeigen.

Diese Klasse an Graphen bezeichnen wir dann als $\Delta(k, r, s)$ Graphen beziehungsweise Δ Graphen. Für den Beweis teilen wir die $\Delta(k, r, s)$ Graphen in drei Kategorien ein.

$\Delta_1(k, r, s)$: Diese Kategorie fasst alle Graphen zusammen, die zu jeder Kante von $\mathbf{i}$ nach $\mathbf{j}$ genau eine Kante vom gleichen $\mathbf{j}$ -Knoten zum gleichen $\mathbf{i}$ -Knoten haben. Hier gilt $r + s = k$.

$\Delta_2(k, r, s)$: Diese Kategorie beinhaltet alle Graphen, die zwischen zwei Knoten mindestens einmal genau eine Kante besitzen, also Graphen, die mindestens eine *Einzelkante* besitzen.

$\Delta_3(k, r, s)$: Die letzte Kategorie $\Delta_3(k, r, s)$ beinhaltet alle Graphen, die weder in $\Delta_1(k, r)$ noch in $\Delta_2(k, r, s)$ liegen.




Abbildung 3.1: Beispiel für Graphen

Zur besseren Lesbarkeit schreiben wir für die jeweiligen Kategorien $\Delta_i(k, r, s)$ nur noch Δ_i , wobei $i \in \{1, 2, 3\}$. Wir bezeichnen zwei Graphen als isomorph, wenn wir für die i/j -Knoten eine geeignete Zuweisung von Knotenwerten so finden, dass die Graphen identisch sind.




Abbildung 3.2: Beispiel für Isomorphie

Beispiel 3.12. Graph a) ist isomorph zu b), da wir die Werte von zwei Knoten ändern können und einen identischen Graphen erhalten. Graph c) ist aber nicht isomorph zu a), da die Graphenstruktur unterschiedlich ist.

Zu den Δ Graphen benötigen wir noch ein paar Lemmata.

Lemma 3.13 ([3, S. 43]). Die Anzahl der Graphen in jeder Isomorphieklasse von $\Delta(k, r, s)$ Graphen, mit festen k, r und s , ist

$$\alpha = p(p-1) \cdots (p-r)n(n-1) \cdots (n-s+1) = p^{r+1}n^s \left(1 + \mathcal{O}\left(\frac{1}{n}\right)\right).$$

Lemma 3.14 ([3, S. 43]). Die Anzahl nicht koinzidenter Knoten von $\Delta_3(k, r, s)$ Graphen ist kleiner oder gleich k , also $r + s \leq k$.

Lemma 3.15 ([3, S. 43]). Die Anzahl nicht-isomorpher $\Delta_1(k, r, s)$ Graphen für festes g und r beträgt

$$\frac{1}{r+1} \binom{k}{r} \binom{k-1}{r}.$$

Zusätzlich zu den Graphen verwenden wir noch Elemente aus der Stochastik. Zum einen benötigen wir das starke Gesetz der großen Zahlen und zum anderen eine Metrik für Wahrscheinlichkeitsverteilungen, die Lévy-Metrik.

Satz 3.16 (Starkes Gesetz der großen Zahlen [6, S. 139]). Seien $\{\mathcal{Z}_i\}_{i \in \mathbb{N}}$ unabhängige und identisch verteilte Zufallsvariablen, die einen Moment erster Ordnung besitzen, dann gilt

$$\frac{1}{n} \sum_{i=1}^n \mathcal{Z}_i \xrightarrow[\text{f.s.}]{n \rightarrow \infty} \mathbb{E}(\mathcal{Z}_1).$$

Definition 3.17 (Lévy-Metrik [6, S. 164]). Seien F_1 und F_2 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit zugehörigen Verteilungsfunktionen $\mathbf{F}_1$ und $\mathbf{F}_2$. Dann ist die *Lévy-Metrik* definiert durch

$$\mathcal{L}(F_1, F_2) = \inf\{\varepsilon > 0, x \in \mathbb{R}: \mathbf{F}_1(x - \varepsilon) - \varepsilon \leq \mathbf{F}_2(x) \leq \mathbf{F}_1(x + \varepsilon) + \varepsilon\}.$$

Lemma 3.18 ([3, S. 502]). Seien $A, B \in \mathbb{C}^{p \times n}$ und $S = AA^H$, $\bar{S} = BB^H$. Dann gilt für die Lévy-Metrik

$$\mathcal{L}^4(F^S, F^{\bar{S}}) \leq \frac{2}{p^2} \text{tr}(AA^H + BB^H) \text{tr}((A - B)(A - B)^H).$$

3.4 Konvergenzsatz und Beweis

Kommen wir nun zum Satz über die Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung.

Satz 3.19. Sei $\{\mathbf{X}_\eta\}$ eine Folge an $p_\eta \times n_\eta$ Zufallsmatrizen, wie in Definition 3.2 beschrieben, und seien ihre Einträge $\{x_{ij}\}$ mit $i = 1, \dots, p_\eta$ und $j = 1, \dots, n_\eta$ unabhängig und identisch verteilte komplexe Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2 . Seien weiter p_η und n_η monoton steigend mit η und $\lim_{\eta \rightarrow \infty} \frac{p_\eta}{n_\eta} = y \in (0, \infty)$.

Dann konvergiert die empirische Spektralverteilung der Stichproben-Kovarianzmatrix $F^{\mathbf{S}_\eta}$ mit $\eta \rightarrow \infty$ fast sicher gegen die Marčenko–Pastur–Verteilung F_y aus Kapitel 3.2.

Im folgenden Beweis nehmen wir mit Lemma 3.6 ohne Beschränkung der Allgemeinheit an, dass die Varianz $\sigma^2 = 1$ ist, wir also den Standardfall betrachten.

Wir zeigen die schwache Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung mithilfe der Momentmethode.

Nach der Momentmethode konvergiert eine Folge an Wahrscheinlichkeitsverteilungen $\{F_n\}_n$, wenn ihre Momente $\beta_{n,k}$ jeder Ordnung $k \geq 0$ endlich sind und gegen einen Grenzwert β_k konvergieren, schwach gegen eine Wahrscheinlichkeitsverteilung, die eindeutig von ihren Momenten β_k bestimmt sein muss [3, S. 507]. Mit dem Beweis von Lemma 3.8 haben wir bereits gezeigt, dass die Momente der Marčenko–Pastur–Verteilung die Carleman–Bedingung 3.7 und damit die Eindeutigkeit erfüllen.

Beweis. Die Momentmethode verlangt, dass die Momente jeder Ordnung der Verteilung endlich sind. Um das garantieren zu können, müssen wir dafür sorgen, dass die Zufallsvariablen $\{x_{ij}\}$ nicht unendlich groß werden können.

Seien $C \in \mathbb{R}_+$ und $\mathbf{1}$ die Indikatorfunktion auf $\mathbb{R}$, dann beschränken wir $\{x_{ij}\}$ und definieren die beschränkte Stichproben-Kovarianzmatrix $\hat{\mathbf{S}}_\eta$ durch

$$\begin{aligned}\hat{x}_{ij} &:= x_{ij} \mathbf{1}(|x_{ij}| \leq C), \\ \hat{x}_i &:= (\hat{x}_{i1}, \dots, \hat{x}_{ip_\eta})^\top, \\ \hat{\mathbf{S}}_\eta &:= \frac{1}{n_\eta} \sum_{i=1}^{n_\eta} \hat{x}_i \hat{x}_i^H = \frac{1}{n_\eta} \hat{\mathbf{X}}_\eta \hat{\mathbf{X}}_\eta^H.\end{aligned}$$

Da das Beschränken die Erwartungswerte verändert hat, müssen wir $\hat{x}_{ij}$ noch zentralisieren, indem wir die Erwartungswerte von den Zufallsvariablen abziehen. Für die zentralisierten Zufallsvariablen und die entsprechende Stichproben-Kovarianzmatrix erhalten

wir

$$\begin{aligned}\tilde{x}_{ij} &:= \hat{x}_{ij} - \mathbb{E}(\hat{x}_{11}), \\ \tilde{x}_i &:= (\tilde{x}_{i1}, \dots, \tilde{x}_{ip_\eta})^\top, \\ \tilde{\mathbf{S}}_\eta &:= \frac{1}{n_\eta} \sum_{i=1}^{n_\eta} \tilde{x}_i \tilde{x}_i^H = \frac{1}{n_\eta} \tilde{\mathbf{X}}_\eta \tilde{\mathbf{X}}_\eta^H.\end{aligned}$$

Wir bezeichnen ab hier alle $\mathbf{X}_\eta$ als $\mathbf{X}$. Mit $\hat{\mathbf{S}}_\eta$ und $\tilde{\mathbf{S}}_\eta$ erhalten wir die beschränkte und zentralisierte Stichproben Kovarianzmatrix.

Im Folgenden stellen wir sicher, dass sich der Grenzwert durch das Beschränken und Zentralisieren nicht ändert. Nach Lemma 3.18 erhalten wir

$$\begin{aligned}\mathcal{L}^4(F^{\mathbf{S}}, F^{\hat{\mathbf{S}}_\eta}) &\leq \frac{2}{n_\eta p_\eta} \operatorname{tr}(\mathbf{X} \mathbf{X}^H + \hat{\mathbf{X}} \hat{\mathbf{X}}^H) \operatorname{tr}((\mathbf{X} - \hat{\mathbf{X}})(\mathbf{X} - \hat{\mathbf{X}})^H) \\ &= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} x_{ij} \bar{x}_{ij} + \hat{x}_{ij} \bar{\hat{x}}_{ij} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} (x_{ij} - \hat{x}_{ij}) \overline{(x_{ij} - \hat{x}_{ij})} \right) \\ &= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 + |\hat{x}_{ij}|^2 \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |x_{ij} - \hat{x}_{ij}|^2 \right) \\ &\leq \left(\frac{4}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 \mathbf{1}(|x_{ij}| > C) \right) \\ &\stackrel{(3.16) \text{ f.s.}}{\longrightarrow} 4 \mathbb{E}(|x_{ij}|^2) \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\stackrel{\text{f.s.}}{\longrightarrow} 4 \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\stackrel{C \rightarrow \infty}{\longrightarrow} 0.\end{aligned}$$

Der Abstand der empirischen Spektralverteilung und ihrer beschränkten Version ist also für ein hinreichend großes C vernachlässigbar klein. Nach Satz 3.4 können wir durch

$$\begin{aligned}\left\| F^{\hat{\mathbf{S}}_\eta} - F^{\tilde{\mathbf{S}}_\eta} \right\|_\infty &\leq \frac{1}{p_\eta} \operatorname{rang}(\hat{\mathbf{X}} - \tilde{\mathbf{X}}) \\ &= \frac{1}{p_\eta} \operatorname{rang}(\mathbb{E}(\hat{x}_{11})) \\ &= \frac{1}{p_\eta}\end{aligned}$$

sehen, dass die Zentralisierung der Zufallsvariablen, ebenfalls keinen Einfluss auf die

Konvergenz hat.

Die Verteilung wurde jetzt so modifiziert, dass die Zufallsvariablen nicht mehr unendlich groß werden können und den Erhalt des Erwartungswertes garantiert, ohne die Konvergenz zu beeinträchtigen.

Wir müssen zusätzlich noch dafür sorgen, dass die Varianz erhalten bleibt. Dafür müssen wir zeigen, dass durch Skalierung von $\tilde{\mathbf{S}}_\eta$ mit $\tilde{\sigma}^2 = \mathbb{E}(|\tilde{x}_{ij}|^2) \rightarrow 1$, wenn $C \rightarrow \infty$ gilt, der Abstand zu $\tilde{\mathbf{S}}_\eta$ vernachlässigbar klein wird.

Es gilt wieder mit Lemma 3.18

$$\begin{aligned}
\mathcal{L}^4(F^{\tilde{\mathbf{S}}_\eta}, F^{\tilde{\sigma}^{-2}\tilde{\mathbf{S}}_\eta}) &\leq \frac{2}{n_\eta} \operatorname{tr} \left(\tilde{\mathbf{X}} \tilde{\mathbf{X}}^H + \frac{1}{\tilde{\sigma}^2} \tilde{\mathbf{X}} \tilde{\mathbf{X}}^H \right) \operatorname{tr} \left(\left(1 - \frac{1}{\tilde{\sigma}} \right)^2 \tilde{\mathbf{X}} \tilde{\mathbf{X}}^H \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H - \frac{2\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}} + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} |\tilde{x}_{ij}|^2 + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |\tilde{x}_{ij}|^2 - \frac{2|\tilde{x}_{ij}|^2}{\tilde{\sigma}} + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 - \tilde{\sigma} 2|\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\
&= 2 \left(\frac{\tilde{\sigma}^2 + 1}{n_\eta p_\eta \tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \left(\frac{(\tilde{\sigma} - 1)^2}{n_\eta p_\eta \tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \\
&\xrightarrow{\text{f.s.}} 2 \frac{\tilde{\sigma}^2 + 1}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \frac{(\tilde{\sigma} - 1)^2}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \\
&\xrightarrow{C \rightarrow \infty} 0.
\end{aligned}$$

Damit haben wir die Endlichkeit der Momente aller Ordnungen garantiert. Für einen besseren Überblick verwenden wir weiterhin die Notation von $\mathbf{S}_\eta$ und $\mathbf{X}$, verwenden aber die modifizierten Matrizen. Wir haben also eine gleichmäßig durch C beschränkte Zufallsvariable x_{ij} mit Erwartungswert 0 und Varianz 1.

Nach Definition 3.1 erhalten wir

$$\begin{aligned}
\beta_{\eta,k}(\mathbf{S}_\eta) &= \int_{-\infty}^{\infty} x^k dF^{\mathbf{S}_\eta}(x) \\
&= \frac{1}{p_\eta} \operatorname{tr} \left(\mathbf{S}_\eta^k \right) \\
&= \frac{1}{p_\eta n_\eta^k} \operatorname{tr} \left((\mathbf{X} \mathbf{X}^H)^k \right)
\end{aligned}$$

für die Momente der empirischen Spektralverteilung.

Hier verwenden wir die eingeführte Klasse von Δ Graphen. Wir können die Spur nämlich mit $\mathbf{i} = \{i_1, \dots, i_k\}$ und $\mathbf{j} = \{j_1, \dots, j_k\}$, wobei die Elemente von $\mathbf{i}$ in $\{1, \dots, p_\eta\}$ und $\mathbf{j}$ in $\{1, \dots, n_\eta\}$ liegen, durch

$$\frac{1}{p_\eta n_\eta^k} \text{tr} \left((\mathbf{X} \mathbf{X}^H)^k \right) = \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k}$$

beschreiben. Dabei sind $x_{i_1 j_1} \bar{x}_{i_2 j_1} \dots$ die Produkte der einzelnen Summanden der Spur und wir summieren über alle Permutationen von $\mathbf{i}$ und $\mathbf{j}$. Die Zufallsvariablen x_{ij} geben die Kanten von $\mathbf{i}$ -Knoten zu $\mathbf{j}$ -Knoten an und $\bar{x}_{ij}$ Kanten von $\mathbf{j}$ -Knoten zu $\mathbf{i}$ -Knoten. Wir definieren dann

$$\frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k} =: \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbf{X}_{\Delta(k, r, s)}.$$

Nach der Momentmethode konvergiert die empirische Spektralverteilung schwach gegen die Marčenko–Pastur–Verteilung, wenn die Momente der empirischen Spektralverteilung gegen die Momente der Marčenko–Pastur–Verteilung konvergieren. Das zeigen wir, indem wir den Erwartungswert und die Varianz der Momente der empirischen Spektralverteilung bestimmen. Sie konvergieren genau dann, wenn der Erwartungswert $\mathbb{E}(\beta_k(\mathbf{S}_\eta))$ gegen die Momente der Marčenko–Pastur–Verteilung läuft und die Varianz gegen null läuft.

Wir prüfen zunächst den Erwartungswert. Es gilt

$$\mathbb{E}(\beta_k(\mathbf{S}_\eta)) = \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbb{E}(\mathbf{X}_{\Delta(k, r, s)}).$$

Teilen wir die Graphen in ihre Kategorien, wie in Kapitel Hilfsmittel für den Konvergenzbeweis 3.3 beschrieben, ein, erhalten wir mit Lemma 3.13

$$\mathbb{E}(\beta_k(\mathbf{S}_\eta)) = \frac{1}{p_\eta n_\eta^k} \left(\overbrace{\sum_{\Delta_1} \alpha \mathbb{E}(\mathbf{X}_{\Delta_1})}^{W_1 :=} + \overbrace{\sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2})}^{W_2 :=} + \overbrace{\sum_{\Delta_3} \alpha \mathbb{E}(\mathbf{X}_{\Delta_3})}^{W_3 :=} \right).$$

Für W_1 erhalten wir mit $s = k - r$ und nach Lemma 3.13 und Lemma 3.14

$$W_1 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p_\eta^{r+1} n_\eta^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right) \right) \mathbb{E}(\mathbf{X}_{\Delta_1}).$$

Da es zu jeder Kante genau eine Kante in die entgegengesetzte Richtung gibt, gilt $\mathbb{E}(|x_{ij}|^2) = 1$. Wir können W_1 also schreiben als

$$\begin{aligned}
W_1 &= \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p_\eta^{r+1} n_\eta^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} \frac{p_\eta^{r+1} n_\eta^{k-r}}{n_\eta^k p_\eta} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p_\eta}\right). \tag{3.10}
\end{aligned}$$

Für W_2 können wir den Erwartungswert in

$$W_2 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2})$$

aufteilen. Da sich Δ_2 -Graphen dadurch auszeichnen, dass sie mindestens eine Einzelkante besitzen, existiert mindestens ein Exponent $\omega_i \in \mathbb{N}$ in

$$\mathbb{E}(\mathbf{X}_{\Delta_2}) = \mathbb{E}(x_{i_1 j_1}^{\omega_1}) \mathbb{E}(x_{i_2 j_1}^{\omega_2}) \dots$$

welcher 1 ist. Da der Erwartungswert der Zufallsvariablen $x_{i_m j_m}$ 0 ist, gilt $\mathbb{E}(x_{i_m j_m}^1) = 0 = \mathbb{E}(\mathbf{X}_{\Delta_2})$. Für W_2 ergibt sich dann

$$W_2 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2}) = 0. \tag{3.11}$$

Für W_3 erhalten wir wieder mit Lemma 3.13, dass

$$W_3 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_3} \alpha \mathbb{E}(\mathbf{X}_{\Delta_3})$$

gilt. Wir haben gezeigt, dass x_{ij} gleichmäßig durch ein $C > 0$ beschränkt ist. Daraus erhalten wir, dass $|X_{\Delta(k,r,s)}| \leq C^{2k}$ gilt. Mit Lemma 3.14 wissen wir, dass die Anzahl nicht koinzidenter Knoten maximal k betragen kann. Dadurch ist die Anzahl unterschiedlicher

Δ_3 Graphen in $\mathcal{O}(n^k)$. Wir haben also

$$\begin{aligned} \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_3} \alpha(\mathbf{X}_{\Delta_3}) &= \frac{C^{2k}}{n_\eta^k p_\eta} \mathcal{O}(n_\eta^k) \\ &= \mathcal{O}\left(\frac{1}{p_\eta}\right). \end{aligned} \quad (3.12)$$

Mit (3.10), (3.11) und (3.12) erhalten wir dann

$$\begin{aligned} \mathbb{E}(\beta_k(\mathbf{S}_\eta)) &= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p_\eta}\right) \\ &= \beta_k(y, \sigma^2) + o(1). \end{aligned} \quad (3.13)$$

Der Erwartungswert der Momente konvergiert folglich gegen die Momente der Marčenko–Pastur–Verteilung plus einen vernachlässigbar kleinen Term, da p_η gegen unendlich läuft. Zuletzt müssen wir noch die Varianz prüfen. Für diese gilt

$$\text{Var}(\beta_k(\mathbf{S}_\eta)) := \frac{1}{p_\eta n_\eta^k} \sum_{i,j} (\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) - \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)})).$$

Dabei sind Δ_a und Δ_b zwei Δ Graphen mit unterschiedlichen Permutationen von $\mathbf{i}$ und $\mathbf{j}$. Wie für den Erwartungswert suchen wir uns Kategorien, um die Varianz stückweise zu beschreiben.

Als Erstes betrachten wir alle Graphen Δ_a und Δ_b so, dass Δ_a und Δ_b unabhängig sind, sich also keine Kanten teilen. Daraus folgt direkt

$$\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) = \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)}).$$

Das heißt, für unabhängige Graphen ist die Varianz gleich 0.

Als Nächstes betrachten wir alle Graphen Δ_a und Δ_b , die mindestens eine Einzelkante besitzen. Damit erhalten wir wie in (3.11) wieder

$$\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) = 0 = \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)}).$$

In allen anderen Möglichkeiten haben die Graphen keine Einzelkante und Δ_a und Δ_b teilen sich Kanten. Analog zu W_3 können wir sagen, dass die Anzahl möglicher Graphen in $\mathcal{O}(n_\eta^k)$ liegt. Da wir zwei Graphen Δ_a und Δ_b betrachten, liegt die Anzahl möglicher Graphen in $\mathcal{O}(n_\eta^{2k})$. Durch die gleichmäßige Beschränkung von x_{ij} durch C können wir

die Varianz durch

$$\begin{aligned}\mathrm{Var}(\beta_k(\mathbf{S}_\eta)) &\leq \frac{1}{p_\eta^2 n_\eta^{2k}} C\mathcal{O}(n_\eta^{2k}) \\ &= \mathcal{O}\left(\frac{1}{p_\eta^2}\right)\end{aligned}\tag{3.14}$$

abschätzen. Da p_η gegen unendlich läuft, wird die Varianz vernachlässigbar klein. Mit dem Erwartungswert (3.13) und der Varianz (3.14) können wir darauf schließen, dass die empirische Spektralverteilung fast sicher gegen die Marčenko–Pastur–Verteilung konvergiert. $\square$

Literatur

- [1] M. Aigner. *Diskrete Mathematik*. 6th revised ed. Vieweg Stud. Wiesbaden: Vieweg, 2006.
- [2] E. Artin. *The gamma function*. Athena Series. Selected Topics in Mathematics. New York-Chicago-San Francisco-Toronto-London: Holt, Rinehart and Winston. VII, 39 p. (1964). 1964.
- [3] Z. Bai und J. W. Silverstein. *Spectral analysis of large dimensional random matrices*. 2nd ed. Springer Ser. Stat. Dordrecht: Springer, 2010. DOI: 10.1007/978-1-4419-0661-8.
- [4] S. L. Brunton und J. N. Kutz. *Data-driven science and engineering. Machine learning, dynamical systems, and control*. 2nd edition. Cambridge: Cambridge University Press, 2022. DOI: 10.1017/9781009089517.
- [5] M. Gavish und D. L. Donoho. *The optimal hard threshold for singular values is $4/\sqrt{3}$* . IEEE Trans. Inf. Theory 60.8 (2014), S. 5040–5053. DOI: 10.1109/TIT.2014.2323359.
- [6] H.-O. Georgii. *Stochastik. Einführung in die Wahrscheinlichkeitstheorie und Statistik*. 5th, revised and expanded ed. De Gruyter Stud. Berlin: De Gruyter, 2015. DOI: 10.1515/9783110359701.
- [7] A. Meister und T. Sonar. *Numerik. Eine lebendige und gut verständliche Einführung mit vielen Beispielen*. Berlin: Springer Spektrum, 2019. DOI: 10.1007/978-3-662-58358-6.

Hinweise zu den offiziellen Erklärungen

1. Die folgende Seite mit den offiziellen Erklärungen

A) Eigenständigkeitserklärung

B) Erklärung zur Veröffentlichung von Bachelor- oder Masterarbeiten

C) Einverständniserklärung über die Bereitstellung und Nutzung der Bachelorarbeit / Masterarbeit in elektronischer Form zur Überprüfung durch eine Plagiatssoftware

ist entweder direkt in jedes Exemplar der Bachelor- oder Masterarbeit fest mit einzubinden oder unverändert im Wortlaut in jedes Exemplar der Bachelor- oder Masterarbeit zu übernehmen.

Bitte achten Sie darauf, jede Erklärung in allen drei Exemplaren der Arbeit zu unterschreiben.

2. In der digitalen Fassung kann auf die Unterschrift verzichtet werden. Die Angaben und Entscheidungen müssen jedoch enthalten sein.

Zu B)

Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die Zukunft, widerrufen werden.

Zu C)

Das Einverständnis der dauerhaften Speicherung des Textes ist freiwillig.

Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die Zukunft, widerrufen werden.

Weitere Informationen zur Überprüfung von schriftlichen Arbeiten durch die Plagiatsoftware sind im Nutzungs- und Datenschutzkonzept enthalten. Diese finden Sie auf der Internetseite der Universität Bremen.

Notes on the official declarations

1. The following pages with the official declarations

A) Declaration of Authorship

B) Declaration on the Publication of Bachelor's or Master's Thesis

C) Declaration of Consent for the Provision and Use of the Bachelor's Thesis / Master's Thesis in Electronic Form for Review by Plagiarism Software

is to be either integrated directly into each copy of the bachelor's or master's thesis or adopted unchanged in the wording of each copy of the bachelor's or master's thesis.

Please be sure to sign each declaration in all three copies of the thesis.

2. The signature can be omitted from the digital version. However, the information and decisions must be included.

Regarding B)

The consent can be revoked at any time with future effect by notifying the University of Bremen.

Regarding C)

Consent for the permanent storage of the text is voluntary. The consent can be revoked at any time with future effect by notifying the University of Bremen.

Further information on the checking of written work using plagiarism software can be found in the data protection and usage concept. This can be found on the University of Bremen website.

**Eigenständigkeits- und Einverständniserklärung zur Überprüfung mit Plagiatsoftware
sowie die Erklärung zur Veröffentlichung bei Bachelor- und Masterarbeiten****Declarations of Authorship and Consent for Checking with Plagiarism Software and the
Declaration of Publication for Bachelor's and Master's Thesis**

Studierenden-Angaben / Student Information:

Matrikelnr./ Student ID

Nachname / Surname

Vorname / First Name

Titel der Arbeit / Title of Thesis

A) Eigenständigkeitserklärung / Declaration of Authorship

Ich versichere, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe. Alle Teile meiner Arbeit, die wortwörtlich oder dem Sinn nach anderen Werken entnommen sind, wurden unter Angabe der Quelle kenntlich gemacht. Gleiches gilt auch für Zeichnungen, Skizzen, bildliche Darstellungen sowie für Quellen aus dem Internet, dazu zählen auch KI-basierte Anwendungen oder Werkzeuge. Die Arbeit wurde in gleicher oder ähnlicher Form noch nicht als Prüfungsleistung eingereicht.

I hereby affirm that I have written the present work independently and have used no sources or aids other than those indicated. All parts of my work that have been taken from other works, either verbatim or in terms of meaning, have been marked as such, indicating the source. The same applies to drawings, sketches, pictorial representations and sources from the Internet, including AI-based applications or tools. The work has not yet been submitted in the same or a similar form as a final examination paper.

- ☐ Ich habe KI-basierte Anwendungen und/oder Werkzeuge genutzt und diese im Anhang "Nutzung KI basierte Anwendungen" dokumentiert.

I have used AI-based applications and/or tools and documented them in the appendix "Use of AI-based applications".

B) Erklärung zur Veröffentlichung von Bachelor- oder Masterarbeiten

Declaration regarding the publication of bachelor's or master's thesis

Die Abschlussarbeit wird zwei Jahre nach Studienabschluss dem Archiv der Universität Bremen zur dauerhaften Archivierung angeboten. Archiviert werden:

Two years after graduation, the thesis is offered to the archive of the University of Bremen for permanent archiving. The following are archived:

- 1) Masterarbeiten mit lokalem oder regionalem Bezug sowie pro Studienfach und Studienjahr 10 % aller Masterarbeiten
Master's theses with a local or regional focus, as well as per subject and academic year 10% of all Master's thesis
- 2) Bachelorarbeiten des jeweils ersten und letzten Bachelorabschlusses pro Studienfach und Jahr.
Bachelor's thesis for the first and last bachelor's degrees per subject and year.

☐ Ich bin damit einverstanden, dass meine Abschlussarbeit im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I agree that my thesis may be viewed by third parties in the university archive for academic purposes.

☐ Ich bin damit einverstanden, dass meine Abschlussarbeit nach 30 Jahren (gem. §7 Abs. 2 BremArchivG) im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I agree that my thesis may be viewed by third parties for academic purposes in the university archive after 30 years (in accordance with §7 para. 2 BremArchivG).

☐ Ich bin **nicht** damit einverstanden, dass meine Abschlussarbeit im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I do not consent to my thesis being made available in the university archive for third parties to view for academic purposes.

C) Einverständniserklärung zur elektronischen Überprüfung der Arbeit auf Plagiate Declaration of consent for electronic checking of the work for plagiarism

Eingereichte Arbeiten können nach § 18 des Allgemeinen Teil der Bachelor- bzw. der Masterprüfungsordnungen der Universität Bremen mit qualifizierter Software auf Plagiatsvorwürfe untersucht werden.

Zum Zweck der Überprüfung auf Plagiate erfolgt das Hochladen auf den Server der von der Universität Bremen aktuell genutzten Plagiatssoftware.

Submitted papers can be checked for plagiarism using qualified software in accordance with § 18 of the General Section of the Bachelor's or Master's Degree Examination Regulations of the University of Bremen. For the purpose of checking for plagiarism, the upload to the server is done using the plagiarism software currently used by the University of Bremen.

- ☐ Ich bin damit einverstanden, dass die von mir vorgelegte und verfasste Arbeit zum oben genannten Zweck dauerhaft auf dem externen Server der aktuell von der Universität Bremen genutzten Plagiatssoftware, in einer institutionseigenen Bibliothek (Zugriff nur durch die Universität Bremen), gespeichert wird.

I agree that the work I have submitted and written will be stored permanently on the external server of the plagiarism software currently used by the University of Bremen, in a library belonging to the institution (accessed only by the University of Bremen), for the above-mentioned purpose.

- ☐ Ich bin **nicht** damit einverstanden, dass die von mir vorgelegte und verfasste Arbeit zum o.g. Zweck dauerhaft auf dem externen Server der aktuell von der Universität Bremen genutzten Plagiatssoftware, in einer institutionseigenen Bibliothek (Zugriff nur durch die Universität Bremen), gespeichert wird.

I do not consent to the work I submitted and wrote being permanently stored on the external server of the plagiarism software currently used by the University of Bremen, in a library belonging to the institution (accessed only by the University of Bremen), for the above-mentioned purpose.

Das Einverständnis der dauerhaften Speicherung des Textes ist freiwillig. Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die Zukunft, widerrufen werden. Weitere Informationen zur Überprüfung von schriftlichen Arbeiten durch die Plagiatsoftware sind im Nutzungs- und Datenschutzkonzept enthalten. Diese finden Sie auf der Internetseite der Universität Bremen.

Consent to the permanent storage of the text is voluntary. Consent can be withdrawn at any time by making a declaration to this effect to the University of Bremen, with effect for the future. Further information on the checking of written work using plagiarism software can be found in the data protection and usage concept. This can be found on the University of Bremen website.

Mit meiner Unterschrift versichere ich, dass ich die obenstehenden Erklärungen gelesen und verstanden habe und bestätige die Richtigkeit der gemachten Angaben.

With my signature, I confirm that I have read and understood the above explanations and confirm the accuracy of the information provided.

Datum / Date

Unterschrift/ Signature