



Universität
Bremen

Rangreduzierung in DMD mittels Marčenko-Pastur-Verteilung

Bachelorarbeit zur Erlangung des akademischen Grades
Bachelor of Science Technomathematik

Eingereicht von

Lennart Koliwer

koliwer1@uni-bremen.de

Gutachter:innen

Dr. Maxim Kirsebom

Prof. Dr. Anke Pohl

Fachbereich 3

Universität Bremen

WiSe 2025/26

6. April 2026

Inhaltsverzeichnis

1	Einleitung	1
2	DMD	5
2.1	Frobeniusnorm	5
2.2	Singulärwertzerlegung	6
2.3	Exact DMD	11
3	Marčenko-Pastur-Verteilung	13
3.1	Vorbereitung	13
3.2	Marčenko-Pastur-Momente	15
3.3	Marčenko-Pastur-Verteilung	23
	Literatur	35
	Eigenständigkeits- und Einverständniserklärung	38

1 Einleitung

Bei der Rangreduzierung handelt es sich um das Approximieren einer Matrix durch eine Matrix eines niedrigeren Ranges. Sie ist also ein wichtiges Werkzeug im Umgang mit großen Datenmengen welche als Matrix vorliegen, um Rechenaufwand zu minimieren, der beim Verwenden der Daten aufkommen würde.

Ein Beispiel das wir in dem Zusammenhang betrachten ist der Dynamic Mode Decomposition Algorithmus kurz DMD aus [2]. DMD ist ein datengetriebener Algorithmus, der ursprünglich im Forschungsgebiet der Strömungsdynamik entwickelt wurde. Grundsätzlich dient er der Analyse von Messdaten eines dynamischen Systems mittels Singulärwertzerlegung von großen Datenmatrizen. DMD kann anhand von Messdaten mehrerer Zeitpunkte die Dynamik eines Systems approximieren. Die Genauigkeit hängt unter anderem davon ab, wie viele Informationen in Form von Messdaten über das System zur Verfügung stehen und wie groß die Messfehler, also das Rauschen der Daten, ist. Dabei ist DMD gut im Erkennen von Mustern, wie im Falle der Strömungsdynamik z.B. Verwirbelungen. Probleme treten jedoch auf, wenn man DMD außerhalb von Simulationen verwendet und echte Messungen analysieren will. Bei Messungen hat man immer ein Rauschen in den Daten, welche das Ergebnis verfälschen. Dadurch kommt es durch Fehlerfortpflanzung schnell zu größeren Ungenauigkeiten. Im Laufe der letzten Jahre wurden eine Vielzahl von Varianten des DMD Algorithmus entwickelt, um unterschiedliche Schwächen des Algorithmus auszugleichen.

Das klassische DMD benötigt Messdaten aus k Messungen in einheitlichen Zeitabständen. Für jeden Zeitpunkt i werden die jeweiligen Messdaten in die i -te Spalte einer Datenmatrix X eingetragen. Zusätzlich legen wir eine zweite Datenmatrix X' so an, dass wir in X die Messungen $(x_1, \dots, x_{k-1})$ und in X' die Messungen $(x_2, \dots, x_k)$ haben. Die Datenmatrizen sind in der Regel $p \times n$ große Matrizen, wobei p die Dimension des Systems bzw. die Anzahl der Messdaten zum i -ten Zeitpunkt ist und $n = k - 1$ ist die Anzahl der Messungen. In der Regel haben die Datenmatrizen deutlich mehr Zeilen als Spalten also gilt $p \gg n$. Normalerweise sind die Systeme, die betrachtet werden, hochgradig nicht-linear. Durch das Aneinanderreihen der Messdaten in den Datenmatrizen wird die Dimension p des Systems erhöht. Dadurch lässt sich das System näherungsweise linear beschreiben.

Das Ziel von DMD ist es einen linearen Operator A bzw. seine Spektralzerlegung zu finden, für den

$$X' \approx AX$$

so gut wie möglich gilt. Der Operator A muss also diagonalisierbar sein. Der dafür am besten passende Operator A lässt sich durch

$$A = \arg \min_A \|X' - AX\|_F = X'X^\dagger$$

bestimmen. Dabei sind $\|\cdot\|_F$ die Frobeniusnorm und $X^\dagger$ die Moore-Penrose-Inverse, welche wir in Kapitel 2.1 und 2.3 noch genauer beschreiben werden. Die Moore-Penrose-Inverse lässt sich dann mittels Singulärwertzerlegung (SWZ) der Datenmatrix X bestimmen. Die SWZ beschreiben wir in Kapitel 2.2 nochmal genauer, liefern aber für einen kleinen Überblick eine vereinfachte Beschreibung. Bei der SWZ finden wir für ein $X \in \mathbb{R}^{p \times n}$ zwei orthogonale Matrizen U und V mit passenden Dimensionen $p \times n$ und $\hat{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_r)$ mit $r \leq \min(p, n)$ und $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U\Sigma V^\top \text{ mit } \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Bei der Bestimmung von A wird der Rechenaufwand schnell zu groß, weshalb der DMD Algorithmus eine Dimensionsreduktion durchführt. Die Dimensionsreduktion ist dabei eine Methode, die Dimension einer Matrix auf zum Beispiel ihren Rang zu reduzieren. Damit kann man eine Spektralzerlegung von A machen, ohne A direkt zu benutzen. Durch die oben genannte Form der Datenmatrizen kann man direkt sehen, dass X maximal von Rang n sein kann. Es gibt also maximal $r \leq n$ Singulärwerte, die nicht Null sind. Reduzieren wir also unser Σ aus der SWZ auf eine $r \times r$ große Matrix also $\hat{\Sigma}$, und entfernen bis auf die ersten r Spalten alle Spalten von U und V , erhalten wir mit den reduzierten Matrizen U_r , Σ_r und V_r ,

$$X_r = U_r \Sigma_r V_r^\top = U_r \hat{\Sigma} V_r^\top.$$

Nach dem Eckart-Young-Theorem [2, S. 9] lässt sich durch

$$\|X_r\|_F^2 = \sum_{i=1}^r \sigma_i^2$$

zeigen, dass X_r die beste Rang r -Approximation von X bezüglich der Frobeniusnorm ist.

Die Spektralzerlegung von A können wir damit über die viel kleinere Matrix

$$\tilde{A} = U_r^\top A U_r$$

bestimmen. Diese Methode der Dimensionsreduktion für SWZ ist als ökonomische SWZ bekannt.

Eine weitere Methode der Rangreduzierung, welche im Paper [3] von Matan Gavish und David L. Donoho behandelt wird, ist das „singular value hard thresholding“ (SVHD). Das ist eine Rangreduzierung für Datenmatrizen bis alle Singulärwerte über einem definierten Schwellenwert τ liegen. Gavish und Donoho definieren eine Rahmenstruktur, in der die Datenmatrix X durch eine größer werdende Datenmatrix X_n der Form

$$X_n := X_n^{\text{echt}} + \gamma X_n^{\text{rauschen}}$$

beschrieben wird. Dabei gilt für das Dimensions-Stichproben-Verhältnis $y = \frac{p}{n} \in (0, 1]$, dass es nicht divergiert. Wir haben also X_n in einen echten Teil und einem durch γ skalierten Fehleranteil aufgeteilt. Die Einträge der Fehlermatrix sind dabei unabhängig und identisch verteilte Zufallsvariablen mit Erwartungswert $\mathbb{E}(X_n^{\text{rauschen}}) = 0$ Varianz $\text{Var}(X_n^{\text{rauschen}}) = 1$. Zusätzlich werden die Singulärwerte von X_n^{echt} fixiert. Sei also r der Rang von X^{echt} und $\sigma_1^{\text{echt}}, \dots, \sigma_r^{\text{echt}}$ ihre Singulärwerte, dann ist die Singulärwertzerlegung von X_n^{echt} für alle n in der Form

$$X_n^{\text{echt}} = U_n \text{diag}(\sigma_1^{\text{echt}}, \dots, \sigma_r^{\text{echt}}, 0, \dots, 0) V_n^\top \quad (1.1)$$

mit passenden U_n und V_n .

Innerhalb dieser Rahmenstruktur haben Gavish und Donoho herausgefunden, dass für bekanntes Rauschen γ und bekanntem Dimensions-Stichproben-Verhältnis der optimale Schwellenwert τ_* für Singulärwerte bei

$$\tau_* = \lambda_*(y) \gamma \sqrt{n} \quad \text{mit} \quad \lambda_*(y) := \sqrt{2(y+1) + \frac{8y}{(y+1) + \sqrt{y^2 + 14y + 1}}}$$

liegt. Bei quadratischen Matrizen reduziert sich λ_* sogar auf $\frac{4}{\sqrt{3}}$.

Wenn das Rauschen aber nicht bekannt ist, muss γ geschätzt werden. Das Ziel ist es also einen Schwellenwert $\hat{\tau}_*$ zu finden, ab dem davon ausgegangen werden kann, dass die Singulärwerte, die größer oder gleich diesem Schwellenwert sind, nur zu einem vernachlässigbaren Anteil aus Rauschen bestehen. Im Zusammenhang mit Singulärwerten

von Zufallsmatrizen spielt Marčenko-Pastur-Verteilung eine zentrale Rolle. Sie sagt aus, wie die quadrierten Singulärwerte von bestimmten Zufallsmatrizen verteilt sind.

Für unbekanntes Rauschen haben Gavish und Donoho dann mit dem Median der Singulärwerte $\sigma_{med,n}$ von X_n und dem Median der Marčenko-Pastur-Verteilung, den Rausch-Schätzer

$$\hat{\gamma}(X) := \frac{\sigma_{med,n}}{\sqrt{n \cdot \mu_y}}$$

definiert. Also mit $a = (1 - \sqrt{y})^2$, $b = (1 + \sqrt{y})^2$ und $a \leq \mu_y \leq b$ so, dass

$$\int_a^{\mu_y} \frac{1}{2\pi xy} \sqrt{(b-x)(x-a)} dx = \frac{1}{2}$$

gilt.

Mit $\hat{\gamma}$ haben sie dann den Schwellenwert für Singulärwerte durch

$$\hat{\tau}_*(y, X) := \lambda_*(y) \hat{\gamma} \sqrt{n} = \lambda_*(y) \frac{\sigma_{med,n}}{\sqrt{\mu_y}}$$

definiert.

In dieser Arbeit konzentrieren wir uns zum einen auf den DMD Algorithmus, und zum anderen auf die Herleitung der Marčenko-Pastur-Verteilung, da diese wie gerade beschrieben ein wesentlicher Bestandteil der Dimensionsreduktion ist.

2 DMD

In diesem Kapitel wollen wir einmal genauer auf den DMD Algorithmus bzw. die „exact DMD“ Variante eingehen.

Aus der Einleitung wissen wir, dass die Singulärwertzerlegung und die Frobeniusnorm wichtige Werkzeuge des Algorithmus sind, weshalb wir sie hier einmal konkret definieren.

2.1 Frobeniusnorm

Definition 2.1 (Frobeniusnorm). Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix und x_{ij} mit $i \in \{1, \dots, p\}$, $j \in \{1, \dots, n\}$. Die *Frobeniusnorm* ist definiert durch

$$\|X\|_F := \sqrt{\sum_{i=1}^p \sum_{j=1}^n |x_{ij}|^2}.$$

Die Frobeniusnorm können wir aber auch über die Spur der Matrix beschreiben.

Lemma 2.2. Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix. Dann gilt

$$\|X\|_F = \sqrt{\text{tr}(X^H X)}.$$

Beweis. Sei x_i ein Spaltenvektor von X und $\bar{x}_{ij}$ das komplex Konjugierte. Dann ist

$$\begin{aligned} X^H X &= \begin{pmatrix} x_1 & \dots & x_n \end{pmatrix}^H \begin{pmatrix} x_1 & \dots & x_n \end{pmatrix} \\ &= \begin{pmatrix} \sum_{j=1}^p x_{1j}^H x_{1j} & & * \\ & \ddots & \\ * & & \sum_{j=1}^p x_{nj}^H x_{nj} \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^p \bar{x}_{1j} x_{1j} & & * \\ & \ddots & \\ * & & \sum_{j=1}^p \bar{x}_{nj} x_{nj} \end{pmatrix}. \end{aligned}$$

Mit $\bar{x}x = |x|^2$ erhalten wir

$$\operatorname{tr}(X^H X) = \sum_{i=1}^n \sum_{j=1}^p \bar{x}_{ij} x_{ij} = \sum_{i=1}^n \sum_{j=1}^p |x_{ij}|^2 = \|X\|_F^2. \quad (2.1)$$

□

Die Frobeniusnorm wird im weiteren Verlauf aufgrund ihrer Invarianz bezüglich unitärer Transformation verwendet, welche wir durch folgendes Lemma zeigen.

Lemma 2.3. Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix und $U \in \mathbb{C}^{p \times p}$ und $V \in \mathbb{C}^{n \times n}$ unitäre Matrizen. Dann gilt

1. $\|X\|_F = \|X^H\|_F$,
2. $\|UX\|_F = \|X\|_F$,
3. $\|XV\|_F = \|X\|_F$.

Beweis.

1. Aus Gleichung (2.1) folgt

$$\|X\|_F^2 = \operatorname{tr}(X^H X) = \sum_{i=1}^n \sum_{j=1}^p \bar{x}_{ij} x_{ij} = \sum_{j=1}^p \sum_{i=1}^n \bar{x}_{ij} x_{ij} = \operatorname{tr}(X X^H) = \|X^H\|_F^2.$$

2. Es ist

$$\|UX\|_F^2 = \operatorname{tr}(X^H U^H U X) = \operatorname{tr}(X^H \mathbb{1} X) = \operatorname{tr}(X^H X) = \|X\|_F^2.$$

3. Mit 1. und 2. folgt

$$\|XV\|_F = \|V^H X^H\|_F = \|X^H\|_F = \|X\|_F. \quad \square$$

Damit haben wir alles, was wir über die Frobeniusnorm wissen müssen.

2.2 Singulärwertzerlegung

Satz 2.4 (Singulärwertzerlegung [5, S. 228]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix und $r := \operatorname{rang} X$ mit $r \leq \min(p, n)$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ und

eine Diagonalmatrix $\hat{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}$ mit $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U\Sigma V^\top \text{ mit } \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Wir nennen die Diagonalelemente von Σ Singulärwerte.

Der Beweis des Satzes 2.4 folgt etwas später, da dafür noch etwas Vorbereitung benötigt wird. Wichtig zu erwähnen ist noch, dass unter den in Satz 2.4 genannten Voraussetzungen, $\hat{\Sigma}$ durch X eindeutig bestimmt ist [5, S. 229]. Die beiden orthogonalen Matrizen U und V hingegen sind nicht eindeutig.

Lemma 2.5. Seien $X \in \mathbb{R}^{p \times n}$ und σ_i die Singulärwerte von X nach den Voraussetzungen aus Satz 2.4. Seien weiter λ_i die Eigenwerte von $X^\top X$. Dann gilt

$$\sigma_i = \sqrt{\lambda_i}. \quad (2.2)$$

Beweis. Durch

$$\begin{aligned} X^\top X &= (U\Sigma V^\top)^\top (U\Sigma V^\top) \\ &= V\Sigma^\top U^\top U\Sigma V^\top \\ &= V\Sigma^\top \Sigma V^\top \end{aligned}$$

ist $X^\top X$ ähnlich zu $\Sigma^\top \Sigma$. Also haben $X^\top X$ und $\Sigma^\top \Sigma$ auch die gleichen Eigenwerte. Damit sind auch die Wurzeln der Eigenwerte von $X^\top X$ gleich der Eigenwerte bzw. Singulärwerte von Σ wie in (2.2). $\square$

Lemma 2.6. Die aus der Singulärwertzerlegung in 2.4 entstehenden Singulärwerte sind invariant bezüglich Transposition von X .

Beweis. Seien die Voraussetzungen aus Satz 2.4 gegeben, dann gilt

$$X^\top = (U\Sigma V^\top)^\top = V\Sigma^\top U^\top.$$

Da Σ nur auf der Hauptdiagonalen Einträge hat und sonst mit Nullen gefüllt ist, erhalten wir

$$\text{diag } \Sigma^\top = \{\sigma_1, \sigma_2, \dots, \sigma_m\} = \text{diag } \Sigma.$$

$\square$

Den Beweis von Satz 2.4 teilen wir in zwei Teile ein. Wir betrachten dafür einmal die Singulärwertzerlegung für den Fall, dass X vollen Rang besitzt und einmal für den rangreduzierten Fall. Für den vollen Rang benutzen wir das folgende Lemma.

Lemma 2.7 ([5, S. 191]). Sei $X \in \mathbb{R}^{p \times p}$ eine symmetrische Matrix. Dann existiert eine orthogonale Matrix $U \in \mathbb{R}^{p \times p}$ und eine Diagonalmatrix $D \in \mathbb{R}^{p \times p}$ so, dass

$$U^\top XU = D$$

gilt.

Für den rangreduzierten Fall brauchen wir aber das folgende Lemma. Dafür nehmen wir nach Lemma 2.6 o.B.d.A an, dass $n \leq p$ gilt.

Lemma 2.8 ([5, S. 227]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix mit $\text{rang } X = r < n \leq p$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ sowie eine reguläre obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$ so, dass

$$U^\top XV = R \text{ mit } R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt.

Für den Beweis gehen wir mit Lemma 2.6 o.B.d.A davon aus, dass $p > n$ gilt.

Beweis Satz 2.4. Zunächst betrachten wir den Fall des vollen Ranges von X , also $\text{rang } X = r = n$. Bei vollem Rang ist $X^\top X \in \mathbb{R}^{n \times n}$ sowohl symmetrisch als auch positiv definit. Die Eigenwerte λ_i von $X^\top X$ sortieren wir nach ihrer Größe, also

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0.$$

Mit Lemma 2.7 finden wir ein orthogonales $V \in \mathbb{R}^{n \times n}$ so, dass

$$V^\top X^\top XV = D = \text{diag}\{\lambda_1, \dots, \lambda_n\} \in \mathbb{R}^{n \times n}.$$

Weiter definieren wir

$$\hat{\Sigma} := \text{diag}\{\sigma_1, \dots, \sigma_n\}$$

mit $\sigma_i := \sqrt{\lambda_i} \in (0, \infty]$, für $i = 1, \dots, n$, und setzen

$$\hat{U} := XV\hat{\Sigma}^{-1} \in \mathbb{R}^{p \times n}.$$

Jetzt kann man durch Umformung von

$$\begin{aligned}
\hat{U}^\top \hat{U} &= \hat{\Sigma}^{-\top} V^\top X^\top X V \hat{\Sigma}^{-1} \\
&= \hat{\Sigma}^{-1} D \hat{\Sigma}^{-1} \\
&= \hat{\Sigma}^{-1} \hat{\Sigma}^{-1} D \\
&= D^{-1} D \\
&= \mathbb{1}
\end{aligned}$$

die Orthonormalität der Spalten von $\hat{U}$ sehen.

Da $\hat{U}$ in $\mathbb{R}^{p \times n}$ liegt und aus orthonormalen Spaltenvektoren besteht, finden wir ein $Z \in \mathbb{R}^{p \times (p-n)}$, welches $\hat{U}$ so um $p - n$ orthonormale Spaltenvektoren ergänzt, dass

$$U = (\hat{U} \ Z) \in \mathbb{R}^{p \times p}$$

eine orthogonale Matrix ist. Es gilt also

$$\begin{aligned}
Z^\top X V \hat{\Sigma}^{-1} &= Z^\top \hat{U} \\
&= 0 \in \mathbb{R}^{(p-n) \times p}.
\end{aligned}$$

Da $\hat{\Sigma} \hat{\Sigma}^{-1} = \mathbb{1}$ ist, folgt auch direkt

$$Z^\top X V = 0.$$

Zusammengetragen haben wir dann

$$\begin{aligned}
U^\top X V &= \begin{pmatrix} \hat{U}^\top \\ Z^\top \end{pmatrix} X V = \begin{pmatrix} \hat{\Sigma}^{-1} V^\top X^\top X V \\ Z^\top X V \end{pmatrix} \\
&= \begin{pmatrix} \hat{\Sigma}^{-1} D \\ 0 \end{pmatrix} \\
&= \begin{pmatrix} \hat{\Sigma} \\ 0 \end{pmatrix},
\end{aligned}$$

womit wir den Fall des vollen Ranges bewiesen hätten.

Seien λ_i wie oben definiert wieder die Eigenwerte von $X^\top X$ und sei $X_r \in \mathbb{R}^{p \times n}$ eine Matrix mit $\text{rang } X_r = r < n$. Nach Lemma 2.8 gibt es zwei orthogonale Matrizen

$\tilde{U} \in \mathbb{R}^{p \times p}$ und $\tilde{V} \in \mathbb{R}^{n \times n}$, sowie eine obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$ so, dass

$$\tilde{U}^\top X_r \tilde{V} = R \text{ mit } R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Nach obigem Fall mit vollem Rang, wissen wir, dass es orthogonale Matrizen $U_r \in \mathbb{R}^{p \times p}$ und $V_r \in \mathbb{R}^{r \times r}$ gibt, sodass

$$U_r^\top \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix} V_r = \begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{p \times r}$$

gilt. ...gilt. ...gilt. nicht so schön. Dabei ist $\hat{\Sigma}_r := \text{diag}\{\sigma_1, \dots, \sigma_r\}$ mit $\sigma_i = \sqrt{\lambda_i}$. Im Folgenden erweitern wir

$$\begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{p \times r} \quad \text{zu} \quad \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} = \Sigma \in \mathbb{R}^{p \times n}$$

und finden eine orthogonale Fortsetzung für V_r zu

$$\bar{V}_r = \begin{pmatrix} V_r & 0 \\ 0 & \mathbb{1} \end{pmatrix} \in \mathbb{R}^{n \times n}.$$

Wenn wir uns jetzt die orthogonalen Matrizen

$$U := \tilde{U} U_r \in \mathbb{R}^{p \times p} \quad \text{und} \quad V := \tilde{V} \bar{V}_r \in \mathbb{R}^{n \times n}$$

definieren, erhalten wir durch

$$\begin{aligned} U^\top X_r V &= U_r^\top \tilde{U} X_r \tilde{V} \bar{V}_r \\ &= U_r^\top \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \bar{V}_r \\ &= \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} =: \Sigma \end{aligned}$$

eine erfolgreiche Zerlegung von X_r durch orthogonale Matrizen. □

2.3 Exact DMD

In der Einleitung haben wir grob den DMD Algorithmus erklärt. Wir gehen hier jetzt aber auf die „exact DMD“ Variante ein, da sie im Gegensatz zur ursprünglichen Variante keine einheitlichen Zeitabstände zwischen den Messungen erfordert. Dieses Kapitel beruht auf dem Buch [2].

Exact DMD erlaubt es uns Daten über mehrere Messungen die zeitlich unterschiedlich auseinanderliegen zusammenzutragen. Zu jeder Messung gehört dann ein Datenpaar $\{x(t_i), x(t'_i)\}$ mit $i = 1, \dots, n$ und $t'_i = t_i + \Delta t$. Fügen wir die Datenpaare in zwei Matrizen $X, X' \in \mathbb{R}^{p \times n}$ ein, erhalten wir die Zustände des Systems zu n diskreten Zeitpunkten. Wir haben also

$$X = \begin{pmatrix} | & | & & | \\ x(t_1) & x(t_2) & \dots & x(t_n) \\ | & | & & | \end{pmatrix} \quad \text{und} \quad X' = \begin{pmatrix} | & | & & | \\ x(t'_1) & x(t'_2) & \dots & x(t'_n) \\ | & | & & | \end{pmatrix}.$$

Mit den Vorbereitungen abgeschlossen, gehen wir jetzt auf den Algorithmus ein.

Als Erstes bestimmen wir die Singulärwertzerlegung von X also

$$X = U \Sigma V^\top.$$

Um den Rechenaufwand zu minimieren, finden wir eine geeignete Rangreduzierung. Wir finden also ein $r \in \mathbb{N}$ mit $r < n$ so, dass wir mit $U_r \in \mathbb{R}^{p \times r}$, $\Sigma_r \in \mathbb{R}^{r \times r}$ und $V_r \in \mathbb{R}^{n \times r}$

$$X \approx U_r \Sigma_r V_r^\top =: X_r$$

approximieren. Um den diagonalisierbaren, linearen Operator A zu finden, der

$$X' \approx AX$$

löst, benötigen wir die Pseudoinverse von X . Um eine eindeutige Inverse zu bekommen, benutzen wir die Moore-Penrose-Inverse aus dem folgenden Satz.

Satz 2.9 (Moore-Penrose-Inverse [5, S. 230]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix und $U, \hat{\Sigma}$ und V die Matrizen aus der Singulärwertzerlegung in Satz 2.4. Dann existiert genau eine Moore-Penrose-Inverse der Form

$$X^\dagger = V \begin{pmatrix} \hat{\Sigma}^{-1} & 0 \\ 0 & 0 \end{pmatrix} U^\top \in \mathbb{R}^{n \times p}.$$

Mit Satz 2.9 können wir A durch

$$A = X'V_r\Sigma_r^{-1}U_r^\top = X'X_r^\dagger$$

bestimmen. Das Ziel ist es die Spektralzerlegung von A zu finden, damit wir analysieren können wie sich das System über die Zeit entwickelt. Da A aber eine $p \times p$ große Matrix ist und p schnell sehr groß werden kann, können wir den Rechenaufwand minimieren, indem wir die Spektralzerlegung von einem A_r bestimmen, welches nur noch die für uns relevante Dimension r hat. Wir bestimmen A_r durch

$$\begin{aligned} A_r &= U_r^\top A U_r \\ &= U_r^\top X'X_r^\dagger U_r \\ &= U_r^\top X'V_r\Sigma_r^{-1}. \end{aligned}$$

Sei W die Matrix aus Eigenvektoren von A_r und Λ eine Diagonalmatrix dessen Einträge die Eigenwerte λ_i von A_r sind, dann ist die Spektralzerlegung von A_r genau

$$A_r W = W \Lambda.$$

Sei Φ die Matrix, dessen Spalten die Eigenvektoren von A sind. Dann können wir Φ durch die reduzierten Eigenvektoren W mit

$$\Phi = X'V_r\Sigma_r^{-1}W$$

rekonstruieren.

Durch

$$\begin{aligned} A\Phi &= (X'V_r\Sigma_r^{-1}U_r^\top)(X'V_r\Sigma_r^{-1}W) \\ &= X'V_r\Sigma_r^{-1}A_r W \\ &= X'V_r\Sigma_r^{-1}W\Lambda \\ &= \Phi\Lambda \end{aligned}$$

kann sehen wir, dass die Spalten von Φ auch die Eigenvektoren zu den Eigenwerten von A_r sind. Damit können wir also die Spektralzerlegung von A mit der Spektralzerlegung von A_r bestimmen.

3 Marčenko-Pastur-Verteilung

In Bezug auf die Rangreduzierung sind wir in der Einleitung auf das Paper von Gravish und Donoho [3] eingegangen. In dem Paper wird erwähnt, dass in

$$X_n := X_n^{\text{echt}} + \gamma X_n^{\text{rauschen}}$$

der durch $\frac{\sigma_{med,n}}{\sqrt{n}}$ normierte Median der Singulärwerte von X_n fast sicher gegen den Median der Marčenko-Pastur-Verteilung μ_y konvergiert [3, S. 11]. Daraus ergibt sich dann, dass der Schwellenwert für die Dimensionsreduktion

$$\hat{\tau}_*(y, X) = \lambda_*(y) \frac{\sigma_{med,n}}{\sqrt{\mu_y}}$$

fast sicher gegen

$$\lim_{n \rightarrow \infty} \lambda_*(y) \frac{\sigma_{med,n}}{\sqrt{\mu_y}} \stackrel{f.s.}{=} \lambda_*(y) = \sqrt{2(y+1) + \frac{8y}{(y+1) + \sqrt{y^2 + 14y + 1}}}$$

konvergiert.

Um die Notation im Folgenden zu vereinfachen, bezeichnen wir die Rauschmatrix X_n^{rauschen} mit $\mathbf{X}_n$.

Die Marčenko-Pastur-Verteilung beschreibt die asymptotische empirische Spektralverteilung der Eigenwerte von großen Zufallsmatrizen der Form $\frac{1}{n} \mathbf{X} \mathbf{X}^H$. Die genauen Anforderungen an $\mathbf{X}$, stellen wir im kommenden Unterkapitel.

Ziel dieses Kapitels ist es, die schwache Konvergenz der empirischen Spektralverteilung gegen die Marčenko-Pastur-Verteilung zu zeigen. Die Herleitung orientiert sich dabei an dem Buch „Spectral analysis of large dimensional random matrices“ von Zhidong Bai und Jack W. Silverstein [1].

3.1 Vorbereitung

Wir beginnen damit die empirische Spektralverteilung einmal konkret zu definieren.

Definition 3.1. Sei B eine $p \times p$ große hermitesche Matrix mit Eigenwerten λ_i mit $i = 1, \dots, p$. Dann ist auf dem Ereignisraum $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $\mathcal{B}(\mathbb{R})$ als borelsche σ -Algebra durch

$$F^B(x) := \frac{1}{p} |A_x| \quad \text{mit } A_x := \{i \in \{1, \dots, p\} : \lambda_i \leq x\}$$

die *empirische Spektralverteilung* $F^B: \mathbb{R} \rightarrow [0, 1]$ definiert. Ihre Momente sind durch

$$\beta_k(B) = \int_{-\infty}^{\infty} x^k F^B dx = \frac{1}{p} \operatorname{tr}(B^k)$$

gegeben.

Die Konvergenz betrachten wir in dem Sinne, dass wir analysieren, wie sich die Verteilung verhält, wenn wir immer größere Matrizen betrachten, also p gegen unendlich laufen lassen.

Sei $\mathbf{X}$ eine $p \times n$ große Matrix, dessen Elemente unabhängig und identisch verteilte Zufallsvariablen sind. Dabei sind ihre Erwartungswerte 0 und ihre Varianz bezeichnen wir mit σ^2 . Weiter sind $x_k = (x_{1k}, \dots, x_{pk})^\top$, $\mathbf{X} = (x_1, \dots, x_n)$ und $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$. Dann ist die durch

$$S = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})(x_k - \bar{x})^H \in \mathbb{R}^{p \times p} \quad (3.1)$$

gegebene Matrix S die Stichproben-Kovarianzmatrix.

mehr zu Stichproben-Kovarianzmatrix?

Durch folgenden Satz können wir die Stichproben-Kovarianzmatrix noch weiter vereinfachen.

Satz 3.2 ([1, S. 503]). Seien $A, B \in \mathbb{C}^{p \times n}$. Dann gilt

$$\left\| F^{AA^H} - F^{BB^H} \right\|_{\infty} \leq \frac{1}{p} \operatorname{rang}(A - B).$$

Schreiben wir S als

$$\begin{aligned}
S &= \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})(x_k - \bar{x})^H \\
&= \frac{1}{n} \left(\sum_{k=1}^n x_k x_k^H - \sum_{k=1}^n x_k \bar{x}^H - \sum_{k=1}^n x_k^H \bar{x} + \sum_{k=1}^n \bar{x} \bar{x}^H \right) \\
&= \frac{1}{n} \left(\sum_{k=1}^n x_k x_k^H - n \bar{x} \bar{x}^H \right) \\
&= \frac{1}{n} \mathbf{X} \mathbf{X}^H - \bar{x} \bar{x}^H
\end{aligned}$$

und beschreiben S durch

$$\begin{aligned}
S &= \frac{1}{n} \sum_{k=1}^n x_k x_k^H \\
&= \frac{1}{n} \mathbf{X} \mathbf{X}^H .
\end{aligned} \tag{3.2}$$

Mit Satz 3.2 können wir durch

$$\begin{aligned}
\|F^S - F^{\mathbf{S}}\|_{\infty} &\leq \frac{1}{p} \text{rang}(\mathbf{X} - \bar{x} \bar{x}^H - \mathbf{X}) \\
&= \frac{1}{p} \text{rang}(\bar{x} \bar{x}^H) \\
&= \frac{1}{p}
\end{aligned}$$

zeigen, dass $\bar{x} \bar{x}^H$ keinen Einfluss auf die Konvergenz von F^S hat. Wir verwenden daher die vereinfachte Form S für die Stichproben-Kovarianzmatrix.

3.2 Marčenko-Pastur-Momente

Mit dem Dimensions-Stichproben-Verhältnis $y = \frac{p}{n}$, wird die Marčenko-Pastur-Verteilung durch das Wahrscheinlichkeitsmaß F_y auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ beschrieben. Für $y, \sigma^2 \in (0, \infty)$ und $x \in \mathbb{R}$ sind

$$a = \sigma^2 (1 - \sqrt{y})^2 \quad \text{und} \quad b = \sigma^2 (1 + \sqrt{y})^2 .$$

Die Dichtefunktion der Marčenko-Pastur-Verteilung ist dann durch

$$p_y(x) = \begin{cases} \frac{1}{2\pi xy\sigma^2} \sqrt{(b-x)(x-a)}, & \text{wenn } a \leq x \leq b \\ 0, & \text{sonst} \end{cases} \quad (3.3)$$

definiert. Die Verteilungsfunktion ergibt sich dann durch

$$F_y(t) = \int_a^t p_y(x) \, dx.$$

Wenn $\sigma^2 = 1$ ist, dann sprechen wir von der Standard-M-P-Verteilung. Die k -ten Momente der M-P-Verteilung sind durch

$$\beta_k(y, \sigma^2) := \int_a^b x^k p_y(x) \, dx \quad (3.4)$$

definiert. Wir können die Momente der M-P-Verteilung durch ihren Standardfall beschreiben, was wir im folgenden Lemma zeigen.

Lemma 3.3. Für alle $k \geq 1$ gilt

$$\beta_k(y, \sigma^2) = \sigma^{2k} \beta_k(y, 1) =: \beta_k.$$

Beweis. Nach (3.4) und 3.3 haben wir

$$\begin{aligned} \beta_k(y, \sigma^2) &= \int_a^b x^k p_y(x) \, dx \\ &= \int_{\sigma^2(1-\sqrt{y})^2}^{\sigma^2(1+\sqrt{y})^2} x^k \frac{1}{2\pi xy\sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - x)(x - \sigma^2(1-\sqrt{y})^2)} \, dx. \end{aligned}$$

Substituieren wir mit $x = u\sigma^2$ erhalten wir

$$\begin{aligned} \beta_k(y, \sigma^2) &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} (u\sigma^2)^k \frac{1}{2\pi uy\sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - u\sigma^2)(u\sigma^2 - \sigma^2(1-\sqrt{y})^2)} \, du \\ &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \sigma^{2k} \frac{1}{2\pi uy\sigma^2} \sqrt{\sigma^4((1+\sqrt{y})^2 - u)(u - (1-\sqrt{y})^2)} \, du \\ &= \sigma^{2k} \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \frac{1}{2\pi uy} \sqrt{((1+\sqrt{y})^2 - u)(u - (1-\sqrt{y})^2)} \, du \\ &= \sigma^{2k} \beta_k(y, 1). \end{aligned}$$

Die Momente lassen sich also durch σ^{2k} skaliert über die Standard-M-P-Verteilung beschreiben. $\square$

Damit können wir dann zeigen, dass die Marčenko-Pastur-Verteilung eindeutig durch die Momente β_k bestimmt wird und wie die Momente explizit bestimmt aussehen.

Lemma 3.4 (Carleman [1, S. 509]). Sei $\{\beta_k = \beta_k(F)\}_{k \in \mathbb{N}_0}$ die Folge von Momenten der Verteilungsfunktion F . Ist die *Carleman-Bedingung*

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} = \infty$$

erfüllt, dann wird die Verteilung F durch $\{\beta_k\}_{k \in \mathbb{N}_0}$ eindeutig bestimmt.

Dass β_k die Marčenko-Pastur-Verteilung eindeutig bestimmt, lässt sich dann mit Lemma 3.4 zeigen. Wir sehen einmal nach (3.4) und (3.3), dass wir β_{2k} durch

$$\begin{aligned} \beta_{2k} &= \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-x)(x-a)} dx \\ &\leq \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-a)(b-a)} dx \\ &= \frac{1}{2\pi y} \int_a^b x^{2k-1} (b-a) dx \\ &= \frac{1}{4k\pi y} (b^{2k} - a^{2k}) (b-a) \\ &= \frac{1}{k\pi\sqrt{y}} (b^{2k} - a^{2k}) \\ &\leq \frac{1}{k\pi\sqrt{y}} b^{2k} \\ &\leq b^{2k} = (1 + \sqrt{y})^{4k} \end{aligned} \tag{3.5}$$

abschätzen können. Mit der Abschätzung (3.5) und Lemma 3.4 haben wir durch

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} \leq \sum_{k=1}^{\infty} (1 + \sqrt{y})^2 = \infty$$

die Carleman-Bedingung erfüllt, womit wir gezeigt haben, dass die Marčenko-Pastur-Verteilung durch die Momente β_k eindeutig bestimmt ist.

Lemma 3.5. Die explizite Darstellung der Momente ist

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r. \quad (3.6)$$

Beweis. Wir haben nach (3.4) und (3.3)

$$\beta_k = \frac{1}{2\pi y} \int_a^b x^{k-1} \sqrt{(b-x)(x-a)} \, dx.$$

Substituieren wir mit $x = 1 + y + z$ und setzen a und b ein, erhalten wir

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{\left((1+\sqrt{y})^2 - 1 - y - z\right) \left(1+y+z - (1-\sqrt{y})^2\right)} \, dz \\ &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{4y - z^2} \, dz. \end{aligned}$$

Durch Einsetzen des Binomischen Lehrsatzes lässt sich das Integral zu

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} z^\ell \sqrt{4y - z^2} \, dz \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-2\sqrt{y}}^{2\sqrt{y}} z^\ell \sqrt{4y - z^2} \, dz \end{aligned}$$

umformen. Um das Integral weiter zu vereinfachen, substituieren wir mit $z = 2\sqrt{y}u$ und erhalten

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-1}^1 (2\sqrt{y}u)^\ell \sqrt{4y - 4yu^2} 2\sqrt{y} \, du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} (2\sqrt{y})^\ell 4y \int_{-1}^1 u^\ell \sqrt{1-u^2} \, du. \end{aligned}$$

Hier ist unser Integrand ungerade, sofern ℓ ungerade ist. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen, ist das Integral für alle ungeraden ℓ gleich 0. Dadurch ist jeder zweite Summand 0. Wir können also jeden zweiten Summanden überspringen. Dafür lassen wir die Summe bis zur Hälfte von $k-1$ laufen und summieren über 2ℓ statt ℓ . Für den Fall, dass $k-1$ ungerade ist, runden wir ab, weil es dann nur $\frac{k-2}{2}$ Summanden gibt, die ungleich 0 sind. Wir haben also

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (2\sqrt{y})^{2\ell} 4y \int_{-1}^1 u^{2\ell} \sqrt{1-u^2} du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \int_{-1}^1 u^{2\ell} \sqrt{1-u^2} du.\end{aligned}$$

Hier ist der Integrand eine gerade Funktion. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen können wir auch zweimal über das halbe Intervall integrieren. Zur Übersicht betrachten wir vorerst nur noch das Integral und fügen später wieder alles zusammen. Folglich gilt

$$(4y)^{\ell+1} \int_{-1}^1 u^{2\ell} \sqrt{1-u^2} dz = (4y)^{\ell+1} 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} du.$$

Wenn wir jetzt mit $u = \sqrt{w}$ substituieren,

$$\begin{aligned}(4y)^{\ell+1} 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} dz &= (4y)^{\ell+1} \int_0^1 w^\ell \sqrt{1-w} \frac{1}{\sqrt{w}} dw \\ &= (4y)^{\ell+1} \int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} dw\end{aligned}$$

erhalten wir ein Integral, dass wir mittels Eulerschen Betafunktion [Quelle!](#) lösen können. Die Eulersche Betafunktion ist durch

$$\int_0^1 t^{p-1} (1-t)^{q-1} dt = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

gegeben. Wir können also mit $p = \ell + \frac{1}{2}$ und $q = 1 + \frac{1}{2}$ das Integral durch die Gamma-

funktionen

$$\begin{aligned}
\int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} \, dw &= \frac{\Gamma(\ell+\frac{1}{2})\Gamma(1+\frac{1}{2})}{\Gamma(\ell+2)} \\
&= \frac{1}{(\ell+1)!} \left(\frac{(2\ell)! \sqrt{\pi}}{\ell! 4^\ell} \frac{2! \sqrt{\pi}}{4} \right) \\
&= \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{\ell! 4^\ell} \frac{1}{2} \pi \right)
\end{aligned} \tag{3.7}$$

beschreiben. Nach Einsetzen von (3.7) erhalten wir

$$\begin{aligned}
\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{\ell! 4^\ell} \frac{1}{2} \pi \right) \\
&= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{1}{2\pi y} \frac{(k-1)!}{(2\ell)!(k-1-2\ell)!} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{\ell! 4^\ell} \frac{1}{2} \pi \right).
\end{aligned}$$

Hier lassen sich diverse Variablen so kürzen, dass wir

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell (1+y)^{k-1-2\ell}$$

erhalten. Wenn wir den Binomischen Lehrsatz mit

$$\begin{aligned}
(1+y)^{k-1-2\ell} &= \sum_{s=0}^{k-1-2\ell} \binom{k-1-2\ell}{s} y^s \\
&= \sum_{s=0}^{k-1-2\ell} \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s
\end{aligned}$$

einsetzen, haben wir

$$\begin{aligned}
\beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s \\
&= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!s!(k-1-2\ell-s)!} y^{\ell+s}.
\end{aligned}$$

Jetzt wollen wir den Term wieder vereinfachen. Dafür setzen wir $r = s + \ell$

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} y^r$$

und erweitern mit zwei Einsen

$$\begin{aligned} \beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} \frac{r!}{r!} \frac{(k-r)!}{(k-r)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{r!(k-r)!} \frac{r!}{\ell!(\ell-r)!} \frac{(k-r)!}{(k-r-\ell-1)!(\ell+1)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \frac{k!}{r!(k-r)!} \frac{r!}{\ell!(\ell-r)!} \frac{(k-r)!}{(\ell+1)!(k-r-(\ell+1))!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r. \end{aligned}$$

Für den nächsten Schritt müssen wir die Laufvariablen von 0 starten lassen. Momentan haben wir erst das ℓ und ermitteln damit, inwieweit das r eingeschränkt ist. Für ein festes aber beliebiges k liegen unsere Laufvariablen in

$$A = \left\{ (\ell, r) \in \mathbb{N}^2 \mid 0 \leq \ell \leq \left\lfloor \frac{k-1}{2} \right\rfloor, \ell \leq r \leq k-1-\ell \right\}.$$

Daraus wissen wir, dass

$$0 \leq \ell, r \leq k-1-\ell$$

gilt, woraus wir

$$\ell \leq k-1-r$$

folgern können. Damit erhalten wir

$$\begin{aligned} 0 \leq \ell \leq r \leq k-1-\ell \leq k-1 \\ \implies 0 \leq r \leq k-1, 0 \leq \ell \leq \min(r, k-1-r) \end{aligned}$$

damit können wir also die Summen äquivalent über

$$A = \left\{ (\ell, r) \in \mathbb{N}^2 \mid 0 \leq r \leq k-1, 0 \leq \ell \leq \min(r, k-1-r) \right\} \quad (3.8)$$

laufen lassen.

Wir haben also mit (3.8)

$$\begin{aligned}\beta_k &= \sum_{r=0}^{k-1} \sum_{\ell=0}^{\min(r, k-1-r)} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{\min(r, k-1-r)} \binom{r}{\ell} \binom{k-r}{\ell+1}.\end{aligned}$$

Das Minimum können wir noch weiter vereinfachen, da die Summanden gleich 0 sind, sobald $\ell > r$ oder $\ell > k-1-r$ ist. Wenn wir die Summe also bis r laufen lassen, ändern wir nichts am Ergebnis.

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^r \binom{r}{\ell} \binom{k-r}{\ell+1}.$$

An diesem Punkt müssen wir nur noch die innere Summe vereinfachen. Dafür machen wir einen Indexshift und formen die Binomialkoeffizienten etwas um. Wir haben also

$$\begin{aligned}\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{\ell-1} \binom{k-r}{\ell} \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{r-(\ell-1)} \binom{k-r}{\ell} \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell}.\end{aligned}$$

Wir wollen hier die Vandermonde Identität [Quelle!](#)

$$\sum_{\ddot{o}=0}^{\ddot{u}} \binom{n}{\ddot{o}} \binom{m}{\ddot{u}-\ddot{o}} = \binom{n+m}{\ddot{u}} \quad (3.9)$$

nutzen. Dafür lassen wir die Summe von $\ell = 0$ beginnen, da der Summand das Ergebnis

nicht ändert. Mit der Identität (3.9) erhalten wir

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \frac{r+1}{r+1} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r.
\end{aligned}$$

□

3.3 Marčenko-Pastur-Verteilung

Im Beweis über die Konvergenz benutzen wir Elemente aus der Graphentheorie und der Stochastik, die wir vorher noch einführen wollen.

Dafür definieren wir eine Klasse von Graphen mit folgenden Eigenschaften.

Sei k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten mit der Gestalt $\mathbf{i} = (i_1, \dots, i_k)$ bzw. $\mathbf{j} = (j_1, \dots, j_k)$. Wobei die $\mathbf{i}$ -Knoten ganzzahlige Werte in $[0, p]$ und $\mathbf{j}$ -Knoten ganzzahlige Werte in $[0, n]$ annehmen können. Wenn unterschiedliche $\mathbf{i}/\mathbf{j}$ -Knoten den gleichen Wert annehmen, bezeichnen wir sie als *koinzident*. Wir betrachten koinzidente Knoten als *einen* Knoten mit mehreren Namen. Nehmen zum Beispiel die Knoten i_2 und i_5 den gleichen Wert x an, haben wir einen Knoten welchen sowohl i_2 als auch i_5 nennen was für die Eigenschaften der Kanten wichtig wird.

Alle Kanten richten sich nach den folgenden Regeln: Die Kanten sind gerichtet. Es ist also wichtig von wo nach wo sie laufen. Sie laufen von Knoten i_m zu j_m und von j_m zu i_{m+1} mit $m = 1, \dots, k$ und der Konvention, dass $i_1 = i_{k+1}$ gilt. Wenn wir also den Graphen zeichnen und bei i_1 anfangen sind wir fertig, wenn wir wieder am Startpunkt angelangt sind.

Sei $\hat{r}$ die Anzahl nicht koinzidenter $\mathbf{i}$ -Knoten, dann ist $r = \hat{r} - 1$ und s die Anzahl nicht koinzidenter $\mathbf{j}$ -Knoten. Da k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten ist, ist k auch die Anzahl an Kanten, die auf $\mathbf{i}$ -Knoten zeigen.


Diese Graphen Bezeichnen wir dann als $\Delta(k, r, s)$. Für den Beweis teilen wir die Graphen

in drei Kategorien ein.

$\Delta_1(k, r, s)$: Diese Kategorie fasst alle Graphen zusammen, die zu jeder Kante von i nach j genau eine Kante vom gleichen j -Knoten zum gleichen i -Knoten haben. Hier gilt $r + s = k$.

$\Delta_2(k, r, s)$: Diese Kategorie beinhaltet alle Graphen, die mindestens einmal zwischen zwei Knoten genau eine Kante besitzen, also Graphen, die mindestens eine *Einzelkante* besitzen.


$\Delta_3(k, r, s)$: Die letzte Kategorie $\Delta_3(k, r, s)$ sind alle Graphen die weder in $\Delta_1(k, r)$ noch in $\Delta_2(k, r, s)$ gehören.



Beispiel für Graphen(Platzhalter)

Für bessere Lesbarkeit schreiben wir für die Kategorien $\Delta_{1,2,3}(k, r, s)$ nur noch $\Delta_{1,2,3}$. Wir bezeichnen zwei Graphen als isomorph, wenn wir für die i/j -Knoten eine geeignete Zuweisung von Werten finden so, dass die Graphen identisch sind.

Dazu machen wir ein Beispiel:



Platzhalter

Graph a) ist isomorph zu b), da wir die Werte von zwei Knoten ändern können und einen identischen Graphen erhalten. Graph c) ist aber nicht isomorph zu a) da wir zusätzlich

noch die Indices der Knotennamen tauschen müssten was aber nicht geht da der Knoten fest ist.

Für die Graphen haben wir noch ein paar Lemmata.

Lemma 3.6 ([1, S. 43]). Die Anzahl der Graphen in jeder Isomorphismenklasse von $\Delta(k, r, s)$ Graphen, mit festen k, r und s ist

$$\alpha = p(p-1) \cdots (p-r)n(n-1) \cdots (n-s+1) = p^{r+1}n^s \left(1 + \mathcal{O}\left(\frac{1}{n}\right)\right).$$

Lemma 3.7 ([1, S. 43]). Die Anzahl nicht koinzidenter Knoten von $\Delta_3(k, r, s)$ Graphen also $r+s$ ist kleiner gleich k .

Lemma 3.8 ([1, S. 43]). Die Anzahl nicht-isomorpher $\Delta_1(k, r, s)$ Graphen für festes k und r beträgt

$$\frac{1}{r+1} \binom{k}{r} \binom{k-1}{r}.$$

Aus der Stochastik benötigen wir einmal das Starke Gesetz der großen Zahlen und eine Metrik für Wahrscheinlichkeitsverteilungen.

Satz 3.9 (Starkes Gesetz der großen Zahlen [4, S. 139]). Seien $\{\mathcal{Z}_i\}_{i \in \mathbb{N}}$ unabhängige und identisch verteilte Zufallsvariablen und besitzen ein Moment erster Ordnung, dann gilt

$$\frac{1}{n} \sum_{i=1}^n \mathcal{Z}_i \xrightarrow[n \rightarrow \infty]{f.s.} \mathbb{E}(\mathcal{Z}_1).$$

Definition 3.10 (Lévy-Metrik [4, S. 164]). Seien F_1 und F_2 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathcal{B})$ mit $\mathcal{B}(\mathbb{R})$ als borelsche σ -Algebra und zugehörigen Verteilungsfunktionen $\mathbf{F}_1$ und $\mathbf{F}_2$. Dann ist die *Lévy-Metrik* definiert durch

$$\mathcal{L}(F_1, F_2) = \inf\{\varepsilon > 0, x \in \mathbb{R}: \mathbf{F}_1(x - \varepsilon) - \varepsilon \leq \mathbf{F}_2(x) \leq \mathbf{F}_1(x + \varepsilon) + \varepsilon\}.$$

Für den Beweis Benutzen wir dann die Eigenschaft aus dem folgenden Lemma.

Lemma 3.11 ([1, S. 502]). Seien $A, B \in \mathbb{C}^{p \times n}$ und $S = AA^H$, $\bar{S} = BB^H$. Dann gilt für die Lévy-Metrik aus 3.10

$$\mathcal{L}^4(F^S, F^{\bar{S}}) \leq \frac{2}{p^2} \text{tr}(AA^H + BB^H) \text{tr}((A-B)(A-B)^H).$$

Kommen wir nun zum Satz über die Konvergenz der empirischen Spektralverteilung gegen die Marčenko-Pastur-Verteilung.

Satz 3.12. Seien $\{x_{ij}\}$ unabhängig und identisch verteilte Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2 . Sei weiter $\frac{p}{n} \xrightarrow{n \rightarrow \infty} y \in (0, \infty)$. Dann konvergiert F^{S_n} mit $n \rightarrow \infty$ und fast sicher gegen die Marčenko-Pastur-Verteilung F_y wie sie in Kapitel 3.2 beschrieben wurde.

Im folgenden Beweis nehmen wir mit Lemma ??, o.B.d.A an, dass die Varianz $\sigma^2 = 1$ ist, wir also den Standardfall betrachten. Wir zeigen die Konvergenz der empirischen Spektralverteilung gegen die Marčenko-Pastur-Verteilung mithilfe der Momentmethode. Die Momentmethode verlangt aber, dass die Momente jeder Ordnung der Verteilung endlich sind. Um das garantieren zu können, müssen wir erstmal dafür sorgen, dass die Zufallsvariablen $\{x_{ij}\}$ nicht unendlich groß werden können. Dafür können wir die Zufallsvariablen gleichmäßig beschränken. Entsprechend müssen wir dann die Erwartungswerte zentralisieren also auf 0 setzen und um die Varianz zu erhalten, müssen wir sie Reskalieren.

Beweis. Seien $C \in \mathbb{R}_+$ und $\mathbf{1}$ die Indikatorfunktion auf $\mathbb{R}$. Weiter seien

$$\begin{aligned} \hat{x}_{ij} &:= x_{ij} \mathbf{1}(|x_{ij}| \leq C), & \tilde{x}_{ij} &:= \hat{x}_{ij} - \mathbb{E}(\hat{x}_{11}) \\ \hat{x}_i &:= (\hat{x}_{i1}, \dots, \hat{x}_{ip})^\top, & \tilde{x}_i &:= (\tilde{x}_{i1}, \dots, \tilde{x}_{ip})^\top \\ \hat{S}_n &:= \frac{1}{n} \sum_{i=1}^n \hat{x}_i \hat{x}_i^H = \frac{1}{n} \hat{\mathbf{X}}_n \hat{\mathbf{X}}_n^H, & \tilde{S}_n &:= \frac{1}{n} \sum_{i=1}^n \tilde{x}_i \tilde{x}_i^H = \frac{1}{n} \tilde{\mathbf{X}}_n \tilde{\mathbf{X}}_n^H. \end{aligned}$$

Wir bezeichnen ab hier alle $\mathbf{X}_n$ als $\mathbf{X}$. Mit $\hat{S}_n$ und $\tilde{S}_n$ haben wir die beschränkte und zentralisierte Stichproben Kovarianzmatrix. Im Folgenden wollen wir zeigen, dass sich durch Beschränken und Zentralisieren der Grenzwert nicht ändert. Nach Lemma 3.11

erhalten wir

$$\begin{aligned}
\mathcal{L}^4(F^{\mathbf{S}}, F^{\hat{\mathbf{S}}_n}) &\leq \frac{2}{np} \operatorname{tr}(\mathbf{X}\mathbf{X}^H + \hat{\mathbf{X}}\hat{\mathbf{X}}^H) \operatorname{tr}((\mathbf{X} - \hat{\mathbf{X}})(\mathbf{X} - \hat{\mathbf{X}})^H) \\
&= \left(\frac{2}{np} \sum_{i,j} x_{ij}x_{ij}^H + \hat{x}_{ij}\hat{x}_{ij}^H \right) \left(\frac{1}{np} \sum_{i,j} (x_{ij} - \hat{x}_{ij})(x_{ij} - \hat{x}_{ij})^H \right) \\
&= \left(\frac{2}{np} \sum_{i,j} |x_{ij}|^2 + |\hat{x}_{ij}|^2 \right) \left(\frac{1}{np} \sum_{i,j} |x_{ij} - \hat{x}_{ij}|^2 \right) \\
&\leq \left(\frac{4}{np} \sum_{i,j} |x_{ij}|^2 \right) \left(\frac{1}{np} \sum_{i,j} |x_{ij}|^2 \mathbf{1}(|x_{ij}| > C) \right) \\
&\xrightarrow{f.s.} 4\mathbb{E}(|x_{ij}|^2) \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\
&\xrightarrow{f.s.} 4\mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\
&\xrightarrow{C \rightarrow \infty} 0
\end{aligned}$$

Der Abstand der empirischen Spektralverteilung und ihrer beschränkten Version ist also für ein genügend großes C vernachlässigbar klein. Nach Satz 3.2

$$\begin{aligned}
\|F^{\hat{\mathbf{S}}_n} - F^{\tilde{\mathbf{S}}_n}\|_{\infty} &\leq \frac{1}{p} \operatorname{rang}(\hat{\mathbf{X}} - \tilde{\mathbf{X}}) \\
&= \frac{1}{p} \operatorname{rang}(\mathbb{E}(\hat{x}_{11})) \\
&= \frac{1}{p}
\end{aligned}$$

können wir sehen, dass das Entfernen des Erwartungswertes, also die Zentralisierung der Zufallsvariablen, auch keinen Einfluss auf die Konvergenz hat.

Wir haben jetzt die Verteilung so modifiziert, dass die Zufallsvariablen nicht mehr unendlich groß werden können und den Erhalt des Erwartungswertes garantiert, ohne die Konvergenz zu beeinträchtigen. Um die letzte Bedingung, also den Erhalt der Varianz, zu erfüllen müssen wir zeigen, dass durch Skalierung von $\tilde{\mathbf{S}}_n$ mit $\tilde{\sigma}^2 = \mathbb{E}(|\tilde{x}_{ij}|^2) \rightarrow 1$, wenn $C \rightarrow \infty$ gilt, der Abstand zu $\tilde{\mathbf{S}}_n$ wieder vernachlässigbar klein wird.

Es gilt wieder mit Lemma 3.11

$$\begin{aligned}
\mathcal{L}^4(F\tilde{\mathbf{S}}_n, F\tilde{\sigma}^{-2}\tilde{\mathbf{S}}_n) &\leq \frac{2}{n} \operatorname{tr} \left(\tilde{\mathbf{X}} \tilde{\mathbf{X}}^H + \frac{1}{\tilde{\sigma}^2} \tilde{\mathbf{X}} \tilde{\mathbf{X}}^H \right) \operatorname{tr} \left(\left(1 - \frac{1}{\tilde{\sigma}} \right)^2 \tilde{\mathbf{X}} \tilde{\mathbf{X}}^H \right) \\
&= \left(\frac{2}{np} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H - \frac{2\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}} + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \\
&= \left(\frac{2}{np} \sum_{i,j} |\tilde{x}_{ij}|^2 + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} |\tilde{x}_{ij}|^2 - \frac{2|\tilde{x}_{ij}|^2}{\tilde{\sigma}} + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\
&= \left(\frac{2}{np} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 - \tilde{\sigma} 2|\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\
&= 2 \left(\frac{\tilde{\sigma}^2 + 1}{np\tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \left(\frac{(\tilde{\sigma} - 1)^2}{np\tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \\
&\xrightarrow{f.s.} 2 \frac{\tilde{\sigma}^2 + 1}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \frac{(\tilde{\sigma} - 1)^2}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \\
&\xrightarrow{C \rightarrow \infty} 0.
\end{aligned}$$

Damit haben wir die Endlichkeit der Momente aller Ordnungen garantiert. Für einen besseren Überblick verwenden wir weiterhin die Notation von $\mathbf{S}_n$ und $\mathbf{X}$, meinen aber die modifizierten Matrizen. Wir haben also eine gleichmäßig durch C beschränkte Zufallsvariable x_{ij} mit Erwartungswert 0 und Varianz 1.

Nach Definition 3.1 erhalten wir

$$\begin{aligned}
\beta_k(\mathbf{S}_n) &= \int_{-\infty}^{\infty} x^k F^{\mathbf{S}_n} dx \\
&= \frac{1}{p} \operatorname{tr} \left(\mathbf{S}_n^k \right) \\
&= \frac{1}{pn^k} \operatorname{tr} \left((\mathbf{X} \mathbf{X}^H)^k \right)
\end{aligned}$$

für die Momente der empirischen Spektralverteilung. Da die Dimensionen $p \times n$ von $\mathbf{X}$ gegen unendlich laufen, läuft auch die Anzahl der Summanden der Spur gegen unendlich. Wir können die Spur aber auch als

$$\frac{1}{pn^k} \operatorname{tr} \left((\mathbf{X} \mathbf{X}^H)^k \right) = \frac{1}{pn^k} \sum_i \sum_j x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k}$$

darstellen. Hier sind $\bar{x}_{ij}$ die Einträge aus $\mathbf{X}^H$ und damit komplex konjugiert. Dabei sind $x_{i_1 j_1} \bar{x}_{i_2 j_1} \dots$ die Faktoren der einzelnen Summanden der Spur und wir summieren über alle Permutationen von $\mathbf{i}$ und $\mathbf{j}$. Wenn wir über alle Permutationen summieren, können wir diese als oben definierte Graphen darstellen. Hier stellen x_{ij} die Kanten von $\mathbf{i}$ -Knoten zu $\mathbf{j}$ -Knoten dar und $\bar{x}_{ij}$ Kanten von $\mathbf{j}$ - zu $\mathbf{i}$ -Knoten. Wir definieren dann

$$\frac{1}{pn^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k} := \frac{1}{pn^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbf{X}_{\Delta(k, r, s)}.$$

Nach der Momentmethode (S.507) konvergiert die empirische Spektralverteilung schwach gegen die Marčenko-Pastur-Verteilung, wenn die Momente der empirische Spektralverteilung gegen die der Marčenko-Pastur-Verteilung konvergieren. Das zeigen wir, indem wir den Erwartungswert und die Varianz der Momente der empirische Spektralverteilung bestimmen. Sie konvergieren, wenn der Erwartungswert $\mathbb{E}(\beta_k(\mathbf{S}_n))$ gegen die Momente der Marčenko-Pastur-Verteilung läuft und die Varianz gegen null geht.

Fangen wir an mit dem Erwartungswert. Nach Definition gilt

$$\mathbb{E}(\beta_k(S_n)) = \frac{1}{pn^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbb{E}(\mathbf{X}_{\Delta(k, r, s)}).$$

Teilen wir die Graphen in ihre Kategorien ein, erhalten wir mit Lemma 3.6

$$\mathbb{E}(\beta_k(S_n)) = \frac{1}{pn^k} \left(\overbrace{\sum_{\Delta_1} \alpha \mathbb{E}(\mathbf{X}_{\Delta_1})}^{W_1 :=} + \overbrace{\sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2})}^{W_2 :=} + \overbrace{\sum_{\Delta_3} \alpha \mathbb{E}(\mathbf{X}_{\Delta_3})}^{W_3 :=} \right).$$

Für W_1 erhalten wir nach Lemma 3.6 und Lemma 3.7

$$W_1 = \frac{1}{n^k p} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p^{r+1} n^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p}\right) \right) \mathbb{E}(\mathbf{X}_{\Delta_1})$$

Da es zu jeder Kante genau eine Kante in die entgegengesetzte Richtung gibt, gilt $\mathbb{E}(|x_{ij}|^2) = 1$. Wir können also schreiben

$$\begin{aligned}
W_1 &= \frac{1}{n^k p} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p^{r+1} n^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\
&= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} \frac{p^{r+1} n^{k-r}}{n^k p} \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\
&= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p}\right). \tag{3.10}
\end{aligned}$$

Für W_2 können wir sehen, dass

$$W_2 = \frac{1}{n^k p} \sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2}) = 0 \tag{3.11}$$

gilt, da wir den Erwartungswert auf Kanten aufteilen können, und es in Kategorie Δ_2 mindestens eine Einzelkante gibt. Es gibt demnach mindestens ein ω_i in

$$\mathbb{E}(\mathbf{X}_{\Delta_2}) = \mathbb{E}(x_{i_1 j_1}^{\omega_1}) \mathbb{E}(x_{i_2 j_1}^{\omega_2}) \cdots$$

welches gleich 1 ist, woraus folgt, dass $\mathbb{E}(x_{i_k j_k}^1) = 0 = \mathbb{E}(\mathbf{X}_{\Delta_2})$ ist.

Für W_3 erhalten wir wieder mit Lemma 3.6, dass

$$W_3 = \frac{1}{n^k p} \sum_{\Delta_3} \alpha \mathbb{E}(\mathbf{X}_{\Delta_3})$$

gilt. Weiter oben haben wir gezeigt, dass x_{ij} gleichmäßig durch ein $C > 0$ beschränkt ist. Daraus erhalten wir, dass $|X_{\Delta(k,r,s)}| \leq C^{2k}$ gilt. Mit Lemma ?? wissen wir, dass die Anzahl nicht koinzidenter Knoten maximal k betragen kann. Dadurch ist die Anzahl unterschiedlicher Δ_3 Graphen in $\mathcal{O}(n^k)$. Wir haben also

$$\begin{aligned}
\frac{1}{n^k p} \sum_{\Delta_3} \alpha(\mathbf{X}_{\Delta_3}) &= \frac{C^{2k}}{n^k p} \mathcal{O}(n^k) \\
&= \mathcal{O}\left(\frac{1}{p}\right). \tag{3.12}
\end{aligned}$$

Mit (3.10), (3.11) und (3.12) erhalten wir dann

$$\begin{aligned}\mathbb{E}(\beta_k(S_n)) &= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p}\right) \\ &= \beta_k(y, \sigma^2) + o(1)\end{aligned}\tag{3.13}$$

Jetzt fehlt noch die Varianz. Diese ist nach Definition

$$\text{Var}(\beta_k(S_n)) := \frac{1}{pn^k} \sum_{i,j} \left(\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) - \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)}) \right).$$

Dabei sind Δ_a und Δ_b verschiedene Permutationen i und j . Wie für den Erwartungswert suchen wir uns Kategorien, um die Varianz stückweise zu beschreiben.

Als Erstes betrachten wir alle Graphen Δ_a und Δ_b so, dass Δ_a und Δ_b unabhängig sind, sich also keine Kanten teilen. Daraus folgt direkt durch Rechenregeln von Erwartungswerten, dass

$$\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) = \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)})$$

gilt. Das heißt, für unabhängige Graphen ist die Varianz gleich 0.

Als Nächstes betrachten wir alle Graphen $\Delta_a \cup \Delta_b$, die mindestens eine Einzelkante besitzen. Damit erhalten wir durch Δ_2 Eigenschaften wieder

$$\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) = 0 = \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)}).$$

In allen anderen Möglichkeiten haben die Graphen keine Einzelkante und Δ_a und Δ_b teilen sich Kanten. Analog zu W_3 können wir sagen, dass die Anzahl möglicher Graphen in $\mathcal{O}(n^k)$ liegt. Da wir zwei Graphen haben ist die Anzahl also in $\mathcal{O}(n^{2k})$. Durch die gleichmäßige Beschränkung von x_{ij} durch C können wir die Varianz durch

$$\begin{aligned}\text{Var}(\beta_k(S_n)) &\leq \frac{1}{p^2 n^{2k}} C \mathcal{O}(n^{2k}) \\ &= \mathcal{O}\left(\frac{1}{p^2}\right)\end{aligned}\tag{3.14}$$

abschätzen.

Mit dem Erwartungswert (3.13) und der Varianz (3.14) können wir darauf schließen, dass die empirische Spektralverteilung fast sicher gegen die Marčenko-Pastur-Verteilung konvergiert. $\square$

Literatur

- [1] Z. Bai und J. W. Silverstein. *Spectral analysis of large dimensional random matrices*. 2nd ed. Springer Ser. Stat. Dordrecht: Springer, 2010. DOI: 10.1007/978-1-4419-0661-8.
- [2] S. L. Brunton und J. N. Kutz. *Data-driven science and engineering. Machine learning, dynamical systems, and control*. 2nd edition. Cambridge: Cambridge University Press, 2022. DOI: 10.1017/9781009089517.
- [3] M. Gavish und D. L. Donoho. *The optimal hard threshold for singular values is $4/\sqrt{3}$* . IEEE Trans. Inf. Theory 60.8 (2014), S. 5040–5053. DOI: 10.1109/TIT.2014.2323359.
- [4] H.-O. Georgii. *Stochastik. Einführung in die Wahrscheinlichkeitstheorie und Statistik*. 5th, revised and expanded ed. De Gruyter Stud. Berlin: De Gruyter, 2015. DOI: 10.1515/9783110359701.
- [5] A. Meister und T. Sonar. *Numerik. Eine lebendige und gut verständliche Einführung mit vielen Beispielen*. Berlin: Springer Spektrum, 2019. DOI: 10.1007/978-3-662-58358-6.

Hinweise zu den offiziellen Erklärungen

1. Die folgende Seite mit den offiziellen Erklärungen

A) Eigenständigkeitserklärung

B) Erklärung zur Veröffentlichung von Bachelor- oder Masterarbeiten

C) Einverständniserklärung über die Bereitstellung und Nutzung der Bachelorarbeit / Masterarbeit
in elektronischer Form zur Überprüfung durch eine Plagiatsoftware

ist entweder direkt in jedes Exemplar der Bachelor- oder Masterarbeit fest mit einzubinden oder
unverändert im Wortlaut in jedes Exemplar der Bachelor- oder Masterarbeit zu übernehmen.

Bitte achten Sie darauf, jede Erklärung in allen drei Exemplaren der Arbeit zu unterschreiben.

2. In der digitalen Fassung kann auf die Unterschrift verzichtet werden. Die Angaben und Entscheidungen
müssen jedoch enthalten sein.

Zu B)

Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die
Zukunft, widerrufen werden.

Zu C)

Das Einverständnis der dauerhaften Speicherung des Textes ist freiwillig.

Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die Zukunft,
widerrufen werden.

Weitere Informationen zur Überprüfung von schriftlichen Arbeiten durch die Plagiatsoftware sind im Nutzungs-
und Datenschutzkonzept enthalten. Diese finden Sie auf der Internetseite der Universität Bremen.

Notes on the official declarations

1. The following pages with the official declarations

A) Declaration of Authorship

B) Declaration on the Publication of Bachelor's or Master's Thesis

C) Declaration of Consent for the Provision and Use of the Bachelor's Thesis / Master's Thesis
in Electronic Form for Review by Plagiarism Software

is to be either integrated directly into each copy of the bachelor's or master's thesis or adopted
unchanged in the wording of each copy of the bachelor's or master's thesis.

Please be sure to sign each declaration in all three copies of the thesis.

2. The signature can be omitted from the digital version. However, the information and decisions must be included.

Regarding B)

The consent can be revoked at any time with future effect by notifying the University of Bremen.

Regarding C)

Consent for the permanent storage of the text is voluntary. The consent can be revoked at any time with future
effect by notifying the University of Bremen.

Further information on the checking of written work using plagiarism software can be found in the data protection
and usage concept. This can be found on the University of Bremen website.

**Eigenständigkeits- und Einverständniserklärung zur Überprüfung mit Plagiatsoftware
sowie die Erklärung zur Veröffentlichung bei Bachelor- und Masterarbeiten****Declarations of Authorship and Consent for Checking with Plagiarism Software and the
Declaration of Publication for Bachelor's and Master's Thesis**

Studierenden-Angaben / Student Information:

Matrikelnr./ Student ID

Nachname / Surname

Vorname / First Name

Titel der Arbeit / Title of Thesis

--

A) Eigenständigkeitserklärung / Declaration of Authorship

Ich versichere, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe. Alle Teile meiner Arbeit, die wortwörtlich oder dem Sinn nach anderen Werken entnommen sind, wurden unter Angabe der Quelle kenntlich gemacht. Gleiches gilt auch für Zeichnungen, Skizzen, bildliche Darstellungen sowie für Quellen aus dem Internet, dazu zählen auch KI-basierte Anwendungen oder Werkzeuge.
Die Arbeit wurde in gleicher oder ähnlicher Form noch nicht als Prüfungsleistung eingereicht.

I hereby affirm that I have written the present work independently and have used no sources or aids other than those indicated. All parts of my work that have been taken from other works, either verbatim or in terms of meaning, have been marked as such, indicating the source. The same applies to drawings, sketches, pictorial representations and sources from the Internet, including AI-based applications or tools. The work has not yet been submitted in the same or a similar form as a final examination paper.

- ☐ Ich habe KI-basierte Anwendungen und/oder Werkzeuge genutzt und diese im Anhang "Nutzung KI basierte Anwendungen" dokumentiert.

I have used AI-based applications and/or tools and documented them in the appendix "Use of AI-based applications".

B) Erklärung zur Veröffentlichung von Bachelor- oder Masterarbeiten

Declaration regarding the publication of bachelor's or master's thesis

Die Abschlussarbeit wird zwei Jahre nach Studienabschluss dem Archiv der Universität Bremen zur dauerhaften Archivierung angeboten. Archiviert werden:

Two years after graduation, the thesis is offered to the archive of the University of Bremen for permanent archiving. The following are archived:

- 1) Masterarbeiten mit lokalem oder regionalem Bezug sowie pro Studienfach und Studienjahr 10 % aller Masterarbeiten
Master's theses with a local or regional focus, as well as per subject and academic year 10% of all Master's thesis
- 2) Bachelorarbeiten des jeweils ersten und letzten Bachelorabschlusses pro Studienfach und Jahr.
Bachelor's thesis for the first and last bachelor's degrees per subject and year.

☐ Ich bin damit einverstanden, dass meine Abschlussarbeit im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I agree that my thesis may be viewed by third parties in the university archive for academic purposes.

☐ Ich bin damit einverstanden, dass meine Abschlussarbeit nach 30 Jahren (gem. §7 Abs. 2 BremArchivG) im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I agree that my thesis may be viewed by third parties for academic purposes in the university archive after 30 years (in accordance with §7 para. 2 BremArchivG).

☐ Ich bin **nicht** damit einverstanden, dass meine Abschlussarbeit im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I do not consent to my thesis being made available in the university archive for third parties to view for academic purposes.

C) Einverständniserklärung zur elektronischen Überprüfung der Arbeit auf Plagiate Declaration of consent for electronic checking of the work for plagiarism

Eingereichte Arbeiten können nach § 18 des Allgemeinen Teil der Bachelor- bzw. der Masterprüfungsordnungen der Universität Bremen mit qualifizierter Software auf Plagiatsvorwürfe untersucht werden.

Zum Zweck der Überprüfung auf Plagiate erfolgt das Hochladen auf den Server der von der Universität Bremen aktuell genutzten Plagiatssoftware.

Submitted papers can be checked for plagiarism using qualified software in accordance with § 18 of the General Section of the Bachelor's or Master's Degree Examination Regulations of the University of Bremen. For the purpose of checking for plagiarism, the upload to the server is done using the plagiarism software currently used by the University of Bremen.

- ☐ Ich bin damit einverstanden, dass die von mir vorgelegte und verfasste Arbeit zum oben genannten Zweck dauerhaft auf dem externen Server der aktuell von der Universität Bremen genutzten Plagiatssoftware, in einer institutionseigenen Bibliothek (Zugriff nur durch die Universität Bremen), gespeichert wird.

I agree that the work I have submitted and written will be stored permanently on the external server of the plagiarism software currently used by the University of Bremen, in a library belonging to the institution (accessed only by the University of Bremen), for the above-mentioned purpose.

- ☐ Ich bin **nicht** damit einverstanden, dass die von mir vorgelegte und verfasste Arbeit zum o.g. Zweck dauerhaft auf dem externen Server der aktuell von der Universität Bremen genutzten Plagiatssoftware, in einer institutionseigenen Bibliothek (Zugriff nur durch die Universität Bremen), gespeichert wird.

I do not consent to the work I submitted and wrote being permanently stored on the external server of the plagiarism software currently used by the University of Bremen, in a library belonging to the institution (accessed only by the University of Bremen), for the above-mentioned purpose.

Das Einverständnis der dauerhaften Speicherung des Textes ist freiwillig. Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die Zukunft, widerrufen werden. Weitere Informationen zur Überprüfung von schriftlichen Arbeiten durch die Plagiatsoftware sind im Nutzungs- und Datenschutzkonzept enthalten. Diese finden Sie auf der Internetseite der Universität Bremen.

Consent to the permanent storage of the text is voluntary. Consent can be withdrawn at any time by making a declaration to this effect to the University of Bremen, with effect for the future. Further information on the checking of written work using plagiarism software can be found in the data protection and usage concept. This can be found on the University of Bremen website.

Mit meiner Unterschrift versichere ich, dass ich die obenstehenden Erklärungen gelesen und verstanden habe und bestätige die Richtigkeit der gemachten Angaben.

With my signature, I confirm that I have read and understood the above explanations and confirm the accuracy of the information provided.

Datum / Date

Unterschrift/ Signature