



Rangreduzierung in DMD mittels Marchenko-Pastur-Verteilung

Eingereicht von

Lennart Koliwer

koliwer1@uni-bremen.de

Gutachter:innen

Prof. Dr. Anke Pohl

Dr. Maxim Kirsebom

Fachbereich 3

Universität Bremen

WiSe 2025/26

25. Februar 2026

Inhaltsverzeichnis

1. Einleitung	1
2. DMD	5
2.1. Dynamic Mode Decomposition (DMD) [2]	5
3. Marčenko-Pastur	13
3.1. Marčenko-Pastur Momente	13
3.2. Vorbereitung (Text ist mir noch zu holprig)	20
3.3. Marčenko-Pastur-Verteilung	23
4. Marchenko-Pastur-Verteilung	31
A. Stochastische Grundlagen	37
Literatur	41
Eigenständigkeits- und Einverständniserklärung	44

1. Einleitung

Fehlen noch Quellen natürlich Dynamic Mode Decomposition, kurz DMD, ist ein datengetriebener Algorithmus, der ursprünglich im Feld der Strömungsdynamik entwickelt wurde. Grundsätzlich dient er der Analyse dynamischer Systeme mittels Singulärwertzerlegung von großen Datenmatrizen. DMD kann anhand von Messdaten mehrerer Zeitpunkte die Dynamik eines Systems approximieren. Die Genauigkeit hängt unter anderem davon ab, wie viele Informationen in Form von Messdaten über das System zur Verfügung stehen und wie groß die Messfehler also das Rauschen der Daten ist. Dabei ist DMD gut im Erkennen von Mustern, wie im Falle der Strömungsdynamik z.B. Wirbelungen. Probleme treten jedoch auf, wenn man DMD außerhalb von Simulationen verwendet und echte Messungen analysieren will. Bei Messungen hat man immer ein Rauschen in den Daten, welche das Ergebnis verfälschen. Dadurch kommt es durch Fehlerfortpflanzung schnell zu größeren Ungenauigkeiten. Im Laufe der letzten Jahre wurden eine Vielzahl von Varianten der DMD Algorithmen entwickelt, um unterschiedliche Schwächen des Algorithmus auszugleichen.

Das klassische DMD benötigt Messdaten in einheitlichen Zeitabständen. Für jeden Zeitpunkt i werden die jeweiligen Messdaten in die i -te Spalte einer Datenmatrix X eingetragen. Zusätzlich legen wir eine zweite Datenmatrix X' so an, dass wir in X die Messungen $(x_1, \dots, x_{k-1})$ und in X' die Messungen $(x_2, \dots, x_k)$ haben. Die Datenmatrizen sind in der Regel $n \times m$ große Matrizen, wobei n die Anzahl der Messdaten zum i -ten Zeitpunkt ist und $m = k - 1$ stellt die Anzahl der Messungen dar. In der Regel haben sie deutlich mehr Zeilen als Spalten also $n \gg m$ gilt. Das Ziel von DMD ist es einen linearen Operator A bzw. seine Spektralzerlegung zu finden, für den

$$X' \approx AX$$

so gut wie möglich gilt. Der dafür am besten passende Operator A lässt sich durch

$$A = \arg \min_A \|X' - AX\|_F = X'X^\dagger$$

bestimmen. Dabei sind $\|\cdot\|_F$ die Frobeniusnorm und $X^\dagger$ die Moore-Penrose-Inverse, wel-

che wir **später** noch genauer beschreiben werden. Die Moore-Penrose-Inverse lässt sich dann mittels Singulärwertzerlegung (SWZ) der Datenmatrix X bestimmen. Die SWZ beschreiben wir auch **später** nochmal genauer, liefern aber für einen kleinen Überblick eine vereinfachte Beschreibung. Bei der SWZ finden wir für ein $X \in \mathbb{R}^{n \times m}$ zwei orthogonale Matrizen U und V mit passenden Dimensionen und $\hat{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_r)$ mit $r \leq \min(n, m)$ und $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U \Sigma V^\top \text{ mit } \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{n \times m}$$

gilt. Bei der Bestimmung von A wird der Rechenaufwand schnell zu groß, weshalb der DMD Algorithmus eine Dimensionsreduktion durchführt. Damit kann man eine Spektralzerlegung von A machen, ohne A direkt zu benutzen. Durch die oben genannte Form der Datenmatrizen kann man direkt sehen, dass X maximal von Rang m sein kann. Es gibt also maximal $r \leq m$ Singulärwerte, die nicht Null sind. Reduzieren wir also unser Σ aus der SWZ auf eine $r \times r$ große Matrix also $\hat{\Sigma}$, und entfernen bis auf die ersten r Spalten alle Spalten von U und V , erhalten wir mit den reduzierten Matrizen U_r , Σ_r und V_r ,

$$X_r = U_r \Sigma_r V_r^\top = U_r \hat{\Sigma} V_r^\top .$$

Nach dem Eckart-Young-Mirsky-Theorem **Quelle!! Vielleicht doch eher MSE nehmen weil gleich wie im paper** lässt sich durch

$$\|X_r\|_F^2 = \sum_{i=1}^r \sigma_i^2$$

zeigen, dass X_r die beste Rang r -Approximation bezüglich der Frobeniusnorm ist. Die Spektralzerlegung von A können wir damit über die viel kleinere Matrix

$$\tilde{A} = U_r^\top A U_r$$

bestimmen. Diese Methode der Dimensionsreduktion für SWZ ist als ökonomischer SWZ bekannt.

Eine weitere Methode, welche im Paper [4] von Matan Gavish und David L. Donoho behandelt wird, ist das „singular value hard thresholding“ (SVHD). Das ist eine Rangreduzierung bis alle Singulärwerte über einem definierten Schwellenwert τ liegen. Gavish

und Donoho definieren einer Rahmenstruktur, in der die Datenmatrix X durch

$$X := X^{\text{echt}} + \gamma X^{\text{rauschen}}$$

beschrieben wird. Wir haben also X in einen echten Teil und einem durch γ skalierten Fehleranteil aufgeteilt. Die Einträge der Fehlermatrix sind unabhängig und identisch verteilte Zufallsvariablen mit Erwartungswert $E(X^{\text{rauschen}}) = 0$ Varianz $Var(X^{\text{rauschen}}) = 1$.

nicht sicher wie detailliert ich die Rahmenstruktur definieren soll oder ob überhaupt.

Innerhalb dieser Rahmenstruktur haben Gavish und Donoho herausgefunden, dass für bekanntes Rauschen γ der optimale Schwellenwert τ_* für Singulärwerte bei

$$\tau_* = \lambda_*(y)\gamma\sqrt{n} \quad \text{mit} \quad \lambda_*(y) := \sqrt{2(y+1) + \frac{8y}{(y+1) + \sqrt{y^2 + 14y + 1}}}$$

liegt. Bei quadratischen Matrizen reduziert sich λ_* sogar auf $\frac{4}{\sqrt{3}}$.

ab hier eher ungenau aber wenigstens mal "fertig" formuliert

Da das Rauschen aber nicht unbedingt bekannt ist, haben Gavish und Donoho für diesen Fall einen Rausch-Schätzer

$$\hat{\gamma}(X) := \frac{\sigma_{med}}{\sqrt{m \cdot \mu_y}}$$

definiert. Hier ist σ_{med} der Median der Singulärwerte von X und μ_y ist der Median der standard Marčenko-Pastur-Verteilung. Also mit $y = \frac{n}{m}$, $a = (1 - \sqrt{y})^2$, $b = (1 + \sqrt{y})^2$ und $a \leq \mu_y \leq b$ so, dass

$$\int_a^{\mu_y} \frac{1}{2\pi xy} \sqrt{(b-x)(x-a)} dx = \frac{1}{2}$$

gilt. Mit $\hat{\gamma}$ haben sie dann den Schwellenwert für Singulärwerte durch

$$\hat{\tau}_*(y, X) := \lambda_*(y)\hat{\gamma}\sqrt{n} = \frac{\lambda_*(y)}{\sqrt{\mu_y}}\sigma_{med}$$

definiert.

Uns interessiert hier am Ende die Marčenko-Pastur-Verteilung (MP) im Rahmenbereich der unabhängig und identisch verteilten Zufallsvariablen (uiv). Was MP macht, ist anzugeben, wie die Singulärwerte einer Matrix aus uiv Zufallsvariablen verteilt sind. In dieser Arbeit werden wir die MP einmal konkret beweisen und zeigen, dass es ein μ_y gibt, mit dem die Verteilung $\frac{1}{2}$ ergibt.

2. DMD

2.1. Dynamic Mode Decomposition (DMD) [2]

In diesem Kapitel wollen wir noch einmal genauer den DMD Algorithmus erklären. Es ist aber nicht notwendig für das weitere Verstehen dieser Arbeit.

Aus der Einleitung wissen wir, dass die Singulärwertzerlegung und die Frobeniusnorm wichtige Werkzeuge des Algorithmus sind, weshalb wir sie hier einmal konkret definieren.

Definition 2.1 (Frobeniusnorm). Sei $X \in \mathbb{C}^{n \times m}$ eine Matrix und x_{ij} mit $i \in \{1, \dots, n\}$, $j \in \{1, \dots, m\}$. Die Frobeniusnorm ist definiert durch

$$\|X\|_F := \sqrt{\sum_{i=1}^n \sum_{j=1}^m |x_{ij}|^2}.$$

Lemma 2.2. Sei $X \in \mathbb{C}^{n \times m}$ eine Matrix. Dann gilt

$$\|X\|_F = \sqrt{\text{tr}(X^H X)}.$$

Beweis. Sei x_i ein Spaltenvektor von X und $\bar{x}_{ij}$ in diesem kapitel das komplex konjugierte. Dann ist

$$\begin{aligned} X^H X &= \begin{pmatrix} - & x_1^H & - \\ & \vdots & \\ - & x_m^H & - \end{pmatrix} \begin{pmatrix} | & & | \\ x_1 & \dots & x_m \\ | & & | \end{pmatrix} \\ &= \begin{pmatrix} \sum_{j=1}^n x_{1j}^H x_{1j} & & * \\ & \ddots & \\ * & & \sum_{j=1}^n x_{mj}^H x_{mj} \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^n \bar{x}_{1j} x_{1j} & & * \\ & \ddots & \\ * & & \sum_{j=1}^n \bar{x}_{mj} x_{mj} \end{pmatrix}. \end{aligned}$$

Mit $\bar{x}x = |x|^2$ erhalten wir

$$\operatorname{tr}(X^H X) = \sum_{i=1}^m \sum_{j=1}^n \bar{x}_{ij} x_{ij} = \sum_{i=1}^m \sum_{j=1}^n |x_{ij}|^2 = \|X\|_F^2. \quad (2.1)$$

□

Die Frobeniusnorm wird im weiteren Verlauf aufgrund ihrer Invarianz bezüglich unitärer Transformation verwendet, welche wir durch folgendes Lemma zeigen.

Lemma 2.3. Sei $X \in \mathbb{C}^{n \times m}$ eine Matrix und $U \in \mathbb{C}^{n \times n}$ und $V \in \mathbb{C}^{m \times m}$ unitäre Matrizen. Dann gilt

1. $\|X\|_F = \|X^H\|_F$,
2. $\|UX\|_F = \|X\|_F$,
3. $\|XV\|_F = \|X\|_F$.

Beweis.

1. Aus Gleichung (2.1) folgt

$$\|X\|_F^2 = \operatorname{tr}(X^H X) = \sum_{i=1}^m \sum_{j=1}^n \bar{x}_{ij} x_{ij} = \sum_{j=1}^n \sum_{i=1}^m \bar{x}_{ij} x_{ij} = \operatorname{tr}(X X^H) = \|X^H\|_F^2.$$

2. Es ist

$$\|UX\|_F^2 = \operatorname{tr}(X^H U^H U X) = \operatorname{tr}(X^H \mathbb{1} X) = \operatorname{tr}(X^H X) = \|X\|_F^2.$$

3. Mit 1. und 2. folgt

$$\|XV\|_F = \|V^H X^H\|_F = \|X^H\|_F = \|X\|_F. \quad \square$$

Satz 2.4 (Singulärwertzerlegung [6]). Sei $X \in \mathbb{R}^{n \times m}$ eine Matrix und $r := \operatorname{rang} X$ mit $r \leq \min(n, m)$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{n \times n}$ und $V \in \mathbb{R}^{m \times m}$ und eine Diagonalmatrix $\hat{\Sigma} = \operatorname{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}$ mit $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U \Sigma V^T \text{ mit } \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{n \times m}$$

gilt.

Der Beweis des Satzes 2.4 folgt etwas später, da dafür noch etwas Vorbereitung benötigt wird.

Bemerkung 2.5. Unter den in Satz 2.4 genannten Voraussetzungen, ist $\hat{\Sigma}$ durch X eindeutig bestimmt. Die beiden orthogonalen Matrizen U und V hingegen sind nicht eindeutig.

Lemma 2.6. Sei $X \in \mathbb{R}^{n \times m}$ und λ_i die Eigenwerte von $X^\top X$. Dann gilt für die Singulärwerte unter den Voraussetzungen aus Satz 2.4

$$\sigma_i = \sqrt{\lambda_i}.$$

Beweis. Durch

$$\begin{aligned} X^\top X &= (U\Sigma V^\top)^\top (U\Sigma V^\top) \\ &= V\Sigma^\top U^\top U\Sigma V^\top \\ &= V\Sigma^\top \Sigma V^\top \end{aligned}$$

ist $X^\top X$ ähnlich zu $\Sigma^\top \Sigma$. Also haben $X^\top X$ und $\Sigma^\top \Sigma$ auch die gleichen Eigenwerte. $\square$

Bemerkung 2.7. Damit gilt für die Diagonalelemente von $\hat{\Sigma}$ aus Satz 2.4,

$$\sigma_i = \sqrt{\lambda_i},$$

dass deren Wurzeln gleich der Eigenwerte von $X^\top X$ sind.

Definition 2.8. Wir nennen die Diagonalelemente σ_i von $\hat{\Sigma}$ *Singulärwerte*.

Bemerkung 2.9. Die aus der Singulärwertzerlegung in 2.4 entstehenden Singulärwerte sind invariant bezüglich Transposition von X .

Beweis. Seien die Voraussetzungen aus Satz 2.4 gegeben, dann gilt

$$X^\top = (U\Sigma V^\top)^\top = V\Sigma^\top U^\top.$$

Da Σ nur auf der Hauptdiagonalen Einträge hat und sonst mit Nullen gefüllt ist, erhalten wir

$$\text{diag } \Sigma^\top = \{\sigma_1, \sigma_2, \dots, \sigma_m\} = \text{diag } \Sigma$$

$\square$

Lemma 2.10 ([6, S. 191]). Sei $X \in \mathbb{R}^{n \times n}$ eine symmetrische Matrix. Dann existiert eine orthogonale Matrix $U \in \mathbb{R}^{n \times n}$ und eine Diagonalmatrix $D \in \mathbb{R}^{n \times n}$ so, dass

$$U^\top XU = D$$

gilt.

Lemma 2.11 ([6, S. 227]). Sei $X \in \mathbb{R}^{n \times m}$ eine Matrix mit $\text{rang } X = r < \min(n, m)$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{n \times n}$ und $V \in \mathbb{R}^{m \times m}$ sowie eine reguläre obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$ so, dass

$$U^\top XV = R \text{ mit } R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{n \times m}$$

gilt.

Beweis Satz 2.4. Nach Bemerkung 2.9 nehmen wir o.B.d.A an, dass $m \leq n$ gilt. Zunächst betrachten wir den Fall des vollen Ranges von X , also $\text{rang } X = r = m$. Bei vollem Rang ist $X^\top X \in \mathbb{R}^{m \times m}$ sowohl symmetrisch als auch positiv definit. Die Eigenwerte λ_i von $X^\top X$ sortieren wir nach ihrer Größe, also

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_m > 0.$$

Mit Lemma 2.10 finden wir ein orthogonales $V \in \mathbb{R}^{m \times m}$, sodass

$$V^\top X^\top XV = D = \text{diag}\{\lambda_1, \dots, \lambda_m\} \in \mathbb{R}^{m \times m}.$$

Weiter definieren wir

$$\hat{\Sigma} := \text{diag}\{\sigma_1, \dots, \sigma_m\}$$

mit $\sigma_i := \sqrt{\lambda_i} \in (0, \infty]$, für $i = 1, \dots, m$, und setzen

$$\hat{U} := XV\hat{\Sigma}^{-1} \in \mathbb{R}^{n \times m}.$$

Jetzt kann man durch Umformung von

$$\begin{aligned}
\hat{U}^\top \hat{U} &= \hat{\Sigma}^{-\top} V^\top X^\top X V \hat{\Sigma}^{-1} \\
&= \hat{\Sigma}^{-1} D \hat{\Sigma}^{-1} \\
&= \hat{\Sigma}^{-1} \hat{\Sigma}^{-1} D \\
&= D^{-1} D \\
&= \mathbb{1}
\end{aligned}$$

die Orthonormalität der Spalten von $\hat{U}$ sehen.

Da $\hat{U}$ in $\mathbb{R}^{n \times m}$ mit $m < n$ liegt und aus orthonormalen Spaltenvektoren besteht, finden wir ein $Z \in \mathbb{R}^{n \times (n-m)}$, welches $\hat{U}$ so um $n - m$ orthonormale Spaltenvektoren ergänzt, dass

$$U = (\hat{U} \ Z) \in \mathbb{R}^{n \times n}$$

eine orthogonale Matrix ist. Es gilt also

$$\begin{aligned}
Z^\top X V \hat{\Sigma}^{-1} &= Z^\top \hat{U} \\
&= 0 \in \mathbb{R}^{(n-m) \times n}.
\end{aligned}$$

Da $\hat{\Sigma} \hat{\Sigma}^{-1} = \mathbb{1}$ ist, folgt auch direkt

$$Z^\top X V = 0.$$

Zusammengetragen haben wir dann

$$\begin{aligned}
U^\top X V &= \begin{pmatrix} \hat{U}^\top \\ Z^\top \end{pmatrix} X V = \begin{pmatrix} \hat{\Sigma}^{-1} V^\top X^\top X V \\ Z^\top X V \end{pmatrix} \\
&= \begin{pmatrix} \hat{\Sigma}^{-1} D \\ 0 \end{pmatrix} \\
&= \begin{pmatrix} \hat{\Sigma} \\ 0 \end{pmatrix},
\end{aligned}$$

womit wir den Fall des vollen Ranges bewiesen hätten.

Seien λ_i wie oben definiert wieder die Eigenwerte von $X^\top X$ und sei $X_r \in \mathbb{R}^{n \times m}$ eine Matrix mit $\text{rang } X_r = r < m$. Nach Lemma 2.11 gibt es zwei orthogonale Matrizen

$\tilde{U} \in \mathbb{R}^{n \times n}$ und $\tilde{V} \in \mathbb{R}^{m \times m}$, sowie eine obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$, sodass

$$\tilde{U}^\top X_r \tilde{V} = R \text{ mit } R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{n \times m}$$

gilt. Nach obigem Fall mit vollem Rang, wissen wir, dass es orthogonale Matrizen $U_r \in \mathbb{R}^{n \times n}$ und $V_r \in \mathbb{R}^{r \times r}$, sodass

$$U_r^\top \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix} V_r = \begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{n \times r}.$$

Dabei ist $\hat{\Sigma}_r := \text{diag}\{\sigma_1, \dots, \sigma_r\}$ mit $\sigma_i = \sqrt{\lambda_i}$. Im Folgenden erweitern wir

$$\begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{n \times r} \quad \text{zu} \quad \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} = \Sigma \in \mathbb{R}^{n \times m}$$

und finden eine orthogonale Fortsetzung für V_r zu

$$\bar{V}_r = \begin{pmatrix} V_r & 0 \\ 0 & \mathbb{1} \end{pmatrix} \in \mathbb{R}^{m \times m}.$$

Wenn wir uns jetzt die orthogonalen Matrizen

$$U := \tilde{U} U_r \in \mathbb{R}^{n \times n} \quad \text{und} \quad V := \tilde{V} \bar{V}_r \in \mathbb{R}^{n \times m}$$

definieren, erhalten wir durch

$$\begin{aligned} U^\top X_r V &= U_r^\top \tilde{U} X_r \tilde{V} \bar{V}_r \\ &= U_r^\top \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \bar{V}_r \\ &= \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} =: \Sigma \end{aligned}$$

eine erfolgreiche Zerlegung von X_r durch orthogonale Matrizen. □

Da Wir das jetzt verstanden haben können wir mit DMD anfangen.

Sei nun $X \in \mathbb{R}^{n \times m}$ der Zustand des Systems zu m diskreten Zeitpunkten $t_k = k\Delta t$ mit

$k \in \mathbb{N}$ also

$$X = \begin{pmatrix} | & | & & | \\ x(t_1) & x(t_2) & \dots & x(t_m) \\ | & | & & | \end{pmatrix}$$

und $X' \in \mathbb{R}^{n \times m}$ der Zustand mit jedem Punkt einen Zeitschritt weiter mit $t'_k = t_k + \Delta t$

$$X' = \begin{pmatrix} | & | & & | \\ x(t'_1) & x(t'_2) & \dots & x(t'_m) \\ | & | & & | \end{pmatrix}$$

dann versuchen wir die Matrix A zu finden, der dieses System beschreiben kann und wir mit möglichst geringem Fehler

$$X' \approx AX$$

bestimmen können. Ein ideales A finden wir durch

$$A = \arg \min_A \|X' - AX\|_F = X'X^\dagger$$

mit $X^\dagger$ als Pseudoinversen von X . Dabei sind die hier betrachteten Pseudoinversen alle Moore-Penrose-Inverse. Um die zu bestimmen, machen wir eine Singulärwertzerlegung von X . Damit erhalten wir wie in 2.4 und ??

$$X = U\Sigma V^\top = U \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} V^\top$$

und

$$X^\dagger = V \begin{pmatrix} \hat{\Sigma}^{-1} & 0 \\ 0 & 0 \end{pmatrix} U^\top$$

so, dass $XX^\dagger = \mathbb{1}$ ergibt. Da wir aber häufig mit sehr großen Matrizen arbeiten, liegt es nahe zu versuchen die Dimensionen weitgehend zu reduzieren. **Motivation für Paper.** Haben wir ein passendes $r \leq m$ zum Reduzieren gefunden, erhalten wir

$$X \approx U_r \Sigma_r V_r^\top$$

und

$$X^\dagger \approx V_r \Sigma_r^{-1} U_r^\top.$$

Dabei sind $U_r \in \mathbb{R}^{n \times r}$, $\Sigma_r \in \mathbb{R}^{r \times r}$ und $V_r \in \mathbb{R}^{m \times r}$.
 A würde man also mit

$$A \approx X'X^\dagger \approx X'V_r\Sigma_r^{-1}U_r^\top \quad (2.2)$$

näher approximieren können. Da wir aber nicht an ganz A interessiert sind, sondern nur die ersten r Eigenwerte, Projizieren wir A auf **die POD modes von U** .

- DMD mode ist eigenvektor von A
-

3. Marčenko-Pastur-Verteilung

Dieses Kapitel basiert auf dem Buch „Spectral analysis of large dimensional random matrices“ von Zhidong Bai und Jack W. Silverstein [1].

Das Ziel dieses Kapitels ist es herauszufinden, woher die Marčenko-Pastur-Verteilung kommt und was sie aussagt.

3.1. Marčenko-Pastur Momente

Die Dichtefunktion der Marčenko-Pastur-Verteilung $F_y(x)$ ist durch

$$p_y(x) = \begin{cases} \frac{1}{2\pi xy\sigma^2} \sqrt{(b-x)(x-a)}, & \text{wenn } a \leq x \leq b \\ 0, & \text{sonst} \end{cases} \quad (3.1)$$

gegeben. Dabei sind $a = \sigma^2 (1 - \sqrt{y})^2$ und $b = \sigma^2 (1 + \sqrt{y})^2$ jeweils mit $y = \frac{n}{m}$ die Träger der Dichtefunktion. Wenn $\sigma^2 = 1$ ist, dann sprechen wir von der standard M-P-Verteilung. Die k-ten Momente der M-P-Verteilung sind durch

$$\beta_k = \beta_k(y, \sigma^2) := \int_a^b x^k p_y(x) dx \quad (3.2)$$

definiert. Wir können die Momente der M-P-Verteilung durch ihren Standardfall beschreiben.

Lemma 3.1. Für alle $k \geq 1$ gilt

$$\beta_k(y, \sigma^2) = \sigma^{2k} \beta_k(y, 1) .$$

Beweis. Nach Definition 3.2 haben wir

$$\begin{aligned}\beta_k(y, \sigma^2) &= \int_a^b x^k p_y(x) \, dx \\ &= \int_{\sigma^2(1-\sqrt{y})^2}^{\sigma^2(1+\sqrt{y})^2} x^k \frac{1}{2\pi x y \sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - x)(x - \sigma^2(1-\sqrt{y})^2)} \, dx.\end{aligned}$$

Substituieren wir mit $x = u\sigma^2$ erhalten wir

$$\begin{aligned}\beta_k(y, \sigma^2) &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} (u\sigma^2)^k \frac{1}{2\pi u y \sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - u\sigma^2)(u\sigma^2 - \sigma^2(1-\sqrt{y})^2)} \, du \\ &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \sigma^{2k} \frac{1}{2\pi u y \sigma^2} \sqrt{\sigma^4((1+\sqrt{y})^2 - u)(u - (1-\sqrt{y})^2)} \, du \\ &= \sigma^{2k} \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \frac{1}{2\pi u y} \sqrt{((1+\sqrt{y})^2 - u)(u - (1-\sqrt{y})^2)} \, du \\ &= \sigma^{2k} \beta_k(y, 1).\end{aligned}$$

□

Damit können wir dann zeigen, dass die Marčenko-Pastur-Verteilung eindeutig durch die Momente β_x bestimmt werden und wie die Momente explizit bestimmt aussehen.

Lemma 3.2 (Carlman). [2, S. 509] Sei $\{\beta_k(F)\}_{k \in \mathbb{N}_0}$ eine Folge von Momenten der Verteilungsfunktion F . Ist die *Carlman Bedingung*

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} = \infty$$

erfüllt, dann wird die F durch $\{\beta_k\}_{k \in \mathbb{N}_0}$ eindeutig bestimmt.

Die Eindeutigkeit lässt sich dann mit Lemma 3.2 zeigen. Wir sehen einmal nach Defini-

tion 3.2, dass wir β_{2k} durch

$$\begin{aligned}
\beta_{2k} &= \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-x)(x-a)} dx \\
&\leq \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-a)(b-a)} dx \\
&= \frac{1}{2\pi y} \int_a^b x^{2k-1} (b-a) dx \\
&= \frac{1}{4k\pi y} (b^{2k} - a^{2k}) (b-a) \\
&= \frac{1}{k\pi\sqrt{y}} (b^{2k} - a^{2k}) \\
&\leq \frac{1}{k\pi\sqrt{y}} b^{2k} \\
&\leq b^{2k} = (1 + \sqrt{y})^{4k}
\end{aligned}$$

abschätzen können. Mit der Abschätzung 3.3 und Lemma 3.2 haben wir durch

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} \leq \sum_{k=1}^{\infty} (1 + \sqrt{y})^2 = \infty$$

die Carleman Bedingung erfüllt, womit wir die Eindeutigkeit erhalten.

Lemma 3.3. Die explizite Darstellung der Momente ist

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r. \quad (3.3)$$

Beweis. Wir haben nach Definition 3.2

$$\beta_k = \frac{1}{2\pi y} \int_a^b x^{k-1} \sqrt{(b-x)(x-a)} dx.$$

Substituieren wir mit $x = 1 + y + z$ und setzen a und b ein, erhalten wir

$$\begin{aligned}
\beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1 + y + z)^{k-1} \sqrt{\left((1 + \sqrt{y})^2 - 1 - y - z\right) \left(1 + y + z - (1 - \sqrt{y})^2\right)} dz \\
&= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1 + y + z)^{k-1} \sqrt{4y - z^2} dz.
\end{aligned}$$

Durch Einsetzen des Binomischen Lehrsatzes lässt sich das Integral zu

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} \sum_{l=0}^{k-1} \binom{k-1}{l} (1+y)^{k-1-l} z^l \sqrt{4y-z^2} dz \\ &= \frac{1}{2\pi y} \sum_{l=0}^{k-1} \binom{k-1}{l} (1+y)^{k-1-l} \int_{-2\sqrt{y}}^{2\sqrt{y}} z^l \sqrt{4y-z^2} dz\end{aligned}$$

umformen. Um das Integral weiter zu vereinfachen, substituieren wir mit $z = 2\sqrt{y}u$ und erhalten

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{l=0}^{k-1} \binom{k-1}{l} (1+y)^{k-1-l} \int_{-1}^1 (2\sqrt{y}u)^l \sqrt{4y-4yu^2} du \\ &= \frac{1}{2\pi y} \sum_{l=0}^{k-1} \binom{k-1}{l} (1+y)^{k-1-l} (2\sqrt{y})^l 4y \int_{-1}^1 u^l \sqrt{1-u^2} du.\end{aligned}$$

Hier ist unser Integrand ungerade, sofern l ungerade ist. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen ist das Integral für alle ungeraden l gleich 0. Dadurch ist jeder zweite Summand 0. Wir können also jeden zweiten Summanden überspringen. Dafür lassen wir die Summe bis zur Hälfte von $k-1$ laufen und summieren über $2l$ statt l . Für den Fall, dass $k-1$ ungerade ist, runden wir ab, weil es dann nur $\frac{k-2}{2}$ Summanden gibt die ungleich 0 sind. Wir haben also

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2l} (1+y)^{k-1-2l} (2\sqrt{y})^{2l} 4y \int_{-1}^1 u^{2l} \sqrt{1-u^2} dz \\ &= \frac{1}{2\pi y} \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2l} (1+y)^{k-1-2l} (4y)^{l+1} \int_{-1}^1 u^{2l} \sqrt{1-u^2} dz.\end{aligned}$$

Hier ist der Integrand eine gerade Funktion für alle $0 \leq l$. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen können wir auch zwei mal über das halbe Intervall integrieren. Folglich gilt

$$\beta_k = \frac{1}{2\pi y} \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2l} (1+y)^{k-1-2l} (4y)^{l+1} 2 \int_0^1 u^{2l} \sqrt{1-u^2} dz.$$

Wenn wir jetzt mit $u = \sqrt{w}$ substituieren,

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2l} (1+y)^{k-1-2l} (4y)^{l+1} \int_0^1 w^l \sqrt{1-w} \frac{1}{\sqrt{w}} dw \\ &= \frac{1}{2\pi y} \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2l} (1+y)^{k-1-2l} (4y)^{l+1} \int_0^1 w^{l-\frac{1}{2}} \sqrt{1-w} dw\end{aligned}$$

erhalten wir ein Integral, dass wir mittels Eulerschen Betafunktion [Quelle!](#) lösen können.

Die Eulersche Betafunktion ist durch

$$\int_0^1 t^{p-1} (1-t)^{q-1} dt := \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

definiert. Wir können also mit $p = l + \frac{1}{2}$ und $q = 1 + \frac{1}{2}$ das Integral durch die Gammafunktionen

$$\begin{aligned}\int_0^1 w^{l-\frac{1}{2}} \sqrt{1-w} dw &= \frac{\Gamma(l + \frac{1}{2})\Gamma(1 + \frac{1}{2})}{\Gamma(l + 2)} \\ &= \frac{\frac{(2l)!}{l!4^l} \sqrt{\pi} \frac{2!}{4^1} \sqrt{\pi}}{(l+1)!} \\ &= \frac{\frac{(2l)!}{l!4^l} \frac{1}{2} \pi}{(l+1)!}\end{aligned}\tag{3.4}$$

beschreiben. Nach Einsetzen von 3.4 erhalten wir

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2l} (1+y)^{k-1-2l} (4y)^{l+1} \frac{\frac{(2l)!}{l!4^l} \frac{1}{2} \pi}{(l+1)!} \\ &= \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{1}{2\pi y} \frac{(k-1)!}{(2l)!(k-1-2l)!} (1+y)^{k-1-2l} (4y)^{l+1} \frac{\frac{(2l)!}{l!4^l} \frac{1}{2} \pi}{(l+1)!}.\end{aligned}$$

Hier lassen sich diverse Variablen so kürzen, dass wir

$$\beta_k = \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{(k-1)!}{l!(l+1)!(k-1-2l)!} y^l (1+y)^{k-1-2l}$$

erhalten. Wenn wir den Binomischen Lehrsatz mit

$$\begin{aligned}(1+y)^{k-1-2l} &= \sum_{s=0}^{k-1-2l} \binom{k-1-2l}{s} y^s \\ &= \sum_{s=0}^{k-1-2l} \frac{(k-1-2l)!}{s!(k-1-2l-s)!} y^s\end{aligned}$$

einsetzen, haben wir

$$\begin{aligned}\beta_k &= \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2l} \frac{(k-1)!}{l!(l+1)!(k-1-2l)!} y^l \frac{(k-1-2l)!}{s!(k-1-2l-s)!} y^s \\ &= \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2l} \frac{(k-1)!}{l!(l+1)!s!(k-1-2l-s)!} y^{l+s}.\end{aligned}$$

Jetzt wollen wir den Term wieder vereinfachen. Dafür setzen wir $r = s + l$

$$\beta_k = \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=l}^{k-1-l} \frac{(k-1)!}{l!(l+1)!(r-l)!(k-1-2l-s)!} y^r$$

und erweitern mit zwei Einsen

$$\begin{aligned}\beta_k &= \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=l}^{k-1-l} \frac{(k-1)!}{l!(l+1)!(r-l)!(k-1-2l-s)!} \frac{r!}{r!} \frac{(k-r)!}{(k-r)!} y^r \\ &= \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=l}^{k-1-l} \frac{(k-1)!}{r!(k-r)!} \frac{r!}{l!(l-r)!} \frac{(k-r)!}{(k-r-l-1)!(l+1)!} y^r \\ &= \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=l}^{k-1-l} \frac{1}{k} \frac{k!}{r!(k-r)!} \frac{r!}{l!(l-r)!} \frac{(k-r)!}{(l+1)!(k-r-(l+1))!} y^r \\ &= \sum_{l=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=l}^{k-1-l} \frac{1}{k} \binom{k}{r} \binom{r}{l} \binom{k-r}{l+1} y^r.\end{aligned}$$

Für den nächsten Schritt müssen wir die Laufvariablen voneinander unabhängig machen. Momentan haben wir erst das l und ermitteln damit, inwieweit das r eingeschränkt ist.

Für ein festes aber beliebiges k liegen unsere Laufvariablen in

$$A = \left\{ (l, r) \in \mathbb{N}^2 \mid 0 \leq l \leq \left\lfloor \frac{k-1}{2} \right\rfloor, l \leq r \leq k-1-l \right\}.$$

Daraus wissen wir, dass

$$0 \leq l, r \leq k-1-l$$

gilt, woraus wir

$$l \leq k-1-r$$

folgern können. Damit erhalten wir

$$\begin{aligned} 0 \leq l \leq r \leq k-1-l \leq k-1 \\ \implies 0 \leq r \leq k-1, 0 \leq l \leq \min(r, k-1-r) \end{aligned}$$

damit können wir also die Summen äquivalent über

$$A = \{(l, r) \in \mathbb{N}^2 \mid 0 \leq r \leq k-1, 0 \leq l \leq \min(r, k-1-r)\} \quad (3.5)$$

laufen lassen.

Wir haben also mit 3.5

$$\begin{aligned} \beta_k &= \sum_{r=0}^{k-1} \sum_{l=0}^{\min(r, k-1-r)} \frac{1}{k} \binom{k}{r} \binom{r}{l} \binom{k-r}{l+1} y^r \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{l=0}^{\min(r, k-1-r)} \binom{r}{l} \binom{k-r}{l+1}. \end{aligned}$$

Das Minimum können wir noch weiter vereinfachen, da die Summanden gleich 0 sind, sobald $l > r$ oder $l > k-1-r$ ist. Wenn wir die Summe also bis r laufen lassen, ändern wir nichts am Ergebnis.

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{l=0}^r \binom{r}{l} \binom{k-r}{l+1}.$$

An diesem Punkt müssen wir nur noch die innere Summe vereinfachen. Dafür machen

wir einen Indexshift und formen die Binomialkoeffizienten etwas um. Wir haben also

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{l=1}^{r+1} \binom{r}{l-1} \binom{k-r}{l} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{l=1}^{r+1} \binom{r}{r-(l-1)} \binom{k-r}{l} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{l=1}^{r+1} \binom{r}{(r+1)-l} \binom{k-r}{l}.
\end{aligned}$$

Wir wollen hier die Vandermonde Identität [Quelle!](#)

$$\sum_{\ddot{o}=0}^{\ddot{u}} \binom{n}{\ddot{o}} \binom{m}{\ddot{u}-\ddot{o}} = \binom{n+m}{\ddot{u}} \quad (3.6)$$

nutzen. Dafür lassen wir die Summe von $l = 0$ beginnen, da der Summand das Ergebnis nicht ändert. Mit der Identität 3.6 erhalten wir

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{l=0}^{r+1} \binom{r}{(r+1)-l} \binom{k-r}{l} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \frac{r+1}{r+1} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r.
\end{aligned}$$

□

3.2. Vorbereitung (Text ist mir noch zu holprig)

Sei X eine $p \times n$ große Matrix, dessen Elemente unabhängig und identisch verteilte Zufallsvariablen sind. Dabei sind ihre Erwartungswerte 0 und ihre Varianz beträgt σ^2 . Weiter sind $x_k = (x_{1k}, \dots, x_{pk})$, $\mathbf{X} = (x_1, \dots, x_n)$ und $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$. Dann ist die

Stichproben-Kovarianzmatrix

$$\mathbf{S} = \frac{1}{m} \sum_{k=1}^m (x_k - \bar{x})(x_k - \bar{x})^H. \quad (3.7)$$

Da wir uns im Bereich der großen Zufallsmatrizen befinden, verwenden wir für die Spektralanalyse die empirische Spektralverteilung.

Definition 3.4. Sei $\mathbf{S}$ eine $p \times p$ große hermitesche Matrix mit Eigenwerten λ_i mit $i = 1, \dots, p$ dann ist die *empirische Spektralverteilung* durch

$$F^S(x) = \frac{1}{p} |A| \quad \text{mit } A := \{i \leq p : \lambda_i \leq x\}$$

definiert.

Diese Verteilung sagt aus, wie die Singulärwerte einer Zufallsmatrix verteilt sind. Was uns interessiert, ist was passiert, wenn die Dimensionen gegen unendlich laufen. Dafür verwenden wir die Stichproben-Kovarianzmatrix (3.7) und analysieren ihr Verhalten im unendlich Dimensionalen. Durch folgenden Satz können wir die Stichproben-Kovarianzmatrix noch weiter vereinfachen.

Satz 3.5. Seien $A, B \in \mathbb{C}^{p \times n}$. Dann gilt

$$\left\| F^{AA^H} - F^{BB^H} \right\| \leq \frac{1}{p} \text{rang}(A - B).$$

Damit können wir sehen, dass Rang-1 Matrizen keinen Einfluss auf die Konvergenz der empirische Spektralverteilung haben. Wir können die Stichproben-Kovarianzmatrix

$$\begin{aligned} \mathbf{S} &= \frac{1}{m} \sum_{k=1}^m (x_k - \bar{x})(x_k - \bar{x})^H \\ &= \frac{1}{m} \left(\sum_{k=1}^m x_k x_k^H - \sum_{k=1}^m x_k \bar{x}^H - \sum_{k=1}^m x_k^H \bar{x} + \sum_{k=1}^m \bar{x} \bar{x}^H \right) \\ &= \frac{1}{m} \left(\sum_{k=1}^m x_k x_k^H - m \bar{x} \bar{x}^H \right) \end{aligned}$$

zu

$$\mathbf{S} = \frac{1}{m} \sum_{k=1}^m x_k x_k^H \quad (3.8)$$

vereinfachen, da $\bar{x} \bar{x}^H$ eine Rang-1 Matrix ist, welche wir nach Satz 3.5 vernachlässigen können.

Das Ziel dieses Kapitels, ist es zu zeigen, dass die empirische Spektralverteilung gegen die Marčenko-Pastur-Verteilung konvergiert. Im Beweis über die Konvergenz benutzen wir Elemente aus der Graphentheorie, die wir vorher noch einführen wollen.


Für den Beweis definieren wir uns eine Klasse von gerichteten bipatiten Graphen mit folgenden Eigenschaften.

Seien $\mathbf{i} = (i_1, \dots, i_k)$ k I-Knoten welche Werte zwischen 0 und p annehmen können und $\mathbf{j} = (j_1, \dots, j_k)$ k J-Knoten dessen Werte zwischen 0 und n liegen. Unterschiedliche I/J-Knoten können den gleichen Wert annehmen, also sind sie koinzident. Die Kanten laufen von Knoten i_m zu j_m und von j_m zu i_{m+1} mit $m = 1, \dots, k$ und der Konvention, dass $i_1 = i_{k+1}$ gilt. Wir bezeichnen r als Anzahl nicht koinzidenter $\mathbf{i}$ Knoten -1 , s als Anzahl nicht koinzidenter $\mathbf{j}$ Knoten und k als die Anzahl der Kanten die auf $\mathbf{i}$ Knoten zeigen. Diese Graphen Bezeichnen wir dann als $\Delta(k, r, s)$. Für den Beweis teilen wir die Graphen in drei Kategorien ein.

Die Kategorie $\Delta_1(k, r, s)$ fasst alle Graphen zusammen, die zu jeder Kante von $\mathbf{i}$ nach $\mathbf{j}$ genau eine Kante vom gleichen $\mathbf{j}$ Knoten zum gleichen $\mathbf{i}$ Knoten haben. Hier gilt $r + s = k$.

Die Kategorie $\Delta_2(k, r, s)$ beinhaltet alle Graphen, die mindestens einmal zwischen zwei Knoten genau eine Kante besitzen. Also Graphen die mindestens eine Einzelkante besitzen.

Und die letzte Kategorie $\Delta_3(k, r, s)$ sind alle Graphen die weder in $\Delta_1(k, r)$ noch in $\Delta_2(k, r, s)$ gehören.



Beispiel für Graphen

Für bessere Lesbarkeit schreiben wir nur noch $\Delta_{1,2,3}$. Wir bezeichnen zwei Graphen als isomorph, wenn wir durch eine geeignete Zuweisung von i/j Knoten gibt, mit der die Graphen identisch sind. Für diese Graphen haben wir noch ein paar Lemmata.

Lemma 3.6. [1, S. 43] Die Anzahl der Graphen in jeder Isomorphismenklasse von $\Delta(k, r, s)$ Graphen, mit festen k, r und s ist

$$\alpha = p(p-1) \cdots (p-r)n(n-1) \cdots (n-s+1) = p^{r+1}n^s \left(1 + \mathcal{O}\left(\frac{1}{n}\right)\right).$$

Lemma 3.7. [1, S. 43] Die Anzahl nicht koinzidenter Knoten von $\Delta_3(k, r, s)$ Graphen also $r+s$ ist kleiner gleich k .

Lemma 3.8. [1, S. 43] Die Anzahl nicht-isomorpher $\Delta_1(k, r, s)$ Graphen für festes k und r beträgt

$$\frac{1}{r+1} \binom{k}{r} \binom{k-1}{r}.$$

3.3. Marčenko-Pastur-Verteilung

Satz 3.9. Seien $\{x_{ij}\}$ unabhängig und identisch verteilte Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2 . Sei weiter $\frac{p(n)}{n} \xrightarrow{n \rightarrow \infty} y \in (0, \infty)$. Dann konvergiert F^S fast sicher gegen

$$p_y(x) = \begin{cases} \frac{1}{2\pi xy\sigma^2} \sqrt{(b-x)(x-a)}, & \text{wenn } a \leq x \leq b \\ 0, & \text{sonst.} \end{cases} \quad (3.9)$$

Im folgenden Beweis nehmen wir o.B.d.A an, dass die Varianz $\sigma^2 = 1$ ist, wir also den Standardfall betrachten. Um die Konvergenz der empirischen Spektralverteilung 3.4

gegen die Marčenko-Pastur-Verteilung zu zeigen, müssen wir erstmal sicherstellen, dass die Zufallsvariablen x_{ij} die notwendigen Bedingungen erfüllen damit wir die Moment Methode benutzen können. Dafür müssen wir einmal die Zufallsvariablen gleichmäßig beschränken, damit wir keine unendlich großen Eigenwerte haben und entsprechend die Erwartungswerte wieder zentralisieren also auf 0 setzen und wir Reskalieren um die Varianz zu erhalten.

Beweis. Sei $C \in \mathbb{R}_+$. Weiter seien

$$\begin{aligned}\hat{x}_{ij} &= x_{ij} \mathbf{1}(|x_{ij}| \leq C), \quad \tilde{x}_{ij} = \hat{x}_{ij} - \mathbb{E}(\hat{x}_{11}) \\ \hat{x}_i &= (\hat{x}_{i1}, \dots, \hat{x}_{ip})^\top, \quad \tilde{x}_i = (\tilde{x}_{i1}, \dots, \tilde{x}_{ip})^\top \\ \hat{S}_n &= \frac{1}{n} \sum_{i=1}^n \hat{x}_i \hat{x}_i^H = \frac{1}{n} \hat{X}_n \hat{X}_n^H, \quad \tilde{S}_n = \frac{1}{n} \sum_{i=1}^n \tilde{x}_i \tilde{x}_i^H = \frac{1}{n} \tilde{X}_n \tilde{X}_n^H.\end{aligned}$$

Wir bezeichnen ab hier alle X_n als X . Mit $\hat{S}_n$ und $\tilde{S}_n$ haben wir die beschränkte und zentralisierte Stichproben Kovarianzmatrix. Im Folgenden wollen wir zeigen, dass sich durch Beschränken und Zentralisieren der Grenzwert nicht ändert. Nach Lemma A.10 erhalten wir

$$\begin{aligned}\mathcal{L}^4(F^{S_n}, F^{\hat{S}_n}) &\leq \frac{2}{np} \operatorname{tr}(X X^H + \hat{X} \hat{X}^H) \operatorname{tr}((X - \hat{X})(X - \hat{X})^H) \\ &= \left(\frac{2}{np} \sum_{i,j} x_{ij} x_{ij}^H + \hat{x}_{ij} \hat{x}_{ij}^H \right) \left(\frac{1}{np} \sum_{i,j} (x_{ij} - \hat{x}_{ij})(x_{ij} - \hat{x}_{ij})^H \right) \\ &= \left(\frac{2}{np} \sum_{i,j} |x_{ij}|^2 + |\hat{x}_{ij}|^2 \right) \left(\frac{1}{np} \sum_{i,j} |x_{ij} - \hat{x}_{ij}|^2 \right) \\ &\leq \left(\frac{4}{np} \sum_{i,j} |x_{ij}|^2 \right) \left(\frac{1}{np} \sum_{i,j} |x_{ij}|^2 \mathbf{1}(|x_{ij}| > C) \right) \\ &\xrightarrow{f.s.} 4 \mathbb{E}(|x_{ij}|^2) \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\xrightarrow{f.s.} 4 \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\xrightarrow{C \rightarrow \infty} 0\end{aligned}$$

Der Abstand der empirischen Spektralverteilung und ihrer beschränkten Version ist also

für ein genügend großes C vernachlässigbar klein. Nach Satz 3.5

$$\begin{aligned} \left\| F^{\hat{S}_n} - F^{\tilde{S}_n} \right\| &\leq \frac{1}{p} \text{rang}(\hat{X}_n - \tilde{X}_n) \\ &= \frac{1}{p} \text{rang}(\mathbb{E}(\hat{x}_{11})) \\ &= \frac{1}{p} \end{aligned}$$

können wir sehen, dass das Entfernen des Erwartungswertes auch keinen Einfluss auf die Konvergenz hat.

Wir haben jetzt die Verteilung so modifiziert, dass die Zufallsvariablen nicht mehr unendlich groß werden können und den Erhalt des Erwartungswertes garantiert ohne die Konvergenz zu beeinträchtigen. Um die letzte Bedingung, also den Erhalt der Varianz, zu erfüllen müssen wir zeigen, dass durch Skalierung von $\tilde{S}_n$ mit $\tilde{\sigma}^2 = \mathbb{E}(|\tilde{x}_{ij}|^2) \rightarrow 1$, wenn $C \rightarrow \infty$ gilt, der Abstand zu $\tilde{S}_n$ wieder vernachlässigbar klein wird.

Es gilt wieder mit Lemma A.10

$$\begin{aligned} \mathcal{L}^4(F^{\tilde{S}_n}, F^{\tilde{\sigma}^{-2}\tilde{S}_n}) &\leq \frac{2}{n} \text{tr} \left(\tilde{X} \tilde{X}^H + \frac{1}{\tilde{\sigma}^2} \tilde{X} \tilde{X}^H \right) \text{tr} \left(\left(1 - \frac{1}{\tilde{\sigma}} \right)^2 \tilde{X} \tilde{X}^H \right) \\ &= \left(\frac{2}{np} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H - \frac{2\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}} + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \\ &= \left(\frac{2}{np} \sum_{i,j} |\tilde{x}_{ij}|^2 + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} |\tilde{x}_{ij}|^2 - \frac{2|\tilde{x}_{ij}|^2}{\tilde{\sigma}} + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\ &= \left(\frac{2}{np} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 - \tilde{\sigma} 2|\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\ &= 2 \left(\frac{\tilde{\sigma}^2 + 1}{np\tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \left(\frac{(\tilde{\sigma} - 1)^2}{np\tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \\ &\xrightarrow{f.s.} 2 \frac{\tilde{\sigma}^2 + 1}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \frac{(\tilde{\sigma} - 1)^2}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \\ &\xrightarrow{C \rightarrow \infty} 0. \end{aligned}$$

Damit haben wir alle Bedingungen erfüllt. Für einen besseren Überblick verwenden wir weiterhin die Notation von S_n und X , meinen aber die modifizierten Matrizen. Wir haben also eine gleichmäßig durch C beschränkte Zufallsvariable x_{ij} mit Erwartungswert 0 und

Varianz 1.

Nach der Moment Methode (S.10) erhalten wir

$$\begin{aligned}\beta_k(S_n) &= \int_{-\infty}^{\infty} x^k F^{S_n} dx \\ &= \frac{1}{p} \operatorname{tr} \left(S_n^k \right) \\ &= \frac{1}{pn^k} \operatorname{tr} \left((XX^H)^k \right).\end{aligned}$$

Da die Dimensionen von X gegen unendlich laufen, läuft auch die Anzahl der Summanden der Spur gegen unendlich. Wir können die Spur aber auch als

$$\frac{1}{pn^k} \operatorname{tr} \left((XX^H)^k \right) = \frac{1}{pn^k} \sum_i \sum_j x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k}$$

darstellen. Hier sind $\bar{x}_{ij}$ die Einträge aus X^H und damit komplex konjugiert. Dabei sind $x_{i_1 j_1} \bar{x}_{i_2 j_1} \cdots$ die Faktoren der einzelnen Summanden der Spur und wir summieren über alle Permutationen von i und j . Wenn wir über alle Permutationen summieren, können wir diese als oben definierte Graphen darstellen. Hier stellen x_{ij} die Kanten von i -Knoten zu j -Knoten dar und $\bar{x}_{ij}$ Kanten von j - zu i -Knoten. Wir definieren dann

$$\frac{1}{pn^k} \sum_i \sum_j x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k} := \frac{1}{pn^k} \sum_{i,j} X_{\Delta(k,r,s)}.$$

Die Konvergenz lässt sich jetzt zeigen, indem wir zeigen, dass der Erwartungswert $\mathbb{E}(\beta_k(S_n))$ gleich der Momente der Marčenko-Pastur-Verteilung ist und die Varianz gegen null geht. Damit hätten wir eine fast sichere Konvergenz der empirischen Spektralverteilung gegen die Marčenko-Pastur-Verteilung.

Fangen wir an mit dem Erwartungswert. Nach Definition gilt

$$\mathbb{E}(\beta_k(S_n)) = \frac{1}{pn^k} \sum_{i,j} \mathbb{E}(X_{\Delta(k,r,s)}).$$

Teilen wir die Graphen in ihre Kategorien ein, erhalten wir mit Lemma 3.6

$$\mathbb{E}(\beta_k(S_n)) = \frac{1}{pn^k} \left(\overbrace{\sum_{\Delta_1} \alpha \mathbb{E}(X_{\Delta_1})}^{W_1:=} + \overbrace{\sum_{\Delta_2} \alpha \mathbb{E}(X_{\Delta_2})}^{W_2:=} + \overbrace{\sum_{\Delta_3} \alpha \mathbb{E}(X_{\Delta_3})}^{W_3:=} \right).$$

Für W_1 erhalten wir nach Lemma 3.6 und Lemma 3.7

$$W_1 = \frac{1}{n^k p} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p^{r+1} n^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \mathbb{E}(X_{\Delta_1})$$

Da es zu jeder Kante genau eine Kante in die entgegengesetzte Richtung gibt, gilt $\mathbb{E}(|x_{ij}|^2) = 1$. Wir können also schreiben

$$\begin{aligned} W_1 &= \frac{1}{n^k p} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p^{r+1} n^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\ &= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} \frac{p^{r+1} n^{k-r}}{n^k p} \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\ &= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\ &= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p}\right). \end{aligned} \tag{3.10}$$

Für W_2 können wir sehen, dass

$$W_2 = \frac{1}{n^k p} \sum_{\Delta_2} \alpha \mathbb{E}(X_{\Delta_2}) = 0 \tag{3.11}$$

gilt, da wir den Erwartungswert auf Kanten aufteilen können, und es in Kategorie Δ_2 mindestens eine Einzelkante gibt. Es gibt demnach mindestens ein ω_i in

$$\mathbb{E}(X_{\Delta_2}) = \mathbb{E}(x_{i_1 j_1}^{\omega_1}) \mathbb{E}(x_{i_2 j_1}^{\omega_2}) \cdots$$

welches gleich 1 ist, woraus folgt, dass $\mathbb{E}(x_{i_k j_k}^1) = 0 = \mathbb{E}(X_{\Delta_2})$ ist.

Für W_3 erhalten wir wieder mit Lemma 3.6, dass

$$W_3 = \frac{1}{n^k p} \sum_{\Delta_3} \alpha \mathbb{E}(X_{\Delta_3})$$

gilt. Weiter oben haben wir gezeigt, dass x_{ij} gleichmäßig durch ein $C > 0$ beschränkt ist. Daraus erhalten wir, dass $|X_{\Delta(k,r,s)}| \leq C^{2k}$ gilt. Mit Lemma ?? wissen wir, dass die Anzahl nicht koinzidenter Knoten maximal k betragen kann. Dadurch ist die Anzahl

unterschiedlicher Δ_3 Graphen in $\mathcal{O}(n^k)$. Wir haben also

$$\begin{aligned} \frac{1}{n^k p} \sum_{\Delta_3} \alpha(X_{\Delta_3}) &= \frac{C^{2k}}{n^k p} \mathcal{O}(n^k) \\ &= \mathcal{O}\left(\frac{1}{p}\right). \end{aligned} \quad (3.12)$$

Mit (3.10), (3.11) und (3.12) erhalten wir dann

$$\begin{aligned} \mathbb{E}(\beta_k(S_n)) &= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p}\right) \\ &= \beta_k(y, \sigma^2) + o(1) \end{aligned} \quad (3.13)$$

Jetzt fehlt noch die Varianz. Diese ist nach Definition

$$\text{Var}(\beta_k(S_n)) := \frac{1}{pn^k} \sum_{i,j} (\mathbb{E}(X_{\Delta_a(k,r,s)} X_{\Delta_b(k,r,s)}) - \mathbb{E}(X_{\Delta_a(k,r,s)}) \mathbb{E}(X_{\Delta_b(k,r,s)})) .$$

Dabei sind Δ_a und Δ_b verschiedene Permutationen $\mathbf{i}$ und $\mathbf{j}$. Wie für den Erwartungswert suchen wir uns Kategorien, um die Varianz stückweise zu beschreiben.

Als Erstes betrachten wir alle Graphen Δ_a und Δ_b so, dass Δ_a und Δ_b unabhängig sind, sich also keine Kanten teilen. Daraus folgt direkt durch Rechenregeln von Erwartungswerten, dass

$$\mathbb{E}(X_{\Delta_a(k,r,s)} X_{\Delta_b(k,r,s)}) = \mathbb{E}(X_{\Delta_a(k,r,s)}) \mathbb{E}(X_{\Delta_b(k,r,s)})$$

gilt. Das heißt, für unabhängige Graphen ist die Varianz gleich 0.

Als Nächstes betrachten wir alle Graphen $\Delta_a \cup \Delta_b$, die mindestens eine Einzelkante besitzen. Damit erhalten wir durch Δ_2 Eigenschaften wieder

$$\mathbb{E}(X_{\Delta_a(k,r,s)} X_{\Delta_b(k,r,s)}) = 0 = \mathbb{E}(X_{\Delta_a(k,r,s)}) \mathbb{E}(X_{\Delta_b(k,r,s)}) .$$

In allen anderen Möglichkeiten haben die Graphen keine Einzelkante und Δ_a und Δ_b teilen sich Kanten. Analog zu W_3 können wir sagen, dass die Anzahl möglicher Graphen in $\mathcal{O}(n^k)$ liegt. Da wir zwei Graphen haben ist die Anzahl also in $\mathcal{O}(n^{2k})$. Durch die

gleichmäßige Beschränkung von x_{ij} durch C können wir die Varianz durch

$$\begin{aligned}\mathrm{Var}(\beta_k(S_n)) &\leq \frac{1}{p^2 n^{2k}} C \mathcal{O}(n^{2k}) \\ &= \mathcal{O}\left(\frac{1}{p^2}\right)\end{aligned}\tag{3.14}$$

abschätzen.

Mit dem Erwartungswert (3.13) und der Varianz (3.14) können wir darauf schließen, dass die empirische Spektralverteilung fast sicher gegen die Marčenko-Pastur-Verteilung konvergiert.

□

4. Marchenko-Pastur-Verteilung-old

Lemma 4.1. Sei $\beta \in (0, 1]$ und $\beta_{\pm} = (1 \pm \sqrt{\beta})^2$. Dann gilt

$$\beta_+ - \beta_- = 4\sqrt{\beta} \quad (4.1)$$

$$\beta_+ + \beta_- = 2\beta + 2 \quad (4.2)$$

$$\beta_+\beta_- = (\beta - 1)^2 \quad (4.3)$$

$$m = \beta + 1 \quad (4.4)$$

$$r = 4\sqrt{\beta} \quad (4.5)$$

Beweis, dass die Lösung der Marchenko Pastur Verteilung mit $\beta_- \leq \mu_{\beta} \leq \beta_+$ und $\beta_{\pm} = (1 \pm \sqrt{\beta})^2$ also

$$\int_{\beta_-}^{\mu_{\beta}} \frac{\sqrt{(\beta_+ - t)(t - \beta_-)}}{2\pi\beta t} dt = \frac{1}{2} \quad (4.6)$$

ergeben kann.

Umgangssprache ist überall :(. Definitionen und Sätze aufschreiben. Und aus den align Umgebungen vielleicht noch die Label auf ein angenehmes Minimum reduzieren.

Beweis. Da das Integral mit $\mu_{\beta} = \beta_-$ gleich 0 ist und das Integral stetig innerhalb des Intervalls $[\beta_-, \beta_+]$ ist, müssen wir nur noch zeigen, dass das Integral bei $\mu_{\beta} = \beta_+$ gleich 1 ist, damit wir den Zwischenwertsatz nutzen können. Dafür bietet sich an, das Integral

$$\frac{1}{2\pi\beta} \int_{\beta_-}^{\beta_+} \frac{\sqrt{(\beta_+ - t)(t - \beta_-)}}{t} dt \quad (4.7)$$

mit $\mu_{\beta} = \beta_+$ auszurechnen. Wir beginnen damit eine Substitution zu finden. Dafür bauen wir uns also einen Weg δ , der von β_- zu β_+ läuft. Sei $m = \frac{\beta_+ + \beta_-}{2}$ der Mittelpunkt zwischen β_- und β_+ und $r = \frac{\beta_+ - \beta_-}{2}$ der Abstand von Mittelpunkt zu den Grenzen, dann brauchen wir nur noch eine Funktion, die von -1 bis 1 läuft, damit wir den Weg von einer Grenze zur anderen ablaufen. Dafür eignet sich der Cosinus von $-\pi$ bis 0 . Da dieser aber eine gerade Funktion ist, können wir auch von 0 bis π gehen.

Damit erhalten wir

$$\delta: [0, \pi] \rightarrow \mathbb{R} \quad (4.8)$$

$$\varphi \mapsto m + r \cos(\varphi). \quad (4.9)$$

Da δ injektiv und stetig differenzierbar ist, substituieren wir t mit δ und erhalten

$$- \frac{1}{2\pi\beta} \int_{\pi}^0 \frac{\sqrt{(\beta_+ - (m + r \cos(\varphi))) ((m + r \cos(\varphi)) - \beta_-)}}{m + r \cos(\varphi)} r \sin(\varphi) d\varphi$$

setzen wir $\beta_+ = m + r$ und $\beta_- = m - r$

$$\begin{aligned} &= - \frac{1}{2\pi\beta} \int_{\pi}^0 \frac{\sqrt{((m + r) - (m + r \cos(\varphi))) ((m + r \cos(\varphi)) - (m - r))}}{m + r \cos(\varphi)} r \sin(\varphi) d\varphi \\ &= - \frac{1}{2\pi\beta} \int_{\pi}^0 \frac{\sqrt{(r - r \cos(\varphi)) (r + r \cos(\varphi))}}{m + r \cos(\varphi)} r \sin(\varphi) d\varphi \\ &= - \frac{1}{2\pi\beta} \int_{\pi}^0 \frac{\sqrt{(r^2 - r^2 \cos^2(\varphi))}}{m + r \cos(\varphi)} r \sin(\varphi) d\varphi \\ &= - \frac{1}{2\pi\beta} \int_{\pi}^0 \frac{(r - r \cos(\varphi))}{m + r \cos(\varphi)} r \sin(\varphi) d\varphi \\ &= - \frac{1}{2\pi\beta} \int_{\pi}^0 \frac{r^2 \sin^2(\varphi)}{m + r \cos(\varphi)} d\varphi \end{aligned}$$

Nutzen wir hier Lemma 4.1, erhalten wir

$$\begin{aligned} &= - \frac{1}{2\pi\beta} \int_{\pi}^0 \frac{4\beta \sin^2(\varphi)}{\beta + 1 + 2\sqrt{\beta} \cos(\varphi)} d\varphi \\ &= \frac{1}{2\pi\beta} \int_0^{\pi} \frac{4\beta \sin^2(\varphi)}{\beta + 1 + 2\sqrt{\beta} \cos(\varphi)} d\varphi. \end{aligned}$$

Ab hier müssen wir eine Fallunterscheidung vornehmen.

Fall 1: $\beta = 1$.

$$\frac{1}{2\pi} \int_0^\pi \frac{4 \sin^2(\varphi)}{2 + 2 \cos(\varphi)} d\varphi \quad (4.10)$$

$$= \frac{1}{2\pi} \int_0^\pi \frac{2^2 - 2^2 \cos^2(\varphi)}{2 + 2 \cos(\varphi)} d\varphi \quad (4.11)$$

$$= \frac{1}{2\pi} \int_0^\pi \frac{(2 - 2 \cos(\varphi)) (2 + 2 \cos(\varphi))}{2 + 2 \cos(\varphi)} d\varphi \quad (4.12)$$

$$= \frac{1}{\pi} \int_0^\pi 1 - \cos(\varphi) d\varphi \quad (4.13)$$

$$= 1. \quad (4.14)$$

Fall 2: $\beta \in (0, 1)$. **hier noch eine Motivation finden den Residuensatz nutzen zu wollen**
 Bei genauerer Betrachtung des Integranten, nennen wir ihn f , kann man erkennen, dass man ihn in zwei Teile separieren kann, genau

$$f(\varphi) = a \cdot \sin^2(\varphi) \quad \text{mit} \quad a = \frac{1}{m + r \cos(\varphi)}. \quad (4.15)$$

Da der Cosinus 2π -periodisch ist und m und r konstant sind, ist auch a 2π -periodisch und spiegelt sich an $\varphi = \pi$. $\sin^2(\varphi)$ hingegen ist π -periodisch. Daraus erkennen wir in f eine 2π -Periodizität mit einer Symmetrie um π . Wir können das integral also von 0 bis 2π laufen lassen und dann halbieren. Wir haben also jetzt

$$\frac{1}{\pi} \int_0^{2\pi} \frac{\sin^2(\varphi)}{\beta + 1 + 2\sqrt{\beta} \cos(\varphi)} d\varphi \quad (4.16)$$

Sei nun $z = Re^{i\varphi}$, $\cos(\varphi) = \frac{e^{i\varphi} + e^{-i\varphi}}{2}$ und $\sin(\varphi) = \frac{e^{i\varphi} - e^{-i\varphi}}{2i}$ und setzen ein

$$- \frac{1}{4\pi} \int_0^{2\pi} \frac{(e^{i\varphi} - e^{-i\varphi})^2}{(e^{i\varphi} + \sqrt{\beta})(e^{-i\varphi} + \sqrt{\beta})} d\varphi. \quad (4.17)$$

Um den Residuensatz anwenden zu wollen brauchen wir ein Wegintegral, das wir uns bauen können, indem wir eine Definition für komplexe Wegintegrale nutzen (Definition

3.7 Funktheo Skript). Durch Multiplizieren mit einer passenden 1 können wir also aus

$$-\frac{1}{4\pi} \int_0^{2\pi} \frac{(e^{i\varphi} - e^{-i\varphi})^2}{(e^{i\varphi} + \sqrt{\beta})(e^{-i\varphi} + \sqrt{\beta})} \cdot \frac{ie^{i\varphi}}{ie^{i\varphi}} d\varphi \quad (4.18)$$

$$= -\frac{1}{4\pi i} \int_{|z|=1} \frac{(z - z^{-1})^2}{z(z + \sqrt{\beta})(z^{-1} + \sqrt{\beta})} dz \quad (4.19)$$

$$= -\frac{1}{4\pi i} \int_{|z|=1} \frac{z^2 - 2 + z^{-2}}{(z + \sqrt{\beta})(z\sqrt{\beta} + 1)} dz \quad (4.20)$$

machen. Um die z^{-2} in Zähler zu eliminieren multiplizieren wir erneut mit einer passenden 1

$$= -\frac{1}{4\pi i} \int_{|z|=1} \frac{z^4 - 2z^2 + 1}{z^2(z + \sqrt{\beta})(z\sqrt{\beta} + 1)} dz. \quad (4.21)$$

Sichtbar werden hier die Singularitäten $z = 0$, welche eine Polstelle 2. Ordnung ist und $z = -\sqrt{\beta}$, welche eine einfache Polstelle ist. Die Singularität $-\sqrt{\beta}^{-1}$ liegt außerhalb des Einheitskreises und damit $\text{ind}(\gamma, -\sqrt{\beta}^{-1}) = 0$. Weiter nennen wir den Weg des Einheitskreises γ . Der Residuensatz gibt uns dann

$$= -\frac{1}{4\pi i} \int_{\gamma} \frac{z^4 - 2z^2 + 1}{z^2(z + \sqrt{\beta})(z\sqrt{\beta} + 1)} dz \quad (4.22)$$

$$= -\frac{1}{4\pi i} 2\pi i \sum_{z \in \mathbb{C}} \text{ind}(\gamma, z) \text{res}(f, z) \quad (4.23)$$

Für unsere beiden Singularitäten bekommen wir also

$$= -\frac{1}{2} \left(\text{res}(f, -\sqrt{\beta}) + \text{res}(f, 0) \right). \quad (4.24)$$

Fangen wir mit $z = -\sqrt{\beta}$ an.

$$\text{res}(f, -\sqrt{\beta}) = \lim_{z \rightarrow -\sqrt{\beta}} \left((z + \sqrt{\beta}) f(z) \right) \quad (4.25)$$

$$= \lim_{z \rightarrow -\sqrt{\beta}} \frac{z^4 - 2z^2 + 1}{z^2(z\sqrt{\beta} + 1)} \quad (4.26)$$

$$= \frac{1 - \beta}{\beta} \quad (4.27)$$

Weiter mit $z = 0$.

$$\operatorname{res}(f, 0) = \lim_{z \rightarrow 0} \frac{d}{dz} (z^2 f(z)) = \lim_{z \rightarrow 0} \frac{d}{dz} \frac{z^4 - 2z^2 + 1}{(z + \sqrt{\beta})(z\sqrt{\beta} + 1)} \quad (4.28)$$

$$= \lim_{z \rightarrow 0} \frac{(4z^3 - 4z)(z + \sqrt{\beta})(z\sqrt{\beta} + 1) - (z^4 - 2z^2 + 1)(2z\sqrt{\beta} + 1 + \beta)}{((z + \sqrt{\beta})(z\sqrt{\beta} + 1))^2} \quad (4.29)$$

$$= -\frac{1 + \beta}{\beta}. \quad (4.30)$$

Zusammengefasst erhalten wir

$$= -\frac{1}{2} \left(\operatorname{res}(f, -\sqrt{\beta}) + \operatorname{res}(f, 0) \right) \quad (4.31)$$

$$= -\frac{1}{2} \left(\frac{1 - \beta}{\beta} - \frac{1 + \beta}{\beta} \right) \quad (4.32)$$

$$= 1. \quad (4.33)$$

Juhu

□

Satz 4.2 (Zwischenwertsatz [3] **weiß noch nicht ob das rein sollte oder nicht weil zu trivial vielleicht**). Sei $f: [a, b] \rightarrow \mathbb{R}$ eine stetige Funktion und $n \in \mathbb{R}$. Weiter sei $f(a) < n$ und $f(b) > n$. Dann gibt es ein $c \in [a, b]$, sodass $f(c) = n$.

A. Stochastische Grundlagen

Definition A.1. [5, S. 10] Sei $\Omega \neq \emptyset$ eine nichtleere Menge (von Ereignissen) und $\mathcal{A} \subset 2^\Omega$ ein Mengensystem aus der Potenzmenge von Ω .

Mit den Eigenschaften

1. $\Omega \in \mathcal{A}$,
2. $E \in \mathcal{A} \implies \Omega \setminus E \in \mathcal{A}$
3. und $E_1, E_2, \dots \in \mathcal{A} \implies \bigcup_{i=1}^{\infty} E_i \in \mathcal{A}$

nennt man $\mathcal{A}$ eine σ -Algebra und das Paar $(\Omega, \mathcal{A})$ einen (Ereignis-)Messraum.

Definition A.2. [5, S. 13] Sei $(\Omega, \mathcal{A})$ ein Messraum. Sei weiter $\mu: \mathcal{A} \rightarrow [0, 1]$ eine Funktion. Mit den Eigenschaften

1. $\mu(\Omega) = 1$
2. und $E_1, E_2, \dots \in \mathcal{A}$, E_i paarweise disjunkte Elemente $\implies \mu\left(\bigcup_{i=1}^{\infty} E_i\right) = \sum_{i=1}^{\infty} \mu(E_i)$

ist μ ein Wahrscheinlichkeitsmaß oder eine Wahrscheinlichkeitsverteilung (Verteilung) auf $\mathcal{A}$. Dann nennt man das Tripel $(\Omega, \mathcal{A}, \mu)$ Wahrscheinlichkeitsraum.

Definition A.3. [5, S. 21] Seien $(\Omega, \mathcal{A})$ und $(\Omega', \mathcal{A}')$ zwei Messräume. Sei weiter $\mathcal{Z}: \Omega \rightarrow \Omega'$ eine Abbildung mit der folgenden Eigenschaft:

$$E' \in \mathcal{A}' \implies \mathcal{Z}^{-1}E' \in \mathcal{A}.$$

Dann heißt $\mathcal{Z}$ Zufallsvariable von $(\Omega, \mathcal{A})$ nach $(\Omega', \mathcal{A}')$.

Man schreibt auch $\mathcal{Z}: (\Omega, \mathcal{A}) \rightarrow (\Omega', \mathcal{A}')$.

Definition A.4. [7, S. 4] **unzufrieden weil nur $\mathbb{R}$.** Sei $\mathcal{Z}: (\Omega, \mathcal{A}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$ eine Zufallsvariable in $(\Omega, \mathcal{A}, \mu)$ mit $\mathcal{B}(\mathbb{R})$ als borelsche σ -Algebra. Sei weiter das Bildmaß

von μ bezüglich $\mathcal{Z}$ gleich

$$B \mapsto \mu_{\mathcal{Z}}(B) := \mu(\mathcal{Z}^{-1}(B)) \quad \text{mit} \quad B \in \mathcal{B}(\mathbb{R}).$$

Dann ist der Erwartungswert einer reellen Zufallsvariable $\mathcal{Z}$ genau

$$\mathbb{E}(\mathcal{Z}) = \int \mathcal{Z} \, d\mu = \int_{\Omega} \mathcal{Z}(\omega) \mu(d\omega) = \int_{\mathbb{R}} z \mu_{\mathcal{Z}}(dz).$$

Definition A.5. Varianz

Definition A.6. Moment

Definition A.7. Kovarianz

Satz A.8 (Starkes gesetz der großen Zahlen). [5, S. 139] Seien $\{\mathcal{Z}_i\}_{i \in \mathbb{N}}$ unabhängige und identisch verteilte Zufallsvariablen und besitzen ein Moment erster Ordnung, dann gilt

$$\frac{1}{n} \sum_{i=1}^n \mathcal{Z}_i \xrightarrow[n \rightarrow \infty]{f.s.} \mathbb{E}(\mathcal{Z}_1).$$

Definition A.9 (Lévy-Metrik). [5, S. 164] Seien F_1 und F_2 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathcal{B})$ mit zugehörigen Verteilungsfunktionen $\mathbf{F}_1$ und $\mathbf{F}_2$. Dann ist die *Lévy-Metrik* definiert durch

$$\mathcal{L}(F_1, F_2) = \inf\{\varepsilon > 0, x \in \mathbb{R}: \mathbf{F}_1(x - \varepsilon) - \varepsilon \leq \mathbf{F}_2(x) \leq \mathbf{F}_1(x + \varepsilon) + \varepsilon\}.$$

Lemma A.10. Seien $A, B \in \mathbb{C}^{p \times n}$ und $S = AA^H$, $\bar{S} = BB^H$. Dann gilt für die Lévy-Metrik aus A.9

$$\mathcal{L}^4(F^S, F^{\bar{S}}) \leq \frac{2}{p^2} \operatorname{tr}(AA^H + BB^H) \operatorname{tr}((A - B)(A - B)^H).$$

Literatur

- [1] Z. Bai und J. W. Silverstein. *Spectral analysis of large dimensional random matrices*. 2nd ed. Springer Ser. Stat. Dordrecht: Springer, 2010. DOI: 10.1007/978-1-4419-0661-8.
- [2] S. L. Brunton und J. N. Kutz. *Data-driven science and engineering. Machine learning, dynamical systems, and control*. 2nd edition. Cambridge: Cambridge University Press, 2022. DOI: 10.1017/9781009089517.
- [3] O. Forster. *Analysis 1. Differential- und Integralrechnung einer Veränderlichen*. 11th revised ed. Grundkurs Math. Heidelberg: Springer Spektrum, 2013. DOI: 10.1007/978-3-658-00317-3.
- [4] M. Gavish und D. L. Donoho. *The optimal hard threshold for singular values is $4/\sqrt{3}$* . IEEE Trans. Inf. Theory 60.8 (2014), S. 5040–5053. DOI: 10.1109/TIT.2014.2323359.
- [5] H.-O. Georgii. *Stochastik. Einführung in die Wahrscheinlichkeitstheorie und Statistik*. 5th, revised and expanded ed. De Gruyter Stud. Berlin: De Gruyter, 2015. DOI: 10.1515/9783110359701.
- [6] A. Meister und T. Sonar. *Numerik. Eine lebendige und gut verständliche Einführung mit vielen Beispielen*. Berlin: Springer Spektrum, 2019. DOI: 10.1007/978-3-662-58358-6.
- [7] R. L. Schilling. *Wahrscheinlichkeit. Stochastik: von Abweichungen bis Zufall*. 2nd edition. De Gruyter Stud. Berlin: De Gruyter, 2025. DOI: 10.1515/9783111342252.

Hinweise zu den offiziellen Erklärungen

1. Die folgende Seite mit den offiziellen Erklärungen

A) Eigenständigkeitserklärung

B) Erklärung zur Veröffentlichung von Bachelor- oder Masterarbeiten

C) Einverständniserklärung über die Bereitstellung und Nutzung der Bachelorarbeit / Masterarbeit in elektronischer Form zur Überprüfung durch eine Plagiatsoftware

ist entweder direkt in jedes Exemplar der Bachelor- oder Masterarbeit fest mit einzubinden oder unverändert im Wortlaut in jedes Exemplar der Bachelor- oder Masterarbeit zu übernehmen.

Bitte achten Sie darauf, jede Erklärung in allen drei Exemplaren der Arbeit zu unterschreiben.

2. In der digitalen Fassung kann auf die Unterschrift verzichtet werden. Die Angaben und Entscheidungen müssen jedoch enthalten sein.

Zu B)

Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die Zukunft, widerrufen werden.

Zu C)

Das Einverständnis der dauerhaften Speicherung des Textes ist freiwillig.

Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die Zukunft, widerrufen werden.

Weitere Informationen zur Überprüfung von schriftlichen Arbeiten durch die Plagiatsoftware sind im Nutzungs- und Datenschutzkonzept enthalten. Diese finden Sie auf der Internetseite der Universität Bremen.

Notes on the official declarations

1. The following pages with the official declarations

A) Declaration of Authorship

B) Declaration on the Publication of Bachelor's or Master's Thesis

C) Declaration of Consent for the Provision and Use of the Bachelor's Thesis / Master's Thesis in Electronic Form for Review by Plagiarism Software

is to be either integrated directly into each copy of the bachelor's or master's thesis or adopted unchanged in the wording of each copy of the bachelor's or master's thesis.

Please be sure to sign each declaration in all three copies of the thesis.

2. The signature can be omitted from the digital version. However, the information and decisions must be included.

Regarding B)

The consent can be revoked at any time with future effect by notifying the University of Bremen.

Regarding C)

Consent for the permanent storage of the text is voluntary. The consent can be revoked at any time with future effect by notifying the University of Bremen.

Further information on the checking of written work using plagiarism software can be found in the data protection and usage concept. This can be found on the University of Bremen website.

**Eigenständigkeits- und Einverständniserklärung zur Überprüfung mit Plagiatsoftware
sowie die Erklärung zur Veröffentlichung bei Bachelor- und Masterarbeiten****Declarations of Authorship and Consent for Checking with Plagiarism Software and the
Declaration of Publication for Bachelor's and Master's Thesis**

Studierenden-Angaben / Student Information:

Matrikelnr./ Student ID

Nachname / Surname

Vorname / First Name

Titel der Arbeit / Title of Thesis

A) Eigenständigkeitserklärung / Declaration of Authorship

Ich versichere, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe. Alle Teile meiner Arbeit, die wortwörtlich oder dem Sinn nach anderen Werken entnommen sind, wurden unter Angabe der Quelle kenntlich gemacht. Gleiches gilt auch für Zeichnungen, Skizzen, bildliche Darstellungen sowie für Quellen aus dem Internet, dazu zählen auch KI-basierte Anwendungen oder Werkzeuge.
Die Arbeit wurde in gleicher oder ähnlicher Form noch nicht als Prüfungsleistung eingereicht.

I hereby affirm that I have written the present work independently and have used no sources or aids other than those indicated. All parts of my work that have been taken from other works, either verbatim or in terms of meaning, have been marked as such, indicating the source. The same applies to drawings, sketches, pictorial representations and sources from the Internet, including AI-based applications or tools. The work has not yet been submitted in the same or a similar form as a final examination paper.

- ☐ Ich habe KI-basierte Anwendungen und/oder Werkzeuge genutzt und diese im Anhang "Nutzung KI basierte Anwendungen" dokumentiert.

I have used AI-based applications and/or tools and documented them in the appendix "Use of AI-based applications".

B) Erklärung zur Veröffentlichung von Bachelor- oder Masterarbeiten

Declaration regarding the publication of bachelor's or master's thesis

Die Abschlussarbeit wird zwei Jahre nach Studienabschluss dem Archiv der Universität Bremen zur dauerhaften Archivierung angeboten. Archiviert werden:

Two years after graduation, the thesis is offered to the archive of the University of Bremen for permanent archiving. The following are archived:

- 1) Masterarbeiten mit lokalem oder regionalem Bezug sowie pro Studienfach und Studienjahr 10 % aller Masterarbeiten
Master's theses with a local or regional focus, as well as per subject and academic year 10% of all Master's thesis
- 2) Bachelorarbeiten des jeweils ersten und letzten Bachelorabschlusses pro Studienfach und Jahr.
Bachelor's thesis for the first and last bachelor's degrees per subject and year.

☐ Ich bin damit einverstanden, dass meine Abschlussarbeit im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I agree that my thesis may be viewed by third parties in the university archive for academic purposes.

☐ Ich bin damit einverstanden, dass meine Abschlussarbeit nach 30 Jahren (gem. §7 Abs. 2 BremArchivG) im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I agree that my thesis may be viewed by third parties for academic purposes in the university archive after 30 years (in accordance with §7 para. 2 BremArchivG).

☐ Ich bin **nicht** damit einverstanden, dass meine Abschlussarbeit im Universitätsarchiv für wissenschaftliche Zwecke von Dritten eingesehen werden darf.
I do not consent to my thesis being made available in the university archive for third parties to view for academic purposes.

C) Einverständniserklärung zur elektronischen Überprüfung der Arbeit auf Plagiate Declaration of consent for electronic checking of the work for plagiarism

Eingereichte Arbeiten können nach § 18 des Allgemeinen Teil der Bachelor- bzw. der Masterprüfungsordnungen der Universität Bremen mit qualifizierter Software auf Plagiatsvorwürfe untersucht werden.

Zum Zweck der Überprüfung auf Plagiate erfolgt das Hochladen auf den Server der von der Universität Bremen aktuell genutzten Plagiatssoftware.

Submitted papers can be checked for plagiarism using qualified software in accordance with § 18 of the General Section of the Bachelor's or Master's Degree Examination Regulations of the University of Bremen. For the purpose of checking for plagiarism, the upload to the server is done using the plagiarism software currently used by the University of Bremen.

- ☐ Ich bin damit einverstanden, dass die von mir vorgelegte und verfasste Arbeit zum oben genannten Zweck dauerhaft auf dem externen Server der aktuell von der Universität Bremen genutzten Plagiatssoftware, in einer institutionseigenen Bibliothek (Zugriff nur durch die Universität Bremen), gespeichert wird.

I agree that the work I have submitted and written will be stored permanently on the external server of the plagiarism software currently used by the University of Bremen, in a library belonging to the institution (accessed only by the University of Bremen), for the above-mentioned purpose.

- ☐ Ich bin **nicht** damit einverstanden, dass die von mir vorgelegte und verfasste Arbeit zum o.g. Zweck dauerhaft auf dem externen Server der aktuell von der Universität Bremen genutzten Plagiatssoftware, in einer institutionseigenen Bibliothek (Zugriff nur durch die Universität Bremen), gespeichert wird.

I do not consent to the work I submitted and wrote being permanently stored on the external server of the plagiarism software currently used by the University of Bremen, in a library belonging to the institution (accessed only by the University of Bremen), for the above-mentioned purpose.

Das Einverständnis der dauerhaften Speicherung des Textes ist freiwillig. Die Einwilligung kann jederzeit durch Erklärung gegenüber der Universität Bremen, mit Wirkung für die Zukunft, widerrufen werden. Weitere Informationen zur Überprüfung von schriftlichen Arbeiten durch die Plagiatsoftware sind im Nutzungs- und Datenschutzkonzept enthalten. Diese finden Sie auf der Internetseite der Universität Bremen.

Consent to the permanent storage of the text is voluntary. Consent can be withdrawn at any time by making a declaration to this effect to the University of Bremen, with effect for the future. Further information on the checking of written work using plagiarism software can be found in the data protection and usage concept. This can be found on the University of Bremen website.

Mit meiner Unterschrift versichere ich, dass ich die obenstehenden Erklärungen gelesen und verstanden habe und bestätige die Richtigkeit der gemachten Angaben.

With my signature, I confirm that I have read and understood the above explanations and confirm the accuracy of the information provided.

Datum / Date

Unterschrift/ Signature