

In Bezug auf die Rangreduzierung sind wir in der Einleitung auf das Paper von Gavish und Donoho eingegangen [4]. Wir erinnern uns an die gegebene Rahmenstruktur. Es galt für $\eta \rightarrow \infty$ und $X_\eta \in \mathbb{K}^{p_\eta \times n_\eta}$, dass das Dimensions-Stichproben-Verhältnis $y = \frac{p_\eta}{n_\eta} \in (0, 1]$ nicht divergiert. In dem Paper wird erwähnt, dass in

$$X_\eta := X_\eta^{\text{echt}} + \gamma X_\eta^{\text{rauschen}}$$

der durch $\frac{\sigma_{\text{med},\eta}}{\sqrt{n_\eta}}$ normierte Median der Singulärwerte von X_η fast sicher gegen den Median der Marčenko–Pastur–Verteilung μ_y konvergiert [4, S. 11]. Daraus ergibt sich dann, dass der Schwellenwert für die Dimensionsreduktion

$$\hat{\tau}_*(y, X) = \lambda_*(y) \frac{\sigma_{\text{med},\eta}}{\sqrt{\mu_y}}$$

fast sicher gegen

$$\lim_{\eta \rightarrow \infty} \lambda_*(y) \frac{\sigma_{\text{med},\eta}}{\sqrt{\mu_y}} \stackrel{\text{f.s.}}{=} \lambda_*(y) = \sqrt{2(y+1) + \frac{8y}{(y+1) + \sqrt{y^2 + 14y + 1}}}$$

konvergiert.

Um die Notation im Folgenden zu vereinfachen, bezeichnen wir die Rauschmatrix X_η^{rauschen} mit $\mathbf{X}_\eta$.

Die Marčenko–Pastur–Verteilung (kurz M-P-Verteilung) beschreibt die asymptotische Verteilung der Eigenwerte von großen Zufallsmatrizen der Form $\frac{1}{n_\eta} \mathbf{X}_\eta \mathbf{X}_\eta^H$. Die genauen Anforderungen an $\mathbf{X}_\eta$ stellen wir im kommenden Unterkapitel 0.1 vor. Eine Wahrscheinlichkeitsverteilung, die angibt, wie die Eigenwerte einer Matrix verteilt sind, ist die empirische Spektralverteilung.

Ziel dieses Kapitels ist es, die schwache Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung zu zeigen. Dieses Kapitel orientiert sich dabei an dem Buch „Spectral Analysis of Large Dimensional Random Matrices“ von Zhidong Bai und Jack W. Silverstein [3].

0.1 Grundlagen

Wir beginnen damit, die empirische Spektralverteilung konkret zu definieren.

Definition 0.1. [3, S. 4, 10] Sei B eine $p \times p$ hermitesche Matrix mit Eigenwerten λ_i und $i = 1, \dots, p$. Dann ist auf dem Ereignisraum $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $\mathcal{B}(\mathbb{R})$ als borelsche σ -Algebra

durch

$$F^B(x) := \frac{1}{p} |A_x| \quad \text{mit } A_x := \{i \in \{1, \dots, p\} : \lambda_i \leq x\}$$

die *empirische Spektralverteilung* $F^B: \mathbb{R} \rightarrow [0, 1]$ definiert. Ihre *k-ten Momente* sind durch

$$\beta_k(B) = \int_{-\infty}^{\infty} x^k \, dF^B(x) = \frac{1}{p} \operatorname{tr}(B^k)$$

gegeben.

Die Konvergenz der empirischen Spektralverteilung betrachten wir in dem Sinne, dass wir analysieren, wie sich die Verteilung verhält, wenn wir eine Folge an Matrizen betrachten, deren Dimensionen p und n gegen unendlich laufen.

Definition 0.2. Sei $\mathbf{X}$ eine $p \times n$ Matrix, deren Elemente unabhängig und identisch verteilte komplexe Zufallsvariablen sind. Dabei sind ihre Erwartungswerte 0 und ihre Varianz bezeichnen wir mit σ^2 . Weiter sind $x_m = (x_{1m}, \dots, x_{pm})^\top$ und $\mathbf{X} = (x_1, \dots, x_n)$.

Für die Folge an Zufallsmatrizen $\{\mathbf{X}_\eta\}$ laufen also p und n so gegen unendlich, dass das Verhältnis

$$\lim_{\eta \rightarrow \infty} \frac{p_\eta}{n_\eta} = y$$

nicht divergiert.

Definition 0.3. Wir bezeichnen mit $\bar{x} = \frac{1}{n} \sum_{m=1}^n x_m$ die durch

$$S = \frac{1}{n} \sum_{m=1}^n (x_m - \bar{x})(x_m - \bar{x})^H \in \mathbb{R}^{p \times p} \quad (0.1)$$

gegebene Matrix S als *Stichproben-Kovarianzmatrix*.

Durch folgenden Satz können wir die Stichproben-Kovarianzmatrix noch weiter vereinfachen.

Satz 0.4 ([3, S. 503]). Seien $A, B \in \mathbb{C}^{p \times n}$, dann gilt

$$\left\| F^{AA^H} - F^{BB^H} \right\|_\infty \leq \frac{1}{p} \operatorname{rang}(A - B).$$

Wir formen S zu

$$\begin{aligned}
S &= \frac{1}{n} \sum_{m=1}^n (x_m - \bar{x})(x_m - \bar{x})^H \\
&= \frac{1}{n} \left(\sum_{m=1}^n x_m x_m^H - \sum_{m=1}^n x_m \bar{x}^H - \sum_{m=1}^n x_m^H \bar{x} + \sum_{m=1}^n \bar{x} \bar{x}^H \right) \\
&= \frac{1}{n} \left(\sum_{m=1}^n x_m x_m^H - n \bar{x} \bar{x}^H \right) \\
&= \frac{1}{n} \mathbf{X} \mathbf{X}^H - \bar{x} \bar{x}^H
\end{aligned}$$

um und definieren $\mathbf{S}$ durch

$$\begin{aligned}
\mathbf{S} &:= \frac{1}{n} \sum_{m=1}^n x_m x_m^H \\
&= \frac{1}{n} \mathbf{X} \mathbf{X}^H .
\end{aligned} \tag{0.2}$$

Dann können wir mit Satz 0.4 durch

$$\begin{aligned}
\|F^S - F^{\mathbf{S}}\|_{\infty} &\leq \frac{1}{p} \text{rang} \left(\frac{1}{\sqrt{n}} \mathbf{X} - \bar{x} \bar{x}^H - \frac{1}{\sqrt{n}} \mathbf{X} \right) \\
&= \frac{1}{p} \text{rang} (\bar{x} \bar{x}^H) \\
&= \frac{1}{p}
\end{aligned}$$

zeigen, dass $\bar{x} \bar{x}^H$ keinen Einfluss auf die Konvergenz von F^S hat.

Bemerkung 0.5. Die Folgerung aus Satz 0.4 erlaubt es uns die vereinfachte Form $\mathbf{S}$ für die Stichproben-Kovarianzmatrix zu verwenden. Für den Konvergenzfall betrachten wir entsprechend

$$\mathbf{S}_{\eta} = \frac{1}{n} \mathbf{X}_{\eta} \mathbf{X}_{\eta}^H .$$

0.2 Marčenko–Pastur–Verteilung

Mit dem Verhältnis $y = \frac{p}{n}$ wird die Marčenko–Pastur–Verteilung durch das Wahrscheinlichkeitsmaß F_y auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ beschrieben. Für $y, \sigma^2 \in (0, \infty)$ und $x \in \mathbb{R}$ sind

$$a = \sigma^2 (1 - \sqrt{y})^2 \quad \text{und} \quad b = \sigma^2 (1 + \sqrt{y})^2 .$$

Die Dichtefunktion der Marčenko–Pastur–Verteilung ist dann durch

$$p_y(x) = \begin{cases} \frac{1}{2\pi xy\sigma^2} \sqrt{(b-x)(x-a)}, & \text{wenn } a \leq x \leq b \\ 0, & \text{sonst} \end{cases} \quad (0.3)$$

definiert, wobei sie mit $y > 1$ im Ursprung den Wert $1 - \frac{1}{y}$ annimmt. Die Verteilungsfunktion ergibt sich dann durch

$$F_y(t) = \int_a^t p_y(x) \, dx.$$

Wenn $\sigma^2 = 1$ ist, dann sprechen wir von der Standard-M-P-Verteilung. Die k -ten Momente der M-P-Verteilung sind durch

$$\beta_k(y, \sigma^2) := \int_a^b x^k p_y(x) \, dx \quad (0.4)$$

definiert. Wir können die Momente der M-P-Verteilung durch ihren Standardfall beschreiben, was wir im folgenden Lemma zeigen.

Lemma 0.6. Für alle $k \geq 1$ gilt

$$\beta_k(y, \sigma^2) = \sigma^{2k} \beta_k(y, 1) =: \beta_k.$$

Beweis. Nach (0.3) und (0.4) haben wir

$$\begin{aligned} \beta_k(y, \sigma^2) &= \int_a^b x^k p_y(x) \, dx \\ &= \int_{\sigma^2(1-\sqrt{y})^2}^{\sigma^2(1+\sqrt{y})^2} x^k \frac{1}{2\pi xy\sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - x)(x - \sigma^2(1-\sqrt{y})^2)} \, dx. \end{aligned}$$

Substituieren wir x mit $u\sigma^2$ erhalten wir

$$\begin{aligned}
\beta_k(y, \sigma^2) &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} (u\sigma^2)^k \frac{1}{2\pi u y \sigma^2} \sqrt{\left(\sigma^2(1+\sqrt{y})^2 - u\sigma^2\right) \left(u\sigma^2 - \sigma^2(1-\sqrt{y})^2\right)} du \\
&= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \sigma^{2k} \frac{1}{2\pi u y \sigma^2} \sqrt{\sigma^4 \left((1+\sqrt{y})^2 - u\right) \left(u - (1-\sqrt{y})^2\right)} du \\
&= \sigma^{2k} \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \frac{1}{2\pi u y} \sqrt{\left((1+\sqrt{y})^2 - u\right) \left(u - (1-\sqrt{y})^2\right)} du \\
&= \sigma^{2k} \beta_k(y, 1) .
\end{aligned}$$

Die Momente lassen sich also durch σ^{2k} skaliert über die Standard-M-P-Verteilung beschreiben. $\square$

Damit können wir zeigen, dass die Marčenko–Pastur–Verteilung eindeutig durch die Momente β_k bestimmt wird und wie die Momente explizit aussehen.

Lemma 0.7 (Carleman [3, S. 509]). Sei F eine Verteilungsfunktion und $\{\beta_k = \beta_k(F)\}_{k \in \mathbb{N}_0}$ die Folge ihrer Momente. Ist die *Carleman–Bedingung*

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} = \infty$$

erfüllt, dann wird die Verteilung F durch $\{\beta_k\}_{k \in \mathbb{N}_0}$ eindeutig bestimmt.

Lemma 0.8. Die Momente β_k der Marčenko–Pastur–Verteilung erfüllen die Carleman–Bedingung.

Beweis. Mit (0.3) und (0.4) können wir sehen, dass wir β_{2k} durch

$$\begin{aligned}
\beta_{2k} &= \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-x)(x-a)} dx \\
&\leq \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-a)(b-a)} dx \\
&= \frac{1}{2\pi y} \int_a^b x^{2k-1} (b-a) dx \\
&= \frac{1}{4k\pi y} (b^{2k} - a^{2k}) (b-a) \\
&= \frac{1}{k\pi\sqrt{y}} (b^{2k} - a^{2k}) \\
&\leq \frac{1}{k\pi\sqrt{y}} b^{2k} \\
&\leq b^{2k} = (1 + \sqrt{y})^{4k}
\end{aligned} \tag{0.5}$$

abschätzen können. Mit Lemma 0.7 und der Abschätzung (0.5) haben wir durch

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} \geq \sum_{k=1}^{\infty} (1 + \sqrt{y})^{-2} = \infty$$

die Carleman-Bedingung erfüllt. □

Damit haben wir gezeigt, dass die Marčenko–Pastur–Verteilung durch die Momente β_k eindeutig bestimmt ist. Die explizite Darstellung der Momente zeigen wir im folgenden Lemma.

Lemma 0.9. Die Momente k -ter Ordnung der Marčenko–Pastur–Verteilung haben die Form

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r. \tag{0.6}$$

Beweis. Nach (0.3) und (0.4) gilt

$$\beta_k = \frac{1}{2\pi y} \int_a^b x^{k-1} \sqrt{(b-x)(x-a)} dx.$$

Substituieren wir x mit $1 + y + z$ und setzen $(1 - \sqrt{y})^2$ für a und $(1 + \sqrt{y})^2$ für b ein,

erhalten wir

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{\left((1+\sqrt{y})^2 - 1 - y - z\right) \left(1+y+z - (1-\sqrt{y})^2\right)} dz \\ &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{4y - z^2} dz.\end{aligned}$$

Durch Einsetzen des binomischen Lehrsatzes lässt sich das Integral zu

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} z^\ell \sqrt{4y - z^2} dz \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-2\sqrt{y}}^{2\sqrt{y}} z^\ell \sqrt{4y - z^2} dz\end{aligned}$$

umformen. Um das Integral weiter zu vereinfachen, substituieren wir z mit $2\sqrt{y}u$ und erhalten

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-1}^1 2\sqrt{y} (2\sqrt{y}u)^\ell \sqrt{4y - 4yu^2} du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} (2\sqrt{y})^\ell 4y \int_{-1}^1 u^\ell \sqrt{1 - u^2} du.\end{aligned}$$

Hier ist unser Integrand ungerade, sofern ℓ ungerade ist. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen, ist das Integral für alle ungeraden ℓ gleich 0. Dadurch ist jeder zweite Summand 0. Wir lassen also die Summe bis zur Hälfte von $k-1$ laufen und summieren über 2ℓ statt über ℓ . Für den Fall, dass $k-1$ ungerade ist, runden wir ab, weil es dann nur $\frac{k-2}{2}$ Summanden gibt, die ungleich 0 sind. Wir haben also

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (2\sqrt{y})^{2\ell} 4y \int_{-1}^1 u^{2\ell} \sqrt{1 - u^2} du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \int_{-1}^1 u^{2\ell} \sqrt{1 - u^2} du.\end{aligned}$$

Da die Integralgrenzen symmetrisch um den Nullpunkt liegen und der Integrand gerade ist, können wir zweimal über das halbe Intervall integrieren. Zur Übersicht betrachten

wir vorerst nur noch das Integral und fügen später wieder alles zusammen. Folglich gilt

$$\int_{-1}^1 u^{2\ell} \sqrt{1-u^2} \, du = 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} \, du.$$

Wenn wir jetzt u mit $\sqrt{w}$ substituieren, erhalten wir ein Integral

$$\begin{aligned} 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} \, du &= \int_0^1 w^\ell \sqrt{1-w} \frac{1}{\sqrt{w}} \, dw \\ &= \int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} \, dw, \end{aligned}$$

das wir mittels Eulerscher Betafunktion lösen können. Die Eulersche Betafunktion ist durch

$$\int_0^1 t^{p-1} (1-t)^{q-1} \, dt = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

gegeben [2, S. 19]. Wir können also mit $p = \ell + \frac{1}{2}$ und $q = 1 + \frac{1}{2}$ das Integral durch die Gammafunktionen

$$\begin{aligned} \int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} \, dw &= \frac{\Gamma(\ell + \frac{1}{2})\Gamma(1 + \frac{1}{2})}{\Gamma(\ell + 2)} \\ &= \frac{1}{(\ell + 1)!} \left(\frac{(2\ell)! \sqrt{\pi}}{\ell! 4^\ell} \frac{2! \sqrt{\pi}}{4} \right) \\ &= \frac{1}{(\ell + 1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right) \end{aligned} \tag{0.7}$$

beschreiben. Nach Einsetzen von (0.7) in die wieder zusammengefügte Gleichung, erhalten wir

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right) \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{1}{2\pi y} \frac{(k-1)!}{(2\ell)!(k-1-2\ell)!} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right). \end{aligned}$$

Nach dem Kürzen der Brüche erhalten wir

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell (1+y)^{k-1-2\ell}.$$

Wenn wir den binomischen Lehrsatz mit

$$\begin{aligned}(1+y)^{k-1-2\ell} &= \sum_{s=0}^{k-1-2\ell} \binom{k-1-2\ell}{s} y^s \\ &= \sum_{s=0}^{k-1-2\ell} \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s\end{aligned}$$

einsetzen, haben wir

$$\begin{aligned}\beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!s!(k-1-2\ell-s)!} y^{\ell+s}.\end{aligned}$$

Jetzt wollen wir den Term wieder vereinfachen. Dafür setzen wir $s = r - \ell$, wodurch wir

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} y^r$$

erhalten und erweitern mit zwei Einsen, wodurch

$$\begin{aligned}\beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} \frac{r!}{r!} \frac{(k-r)!}{(k-r)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{r!(k-r)!} \frac{r!}{\ell!(r-\ell)!} \frac{(k-r)!}{(k-r-\ell-1)!(\ell+1)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \frac{k!}{r!(k-r)!} \frac{r!}{\ell!(r-\ell)!} \frac{(k-r)!}{(\ell+1)!(k-r-(\ell+1))!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r\end{aligned}$$

gilt. Für den nächsten Schritt müssen wir die Laufvariablen von 0 starten lassen. Momentan haben wir erst ein ℓ und ermitteln damit, inwieweit r eingeschränkt ist. Für ein

festes, aber beliebiges k liegen unsere Laufvariablen in

$$A = \left\{ (\ell, r) \in \mathbb{N}^2 \mid 0 \leq \ell \leq \left\lfloor \frac{k-1}{2} \right\rfloor, \ell \leq r \leq k-1-\ell \right\}.$$

Daraus wissen wir, dass

$$0 \leq \ell \quad \text{und} \quad r \leq k-1-\ell$$

gilt, woraus wir

$$\ell \leq k-1-r$$

folgern können. Damit erhalten wir

$$\begin{aligned} 0 \leq \ell \leq r \leq k-1-\ell \leq k-1 \\ \implies 0 \leq r \leq k-1, \quad 0 \leq \ell \leq \min(r, k-1-r). \end{aligned}$$

Folglich können wir die Summen äquivalent über

$$A = \{(\ell, r) \in \mathbb{N}^2 \mid 0 \leq r \leq k-1, 0 \leq \ell \leq \min(r, k-1-r)\} \quad (0.8)$$

laufen lassen.

Wir erhalten mit (0.8)

$$\begin{aligned} \beta_k &= \sum_{r=0}^{k-1} \sum_{\ell=0}^{\min(r, k-1-r)} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{\min(r, k-1-r)} \binom{r}{\ell} \binom{k-r}{\ell+1}. \end{aligned}$$

Das Minimum können wir noch weiter vereinfachen, da die Summanden gleich 0 sind, sobald $\ell > r$ oder $\ell > k-1-r$ ist. Wenn wir die Summe also bis r laufen lassen, ändern wir nichts am Ergebnis, wodurch wir den k -ten Moment schreiben können als

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^r \binom{r}{\ell} \binom{k-r}{\ell+1}.$$

An diesem Punkt müssen wir nur noch die innere Summe vereinfachen. Dafür machen

wir eine Indexverschiebung und formen die Binomialkoeffizienten um. Wir haben

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{\ell-1} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{r-(\ell-1)} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell}.
\end{aligned}$$

Hier nutzen wir die Vandermonde Identität [1, S. 16]. Diese ist durch

$$\sum_{\ddot{o}=0}^{\ddot{u}} \binom{n}{\ddot{o}} \binom{m}{\ddot{u}-\ddot{o}} = \binom{n+m}{\ddot{u}} \quad (0.9)$$

gegeben. Um die Vandermonde Identität nutzen zu können, lassen wir die Summe von $\ell = 0$ beginnen, da der zusätzliche Summand das Ergebnis nicht ändert. Mit der Identität (0.9) erhalten wir

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \frac{r+1}{r+1} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r.
\end{aligned}$$

□

0.3 Hilfsmittel für den Konvergenzbeweis

Im Beweis über die Konvergenz der empirischen Spektralverteilung benutzen wir Elemente aus der Graphentheorie und der Stochastik, die wir in diesem Kapitel einführen. Wir definieren eine Klasse von *gerichteten Graphen*, also Graphen, deren Kanten eine Richtung zugewiesen haben.

Gegeben ein Graph, bei dem die Knotenmenge in die Mengen *i*-Knoten und *j*-Knoten

unterteilt ist. Sei k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten mit der Gestalt $\mathbf{i} = \{i_1, \dots, i_k\}$ beziehungsweise $\mathbf{j} = \{j_1, \dots, j_k\}$. Den Knoten sind Werte zugewiesen. Dabei nehmen $\mathbf{i}$ -Knoten Werte in $\{0, \dots, p\}$ und $\mathbf{j}$ -Knoten Werte in $\{0, \dots, n\}$ an. Wenn unterschiedliche $\mathbf{i}/\mathbf{j}$ -Knoten den gleichen Wert annehmen, bezeichnen wir sie als *koinzident*.

Nun erstellen wir einen neuen Graphen, in dem koinzidente Knoten als *einen* Knoten mit mehreren Namen betrachtet werden.

Beispiel 0.10. Falls die Knoten i_2 und i_5 den gleichen Wert x annehmen, erhalten wir einen Knoten, welchen wir sowohl i_2 als auch i_5 nennen. Dies ist für die Definition der Kanten wichtig.

Die Kanten des neuen Graphen unterliegen den folgenden Regeln. Sie laufen von Knoten i_m zu j_m und von j_m zu i_{m+1} mit $m = 1, \dots, k$. Zusätzlich gibt es einen weiteren Knoten i_{k+1} , der den Graphen abschließt und für den $i_{k+1} = i_1$ gilt.

Beispiel 0.11. Wenn alle $\mathbf{i}$ -Knoten den Wert p und alle $\mathbf{j}$ -Knoten den Wert n annehmen, gibt es entsprechend $2k$ Kanten zwischen den zwei Knoten, da wir je k koinzidente $\mathbf{i}/\mathbf{j}$ -Knoten haben.

Sei $\hat{r}$ die Anzahl nicht koinzidenter $\mathbf{i}$ -Knoten, dann definieren wir $r := \hat{r} - 1$ und s als die Anzahl nicht koinzidenter $\mathbf{j}$ -Knoten. Da k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten ist, ist k auch die Anzahl an Kanten, die auf $\mathbf{i}$ -Knoten zeigen.

Diese Klasse an Graphen bezeichnen wir dann als $\Delta(k, r, s)$ Graphen beziehungsweise Δ Graphen. Für den Beweis teilen wir die $\Delta(k, r, s)$ Graphen in drei Kategorien ein.

$\Delta_1(k, r, s)$: Diese Kategorie fasst alle Graphen zusammen, die zu jeder Kante von $\mathbf{i}$ nach $\mathbf{j}$ genau eine Kante vom gleichen $\mathbf{j}$ -Knoten zum gleichen $\mathbf{i}$ -Knoten haben. Hier gilt $r + s = k$.

$\Delta_2(k, r, s)$: Diese Kategorie beinhaltet alle Graphen, die zwischen zwei Knoten mindestens einmal genau eine Kante besitzen, also Graphen, die mindestens eine *Einzelkante* besitzen.

$\Delta_3(k, r, s)$: Die letzte Kategorie $\Delta_3(k, r, s)$ beinhaltet alle Graphen, die weder in $\Delta_1(k, r)$ noch in $\Delta_2(k, r, s)$ liegen.




Abbildung 1: Beispiel für Graphen

Zur besseren Lesbarkeit schreiben wir für die jeweiligen Kategorien $\Delta_i(k, r, s)$ nur noch Δ_i , wobei $i \in \{1, 2, 3\}$. Wir bezeichnen zwei Graphen als isomorph, wenn wir für die i/j -Knoten eine geeignete Zuweisung von Knotenwerten so finden, dass die Graphen identisch sind.




Abbildung 2: Beispiel für Isomorphie

Beispiel 0.12. Graph a) ist isomorph zu b), da wir die Werte von zwei Knoten ändern können und einen identischen Graphen erhalten. Graph c) ist aber nicht isomorph zu a), da die Graphenstruktur unterschiedlich ist.

Zu den Δ Graphen benötigen wir noch ein paar Lemmata.

Lemma 0.13 ([3, S. 43]). Die Anzahl der Graphen in jeder Isomorphieklasse von $\Delta(k, r, s)$ Graphen, mit festen k, r und s , ist

$$\alpha = p(p-1) \cdots (p-r)n(n-1) \cdots (n-s+1) = p^{r+1}n^s \left(1 + \mathcal{O}\left(\frac{1}{n}\right)\right).$$

Lemma 0.14 ([3, S. 43]). Die Anzahl nicht koinzidenter Knoten von $\Delta_3(k, r, s)$ Graphen ist kleiner oder gleich k , also $r + s \leq k$.

Lemma 0.15 ([3, S. 43]). Die Anzahl nicht-isomorpher $\Delta_1(k, r, s)$ Graphen für festes g und r beträgt

$$\frac{1}{r+1} \binom{k}{r} \binom{k-1}{r}.$$

Zusätzlich zu den Graphen verwenden wir noch Elemente aus der Stochastik. Zum einen benötigen wir das starke Gesetz der großen Zahlen und zum anderen eine Metrik für Wahrscheinlichkeitsverteilungen, die Lévy-Metrik.

Satz 0.16 (Starkes Gesetz der großen Zahlen [5, S. 139]). Seien $\{\mathcal{Z}_i\}_{i \in \mathbb{N}}$ unabhängige und identisch verteilte Zufallsvariablen, die einen Moment erster Ordnung besitzen, dann gilt

$$\frac{1}{n} \sum_{i=1}^n \mathcal{Z}_i \xrightarrow[\text{f.s.}]{n \rightarrow \infty} \mathbb{E}(\mathcal{Z}_1).$$

Definition 0.17 (Lévy-Metrik [5, S. 164]). Seien F_1 und F_2 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit zugehörigen Verteilungsfunktionen $\mathbf{F}_1$ und $\mathbf{F}_2$. Dann ist die *Lévy-Metrik* definiert durch

$$\mathcal{L}(F_1, F_2) = \inf\{\varepsilon > 0, x \in \mathbb{R}: \mathbf{F}_1(x - \varepsilon) - \varepsilon \leq \mathbf{F}_2(x) \leq \mathbf{F}_1(x + \varepsilon) + \varepsilon\}.$$

Lemma 0.18 ([3, S. 502]). Seien $A, B \in \mathbb{C}^{p \times n}$ und $S = AA^H$, $\bar{S} = BB^H$. Dann gilt für die Lévy-Metrik

$$\mathcal{L}^4(F^S, F^{\bar{S}}) \leq \frac{2}{p^2} \text{tr}(AA^H + BB^H) \text{tr}((A - B)(A - B)^H).$$

0.4 Konvergenzsatz und Beweis

Kommen wir nun zum Satz über die Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung.

Satz 0.19. Sei $\{\mathbf{X}_\eta\}$ eine Folge an $p_\eta \times n_\eta$ Zufallsmatrizen, wie in Definition 0.2 beschrieben, und seien ihre Einträge $\{x_{ij}\}$ mit $i = 1, \dots, p_\eta$ und $j = 1, \dots, n_\eta$ unabhängig und identisch verteilte komplexe Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2 . Seien weiter p_η und n_η monoton steigend mit η und $\lim_{\eta \rightarrow \infty} \frac{p_\eta}{n_\eta} = y \in (0, \infty)$.

Dann konvergiert die empirische Spektralverteilung der Stichproben-Kovarianzmatrix $F^{\mathbf{S}_\eta}$ mit $\eta \rightarrow \infty$ fast sicher gegen die Marčenko–Pastur–Verteilung F_y aus Kapitel 0.2.

Im folgenden Beweis nehmen wir mit Lemma 0.6 ohne Beschränkung der Allgemeinheit an, dass die Varianz $\sigma^2 = 1$ ist, wir also den Standardfall betrachten.

Wir zeigen die schwache Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung mithilfe der Momentmethode.

Nach der Momentmethode konvergiert eine Folge an Wahrscheinlichkeitsverteilungen $\{F_n\}_n$, wenn ihre Momente $\beta_{n,k}$ jeder Ordnung $k \geq 0$ endlich sind und gegen einen Grenzwert β_k konvergieren, schwach gegen eine Wahrscheinlichkeitsverteilung, die eindeutig von ihren Momenten β_k bestimmt sein muss [3, S. 507]. Mit dem Beweis von Lemma 0.8 haben wir bereits gezeigt, dass die Momente der Marčenko–Pastur–Verteilung die Carleman–Bedingung 0.7 und damit die Eindeutigkeit erfüllen.

Beweis. Die Momentmethode verlangt, dass die Momente jeder Ordnung der Verteilung endlich sind. Um das garantieren zu können, müssen wir dafür sorgen, dass die Zufallsvariablen $\{x_{ij}\}$ nicht unendlich groß werden können.

Seien $C \in \mathbb{R}_+$ und $\mathbf{1}$ die Indikatorfunktion auf $\mathbb{R}$, dann beschränken wir $\{x_{ij}\}$ und definieren die beschränkte Stichproben-Kovarianzmatrix $\hat{\mathbf{S}}_\eta$ durch

$$\begin{aligned}\hat{x}_{ij} &:= x_{ij} \mathbf{1}(|x_{ij}| \leq C), \\ \hat{x}_i &:= (\hat{x}_{i1}, \dots, \hat{x}_{ip_\eta})^\top, \\ \hat{\mathbf{S}}_\eta &:= \frac{1}{n_\eta} \sum_{i=1}^{n_\eta} \hat{x}_i \hat{x}_i^H = \frac{1}{n_\eta} \hat{\mathbf{X}}_\eta \hat{\mathbf{X}}_\eta^H.\end{aligned}$$

Da das Beschränken die Erwartungswerte verändert hat, müssen wir $\hat{x}_{ij}$ noch zentralisieren, indem wir die Erwartungswerte von den Zufallsvariablen abziehen. Für die zentralisierten Zufallsvariablen und die entsprechende Stichproben-Kovarianzmatrix erhalten

wir

$$\begin{aligned}\tilde{x}_{ij} &:= \hat{x}_{ij} - \mathbb{E}(\hat{x}_{11}), \\ \tilde{x}_i &:= (\tilde{x}_{i1}, \dots, \tilde{x}_{ip_\eta})^\top, \\ \tilde{\mathbf{S}}_\eta &:= \frac{1}{n_\eta} \sum_{i=1}^{n_\eta} \tilde{x}_i \tilde{x}_i^H = \frac{1}{n_\eta} \tilde{\mathbf{X}}_\eta \tilde{\mathbf{X}}_\eta^H.\end{aligned}$$

Wir bezeichnen ab hier alle $\mathbf{X}_\eta$ als $\mathbf{X}$. Mit $\hat{\mathbf{S}}_\eta$ und $\tilde{\mathbf{S}}_\eta$ erhalten wir die beschränkte und zentralisierte Stichproben Kovarianzmatrix.

Im Folgenden stellen wir sicher, dass sich der Grenzwert durch das Beschränken und Zentralisieren nicht ändert. Nach Lemma 0.18 erhalten wir

$$\begin{aligned}\mathcal{L}^4(F^{\mathbf{S}}, F^{\hat{\mathbf{S}}_\eta}) &\leq \frac{2}{n_\eta p_\eta} \operatorname{tr}(\mathbf{X} \mathbf{X}^H + \hat{\mathbf{X}} \hat{\mathbf{X}}^H) \operatorname{tr}((\mathbf{X} - \hat{\mathbf{X}})(\mathbf{X} - \hat{\mathbf{X}})^H) \\ &= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} x_{ij} \bar{x}_{ij} + \hat{x}_{ij} \bar{\hat{x}}_{ij} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} (x_{ij} - \hat{x}_{ij}) \overline{(x_{ij} - \hat{x}_{ij})} \right) \\ &= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 + |\hat{x}_{ij}|^2 \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |x_{ij} - \hat{x}_{ij}|^2 \right) \\ &\leq \left(\frac{4}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 \mathbf{1}(|x_{ij}| > C) \right) \\ &\stackrel{(0.16) \text{ f.s.}}{\longrightarrow} 4 \mathbb{E}(|x_{ij}|^2) \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\stackrel{\text{f.s.}}{\longrightarrow} 4 \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\stackrel{C \rightarrow \infty}{\longrightarrow} 0.\end{aligned}$$

Der Abstand der empirischen Spektralverteilung und ihrer beschränkten Version ist also für ein hinreichend großes C vernachlässigbar klein. Nach Satz 0.4 können wir durch

$$\begin{aligned}\left\| F^{\hat{\mathbf{S}}_\eta} - F^{\tilde{\mathbf{S}}_\eta} \right\|_\infty &\leq \frac{1}{p_\eta} \operatorname{rang}(\hat{\mathbf{X}} - \tilde{\mathbf{X}}) \\ &= \frac{1}{p_\eta} \operatorname{rang}(\mathbb{E}(\hat{x}_{11})) \\ &= \frac{1}{p_\eta}\end{aligned}$$

sehen, dass die Zentralisierung der Zufallsvariablen, ebenfalls keinen Einfluss auf die

Konvergenz hat.

Die Verteilung wurde jetzt so modifiziert, dass die Zufallsvariablen nicht mehr unendlich groß werden können und den Erhalt des Erwartungswertes garantiert, ohne die Konvergenz zu beeinträchtigen.

Wir müssen zusätzlich noch dafür sorgen, dass die Varianz erhalten bleibt. Dafür müssen wir zeigen, dass durch Skalierung von $\tilde{\mathbf{S}}_\eta$ mit $\tilde{\sigma}^2 = \mathbb{E}(|\tilde{x}_{ij}|^2) \rightarrow 1$, wenn $C \rightarrow \infty$ gilt, der Abstand zu $\tilde{\mathbf{S}}_\eta$ vernachlässigbar klein wird.

Es gilt wieder mit Lemma 0.18

$$\begin{aligned}
\mathcal{L}^4(F^{\tilde{\mathbf{S}}_\eta}, F^{\tilde{\sigma}^{-2}\tilde{\mathbf{S}}_\eta}) &\leq \frac{2}{n_\eta} \operatorname{tr} \left(\tilde{\mathbf{X}} \tilde{\mathbf{X}}^H + \frac{1}{\tilde{\sigma}^2} \tilde{\mathbf{X}} \tilde{\mathbf{X}}^H \right) \operatorname{tr} \left(\left(1 - \frac{1}{\tilde{\sigma}} \right)^2 \tilde{\mathbf{X}} \tilde{\mathbf{X}}^H \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H - \frac{2\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}} + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} |\tilde{x}_{ij}|^2 + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |\tilde{x}_{ij}|^2 - \frac{2|\tilde{x}_{ij}|^2}{\tilde{\sigma}} + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 - \tilde{\sigma} 2|\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\
&= 2 \left(\frac{\tilde{\sigma}^2 + 1}{n_\eta p_\eta \tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \left(\frac{(\tilde{\sigma} - 1)^2}{n_\eta p_\eta \tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \\
&\xrightarrow{\text{f.s.}} 2 \frac{\tilde{\sigma}^2 + 1}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \frac{(\tilde{\sigma} - 1)^2}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \\
&\xrightarrow{C \rightarrow \infty} 0.
\end{aligned}$$

Damit haben wir die Endlichkeit der Momente aller Ordnungen garantiert. Für einen besseren Überblick verwenden wir weiterhin die Notation von $\mathbf{S}_\eta$ und $\mathbf{X}$, verwenden aber die modifizierten Matrizen. Wir haben also eine gleichmäßig durch C beschränkte Zufallsvariable x_{ij} mit Erwartungswert 0 und Varianz 1.

Nach Definition 0.1 erhalten wir

$$\begin{aligned}
\beta_{\eta,k}(\mathbf{S}_\eta) &= \int_{-\infty}^{\infty} x^k \mathrm{d}F^{\mathbf{S}_\eta}(x) \\
&= \frac{1}{p_\eta} \operatorname{tr} \left(\mathbf{S}_\eta^k \right) \\
&= \frac{1}{p_\eta n_\eta^k} \operatorname{tr} \left((\mathbf{X} \mathbf{X}^H)^k \right)
\end{aligned}$$

für die Momente der empirischen Spektralverteilung.

Hier verwenden wir die eingeführte Klasse von Δ Graphen. Wir können die Spur nämlich mit $\mathbf{i} = \{i_1, \dots, i_k\}$ und $\mathbf{j} = \{j_1, \dots, j_k\}$, wobei die Elemente von $\mathbf{i}$ in $\{1, \dots, p_\eta\}$ und $\mathbf{j}$ in $\{1, \dots, n_\eta\}$ liegen, durch

$$\frac{1}{p_\eta n_\eta^k} \text{tr} \left((\mathbf{X} \mathbf{X}^H)^k \right) = \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k}$$

beschreiben. Dabei sind $x_{i_1 j_1} \bar{x}_{i_2 j_1} \dots$ die Produkte der einzelnen Summanden der Spur und wir summieren über alle Permutationen von $\mathbf{i}$ und $\mathbf{j}$. Die Zufallsvariablen x_{ij} geben die Kanten von $\mathbf{i}$ -Knoten zu $\mathbf{j}$ -Knoten an und $\bar{x}_{ij}$ Kanten von $\mathbf{j}$ -Knoten zu $\mathbf{i}$ -Knoten. Wir definieren dann

$$\frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k} =: \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbf{X}_{\Delta(k, r, s)}.$$

Nach der Momentmethode konvergiert die empirische Spektralverteilung schwach gegen die Marčenko–Pastur–Verteilung, wenn die Momente der empirischen Spektralverteilung gegen die Momente der Marčenko–Pastur–Verteilung konvergieren. Das zeigen wir, indem wir den Erwartungswert und die Varianz der Momente der empirischen Spektralverteilung bestimmen. Sie konvergieren genau dann, wenn der Erwartungswert $\mathbb{E}(\beta_k(\mathbf{S}_\eta))$ gegen die Momente der Marčenko–Pastur–Verteilung läuft und die Varianz gegen null läuft.

Wir prüfen zunächst den Erwartungswert. Es gilt

$$\mathbb{E}(\beta_k(\mathbf{S}_\eta)) = \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbb{E}(\mathbf{X}_{\Delta(k, r, s)}).$$

Teilen wir die Graphen in ihre Kategorien, wie in Kapitel Hilfsmittel für den Konvergenzbeweis 0.3 beschrieben, ein, erhalten wir mit Lemma 0.13

$$\mathbb{E}(\beta_k(\mathbf{S}_\eta)) = \frac{1}{p_\eta n_\eta^k} \left(\overbrace{\sum_{\Delta_1} \alpha \mathbb{E}(\mathbf{X}_{\Delta_1})}^{W_1 :=} + \overbrace{\sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2})}^{W_2 :=} + \overbrace{\sum_{\Delta_3} \alpha \mathbb{E}(\mathbf{X}_{\Delta_3})}^{W_3 :=} \right).$$

Für W_1 erhalten wir mit $s = k - r$ und nach Lemma 0.13 und Lemma 0.14

$$W_1 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p_\eta^{r+1} n_\eta^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right) \right) \mathbb{E}(\mathbf{X}_{\Delta_1}).$$

Da es zu jeder Kante genau eine Kante in die entgegengesetzte Richtung gibt, gilt $\mathbb{E}(|x_{ij}|^2) = 1$. Wir können W_1 also schreiben als

$$\begin{aligned}
W_1 &= \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p_\eta^{r+1} n_\eta^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} \frac{p_\eta^{r+1} n_\eta^{k-r}}{n_\eta^k p_\eta} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p_\eta}\right). \tag{0.10}
\end{aligned}$$

Für W_2 können wir den Erwartungswert in

$$W_2 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2})$$

aufteilen. Da sich Δ_2 -Graphen dadurch auszeichnen, dass sie mindestens eine Einzelkante besitzen, existiert mindestens ein Exponent $\omega_i \in \mathbb{N}$ in

$$\mathbb{E}(\mathbf{X}_{\Delta_2}) = \mathbb{E}(x_{i_1 j_1}^{\omega_1}) \mathbb{E}(x_{i_2 j_1}^{\omega_2}) \dots$$

welcher 1 ist. Da der Erwartungswert der Zufallsvariablen $x_{i_m j_m}$ 0 ist, gilt $\mathbb{E}(x_{i_m j_m}^1) = 0 = \mathbb{E}(\mathbf{X}_{\Delta_2})$. Für W_2 ergibt sich dann

$$W_2 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2}) = 0. \tag{0.11}$$

Für W_3 erhalten wir wieder mit Lemma 0.13, dass

$$W_3 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_3} \alpha \mathbb{E}(\mathbf{X}_{\Delta_3})$$

gilt. Wir haben gezeigt, dass x_{ij} gleichmäßig durch ein $C > 0$ beschränkt ist. Daraus erhalten wir, dass $|X_{\Delta(k,r,s)}| \leq C^{2k}$ gilt. Mit Lemma 0.14 wissen wir, dass die Anzahl nicht koinzidenter Knoten maximal k betragen kann. Dadurch ist die Anzahl unterschiedlicher

Δ_3 Graphen in $\mathcal{O}(n^k)$. Wir haben also

$$\begin{aligned} \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_3} \alpha(\mathbf{X}_{\Delta_3}) &= \frac{C^{2k}}{n_\eta^k p_\eta} \mathcal{O}(n_\eta^k) \\ &= \mathcal{O}\left(\frac{1}{p_\eta}\right). \end{aligned} \quad (0.12)$$

Mit (0.10), (0.11) und (0.12) erhalten wir dann

$$\begin{aligned} \mathbb{E}(\beta_k(\mathbf{S}_\eta)) &= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p_\eta}\right) \\ &= \beta_k(y, \sigma^2) + o(1). \end{aligned} \quad (0.13)$$

Der Erwartungswert der Momente konvergiert folglich gegen die Momente der Marčenko–Pastur–Verteilung plus einen vernachlässigbar kleinen Term, da p_η gegen unendlich läuft. Zuletzt müssen wir noch die Varianz prüfen. Für diese gilt

$$\text{Var}(\beta_k(\mathbf{S}_\eta)) := \frac{1}{p_\eta n_\eta^k} \sum_{i,j} (\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) - \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)})).$$

Dabei sind Δ_a und Δ_b zwei Δ Graphen mit unterschiedlichen Permutationen von $\mathbf{i}$ und $\mathbf{j}$. Wie für den Erwartungswert suchen wir uns Kategorien, um die Varianz stückweise zu beschreiben.

Als Erstes betrachten wir alle Graphen Δ_a und Δ_b so, dass Δ_a und Δ_b unabhängig sind, sich also keine Kanten teilen. Daraus folgt direkt

$$\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) = \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)}).$$

Das heißt, für unabhängige Graphen ist die Varianz gleich 0.

Als Nächstes betrachten wir alle Graphen Δ_a und Δ_b , die mindestens eine Einzelkante besitzen. Damit erhalten wir wie in (0.11) wieder

$$\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) = 0 = \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)}).$$

In allen anderen Möglichkeiten haben die Graphen keine Einzelkante und Δ_a und Δ_b teilen sich Kanten. Analog zu W_3 können wir sagen, dass die Anzahl möglicher Graphen in $\mathcal{O}(n_\eta^k)$ liegt. Da wir zwei Graphen Δ_a und Δ_b betrachten, liegt die Anzahl möglicher Graphen in $\mathcal{O}(n_\eta^{2k})$. Durch die gleichmäßige Beschränkung von x_{ij} durch C können wir

die Varianz durch

$$\begin{aligned}\mathrm{Var}(\beta_k(\mathbf{S}_\eta)) &\leq \frac{1}{p_\eta^2 n_\eta^{2k}} C\mathcal{O}(n_\eta^{2k}) \\ &= \mathcal{O}\left(\frac{1}{p_\eta^2}\right)\end{aligned}\tag{0.14}$$

abschätzen. Da p_η gegen unendlich läuft, wird die Varianz vernachlässigbar klein. Mit dem Erwartungswert (0.13) und der Varianz (0.14) können wir darauf schließen, dass die empirische Spektralverteilung fast sicher gegen die Marčenko–Pastur–Verteilung konvergiert. $\square$