

In Bezug auf die Rangreduzierung sind wir in der Einleitung auf das Paper von Gavish und Donoho eingegangen [4]. Wir erinnern uns an die gegebene Rahmenstruktur. Es galt für $\eta \rightarrow \infty$ und $X_\eta \in \mathbb{K}^{p_\eta \times n_\eta}$, dass das Dimensions-Stichproben-Verhältnis $y = \frac{p_\eta}{n_\eta} \in (0, 1]$ nicht divergiert. In dem Paper wird erwähnt, dass in

$$X_\eta := X_\eta^{\text{echt}} + \gamma X_\eta^{\text{rauschen}}$$

der durch $\frac{\sigma_{\text{med},\eta}}{\sqrt{n_\eta}}$ normierte Median der Singulärwerte von X_η fast sicher gegen den Median der Marčenko–Pastur–Verteilung μ_y konvergiert [4, S. 11]. Daraus ergibt sich dann, dass der Schwellenwert für die Dimensionsreduktion

$$\hat{\tau}_*(y, X) = \lambda_*(y) \frac{\sigma_{\text{med},\eta}}{\sqrt{\mu_y}}$$

fast sicher gegen

$$\lim_{\eta \rightarrow \infty} \lambda_*(y) \frac{\sigma_{\text{med},\eta}}{\sqrt{\mu_y}} \stackrel{\text{f.s.}}{=} \lambda_*(y) = \sqrt{2(y+1) + \frac{8y}{(y+1) + \sqrt{y^2 + 14y + 1}}}$$

konvergiert.

Um die Notation im Folgenden zu vereinfachen, bezeichnen wir die Rauschmatrix X_η^{rauschen} mit $\mathbf{X}_\eta$.

Die Marčenko–Pastur–Verteilung (kurz M-P-Verteilung) beschreibt die asymptotische Verteilung der Eigenwerte von großen Zufallsmatrizen der Form $\frac{1}{n_\eta} \mathbf{X}_\eta \mathbf{X}_\eta^H$. Die genauen Anforderungen an $\mathbf{X}_\eta$ stellen wir im kommenden Unterkapitel 0.1 vor. Eine Wahrscheinlichkeitsverteilung, die angibt, wie die Eigenwerte einer Matrix verteilt sind, ist die empirische Spektralverteilung.

Ziel dieses Kapitels ist es, die schwache Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung zu zeigen. Die Herleitung orientiert sich dabei an dem Buch „Spectral Analysis of Large Dimensional Random Matrices“ von Zhidong Bai und Jack W. Silverstein [3].

0.1 Grundlagen

Wir beginnen damit, die empirische Spektralverteilung einmal konkret zu definieren.

Definition 0.1. [3, S. 4, 10] Sei B eine $p \times p$ hermitesche Matrix mit Eigenwerten λ_i und $i = 1, \dots, p$. Dann ist auf dem Ereignisraum $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit $\mathcal{B}(\mathbb{R})$ als borelsche σ -Algebra

durch

$$F^B(x) := \frac{1}{p} |A_x| \quad \text{mit } A_x := \{i \in \{1, \dots, p\} : \lambda_i \leq x\}$$

die *empirische Spektralverteilung* $F^B: \mathbb{R} \rightarrow [0, 1]$ definiert. Ihre *k-ten Momente* sind durch

$$\beta_k(B) = \int_{-\infty}^{\infty} x^k dF^B(x) = \frac{1}{p} \operatorname{tr}(B^k)$$

gegeben.

Die Konvergenz der empirischen Spektralverteilung betrachten wir in dem Sinne, dass wir analysieren, wie sich die Verteilung verhält, wenn wir eine Folge an Matrizen betrachten, deren Dimensionen p und n gegen unendlich laufen.

Definition 0.2. Sei $\mathbf{X}$ eine $p \times n$ Matrix, deren Elemente unabhängig und identisch verteilte komplexe Zufallsvariablen sind. Dabei sind ihre Erwartungswerte 0 und ihre Varianz bezeichnen wir mit σ^2 . Weiter sind $x_m = (x_{1m}, \dots, x_{pm})^\top$ und $\mathbf{X} = (x_1, \dots, x_n)$.

Für die Folge an Zufallsmatrizen $\{\mathbf{X}_\eta\}$ laufen also p und n so gegen unendlich, dass das Verhältnis

$$\lim_{\eta \rightarrow \infty} \frac{p_\eta}{n_\eta} = y$$

nicht divergiert.

Definition 0.3. Wir bezeichnen mit $\bar{x} = \frac{1}{n} \sum_{m=1}^n x_m$, die durch

$$S = \frac{1}{n} \sum_{m=1}^n (x_m - \bar{x})(x_m - \bar{x})^H \in \mathbb{R}^{p \times p} \quad (0.1)$$

gegebene Matrix S als *Stichproben-Kovarianzmatrix*.

Durch folgenden Satz können wir die Stichproben-Kovarianzmatrix noch weiter vereinfachen.

Satz 0.4 ([3, S. 503]). Seien $A, B \in \mathbb{C}^{p \times n}$. Dann gilt

$$\left\| F^{AA^H} - F^{BB^H} \right\|_\infty \leq \frac{1}{p} \operatorname{rang}(A - B).$$

Formen wir S zu

$$\begin{aligned}
S &= \frac{1}{n} \sum_{m=1}^n (x_m - \bar{x})(x_m - \bar{x})^H \\
&= \frac{1}{n} \left(\sum_{m=1}^n x_m x_m^H - \sum_{m=1}^n x_m \bar{x}^H - \sum_{m=1}^n x_m^H \bar{x} + \sum_{m=1}^n \bar{x} \bar{x}^H \right) \\
&= \frac{1}{n} \left(\sum_{m=1}^n x_m x_m^H - n \bar{x} \bar{x}^H \right) \\
&= \frac{1}{n} \mathbf{X} \mathbf{X}^H - \bar{x} \bar{x}^H
\end{aligned}$$

um und definieren $\mathbf{S}$ durch

$$\begin{aligned}
\mathbf{S} &:= \frac{1}{n} \sum_{m=1}^n x_m x_m^H \\
&= \frac{1}{n} \mathbf{X} \mathbf{X}^H,
\end{aligned} \tag{0.2}$$

dann können wir mit Satz 0.4 durch

$$\begin{aligned}
\|F^S - F^{\mathbf{S}}\|_\infty &\leq \frac{1}{p} \text{rang} \left(\frac{1}{\sqrt{n}} \mathbf{X} - \bar{x} \bar{x}^H - \frac{1}{\sqrt{n}} \mathbf{X} \right) \\
&= \frac{1}{p} \text{rang} (\bar{x} \bar{x}^H) \\
&= \frac{1}{p}
\end{aligned}$$

zeigen, dass $\bar{x} \bar{x}^H$ keinen Einfluss auf die Konvergenz von F^S hat.

Bemerkung 0.5. Wir verwenden daher die vereinfachte Form $\mathbf{S}$ für die Stichproben-Kovarianzmatrix. Für den Konvergenzfall betrachten wir entsprechend

$$\mathbf{S}_\eta = \frac{1}{n} \mathbf{X}_\eta \mathbf{X}_\eta^H.$$

0.2 Marčenko–Pastur–Verteilung

Mit dem Verhältnis $y = \frac{p}{n}$ wird die Marčenko–Pastur–Verteilung durch das Wahrscheinlichkeitsmaß F_y auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ beschrieben. Für $y, \sigma^2 \in (0, \infty)$ und $x \in \mathbb{R}$ sind

$$a = \sigma^2 (1 - \sqrt{y})^2 \quad \text{und} \quad b = \sigma^2 (1 + \sqrt{y})^2.$$

Die Dichtefunktion der Marčenko–Pastur–Verteilung ist dann durch

$$p_y(x) = \begin{cases} \frac{1}{2\pi xy\sigma^2} \sqrt{(b-x)(x-a)}, & \text{wenn } a \leq x \leq b \\ 0, & \text{sonst} \end{cases} \quad (0.3)$$

definiert, wobei sie mit $y > 1$ im Ursprung den Wert $1 - \frac{1}{y}$ annimmt. Die Verteilungsfunktion ergibt sich dann durch

$$F_y(t) = \int_a^t p_y(x) \, dx.$$

Wenn $\sigma^2 = 1$ ist, dann sprechen wir von der Standard-M-P-Verteilung. Die k -ten Momente der M-P-Verteilung sind durch

$$\beta_k(y, \sigma^2) := \int_a^b x^k p_y(x) \, dx \quad (0.4)$$

definiert. Wir können die Momente der M-P-Verteilung durch ihren Standardfall beschreiben, was wir im folgenden Lemma zeigen.

Lemma 0.6. Für alle $k \geq 1$ gilt

$$\beta_k(y, \sigma^2) = \sigma^{2k} \beta_k(y, 1) =: \beta_k.$$

Beweis. Nach 0.3 und (0.4) haben wir

$$\begin{aligned} \beta_k(y, \sigma^2) &= \int_a^b x^k p_y(x) \, dx \\ &= \int_{\sigma^2(1-\sqrt{y})^2}^{\sigma^2(1+\sqrt{y})^2} x^k \frac{1}{2\pi xy\sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - x)(x - \sigma^2(1-\sqrt{y})^2)} \, dx. \end{aligned}$$

Substituieren wir x mit $u\sigma^2$ erhalten wir

$$\begin{aligned}
\beta_k(y, \sigma^2) &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} (u\sigma^2)^k \frac{1}{2\pi u y \sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - u\sigma^2)(u\sigma^2 - \sigma^2(1-\sqrt{y})^2)} du \\
&= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \sigma^{2k} \frac{1}{2\pi u y \sigma^2} \sqrt{\sigma^4((1+\sqrt{y})^2 - u)(u - (1-\sqrt{y})^2)} du \\
&= \sigma^{2k} \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \frac{1}{2\pi u y} \sqrt{((1+\sqrt{y})^2 - u)(u - (1-\sqrt{y})^2)} du \\
&= \sigma^{2k} \beta_k(y, 1) .
\end{aligned}$$

Die Momente lassen sich also durch σ^{2k} skaliert über die Standard-M-P-Verteilung beschreiben. $\square$

Damit können wir dann zeigen, dass die Marčenko–Pastur–Verteilung eindeutig durch die Momente β_k bestimmt wird und wie die Momente explizit bestimmt aussehen.

Lemma 0.7 (Carleman [3, S. 509]). Sei $\{\beta_k = \beta_k(F)\}_{k \in \mathbb{N}_0}$ die Folge von Momenten der Verteilungsfunktion F . Ist die *Carleman-Bedingung*

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} = \infty$$

erfüllt, dann wird die Verteilung F durch $\{\beta_k\}_{k \in \mathbb{N}_0}$ eindeutig bestimmt.

Lemma 0.8. Die Momente β_k der Marčenko–Pastur–Verteilung erfüllen die Carleman-Bedingung.

Beweis. Mit (0.3) und (0.4) können wir sehen, dass wir β_{2k} durch

$$\begin{aligned}
\beta_{2k} &= \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-x)(x-a)} dx \\
&\leq \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-a)(b-a)} dx \\
&= \frac{1}{2\pi y} \int_a^b x^{2k-1} (b-a) dx \\
&= \frac{1}{4k\pi y} (b^{2k} - a^{2k}) (b-a) \\
&= \frac{1}{k\pi\sqrt{y}} (b^{2k} - a^{2k}) \\
&\leq \frac{1}{k\pi\sqrt{y}} b^{2k} \\
&\leq b^{2k} = (1 + \sqrt{y})^{4k}
\end{aligned} \tag{0.5}$$

abschätzen können. Mit Lemma 0.7 und der Abschätzung (0.5) haben wir durch

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} \geq \sum_{k=1}^{\infty} (1 + \sqrt{y})^{-2} = \infty$$

die Carleman-Bedingung erfüllt. □

Damit haben wir gezeigt, dass die Marčenko–Pastur–Verteilung durch die Momente β_k eindeutig bestimmt ist. Die explizite Darstellung der Momente zeigen wir im folgenden Lemma.

Lemma 0.9. Die Momente k -ter Ordnung der Marčenko–Pastur–Verteilung haben die Form

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r. \tag{0.6}$$

Beweis. Nach (0.3) und (0.4) gilt

$$\beta_k = \frac{1}{2\pi y} \int_a^b x^{k-1} \sqrt{(b-x)(x-a)} dx.$$

Substituieren wir x mit $1 + y + z$ und setzen $(1 - \sqrt{y})^2$ für a und $(1 + \sqrt{y})^2$ für b ein,

erhalten wir

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{\left((1+\sqrt{y})^2 - 1 - y - z\right) \left(1+y+z - (1-\sqrt{y})^2\right)} dz \\ &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{4y - z^2} dz.\end{aligned}$$

Durch Einsetzen des binomischen Lehrsatzes lässt sich das Integral zu

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} z^\ell \sqrt{4y - z^2} dz \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-2\sqrt{y}}^{2\sqrt{y}} z^\ell \sqrt{4y - z^2} dz\end{aligned}$$

umformen. Um das Integral weiter zu vereinfachen, substituieren wir z mit $2\sqrt{y}u$ und erhalten

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-1}^1 2\sqrt{y} (2\sqrt{y}u)^\ell \sqrt{4y - 4yu^2} du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} (2\sqrt{y})^\ell 4y \int_{-1}^1 u^\ell \sqrt{1 - u^2} du.\end{aligned}$$

Hier ist unser Integrand ungerade, sofern ℓ ungerade ist. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen, ist das Integral für alle ungeraden ℓ gleich 0. Dadurch ist jeder zweite Summand 0. Wir lassen also die Summe bis zur Hälfte von $k-1$ laufen und summieren über 2ℓ statt über ℓ . Für den Fall, dass $k-1$ ungerade ist, runden wir ab, weil es dann nur $\frac{k-2}{2}$ Summanden gibt, die ungleich 0 sind. Wir haben also

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (2\sqrt{y})^{2\ell} 4y \int_{-1}^1 u^{2\ell} \sqrt{1 - u^2} du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \int_{-1}^1 u^{2\ell} \sqrt{1 - u^2} du.\end{aligned}$$

Da die Integralgrenzen symmetrisch um den Nullpunkt liegen und der Integrand gerade ist, können wir zweimal über das halbe Intervall integrieren. Zur Übersicht betrachten

wir vorerst nur noch das Integral und fügen später wieder alles zusammen. Folglich gilt

$$\int_{-1}^1 u^{2\ell} \sqrt{1-u^2} \, du = 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} \, du.$$

Wenn wir jetzt u mit $\sqrt{w}$ substituieren,

$$\begin{aligned} 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} \, du &= \int_0^1 w^\ell \sqrt{1-w} \frac{1}{\sqrt{w}} \, dw \\ &= \int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} \, dw \end{aligned}$$

erhalten wir ein Integral, das wir mittels Eulerscher Betafunktion lösen können [2, S. 19].

Die Eulersche Betafunktion ist durch

$$\int_0^1 t^{p-1} (1-t)^{q-1} \, dt = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

gegeben. Wir können also mit $p = \ell + \frac{1}{2}$ und $q = 1 + \frac{1}{2}$ das Integral durch die Gammafunktionen

$$\begin{aligned} \int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} \, dw &= \frac{\Gamma(\ell + \frac{1}{2})\Gamma(1 + \frac{1}{2})}{\Gamma(\ell + 2)} \\ &= \frac{1}{(\ell + 1)!} \left(\frac{(2\ell)! \sqrt{\pi}}{\ell! 4^\ell} \frac{2! \sqrt{\pi}}{4} \right) \\ &= \frac{1}{(\ell + 1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right) \end{aligned} \tag{0.7}$$

beschreiben. Nach Einsetzen von (0.7) in die wieder zusammengefügte Gleichung, erhalten wir

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right) \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{1}{2\pi y} \frac{(k-1)!}{(2\ell)!(k-1-2\ell)!} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{2\ell! 4^\ell} \pi \right). \end{aligned}$$

Nach dem Kürzen der Brüche erhalten wir

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell (1+y)^{k-1-2\ell}.$$

Wenn wir den binomischen Lehrsatz mit

$$\begin{aligned} (1+y)^{k-1-2\ell} &= \sum_{s=0}^{k-1-2\ell} \binom{k-1-2\ell}{s} y^s \\ &= \sum_{s=0}^{k-1-2\ell} \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s \end{aligned}$$

einsetzen, haben wir

$$\begin{aligned} \beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!s!(k-1-2\ell-s)!} y^{\ell+s}. \end{aligned}$$

Jetzt wollen wir den Term wieder vereinfachen. Dafür setzen wir $s = r - \ell$, wodurch wir

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} y^r$$

erhalten und erweitern mit zwei Einsen, wodurch

$$\begin{aligned} \beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} \frac{r!}{r!} \frac{(k-r)!}{(k-r)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{r!(k-r)!} \frac{r!}{\ell!(r-\ell)!} \frac{(k-r)!}{(k-r-\ell-1)!(\ell+1)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \frac{k!}{r!(k-r)!} \frac{r!}{\ell!(r-\ell)!} \frac{(k-r)!}{(\ell+1)!(k-r-(\ell+1))!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r \end{aligned}$$

gilt. Für den nächsten Schritt müssen wir die Laufvariablen von 0 starten lassen. Momentan haben wir erst das ℓ und ermitteln damit, inwieweit das r eingeschränkt ist. Für ein festes, aber beliebiges k liegen unsere Laufvariablen in

$$A = \left\{ (\ell, r) \in \mathbb{N}^2 \mid 0 \leq \ell \leq \left\lfloor \frac{k-1}{2} \right\rfloor, \ell \leq r \leq k-1-\ell \right\}.$$

Daraus wissen wir, dass

$$0 \leq \ell \quad \text{und} \quad r \leq k-1-\ell$$

gilt, woraus wir

$$\ell \leq k-1-r$$

folgern können. Damit erhalten wir

$$\begin{aligned} 0 \leq \ell \leq r \leq k-1-\ell \leq k-1 \\ \implies 0 \leq r \leq k-1, \quad 0 \leq \ell \leq \min(r, k-1-r). \end{aligned}$$

Folglich können wir die Summen äquivalent über

$$A = \{ (\ell, r) \in \mathbb{N}^2 \mid 0 \leq r \leq k-1, 0 \leq \ell \leq \min(r, k-1-r) \} \quad (0.8)$$

laufen lassen.

Wir erhalten mit (0.8)

$$\begin{aligned} \beta_k &= \sum_{r=0}^{k-1} \sum_{\ell=0}^{\min(r, k-1-r)} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{\min(r, k-1-r)} \binom{r}{\ell} \binom{k-r}{\ell+1}. \end{aligned}$$

Das Minimum können wir noch weiter vereinfachen, da die Summanden gleich 0 sind, sobald $\ell > r$ oder $\ell > k-1-r$ ist. Wenn wir die Summe also bis r laufen lassen, ändern wir nichts am Ergebnis, wodurch wir den k -ten Moment schreiben können als

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^r \binom{r}{\ell} \binom{k-r}{\ell+1}.$$

An diesem Punkt müssen wir nur noch die innere Summe vereinfachen. Dafür machen

wir eine Indexverschiebung und formen die Binomialkoeffizienten um. Wir haben

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{\ell-1} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{r-(\ell-1)} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell}.
\end{aligned}$$

Hier nutzen wir die Vandermonde Identität [1, S. 16]. Diese ist durch

$$\sum_{\ddot{o}=0}^{\ddot{u}} \binom{n}{\ddot{o}} \binom{m}{\ddot{u}-\ddot{o}} = \binom{n+m}{\ddot{u}} \quad (0.9)$$

gegeben. Um die Vandermonde Identität nutzen zu können, lassen wir die Summe von $\ell = 0$ beginnen, da der zusätzliche Summand das Ergebnis nicht ändert. Mit der Identität (0.9) erhalten wir

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \frac{r+1}{r+1} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r.
\end{aligned}$$

□

0.3 Hilfsmittel für den Konvergenzbeweis

Im Beweis über die Konvergenz der empirischen Spektralverteilung benutzen wir Elemente aus der Graphentheorie und der Stochastik, die wir vorher noch einführen.

Dafür definieren wir eine Klasse von *gerichteten Graphen*. Wir weisen den Kanten also eine Richtung zu.

Die Graphen haben die folgenden Eigenschaften.

Die Knotenmenge der Graphen ist in $\mathbf{i}$ -Knoten und $\mathbf{j}$ -Knoten unterteilt. Sei k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten mit der Gestalt $\mathbf{i} = \{i_1, \dots, i_k\}$ beziehungsweise $\mathbf{j} = \{j_1, \dots, j_k\}$. Dabei nehmen $\mathbf{i}$ -Knoten Werte in $\{0, \dots, p\}$ und $\mathbf{j}$ -Knoten Werte in $\{0, \dots, n\}$ an. Wenn unterschiedliche $\mathbf{i}/\mathbf{j}$ -Knoten den gleichen Wert annehmen, bezeichnen wir sie als *koinzident*. Wir betrachten koinzidente Knoten als *einen* Knoten mit mehreren Namen.

Nehmen wir zum Beispiel für die Knoten i_2 und i_5 den gleichen Wert x an, haben wir einen Knoten, welchen wir sowohl i_2 als auch i_5 nennen, was für die Eigenschaften der Kanten wichtig wird.

Zusätzlich gilt, wenn beispielsweise alle $\mathbf{i}$ -Knoten den Wert p und alle $\mathbf{j}$ -Knoten den Wert n annehmen, dass es entsprechend $2k$ Kanten zwischen den zwei Knoten gibt, da wir je k koinzidente $\mathbf{i}/\mathbf{j}$ -Knoten haben.

Alle Kanten unterliegen den folgenden Regeln. Die Kanten laufen von Knoten i_m zu j_m und von j_m zu i_{m+1} mit $m = 1, \dots, k$ und der Konvention, dass es einen weiteren Knoten i_{k+1} gibt, der den Graphen abschließt und für den $i_{k+1} = i_1$ gilt.

Sei $\hat{r}$ die Anzahl nicht koinzidenter $\mathbf{i}$ -Knoten, dann ist $r = \hat{r} - 1$ und s die Anzahl nicht koinzidenter $\mathbf{j}$ -Knoten. Da k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten ist, ist k auch die Anzahl an Kanten, die auf $\mathbf{i}$ -Knoten zeigen.

Diese Graphen bezeichnen wir dann als $\Delta(k, r, s)$. Für den Beweis teilen wir die Graphen in drei Kategorien ein.

$\Delta_1(k, r, s)$: Diese Kategorie fasst alle Graphen zusammen, die zu jeder Kante von $\mathbf{i}$ nach $\mathbf{j}$ genau eine Kante vom gleichen $\mathbf{j}$ -Knoten zum gleichen $\mathbf{i}$ -Knoten haben. Hier gilt $r + s = k$.

$\Delta_2(k, r, s)$: Diese Kategorie beinhaltet alle Graphen, die zwischen zwei Knoten mindestens einmal genau eine Kante besitzen, also Graphen, die mindestens eine *Einzelkante* besitzen.

$\Delta_3(k, r, s)$: Die letzte Kategorie $\Delta_3(k, r, s)$ sind alle Graphen die weder in $\Delta_1(k, r)$ noch in $\Delta_2(k, r, s)$ gehören.




Abbildung 1: Beispiel für Graphen

Für bessere Lesbarkeit schreiben wir für die Kategorien $\Delta_i(k, r, s)$ nur noch Δ_i , wobei $i \in 1, 2, 3$. Wir bezeichnen zwei Graphen als isomorph, wenn wir für die i/j -Knoten eine geeignete Zuweisung von Werten finden so, dass die Graphen identisch sind.




Abbildung 2: Beispiel für Isomorphie

Beispiel 0.10. Graph a) ist isomorph zu b), da wir die Werte von zwei Knoten ändern können und einen identischen Graphen erhalten. Graph c) ist aber nicht isomorph zu a), da wir zusätzlich noch die Indizes der Knotennamen tauschen müssten, was aber nicht geht, da der Knoten fest ist.

Für die Graphen haben wir noch ein paar Lemmata.

Lemma 0.11 ([3, S. 43]). Die Anzahl der Graphen in jeder Isomorphieklasse von $\Delta(k, r, s)$ Graphen, mit festen k , r und s , ist

$$\alpha = p(p-1) \cdots (p-r)n(n-1) \cdots (n-s+1) = p^{r+1}n^s \left(1 + \mathcal{O}\left(\frac{1}{n}\right)\right).$$

Lemma 0.12 ([3, S. 43]). Die Anzahl nicht koinzidenter Knoten von $\Delta_3(k, r, s)$ Graphen, also $r+s$, ist kleiner gleich k .

Lemma 0.13 ([3, S. 43]). Die Anzahl nicht-isomorpher $\Delta_1(k, r, s)$ Graphen für festes g und r beträgt

$$\frac{1}{r+1} \binom{k}{r} \binom{k-1}{r}.$$

Aus der Stochastik benötigen wir einmal das starke Gesetz der großen Zahlen und eine Metrik für Wahrscheinlichkeitsverteilungen.

Satz 0.14 (Starkes Gesetz der großen Zahlen [5, S. 139]). Seien $\{\mathcal{Z}_i\}_{i \in \mathbb{N}}$ unabhängige und identisch verteilte Zufallsvariablen, die einen Moment erster Ordnung besitzen, dann gilt

$$\frac{1}{n} \sum_{i=1}^n \mathcal{Z}_i \xrightarrow[n \rightarrow \infty]{\text{f.s.}} \mathbb{E}(\mathcal{Z}_1).$$

Definition 0.15 (Lévy-Metrik [5, S. 164]). Seien F_1 und F_2 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ mit zugehörigen Verteilungsfunktionen $\mathbf{F}_1$ und $\mathbf{F}_2$. Dann ist die *Lévy-Metrik* definiert durch

$$\mathcal{L}(F_1, F_2) = \inf\{\varepsilon > 0, x \in \mathbb{R}: \mathbf{F}_1(x - \varepsilon) - \varepsilon \leq \mathbf{F}_2(x) \leq \mathbf{F}_1(x + \varepsilon) + \varepsilon\}.$$

Für den Beweis benutzen wir die Eigenschaft aus dem folgenden Lemma.

Lemma 0.16 ([3, S. 502]). Seien $A, B \in \mathbb{C}^{p \times n}$ und $S = AA^H$, $\bar{S} = BB^H$. Dann gilt für die Lévy-Metrik

$$\mathcal{L}^4(F^S, F^{\bar{S}}) \leq \frac{2}{p^2} \text{tr}(AA^H + BB^H) \text{tr}((A-B)(A-B)^H).$$

0.4 Konvergenzsatz und Beweis

Kommen wir nun zum Satz über die Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung.

Satz 0.17. Seien $\{\mathbf{X}_\eta\}$ eine Folge an $p_\eta \times n_\eta$ Zufallsmatrizen wie in Definition 0.2 beschrieben und ihre Einträge $\{x_{ij}\}$ mit $i = 1, \dots, p_\eta$ und $j = 1, \dots, n_\eta$ unabhängig und identisch verteilte komplexe Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2 . Sei weiter p_η und n_η monoton steigend mit η und $\lim_{\eta \rightarrow \infty} \frac{p_\eta}{n_\eta} = y \in (0, \infty)$.

Dann konvergiert die empirische Spektralverteilung der Stichproben-Kovarianzmatrix $F^{\mathbf{S}_\eta}$ mit $\eta \rightarrow \infty$ fast sicher gegen die Marčenko–Pastur–Verteilung F_y , wie sie in Kapitel 0.2 beschrieben wurde.

Im folgenden Beweis nehmen wir mit Lemma 0.6 ohne Beschränkung der Allgemeinheit an, dass die Varianz $\sigma^2 = 1$ ist, wir also den Standardfall betrachten.

Wir zeigen die schwache Konvergenz der empirischen Spektralverteilung gegen die Marčenko–Pastur–Verteilung mithilfe der Momentmethode.

Nach der Momentmethode konvergiert eine Folge an Wahrscheinlichkeitsverteilungen $\{F_n\}$, wenn ihre Momente $\beta_{n,k}$ jeder Ordnung $k \geq 0$ endlich sind und gegen einen Grenzwert β_k konvergieren, schwach gegen eine Wahrscheinlichkeitsverteilung, die eindeutig von ihren Momenten β_k bestimmt sein muss [3, S. 507]. Mit dem Beweis von Lemma 0.8 haben wir bereits gezeigt, dass die Momente der Marčenko–Pastur–Verteilung die Carleman-Bedingung 0.7 und damit die Eindeutigkeit erfüllen.

Beweis. Die Momentmethode verlangt, dass die Momente jeder Ordnung der Verteilung endlich sind. Um das garantieren zu können, müssen wir dafür sorgen, dass die Zufallsvariablen $\{x_{ij}\}$ nicht unendlich groß werden können.

Seien $C \in \mathbb{R}_+$ und $\mathbf{1}$ die Indikatorfunktion auf $\mathbb{R}$, dann beschränken wir $\{x_{ij}\}$ und definieren die beschränkte Stichproben-Kovarianzmatrix $\hat{\mathbf{S}}_\eta$ durch

$$\begin{aligned}\hat{x}_{ij} &:= x_{ij} \mathbf{1}(|x_{ij}| \leq C), \\ \hat{x}_i &:= (\hat{x}_{i1}, \dots, \hat{x}_{in_\eta})^\top, \\ \hat{\mathbf{S}}_\eta &:= \frac{1}{n_\eta} \sum_{i=1}^{n_\eta} \hat{x}_i \hat{x}_i^H = \frac{1}{n_\eta} \hat{\mathbf{X}}_\eta \hat{\mathbf{X}}_\eta^H.\end{aligned}$$

Da das Beschränken die Erwartungswerte verändert hat, müssen wir $\hat{x}_{ij}$ noch zentralisieren, indem wir die Erwartungswerte von den Zufallsvariablen abziehen. Für die zentralisierten Zufallsvariablen und die entsprechende Stichproben-Kovarianzmatrix erhalten

wir

$$\begin{aligned}\tilde{x}_{ij} &:= \hat{x}_{ij} - \mathbb{E}(\hat{x}_{11}), \\ \tilde{x}_i &:= (\tilde{x}_{i1}, \dots, \tilde{x}_{ip_\eta})^\top, \\ \tilde{\mathbf{S}}_\eta &:= \frac{1}{n_\eta} \sum_{i=1}^{n_\eta} \tilde{x}_i \tilde{x}_i^H = \frac{1}{n_\eta} \tilde{\mathbf{X}}_\eta \tilde{\mathbf{X}}_\eta^H.\end{aligned}$$

Wir bezeichnen ab hier alle $\mathbf{X}_\eta$ als $\mathbf{X}$. Mit $\hat{\mathbf{S}}_\eta$ und $\tilde{\mathbf{S}}_\eta$ haben wir die beschränkte und zentralisierte Stichproben Kovarianzmatrix.

Im Folgenden wollen wir zeigen, dass sich durch das Beschränken und Zentralisieren der Grenzwert nicht ändert. Nach Lemma 0.16 erhalten wir

$$\begin{aligned}\mathcal{L}^4(F^{\mathbf{S}}, F^{\hat{\mathbf{S}}_\eta}) &\leq \frac{2}{n_\eta p_\eta} \operatorname{tr}(\mathbf{X} \mathbf{X}^H + \hat{\mathbf{X}} \hat{\mathbf{X}}^H) \operatorname{tr}((\mathbf{X} - \hat{\mathbf{X}})(\mathbf{X} - \hat{\mathbf{X}})^H) \\ &= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} x_{ij} \bar{x}_{ij} + \hat{x}_{ij} \bar{\hat{x}}_{ij} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} (x_{ij} - \hat{x}_{ij}) \overline{(x_{ij} - \hat{x}_{ij})} \right) \\ &= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 + |\hat{x}_{ij}|^2 \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |x_{ij} - \hat{x}_{ij}|^2 \right) \\ &\leq \left(\frac{4}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |x_{ij}|^2 \mathbf{1}(|x_{ij}| > C) \right) \\ &\stackrel{(0.14) \text{ f.s.}}{\longrightarrow} 4 \mathbb{E}(|x_{ij}|^2) \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\stackrel{\text{f.s.}}{\longrightarrow} 4 \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\stackrel{C \rightarrow \infty}{\longrightarrow} 0.\end{aligned}$$

Der Abstand der empirischen Spektralverteilung und ihrer beschränkten Version ist also für ein hinreichend großes C vernachlässigbar klein. Nach Satz 0.4 können wir durch

$$\begin{aligned}\left\| F^{\hat{\mathbf{S}}_\eta} - F^{\tilde{\mathbf{S}}_\eta} \right\|_\infty &\leq \frac{1}{p_\eta} \operatorname{rang}(\hat{\mathbf{X}} - \tilde{\mathbf{X}}) \\ &= \frac{1}{p_\eta} \operatorname{rang}(\mathbb{E}(\hat{x}_{11})) \\ &= \frac{1}{p_\eta}\end{aligned}$$

sehen, dass das Entfernen des Erwartungswertes, also die Zentralisierung der Zufallsva-

riablen, auch keinen Einfluss auf die Konvergenz hat.

Die Verteilung wurde jetzt so modifiziert, dass die Zufallsvariablen nicht mehr unendlich groß werden können und den Erhalt des Erwartungswertes garantiert, ohne die Konvergenz zu beeinträchtigen.

Wir müssen aber noch dafür sorgen, dass die Varianz erhalten bleibt. Dafür müssen wir zeigen, dass durch Skalierung von $\tilde{\mathbf{S}}_\eta$ mit $\tilde{\sigma}^2 = \mathbb{E}(|\tilde{x}_{ij}|^2) \rightarrow 1$, wenn $C \rightarrow \infty$ gilt, der Abstand zu $\tilde{\mathbf{S}}_\eta$ wieder vernachlässigbar klein wird.

Es gilt wieder mit Lemma 0.16

$$\begin{aligned}
\mathcal{L}^4(F^{\tilde{\mathbf{S}}_\eta}, F^{\tilde{\sigma}^{-2}\tilde{\mathbf{S}}_\eta}) &\leq \frac{2}{n_\eta} \operatorname{tr} \left(\tilde{\mathbf{X}} \tilde{\mathbf{X}}^H + \frac{1}{\tilde{\sigma}^2} \tilde{\mathbf{X}} \tilde{\mathbf{X}}^H \right) \operatorname{tr} \left(\left(1 - \frac{1}{\tilde{\sigma}} \right)^2 \tilde{\mathbf{X}} \tilde{\mathbf{X}}^H \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H - \frac{2\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}} + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} |\tilde{x}_{ij}|^2 + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} |\tilde{x}_{ij}|^2 - \frac{2|\tilde{x}_{ij}|^2}{\tilde{\sigma}} + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\
&= \left(\frac{2}{n_\eta p_\eta} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{n_\eta p_\eta} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 - \tilde{\sigma} 2|\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\
&= 2 \left(\frac{\tilde{\sigma}^2 + 1}{n_\eta p_\eta \tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \left(\frac{(\tilde{\sigma} - 1)^2}{n_\eta p_\eta \tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \\
&\xrightarrow{\text{f.s.}} 2 \frac{\tilde{\sigma}^2 + 1}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \frac{(\tilde{\sigma} - 1)^2}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \\
&\xrightarrow{C \rightarrow \infty} 0.
\end{aligned}$$

Damit haben wir die Endlichkeit der Momente aller Ordnungen garantiert. Für einen besseren Überblick verwenden wir weiterhin die Notation von $\mathbf{S}_\eta$ und $\mathbf{X}$, verwenden aber die modifizierten Matrizen. Wir haben also eine gleichmäßig durch C beschränkte Zufallsvariable x_{ij} mit Erwartungswert 0 und Varianz 1.

Nach Definition 0.1 erhalten wir

$$\begin{aligned}
\beta_{\eta,k}(\mathbf{S}_\eta) &= \int_{-\infty}^{\infty} x^k dF^{\mathbf{S}_\eta}(x) \\
&= \frac{1}{p_\eta} \operatorname{tr} \left(\mathbf{S}_\eta^k \right) \\
&= \frac{1}{p_\eta n_\eta^k} \operatorname{tr} \left((\mathbf{X} \mathbf{X}^H)^k \right)
\end{aligned}$$

für die Momente der empirischen Spektralverteilung.

Hier verwenden wir die oben eingeführte Klasse von Graphen. Wir können die Spur nämlich mit $\mathbf{i} = \{i_1, \dots, i_k\}$ und $\mathbf{j} = \{j_1, \dots, j_k\}$, wobei die Elemente von $\mathbf{i}$ in $\{1, \dots, p_\eta\}$ und $\mathbf{j}$ in $\{1, \dots, n_\eta\}$ liegen, durch

$$\frac{1}{p_\eta n_\eta^k} \operatorname{tr} \left((\mathbf{X} \mathbf{X}^H)^k \right) = \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k}$$

beschreiben. Dabei sind $x_{i_1 j_1} \bar{x}_{i_2 j_1} \dots$ die Produkte der einzelnen Summanden der Spur und wir summieren über alle Permutationen von $\mathbf{i}$ und $\mathbf{j}$. Die Zufallsvariablen x_{ij} stellen die Kanten von $\mathbf{i}$ -Knoten zu $\mathbf{j}$ -Knoten und $\bar{x}_{ij}$ Kanten von $\mathbf{j}$ -Knoten zu $\mathbf{i}$ -Knoten dar. Wir definieren dann

$$\frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k} =: \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbf{X}_{\Delta(k, r, s)}.$$

Nach der Momentmethode konvergiert die empirische Spektralverteilung schwach gegen die Marčenko–Pastur–Verteilung, wenn die Momente der empirischen Spektralverteilung gegen die Momente der Marčenko–Pastur–Verteilung konvergieren. Das zeigen wir, indem wir den Erwartungswert und die Varianz der Momente der empirischen Spektralverteilung bestimmen. Sie konvergieren, wenn der Erwartungswert $\mathbb{E}(\beta_k(\mathbf{S}_\eta))$ gegen die Momente der Marčenko–Pastur–Verteilung läuft und die Varianz gegen null geht.

Fangen wir an mit dem Erwartungswert. Es gilt

$$\mathbb{E}(\beta_k(\mathbf{S}_\eta)) = \frac{1}{p_\eta n_\eta^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbb{E}(\mathbf{X}_{\Delta(k, r, s)}).$$

Teilen wir die Graphen in ihre Kategorien, wie in Kapitel Hilfsmittel für den Konvergenzbeweis 0.3 beschrieben, ein, erhalten wir mit Lemma 0.11

$$\mathbb{E}(\beta_k(\mathbf{S}_\eta)) = \frac{1}{p_\eta n_\eta^k} \left(\overbrace{\sum_{\Delta_1} \alpha \mathbb{E}(\mathbf{X}_{\Delta_1})}^{W_1 :=} + \overbrace{\sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2})}^{W_2 :=} + \overbrace{\sum_{\Delta_3} \alpha \mathbb{E}(\mathbf{X}_{\Delta_3})}^{W_3 :=} \right).$$

Für W_1 erhalten wir mit $s = k - r$ und nach Lemma 0.11 und Lemma 0.12

$$W_1 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p_\eta^{r+1} n_\eta^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right) \right) \mathbb{E}(\mathbf{X}_{\Delta_1}).$$

Da es zu jeder Kante genau eine Kante in die entgegengesetzte Richtung gibt, gilt $\mathbb{E}(|x_{ij}|^2) = 1$. Wir können W_1 also schreiben als

$$\begin{aligned}
W_1 &= \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p_\eta^{r+1} n_\eta^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} \frac{p_\eta^{r+1} n_\eta^{k-r}}{n_\eta^k p_\eta} \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r \left(1 + \mathcal{O}\left(\frac{1}{p_\eta}\right)\right) \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p_\eta}\right). \tag{0.10}
\end{aligned}$$

Für W_2 können wir den Erwartungswert in

$$W_2 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2})$$

aufteilen. Da sich Δ_2 -Graphen dadurch auszeichnen, dass sie mindestens eine Einzelkante besitzen, existiert mindestens ein Exponent $\omega_i \in \mathbb{N}$ in

$$\mathbb{E}(\mathbf{X}_{\Delta_2}) = \mathbb{E}(x_{i_1 j_1}^{\omega_1}) \mathbb{E}(x_{i_2 j_1}^{\omega_2}) \dots$$

welches gleich 1 ist. Da der Erwartungswert der Zufallsvariablen $x_{i_m j_m}$ gleich 0 ist, folgt daraus, dass $\mathbb{E}(x_{i_m j_m}^1) = 0 = \mathbb{E}(\mathbf{X}_{\Delta_2})$ gilt. Für W_2 ergibt sich dann

$$W_2 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_2} \alpha \mathbb{E}(\mathbf{X}_{\Delta_2}) = 0. \tag{0.11}$$

Für W_3 erhalten wir wieder mit Lemma 0.11, dass

$$W_3 = \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_3} \alpha \mathbb{E}(\mathbf{X}_{\Delta_3})$$

gilt. Weiter oben haben wir gezeigt, dass x_{ij} gleichmäßig durch ein $C > 0$ beschränkt ist. Daraus erhalten wir, dass $|X_{\Delta(k,r,s)}| \leq C^{2k}$ gilt. Mit Lemma 0.12 wissen wir, dass die Anzahl nicht koinzidenter Knoten maximal k betragen kann. Dadurch ist die Anzahl

unterschiedlicher Δ_3 Graphen in $\mathcal{O}(n^k)$. Wir haben also

$$\begin{aligned} \frac{1}{n_\eta^k p_\eta} \sum_{\Delta_3} \alpha(\mathbf{X}_{\Delta_3}) &= \frac{C^{2k}}{n_\eta^k p_\eta} \mathcal{O}(n_\eta^k) \\ &= \mathcal{O}\left(\frac{1}{p_\eta}\right). \end{aligned} \quad (0.12)$$

Mit (0.10), (0.11) und (0.12) erhalten wir dann

$$\begin{aligned} \mathbb{E}(\beta_k(\mathbf{S}_\eta)) &= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p_\eta}\right) \\ &= \beta_k(y, \sigma^2) + o(1). \end{aligned} \quad (0.13)$$

Der Erwartungswert der Momente konvergiert folglich gegen die Momente der Marčenko–Pastur–Verteilung plus einen vernachlässigbar kleinen Term, da p_η gegen unendlich läuft. Jetzt fehlt noch die Varianz. Für diese gilt

$$\text{Var}(\beta_k(\mathbf{S}_\eta)) := \frac{1}{p_\eta n_\eta^k} \sum_{i,j} (\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) - \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)})).$$

Dabei sind Δ_a und Δ_b zwei Graphen mit unterschiedlichen Permutationen von $\mathbf{i}$ und $\mathbf{j}$. Wie für den Erwartungswert suchen wir uns Kategorien, um die Varianz stückweise zu beschreiben.

Als Erstes betrachten wir alle Graphen Δ_a und Δ_b so, dass Δ_a und Δ_b unabhängig sind, sich also keine Kanten teilen. Daraus folgt direkt durch Rechenregeln von Erwartungswerten, dass

$$\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) = \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)})$$

gilt. Das heißt, für unabhängige Graphen ist die Varianz gleich 0.

Als Nächstes betrachten wir alle Graphen Δ_a und Δ_b , die mindestens eine Einzelkante besitzen. Damit erhalten wir wie in (0.11) wieder

$$\mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)} \mathbf{X}_{\Delta_b(k,r,s)}) = 0 = \mathbb{E}(\mathbf{X}_{\Delta_a(k,r,s)}) \mathbb{E}(\mathbf{X}_{\Delta_b(k,r,s)}).$$

In allen anderen Möglichkeiten haben die Graphen keine Einzelkante und Δ_a und Δ_b teilen sich Kanten. Analog zu W_3 können wir sagen, dass die Anzahl möglicher Graphen in $\mathcal{O}(n_\eta^k)$ liegt. Da wir zwei Graphen Δ_a und Δ_b betrachten, liegt die Anzahl möglicher

Graphen in $\mathcal{O}(n_\eta^{2k})$. Durch die gleichmäßige Beschränkung von x_{ij} durch C können wir die Varianz durch

$$\begin{aligned}\mathrm{Var}(\beta_k(\mathbf{S}_\eta)) &\leq \frac{1}{p_\eta^2 n_\eta^{2k}} C \mathcal{O}(n_\eta^{2k}) \\ &= \mathcal{O}\left(\frac{1}{p_\eta^2}\right)\end{aligned}\tag{0.14}$$

abschätzen. Da p_η gegen unendlich läuft, wird die Varianz vernachlässigbar klein.

Mit dem Erwartungswert (0.13) und der Varianz (0.14) können wir darauf schließen, dass die empirische Spektralverteilung fast sicher gegen die Marčenko–Pastur–Verteilung konvergiert. $\square$