

Die Marčenko-Pastur-Verteilung ist ein Wahrscheinlichkeitsmaß, dass die asymptotische empirische Spektralverteilung der Eigenwerte von großen Stichproben-Kovarianzmatrizen beschreibt. Das Ziel dieses Kapitels ist es zu zeigen, dass die empirische Spektralverteilung schwach gegen die Marčenko-Pastur-Verteilung konvergiert.

Dieses Kapitel basiert auf dem Buch „Spectral analysis of large dimensional random matrices“ von Zhidong Bai und Jack W. Silverstein [1].

0.1 Vorbereitung

Wir beginnen damit die empirische Spektralverteilung einmal konkret zu definieren.

Definition 0.1. Sei S eine $p \times p$ große hermitesche Matrix mit Eigenwerten λ_i mit $i = 1, \dots, p$ dann definieren wir durch

$$F^S(x) = \frac{1}{p} |A_x| \quad \text{mit } A_x := \{i \leq p : \lambda_i \leq x\}$$

die *empirische Spektralverteilung* F^S .

Die Konvergenz betrachten wir in dem Sinne, dass wir analysieren, wie sich die Verteilung verhält, wenn wir immer größere Matrizen betrachten, also p gegen unendlich laufen lassen.

mehr zu StichKovar?!

Sei $\mathbf{X}$ eine $p \times n$ große Matrix, dessen Elemente unabhängig und identisch verteilte Zufallsvariablen sind. Dabei sind ihre Erwartungswerte 0 und ihre Varianz bezeichnen wir mit σ^2 . Weiter sind $x_k = (x_{1k}, \dots, x_{pk})^\top$, $\mathbf{X} = (x_1, \dots, x_n)$ und $\bar{x} = \frac{1}{n} \sum_{k=1}^n x_k$. Dann ist die Stichproben-Kovarianzmatrix

$$S = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})(x_k - \bar{x})^H \in \mathbb{R}^{p \times p}. \quad (0.1)$$

Durch folgenden Satz können wir die Stichproben-Kovarianzmatrix noch weiter vereinfachen.

Satz 0.2 ([1, S. 503]). Seien $A, B \in \mathbb{C}^{p \times n}$. Dann gilt

$$\left\| F^{AA^H} - F^{BB^H} \right\|_\infty \leq \frac{1}{p} \text{rang}(A - B).$$

Schreiben wir S als

$$\begin{aligned}
S &= \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})(x_k - \bar{x})^H \\
&= \frac{1}{n} \left(\sum_{k=1}^n x_k x_k^H - \sum_{k=1}^n x_k \bar{x}^H - \sum_{k=1}^n x_k^H \bar{x} + \sum_{k=1}^n \bar{x} \bar{x}^H \right) \\
&= \frac{1}{n} \left(\sum_{k=1}^n x_k x_k^H - n \bar{x} \bar{x}^H \right) \\
&= \frac{1}{n} X X^H - \bar{x} \bar{x}^H
\end{aligned}$$

und beschreiben $\mathbf{S}$ durch

$$\begin{aligned}
\mathbf{S} &= \frac{1}{n} \sum_{k=1}^n x_k x_k^H \\
&= \frac{1}{n} X X^H .
\end{aligned} \tag{0.2}$$

Mit Satz 0.2 können wir durch

$$\begin{aligned}
\|F^S - F^{\mathbf{S}}\|_{\infty} &\leq \frac{1}{p} \text{rang}(X - \bar{x} \bar{x}^H - X) \\
&= \frac{1}{p} \text{rang}(\bar{x} \bar{x}^H) \\
&= \frac{1}{p}
\end{aligned}$$

zeigen, dass $\bar{x} \bar{x}^H$ keinen Einfluss auf die Konvergenz von F^S hat. Wir verwenden daher die vereinfachte Form $\mathbf{S}$ für die Stichproben-Kovarianzmatrix.

0.2 Marčenko-Pastur-Momente

Mit dem Dimensions-Stichproben-Verhältnis $y = \frac{p}{n}$, ist die Marčenko-Pastur-Verteilung F_y ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Für $y, \sigma^2 \in (0, \infty)$ und $x \in \mathbb{R}$ sind

$$a = \sigma^2 (1 - \sqrt{y})^2 \quad \text{und} \quad b = \sigma^2 (1 + \sqrt{y})^2 .$$

Die Dichtefunktion der Marčenko-Pastur-Verteilung ist dann durch

$$p_y(x) = \begin{cases} \frac{1}{2\pi xy\sigma^2} \sqrt{(b-x)(x-a)}, & \text{wenn } a \leq x \leq b \\ 0, & \text{sonst} \end{cases} \quad (0.3)$$

definiert. Wenn $\sigma^2 = 1$ ist, dann sprechen wir von der Standard-M-P-Verteilung. Die k -ten Momente der M-P-Verteilung sind durch

$$\beta_k(y, \sigma^2) := \int_a^b x^k p_y(x) dx \quad (0.4)$$

definiert. Wir können die Momente der M-P-Verteilung durch ihren Standardfall beschreiben, was wir im folgenden Lemma zeigen.

Lemma 0.3. Für alle $k \geq 1$ gilt

$$\beta_k(y, \sigma^2) = \sigma^{2k} \beta_k(y, 1) =: \beta_k.$$

Beweis. Nach (0.4) und 0.3 haben wir

$$\begin{aligned} \beta_k(y, \sigma^2) &= \int_a^b x^k p_y(x) dx \\ &= \int_{\sigma^2(1-\sqrt{y})^2}^{\sigma^2(1+\sqrt{y})^2} x^k \frac{1}{2\pi xy\sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - x)(x - \sigma^2(1-\sqrt{y})^2)} dx. \end{aligned}$$

Substituieren wir mit $x = u\sigma^2$ erhalten wir

$$\begin{aligned} \beta_k(y, \sigma^2) &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} (u\sigma^2)^k \frac{1}{2\pi uy\sigma^2} \sqrt{(\sigma^2(1+\sqrt{y})^2 - u\sigma^2)(u\sigma^2 - \sigma^2(1-\sqrt{y})^2)} du \\ &= \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \sigma^{2k} \frac{1}{2\pi uy\sigma^2} \sqrt{\sigma^4((1+\sqrt{y})^2 - u)(u - (1-\sqrt{y})^2)} du \\ &= \sigma^{2k} \int_{(1-\sqrt{y})^2}^{(1+\sqrt{y})^2} u^k \frac{1}{2\pi uy} \sqrt{((1+\sqrt{y})^2 - u)(u - (1-\sqrt{y})^2)} du \\ &= \sigma^{2k} \beta_k(y, 1). \end{aligned}$$

Die Momente lassen sich also durch σ^{2k} skaliert über die Standard-M-P-Verteilung beschreiben. $\square$

Damit können wir dann zeigen, dass die Marčenko-Pastur-Verteilung eindeutig durch die Momente β_k bestimmt wird und wie die Momente explizit bestimmt aussehen.

Lemma 0.4 (Carleman [1, S. 509]). Sei $\{\beta_k = \beta_k(F)\}_{k \in \mathbb{N}_0}$ die Folge von Momenten der Verteilungsfunktion F . Ist die *Carleman-Bedingung*

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} = \infty$$

erfüllt, dann wird die Verteilung F durch $\{\beta_k\}_{k \in \mathbb{N}_0}$ eindeutig bestimmt.

Dass β_k die Marčenko-Pastur-Verteilung eindeutig bestimmt, lässt sich dann mit Lemma 0.4 zeigen. Wir sehen einmal nach (0.4) und (0.3), dass wir β_{2k} durch

$$\begin{aligned} \beta_{2k} &= \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-x)(x-a)} dx \\ &\leq \frac{1}{2\pi y} \int_a^b x^{2k-1} \sqrt{(b-a)(b-a)} dx \\ &= \frac{1}{2\pi y} \int_a^b x^{2k-1} (b-a) dx \\ &= \frac{1}{4k\pi y} (b^{2k} - a^{2k}) (b-a) \\ &= \frac{1}{k\pi\sqrt{y}} (b^{2k} - a^{2k}) \\ &\leq \frac{1}{k\pi\sqrt{y}} b^{2k} \\ &\leq b^{2k} = (1 + \sqrt{y})^{4k} \end{aligned} \tag{0.5}$$

abschätzen können. Mit der Abschätzung (0.5) und Lemma 0.4 haben wir durch

$$\sum_{k=1}^{\infty} \beta_{2k}^{-\frac{1}{2k}} \leq \sum_{k=1}^{\infty} (1 + \sqrt{y})^2 = \infty$$

die Carleman-Bedingung erfüllt, womit wir gezeigt haben, dass die Marčenko-Pastur-Verteilung durch die Momente β_k eindeutig bestimmt ist.

Lemma 0.5. Die explizite Darstellung der Momente ist

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r. \tag{0.6}$$

Beweis. Wir haben nach (0.4) und (0.3)

$$\beta_k = \frac{1}{2\pi y} \int_a^b x^{k-1} \sqrt{(b-x)(x-a)} \, dx.$$

Substituieren wir mit $x = 1 + y + z$ und setzen a und b ein, erhalten wir

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{\left((1+\sqrt{y})^2 - 1 - y - z\right) \left(1+y+z - (1-\sqrt{y})^2\right)} \, dz \\ &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} (1+y+z)^{k-1} \sqrt{4y - z^2} \, dz. \end{aligned}$$

Durch Einsetzen des Binomischen Lehrsatzes lässt sich das Integral zu

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \int_{-2\sqrt{y}}^{2\sqrt{y}} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} z^\ell \sqrt{4y - z^2} \, dz \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-2\sqrt{y}}^{2\sqrt{y}} z^\ell \sqrt{4y - z^2} \, dz \end{aligned}$$

umformen. Um das Integral weiter zu vereinfachen, substituieren wir mit $z = 2\sqrt{y}u$ und erhalten

$$\begin{aligned} \beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} \int_{-1}^1 (2\sqrt{y}u)^\ell \sqrt{4y - 4yu^2} 2\sqrt{y} \, du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{k-1} \binom{k-1}{\ell} (1+y)^{k-1-\ell} (2\sqrt{y})^\ell 4y \int_{-1}^1 u^\ell \sqrt{1-u^2} \, du. \end{aligned}$$

Hier ist unser Integrand ungerade, sofern ℓ ungerade ist. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen, ist das Integral für alle ungeraden ℓ gleich 0. Dadurch ist jeder zweite Summand 0. Wir können also jeden zweiten Summanden überspringen. Dafür lassen wir die Summe bis zur Hälfte von $k-1$ laufen und summieren über 2ℓ statt ℓ . Für den Fall, dass $k-1$ ungerade ist, runden wir ab, weil es dann nur $\frac{k-2}{2}$ Summanden gibt, die ungleich 0 sind. Wir haben also

$$\begin{aligned}\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (2\sqrt{y})^{2\ell} 4y \int_{-1}^1 u^{2\ell} \sqrt{1-u^2} du \\ &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \int_{-1}^1 u^{2\ell} \sqrt{1-u^2} du.\end{aligned}$$

Hier ist der Integrand eine gerade Funktion. Da die Integralgrenzen symmetrisch um den Nullpunkt liegen können wir auch zweimal über das halbe Intervall integrieren. Zur Übersicht betrachten wir vorerst nur noch das Integral und fügen später wieder alles zusammen. Folglich gilt

$$(4y)^{\ell+1} \int_{-1}^1 u^{2\ell} \sqrt{1-u^2} dz = (4y)^{\ell+1} 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} du.$$

Wenn wir jetzt mit $u = \sqrt{w}$ substituieren,

$$\begin{aligned}(4y)^{\ell+1} 2 \int_0^1 u^{2\ell} \sqrt{1-u^2} dz &= (4y)^{\ell+1} \int_0^1 w^\ell \sqrt{1-w} \frac{1}{\sqrt{w}} dw \\ &= (4y)^{\ell+1} \int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} dw\end{aligned}$$

erhalten wir ein Integral, dass wir mittels Eulerschen Betafunktion [Quelle!](#) lösen können. Die Eulersche Betafunktion ist durch

$$\int_0^1 t^{p-1} (1-t)^{q-1} dt = \frac{\Gamma(p)\Gamma(q)}{\Gamma(p+q)}$$

gegeben. Wir können also mit $p = \ell + \frac{1}{2}$ und $q = 1 + \frac{1}{2}$ das Integral durch die Gamma-

funktionen

$$\begin{aligned}
\int_0^1 w^{\ell-\frac{1}{2}} \sqrt{1-w} \, dw &= \frac{\Gamma(\ell+\frac{1}{2})\Gamma(1+\frac{1}{2})}{\Gamma(\ell+2)} \\
&= \frac{1}{(\ell+1)!} \left(\frac{(2\ell)! \sqrt{\pi}}{\ell! 4^\ell} \frac{2! \sqrt{\pi}}{4} \right) \\
&= \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{\ell! 4^\ell} \frac{1}{2} \pi \right)
\end{aligned} \tag{0.7}$$

beschreiben. Nach Einsetzen von (0.7) erhalten wir

$$\begin{aligned}
\beta_k &= \frac{1}{2\pi y} \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \binom{k-1}{2\ell} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{\ell! 4^\ell} \frac{1}{2} \pi \right) \\
&= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{1}{2\pi y} \frac{(k-1)!}{(2\ell)!(k-1-2\ell)!} (1+y)^{k-1-2\ell} (4y)^{\ell+1} \frac{1}{(\ell+1)!} \left(\frac{(2\ell)!}{\ell! 4^\ell} \frac{1}{2} \pi \right).
\end{aligned}$$

Hier lassen sich diverse Variablen so kürzen, dass wir

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell (1+y)^{k-1-2\ell}$$

erhalten. Wenn wir den Binomischen Lehrsatz mit

$$\begin{aligned}
(1+y)^{k-1-2\ell} &= \sum_{s=0}^{k-1-2\ell} \binom{k-1-2\ell}{s} y^s \\
&= \sum_{s=0}^{k-1-2\ell} \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s
\end{aligned}$$

einsetzen, haben wir

$$\begin{aligned}
\beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!(k-1-2\ell)!} y^\ell \frac{(k-1-2\ell)!}{s!(k-1-2\ell-s)!} y^s \\
&= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{s=0}^{k-1-2\ell} \frac{(k-1)!}{\ell!(\ell+1)!s!(k-1-2\ell-s)!} y^{\ell+s}.
\end{aligned}$$

Jetzt wollen wir den Term wieder vereinfachen. Dafür setzen wir $r = s + \ell$

$$\beta_k = \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} y^r$$

und erweitern mit zwei Einsen

$$\begin{aligned} \beta_k &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{\ell!(\ell+1)!(r-\ell)!(k-1-\ell-r)!} \frac{r!}{r!} \frac{(k-r)!}{(k-r)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{(k-1)!}{r!(k-r)!} \frac{r!}{\ell!(\ell-r)!} \frac{(k-r)!}{(k-r-\ell-1)!(\ell+1)!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \frac{k!}{r!(k-r)!} \frac{r!}{\ell!(\ell-r)!} \frac{(k-r)!}{(\ell+1)!(k-r-(\ell+1))!} y^r \\ &= \sum_{\ell=0}^{\lfloor \frac{k-1}{2} \rfloor} \sum_{r=\ell}^{k-1-\ell} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r. \end{aligned}$$

Für den nächsten Schritt müssen wir die Laufvariablen von 0 starten lassen. Momentan haben wir erst das ℓ und ermitteln damit, inwieweit das r eingeschränkt ist. Für ein festes aber beliebiges k liegen unsere Laufvariablen in

$$A = \left\{ (\ell, r) \in \mathbb{N}^2 \mid 0 \leq \ell \leq \left\lfloor \frac{k-1}{2} \right\rfloor, \ell \leq r \leq k-1-\ell \right\}.$$

Daraus wissen wir, dass

$$0 \leq \ell, r \leq k-1-\ell$$

gilt, woraus wir

$$\ell \leq k-1-r$$

folgern können. Damit erhalten wir

$$\begin{aligned} 0 \leq \ell \leq r \leq k-1-\ell \leq k-1 \\ \implies 0 \leq r \leq k-1, 0 \leq \ell \leq \min(r, k-1-r) \end{aligned}$$

damit können wir also die Summen äquivalent über

$$A = \{ (\ell, r) \in \mathbb{N}^2 \mid 0 \leq r \leq k-1, 0 \leq \ell \leq \min(r, k-1-r) \} \quad (0.8)$$

laufen lassen.

Wir haben also mit (0.8)

$$\begin{aligned}\beta_k &= \sum_{r=0}^{k-1} \sum_{\ell=0}^{\min(r, k-1-r)} \frac{1}{k} \binom{k}{r} \binom{r}{\ell} \binom{k-r}{\ell+1} y^r \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{\min(r, k-1-r)} \binom{r}{\ell} \binom{k-r}{\ell+1}.\end{aligned}$$

Das Minimum können wir noch weiter vereinfachen, da die Summanden gleich 0 sind, sobald $\ell > r$ oder $\ell > k-1-r$ ist. Wenn wir die Summe also bis r laufen lassen, ändern wir nichts am Ergebnis.

$$\beta_k = \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^r \binom{r}{\ell} \binom{k-r}{\ell+1}.$$

An diesem Punkt müssen wir nur noch die innere Summe vereinfachen. Dafür machen wir einen Indexshift und formen die Binomialkoeffizienten etwas um. Wir haben also

$$\begin{aligned}\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{\ell-1} \binom{k-r}{\ell} \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{r-(\ell-1)} \binom{k-r}{\ell} \\ &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=1}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell}.\end{aligned}$$

Wir wollen hier die Vandermonde Identität [Quelle!](#)

$$\sum_{\ddot{o}=0}^{\ddot{u}} \binom{n}{\ddot{o}} \binom{m}{\ddot{u}-\ddot{o}} = \binom{n+m}{\ddot{u}} \quad (0.9)$$

nutzen. Dafür lassen wir die Summe von $\ell = 0$ beginnen, da der Summand das Ergebnis

nicht ändert. Mit der Identität (0.9) erhalten wir

$$\begin{aligned}
\beta_k &= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} y^r \sum_{\ell=0}^{r+1} \binom{r}{(r+1)-\ell} \binom{k-r}{\ell} \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{k} \frac{r+1}{r+1} \binom{k}{r} \binom{k}{r+1} y^r \\
&= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r.
\end{aligned}$$

□

0.3 Marčenko-Pastur-Verteilung

Im Beweis über die Konvergenz benutzen wir Elemente aus der Graphentheorie und der Stochastik, die wir vorher noch einführen wollen.

Dafür definieren wir eine Klasse von Graphen mit folgenden Eigenschaften.

Sei k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten mit der Gestalt $\mathbf{i} = (i_1, \dots, i_k)$ bzw. $\mathbf{j} = (j_1, \dots, j_k)$. Wobei die $\mathbf{i}$ -Knoten ganzzahlige Werte in $[0, p]$ und $\mathbf{j}$ -Knoten ganzzahlige Werte in $[0, n]$ annehmen können. Wenn unterschiedliche $\mathbf{i}/\mathbf{j}$ -Knoten den gleichen Wert annehmen, bezeichnen wir sie als *koinzident*. Wir betrachten koinzidente Knoten als *einen* Knoten mit mehreren Namen. Nehmen zum Beispiel die Knoten i_2 und i_5 den gleichen Wert x an, haben wir einen Knoten welchen sowohl i_2 als auch i_5 nennen was für die Eigenschaften der Kanten wichtig wird.

Alle Kanten richten sich nach den folgenden Regeln: Die Kanten sind gerichtet. Es ist also wichtig von wo nach wo sie laufen. Sie laufen von Knoten i_m zu j_m und von j_m zu i_{m+1} mit $m = 1, \dots, k$ und der Konvention, dass $i_1 = i_{k+1}$ gilt. Wenn wir also den Graphen zeichnen und bei i_1 anfangen sind wir fertig, wenn wir wieder am Startpunkt angelangt sind.

Sei $\hat{r}$ die Anzahl nicht koinzidenter $\mathbf{i}$ -Knoten, dann ist $r = \hat{r} - 1$ und s die Anzahl nicht koinzidenter $\mathbf{j}$ -Knoten. Da k die Anzahl an $\mathbf{i}/\mathbf{j}$ -Knoten ist, ist k auch die Anzahl an Kanten, die auf $\mathbf{i}$ -Knoten zeigen.


Diese Graphen Bezeichnen wir dann als $\Delta(k, r, s)$. Für den Beweis teilen wir die Graphen

in drei Kategorien ein.

$\Delta_1(k, r, s)$: Diese Kategorie fasst alle Graphen zusammen, die zu jeder Kante von i nach j genau eine Kante vom gleichen j -Knoten zum gleichen i -Knoten haben. Hier gilt $r + s = k$.

$\Delta_2(k, r, s)$: Diese Kategorie beinhaltet alle Graphen, die mindestens einmal zwischen zwei Knoten genau eine Kante besitzen, also Graphen, die mindestens eine *Einzelkante* besitzen.

$\Delta_3(k, r, s)$: Die letzte Kategorie $\Delta_3(k, r, s)$ sind alle Graphen die weder in $\Delta_1(k, r)$ noch in $\Delta_2(k, r, s)$ gehören.



Beispiel für Graphen

Für bessere Lesbarkeit schreiben wir für die Kategorien $\Delta_{1,2,3}(k, r, s)$ nur noch $\Delta_{1,2,3}$. Wir bezeichnen zwei Graphen als isomorph, wenn wir für die i/j -Knoten eine geeignete Zuweisung von Werten finden so, dass die Graphen identisch sind. Dazu machen wir ein Beispiel.

Bild mit 3 Graphen. 2 isomorph einer nicht.

Graph a) ist isomorph zu b) da wir die Werte von zwei Knoten ändern können und den gleichen. Graph c) ist aber nicht isomorph zu a) da wir die indices der Knotennamen tauschen müssten was aber nicht geht da der Knoten fest ist.

Für die Graphen haben wir noch ein paar Lemmata.

Lemma 0.6 ([1, S. 43]). Die Anzahl der Graphen in jeder Isomorphismenklasse von $\Delta(k, r, s)$ Graphen, mit festen k, r und s ist

$$\alpha = p(p-1) \cdots (p-r)n(n-1) \cdots (n-s+1) = p^{r+1}n^s \left(1 + \mathcal{O}\left(\frac{1}{n}\right)\right).$$

Lemma 0.7 ([1, S. 43]). Die Anzahl nicht koinzidenter Knoten von $\Delta_3(k, r, s)$ Graphen also $r + s$ ist kleiner gleich k .

Lemma 0.8 ([1, S. 43]). Die Anzahl nicht-isomorpher $\Delta_1(k, r, s)$ Graphen für festes k und r beträgt

$$\frac{1}{r+1} \binom{k}{r} \binom{k-1}{r}.$$

Aus der Stochastik benötigen wir einmal das Starke Gesetz der großen Zahlen und eine Metrik für Wahrscheinlichkeitsverteilungen.

Satz 0.9 (Starkes Gesetz der großen Zahlen [2, S. 139]). Seien $\{\mathcal{Z}_i\}_{i \in \mathbb{N}}$ unabhängige und identisch verteilte Zufallsvariablen und besitzen ein Moment erster Ordnung, dann gilt

$$\frac{1}{n} \sum_{i=1}^n \mathcal{Z}_i \xrightarrow[n \rightarrow \infty]{f.s.} \mathbb{E}(\mathcal{Z}_1).$$

Definition 0.10 (Lévy-Metrik [2, S. 164]). Seien F_1 und F_2 Wahrscheinlichkeitsmaße auf $(\mathbb{R}, \mathcal{B})$ mit $\mathcal{B}(\mathbb{R})$ als borelsche σ -Algebra und zugehörigen Verteilungsfunktionen $\mathbf{F}_1$ und $\mathbf{F}_2$. Dann ist die *Lévy-Metrik* definiert durch

$$\mathcal{L}(F_1, F_2) = \inf\{\varepsilon > 0, x \in \mathbb{R}: \mathbf{F}_1(x - \varepsilon) - \varepsilon \leq \mathbf{F}_2(x) \leq \mathbf{F}_1(x + \varepsilon) + \varepsilon\}.$$

Für den Beweis Benutzen wir dann die Eigenschaft aus dem folgenden Lemma.

Lemma 0.11 ([1, S. 502]). Seien $A, B \in \mathbb{C}^{p \times n}$ und $S = AA^H$, $\bar{S} = BB^H$. Dann gilt für die Lévy-Metrik aus 0.10

$$\mathcal{L}^4(F^S, F^{\bar{S}}) \leq \frac{2}{p^2} \text{tr}(AA^H + BB^H) \text{tr}((A - B)(A - B)^H).$$

Einführen

Satz 0.12. Seien $\{x_{ij}\}$ unabhängig und identisch verteilte Zufallsvariablen mit Erwartungswert 0 und Varianz σ^2 . Sei weiter $\frac{p}{n} \xrightarrow{n \rightarrow \infty} y \in (0, \infty)$. Dann konvergiert F^{S_n} mit $n \rightarrow \infty$ und fast sicher gegen die Marčenko-Pastur-Verteilung F_y wie sie in Kapitel 0.2 beschrieben wurde.

Im folgenden Beweis nehmen wir mit Lemma ??, o.B.d.A an, dass die Varianz $\sigma^2 = 1$ ist, wir also den Standardfall betrachten. Um die Konvergenz der empirischen Spektralverteilung 0.1 gegen die Marčenko-Pastur-Verteilung zu zeigen, müssen wir erstmal

sicherstellen, dass die Zufallsvariablen x_{ij} die notwendigen Bedingungen erfüllen damit wir die Momentmethode benutzen können. Dafür müssen wir einmal die Zufallsvariablen gleichmäßig beschränken, damit wir keine unendlich großen Eigenwerte haben und entsprechend die Erwartungswerte wieder zentralisieren also auf 0 setzen und wir Reskalieren um die Varianz zu erhalten.

Beweis. Seien $C \in \mathbb{R}_+$ und $\mathbf{1}$ die Indikatorfunktion auf $\mathbb{R}$. Weiter seien

$$\begin{aligned}\hat{x}_{ij} &:= x_{ij} \mathbf{1}(|x_{ij}| \leq C), & \tilde{x}_{ij} &:= \hat{x}_{ij} - \mathbb{E}(\hat{x}_{11}) \\ \hat{x}_i &:= (\hat{x}_{i1}, \dots, \hat{x}_{ip})^\top, & \tilde{x}_i &:= (\tilde{x}_{i1}, \dots, \tilde{x}_{ip})^\top \\ \hat{S}_n &:= \frac{1}{n} \sum_{i=1}^n \hat{x}_i \hat{x}_i^H = \frac{1}{n} \hat{X}_n \hat{X}_n^H, & \tilde{S}_n &:= \frac{1}{n} \sum_{i=1}^n \tilde{x}_i \tilde{x}_i^H = \frac{1}{n} \tilde{X}_n \tilde{X}_n^H.\end{aligned}$$

Wir bezeichnen ab hier alle X_n als X . Mit $\hat{S}_n$ und $\tilde{S}_n$ haben wir die beschränkte und zentralisierte Stichproben Kovarianzmatrix. Im Folgenden wollen wir zeigen, dass sich durch Beschränken und Zentralisieren der Grenzwert nicht ändert. Nach Lemma 0.11 erhalten wir

$$\begin{aligned}\mathcal{L}^4(F^{S_n}, F^{\hat{S}_n}) &\leq \frac{2}{np} \operatorname{tr}(X X^H + \hat{X} \hat{X}^H) \operatorname{tr}((X - \hat{X})(X - \hat{X})^H) \\ &= \left(\frac{2}{np} \sum_{i,j} x_{ij} x_{ij}^H + \hat{x}_{ij} \hat{x}_{ij}^H \right) \left(\frac{1}{np} \sum_{i,j} (x_{ij} - \hat{x}_{ij})(x_{ij} - \hat{x}_{ij})^H \right) \\ &= \left(\frac{2}{np} \sum_{i,j} |x_{ij}|^2 + |\hat{x}_{ij}|^2 \right) \left(\frac{1}{np} \sum_{i,j} |x_{ij} - \hat{x}_{ij}|^2 \right) \\ &\leq \left(\frac{4}{np} \sum_{i,j} |x_{ij}|^2 \right) \left(\frac{1}{np} \sum_{i,j} |x_{ij}|^2 \mathbf{1}(|x_{ij}| > C) \right) \\ &\xrightarrow{f.s.} 4 \mathbb{E}(|x_{ij}|^2) \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\xrightarrow{f.s.} 4 \mathbb{E}(|x_{ij}|^2 \mathbf{1}(|x_{ij}| > C)) \\ &\xrightarrow{C \rightarrow \infty} 0\end{aligned}$$

Der Abstand der empirischen Spektralverteilung und ihrer beschränkten Version ist also

für ein genügend großes C vernachlässigbar klein. Nach Satz 0.2

$$\begin{aligned}\|F^{\hat{S}_n} - F^{\tilde{S}_n}\|_\infty &\leq \frac{1}{p} \text{rang}(\hat{X}_n - \tilde{X}_n) \\ &= \frac{1}{p} \text{rang}(\mathbb{E}(\hat{x}_{11})) \\ &= \frac{1}{p}\end{aligned}$$

können wir sehen, dass das Entfernen des Erwartungswertes auch keinen Einfluss auf die Konvergenz hat.

Wir haben jetzt die Verteilung so modifiziert, dass die Zufallsvariablen nicht mehr unendlich groß werden können und den Erhalt des Erwartungswertes garantiert, ohne die Konvergenz zu beeinträchtigen. Um die letzte Bedingung, also den Erhalt der Varianz, zu erfüllen müssen wir zeigen, dass durch Skalierung von $\tilde{S}_n$ mit $\tilde{\sigma}^2 = \mathbb{E}(|\tilde{x}_{ij}|^2) \rightarrow 1$, wenn $C \rightarrow \infty$ gilt, der Abstand zu $\tilde{S}_n$ wieder vernachlässigbar klein wird.

Es gilt wieder mit Lemma 0.11

$$\begin{aligned}\mathcal{L}^4(F^{\tilde{S}_n}, F^{\tilde{\sigma}^{-2}\tilde{S}_n}) &\leq \frac{2}{n} \text{tr} \left(\tilde{X} \tilde{X}^H + \frac{1}{\tilde{\sigma}^2} \tilde{X} \tilde{X}^H \right) \text{tr} \left(\left(1 - \frac{1}{\tilde{\sigma}} \right)^2 \tilde{X} \tilde{X}^H \right) \\ &= \left(\frac{2}{np} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} \tilde{x}_{ij} \tilde{x}_{ij}^H - \frac{2\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}} + \frac{\tilde{x}_{ij} \tilde{x}_{ij}^H}{\tilde{\sigma}^2} \right) \\ &= \left(\frac{2}{np} \sum_{i,j} |\tilde{x}_{ij}|^2 + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} |\tilde{x}_{ij}|^2 - \frac{2|\tilde{x}_{ij}|^2}{\tilde{\sigma}} + \frac{|\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\ &= \left(\frac{2}{np} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \left(\frac{1}{np} \sum_{i,j} \frac{\tilde{\sigma}^2 |\tilde{x}_{ij}|^2 - \tilde{\sigma} 2|\tilde{x}_{ij}|^2 + |\tilde{x}_{ij}|^2}{\tilde{\sigma}^2} \right) \\ &= 2 \left(\frac{\tilde{\sigma}^2 + 1}{np\tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \left(\frac{(\tilde{\sigma} - 1)^2}{np\tilde{\sigma}^2} \sum_{i,j} |\tilde{x}_{ij}|^2 \right) \\ &\xrightarrow{f.s.} 2 \frac{\tilde{\sigma}^2 + 1}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \frac{(\tilde{\sigma} - 1)^2}{\tilde{\sigma}^2} \mathbb{E}(|\tilde{x}_{ij}|^2) \\ &\xrightarrow{C \rightarrow \infty} 0.\end{aligned}$$

Damit haben wir alle Bedingungen erfüllt. Für einen besseren Überblick verwenden wir weiterhin die Notation von S_n und X , meinen aber die modifizierten Matrizen. Wir haben also eine gleichmäßig durch C beschränkte Zufallsvariable x_{ij} mit Erwartungswert 0 und

Varianz 1.

Nach der Momentmethode (S.10) erhalten wir

$$\begin{aligned}\beta_k(S_n) &= \int_{-\infty}^{\infty} x^k F^{S_n} dx \\ &= \frac{1}{p} \operatorname{tr} \left(S_n^k \right) \\ &= \frac{1}{pn^k} \operatorname{tr} \left((XX^H)^k \right).\end{aligned}$$

Da die Dimensionen von X gegen unendlich laufen, läuft auch die Anzahl der Summanden der Spur gegen unendlich. Wir können die Spur aber auch als

$$\frac{1}{pn^k} \operatorname{tr} \left((XX^H)^k \right) = \frac{1}{pn^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k}$$

darstellen. Hier sind $\bar{x}_{ij}$ die Einträge aus X^H und damit komplex konjugiert. Dabei sind $x_{i_1 j_1} \bar{x}_{i_2 j_1} \cdots$ die Faktoren der einzelnen Summanden der Spur und wir summieren über alle Permutationen von $\mathbf{i}$ und $\mathbf{j}$. Wenn wir über alle Permutationen summieren, können wir diese als oben definierte Graphen darstellen. Hier stellen x_{ij} die Kanten von $\mathbf{i}$ -Knoten zu $\mathbf{j}$ -Knoten dar und $\bar{x}_{ij}$ Kanten von $\mathbf{j}$ - zu $\mathbf{i}$ -Knoten. Wir definieren dann

$$\frac{1}{pn^k} \sum_{\mathbf{i}} \sum_{\mathbf{j}} x_{i_1 j_1} \bar{x}_{i_2 j_1} x_{i_2 j_2} \bar{x}_{i_3 j_2} \cdots x_{i_k j_k} \bar{x}_{i_1 j_k} := \frac{1}{pn^k} \sum_{\mathbf{i}, \mathbf{j}} X_{\Delta(k, r, s)}.$$

Die Konvergenz lässt sich jetzt zeigen, indem wir zeigen, dass der Erwartungswert $\mathbb{E}(\beta_k(S_n))$ gleich der Momente der Marčenko-Pastur-Verteilung ist und die Varianz gegen null geht. Damit hätten wir eine fast sichere Konvergenz der empirischen Spektralverteilung gegen die Marčenko-Pastur-Verteilung.

Fangen wir an mit dem Erwartungswert. Nach Definition gilt

$$\mathbb{E}(\beta_k(S_n)) = \frac{1}{pn^k} \sum_{\mathbf{i}, \mathbf{j}} \mathbb{E}(X_{\Delta(k, r, s)}).$$

Teilen wir die Graphen in ihre Kategorien ein, erhalten wir mit Lemma 0.6

$$\mathbb{E}(\beta_k(S_n)) = \frac{1}{pn^k} \left(\overbrace{\sum_{\Delta_1} \alpha \mathbb{E}(X_{\Delta_1})}^{W_1 :=} + \overbrace{\sum_{\Delta_2} \alpha \mathbb{E}(X_{\Delta_2})}^{W_2 :=} + \overbrace{\sum_{\Delta_3} \alpha \mathbb{E}(X_{\Delta_3})}^{W_3 :=} \right).$$

Für W_1 erhalten wir nach Lemma 0.6 und Lemma 0.7

$$W_1 = \frac{1}{n^k p} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p^{r+1} n^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \mathbb{E}(X_{\Delta_1})$$

Da es zu jeder Kante genau eine Kante in die entgegengesetzte Richtung gibt, gilt $\mathbb{E}(|x_{ij}|^2) = 1$. Wir können also schreiben

$$\begin{aligned} W_1 &= \frac{1}{n^k p} \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} p^{r+1} n^{k-r} \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\ &= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} \frac{p^{r+1} n^{k-r}}{n^k p} \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\ &= \sum_{\Delta_1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r \left(1 + \mathcal{O}\left(\frac{1}{p}\right)\right) \\ &= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p}\right). \end{aligned} \tag{0.10}$$

Für W_2 können wir sehen, dass

$$W_2 = \frac{1}{n^k p} \sum_{\Delta_2} \alpha \mathbb{E}(X_{\Delta_2}) = 0 \tag{0.11}$$

gilt, da wir den Erwartungswert auf Kanten aufteilen können, und es in Kategorie Δ_2 mindestens eine Einzelkante gibt. Es gibt demnach mindestens ein ω_i in

$$\mathbb{E}(X_{\Delta_2}) = \mathbb{E}(x_{i_1 j_1}^{\omega_1}) \mathbb{E}(x_{i_2 j_1}^{\omega_2}) \cdots$$

welches gleich 1 ist, woraus folgt, dass $\mathbb{E}(x_{i_k j_k}^1) = 0 = \mathbb{E}(X_{\Delta_2})$ ist.

Für W_3 erhalten wir wieder mit Lemma 0.6, dass

$$W_3 = \frac{1}{n^k p} \sum_{\Delta_3} \alpha \mathbb{E}(X_{\Delta_3})$$

gilt. Weiter oben haben wir gezeigt, dass x_{ij} gleichmäßig durch ein $C > 0$ beschränkt ist. Daraus erhalten wir, dass $|X_{\Delta(k,r,s)}| \leq C^{2k}$ gilt. Mit Lemma ?? wissen wir, dass die Anzahl nicht koinzidenter Knoten maximal k betragen kann. Dadurch ist die Anzahl

unterschiedlicher Δ_3 Graphen in $\mathcal{O}(n^k)$. Wir haben also

$$\begin{aligned} \frac{1}{n^k p} \sum_{\Delta_3} \alpha(X_{\Delta_3}) &= \frac{C^{2k}}{n^k p} \mathcal{O}(n^k) \\ &= \mathcal{O}\left(\frac{1}{p}\right). \end{aligned} \quad (0.12)$$

Mit (0.10), (0.11) und (0.12) erhalten wir dann

$$\begin{aligned} \mathbb{E}(\beta_k(S_n)) &= \sum_{r=0}^{k-1} \frac{1}{r+1} \binom{k}{r} \binom{k-1}{r} y^r + \mathcal{O}\left(\frac{1}{p}\right) \\ &= \beta_k(y, \sigma^2) + o(1) \end{aligned} \quad (0.13)$$

Jetzt fehlt noch die Varianz. Diese ist nach Definition

$$\text{Var}(\beta_k(S_n)) := \frac{1}{pn^k} \sum_{i,j} \left(\mathbb{E}(X_{\Delta_a(k,r,s)} X_{\Delta_b(k,r,s)}) - \mathbb{E}(X_{\Delta_a(k,r,s)}) \mathbb{E}(X_{\Delta_b(k,r,s)}) \right).$$

Dabei sind Δ_a und Δ_b verschiedene Permutationen $\mathbf{i}$ und $\mathbf{j}$. Wie für den Erwartungswert suchen wir uns Kategorien, um die Varianz stückweise zu beschreiben.

Als Erstes betrachten wir alle Graphen Δ_a und Δ_b so, dass Δ_a und Δ_b unabhängig sind, sich also keine Kanten teilen. Daraus folgt direkt durch Rechenregeln von Erwartungswerten, dass

$$\mathbb{E}(X_{\Delta_a(k,r,s)} X_{\Delta_b(k,r,s)}) = \mathbb{E}(X_{\Delta_a(k,r,s)}) \mathbb{E}(X_{\Delta_b(k,r,s)})$$

gilt. Das heißt, für unabhängige Graphen ist die Varianz gleich 0.

Als Nächstes betrachten wir alle Graphen $\Delta_a \cup \Delta_b$, die mindestens eine Einzelkante besitzen. Damit erhalten wir durch Δ_2 Eigenschaften wieder

$$\mathbb{E}(X_{\Delta_a(k,r,s)} X_{\Delta_b(k,r,s)}) = 0 = \mathbb{E}(X_{\Delta_a(k,r,s)}) \mathbb{E}(X_{\Delta_b(k,r,s)}).$$

In allen anderen Möglichkeiten haben die Graphen keine Einzelkante und Δ_a und Δ_b teilen sich Kanten. Analog zu W_3 können wir sagen, dass die Anzahl möglicher Graphen in $\mathcal{O}(n^k)$ liegt. Da wir zwei Graphen haben ist die Anzahl also in $\mathcal{O}(n^{2k})$. Durch die

gleichmäßige Beschränkung von x_{ij} durch C können wir die Varianz durch

$$\begin{aligned}\mathrm{Var}(\beta_k(S_n)) &\leq \frac{1}{p^2 n^{2k}} C \mathcal{O}(n^{2k}) \\ &= \mathcal{O}\left(\frac{1}{p^2}\right)\end{aligned}\tag{0.14}$$

abschätzen.

Mit dem Erwartungswert (0.13) und der Varianz (0.14) können wir darauf schließen, dass die empirische Spektralverteilung fast sicher gegen die Marčenko-Pastur-Verteilung konvergiert. $\square$