

In diesem Kapitel wollen wir noch einmal genauer den DMD Algorithmus erklären. Es ist aber nicht notwendig für das weitere Verstehen dieser Arbeit.

Aus der Einleitung wissen wir, dass die Singulärwertzerlegung und die Frobeniusnorm wichtige Werkzeuge des Algorithmus sind, weshalb wir sie hier einmal konkret definieren.

0.1 Frobeniusnorm

Definition 0.1 (Frobeniusnorm). Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix und x_{ij} mit $i \in \{1, \dots, p\}$, $j \in \{1, \dots, n\}$. Die *Frobeniusnorm* ist definiert durch

$$\|X\|_F := \sqrt{\sum_{i=1}^p \sum_{j=1}^n |x_{ij}|^2}.$$

Die Frobeniusnorm können wir aber auch über die Spur der Matrix beschreiben.

Lemma 0.2. Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix. Dann gilt

$$\|X\|_F = \sqrt{\text{tr}(X^H X)}.$$

Beweis. Sei x_i ein Spaltenvektor von X und $\bar{x}_{ij}$ das komplex Konjugierte. Dann ist

$$\begin{aligned} X^H X &= \begin{pmatrix} x_1 & \dots & x_n \end{pmatrix}^H \begin{pmatrix} x_1 & \dots & x_n \end{pmatrix} \\ &= \begin{pmatrix} \sum_{j=1}^p x_{1j}^H x_{1j} & & * \\ & \ddots & \\ * & & \sum_{j=1}^p x_{nj}^H x_{nj} \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^p \bar{x}_{1j} x_{1j} & & * \\ & \ddots & \\ * & & \sum_{j=1}^p \bar{x}_{nj} x_{nj} \end{pmatrix}. \end{aligned}$$

Mit $\bar{x}x = |x|^2$ erhalten wir

$$\text{tr}(X^H X) = \sum_{i=1}^n \sum_{j=1}^p \bar{x}_{ij} x_{ij} = \sum_{i=1}^n \sum_{j=1}^p |x_{ij}|^2 = \|X\|_F^2. \quad (0.1)$$

□

Die Frobeniusnorm wird im weiteren Verlauf aufgrund ihrer Invarianz bezüglich unitärer Transformation verwendet, welche wir durch folgendes Lemma zeigen.

Lemma 0.3. Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix und $U \in \mathbb{C}^{p \times p}$ und $V \in \mathbb{C}^{n \times n}$ unitäre Matrizen. Dann gilt

1. $\|X\|_F = \|X^H\|_F$,
2. $\|UX\|_F = \|X\|_F$,
3. $\|XV\|_F = \|X\|_F$.

Beweis.

1. Aus Gleichung (0.1) folgt

$$\|X\|_F^2 = \text{tr}(X^H X) = \sum_{i=1}^n \sum_{j=1}^p \bar{x}_{ij} x_{ij} = \sum_{j=1}^p \sum_{i=1}^n \bar{x}_{ij} x_{ij} = \text{tr}(X X^H) = \|X^H\|_F^2.$$

2. Es ist

$$\|UX\|_F^2 = \text{tr}(X^H U^H U X) = \text{tr}(X^H \mathbb{1} X) = \text{tr}(X^H X) = \|X\|_F^2.$$

3. Mit 1. und 2. folgt

$$\|XV\|_F = \|V^H X^H\|_F = \|X^H\|_F = \|X\|_F. \quad \square$$

Damit haben wir alles, was wir über die Frobeniusnorm wissen müssen.

0.2 Singulärwertzerlegung

Satz 0.4 (Singulärwertzerlegung [1, S. 228]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix und $r := \text{rang } X$ mit $r \leq \min(p, n)$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ und eine Diagonalmatrix $\hat{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}$ mit $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U \Sigma V^T \text{ mit } \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt.

Der Beweis des Satzes 0.4 folgt etwas später, da dafür noch etwas Vorbereitung benötigt wird. Wichtig zu erwähnen ist noch, dass unter den in Satz 0.4 genannten Voraussetzungen, $\hat{\Sigma}$ durch X eindeutig bestimmt ist. Die beiden orthogonalen Matrizen U und V hingegen sind nicht eindeutig.

Lemma 0.5. Seien $X \in \mathbb{R}^{p \times n}$ und σ_i die Singulärwerte von X nach den Voraussetzungen aus Satz 0.4. Seien weiter λ_i die Eigenwerte von $X^\top X$. Dann gilt

$$\sigma_i = \sqrt{\lambda_i}.$$

Beweis. Durch

$$\begin{aligned} X^\top X &= (U \Sigma V^\top)^\top (U \Sigma V^\top) \\ &= V \Sigma^\top U^\top U \Sigma V^\top \\ &= V \Sigma^\top \Sigma V^\top \end{aligned}$$

ist $X^\top X$ ähnlich zu $\Sigma^\top \Sigma$. Also haben $X^\top X$ und $\Sigma^\top \Sigma$ auch die gleichen Eigenwerte. $\square$

Lemma 0.6. Die aus der Singulärwertzerlegung in 0.4 entstehenden Singulärwerte sind invariant bezüglich Transposition von X .

Beweis. Seien die Voraussetzungen aus Satz 0.4 gegeben, dann gilt

$$X^\top = (U \Sigma V^\top)^\top = V \Sigma^\top U^\top.$$

Da Σ nur auf der Hauptdiagonalen Einträge hat und sonst mit Nullen gefüllt ist, erhalten wir

$$\text{diag } \Sigma^\top = \{\sigma_1, \sigma_2, \dots, \sigma_m\} = \text{diag } \Sigma.$$

$\square$

Den Beweis von Satz 0.4 teilen wir in zwei Teile ein. Wir betrachten dafür einmal die Singulärwertzerlegung für den Fall, dass X vollen Rang besitzt und einmal für den rangreduzierten Fall. Für den vollen Rang benutzen wir das folgende Lemma.

Lemma 0.7 ([1, S. 191]). Sei $X \in \mathbb{R}^{p \times p}$ eine symmetrische Matrix. Dann existiert eine orthogonale Matrix $U \in \mathbb{R}^{p \times p}$ und eine Diagonalmatrix $D \in \mathbb{R}^{p \times p}$ so, dass

$$U^\top X U = D$$

gilt.

Für den rangreduzierten Fall brauchen wir aber das folgende Lemma. Dafür nehmen wir nach Lemma 0.6 o.B.d.A an, dass $n \leq p$ gilt.

Lemma 0.8 ([1, S. 227]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix mit $\text{rang } X = r < n \leq p$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ sowie eine reguläre obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$ so, dass

$$U^\top X V = R \text{ mit } R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt.

Beweis Satz 0.4. Zunächst betrachten wir den Fall des vollen Ranges von X , also $\text{rang } X = r = n$. Bei vollem Rang ist $X^\top X \in \mathbb{R}^{n \times n}$ sowohl symmetrisch als auch positiv definit. Die Eigenwerte λ_i von $X^\top X$ sortieren wir nach ihrer Größe, also

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0.$$

Mit Lemma 0.7 finden wir ein orthogonales $V \in \mathbb{R}^{n \times n}$, sodass

$$V^\top X^\top X V = D = \text{diag}\{\lambda_1, \dots, \lambda_n\} \in \mathbb{R}^{n \times n}.$$

Weiter definieren wir

$$\hat{\Sigma} := \text{diag}\{\sigma_1, \dots, \sigma_n\}$$

mit $\sigma_i := \sqrt{\lambda_i} \in (0, \infty]$, für $i = 1, \dots, n$, und setzen

$$\hat{U} := X V \hat{\Sigma}^{-1} \in \mathbb{R}^{p \times n}.$$

Jetzt kann man durch Umformung von

$$\begin{aligned} \hat{U}^\top \hat{U} &= \hat{\Sigma}^{-\top} V^\top X^\top X V \hat{\Sigma}^{-1} \\ &= \hat{\Sigma}^{-1} D \hat{\Sigma}^{-1} \\ &= \hat{\Sigma}^{-1} \hat{\Sigma}^{-1} D \\ &= D^{-1} D \\ &= \mathbb{1} \end{aligned}$$

die Orthonormalität der Spalten von $\hat{U}$ sehen.

Da $\hat{U}$ in $\mathbb{R}^{p \times n}$ mit $n < p$ liegt und aus orthonormalen Spaltenvektoren besteht, finden wir ein $Z \in \mathbb{R}^{p \times (p-n)}$, welches $\hat{U}$ so um $p - n$ orthonormale Spaltenvektoren ergänzt,

dass

$$U = (\hat{U} \ Z) \in \mathbb{R}^{p \times p}$$

eine orthogonale Matrix ist. Es gilt also

$$\begin{aligned} Z^\top X V \hat{\Sigma}^{-1} &= Z^\top \hat{U} \\ &= 0 \in \mathbb{R}^{(p-n) \times p}. \end{aligned}$$

Da $\hat{\Sigma} \hat{\Sigma}^{-1} = \mathbb{1}$ ist, folgt auch direkt

$$Z^\top X V = 0.$$

Zusammengetragen haben wir dann

$$\begin{aligned} U^\top X V &= \begin{pmatrix} \hat{U}^\top \\ Z^\top \end{pmatrix} X V = \begin{pmatrix} \hat{\Sigma}^{-1} V^\top X^\top X V \\ Z^\top X V \end{pmatrix} \\ &= \begin{pmatrix} \hat{\Sigma}^{-1} D \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} \hat{\Sigma} \\ 0 \end{pmatrix}, \end{aligned}$$

womit wir den Fall des vollen Ranges bewiesen hätten.

Seien λ_i wie oben definiert wieder die Eigenwerte von $X^\top X$ und sei $X_r \in \mathbb{R}^{p \times n}$ eine Matrix mit $\text{rang } X_r = r < n$. Nach Lemma 0.8 gibt es zwei orthogonale Matrizen $\tilde{U} \in \mathbb{R}^{p \times p}$ und $\tilde{V} \in \mathbb{R}^{n \times n}$, sowie eine obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$, sodass

$$\tilde{U}^\top X_r \tilde{V} = R \text{ mit } R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Nach obigem Fall mit vollem Rang, wissen wir, dass es orthogonale Matrizen $U_r \in \mathbb{R}^{p \times p}$ und $V_r \in \mathbb{R}^{r \times r}$, sodass

$$U_r^\top \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix} V_r = \begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{p \times r}.$$

Dabei ist $\hat{\Sigma}_r := \text{diag}\{\sigma_1, \dots, \sigma_r\}$ mit $\sigma_i = \sqrt{\lambda_i}$. Im Folgenden erweitern wir

$$\begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{p \times r} \quad \text{zu} \quad \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} = \Sigma \in \mathbb{R}^{p \times n}$$

und finden eine orthogonale Fortsetzung für V_r zu

$$\bar{V}_r = \begin{pmatrix} V_r & 0 \\ 0 & \mathbb{1} \end{pmatrix} \in \mathbb{R}^{n \times n}.$$

Wenn wir uns jetzt die orthogonalen Matrizen

$$U := \tilde{U}U_r \in \mathbb{R}^{p \times p} \quad \text{und} \quad V := \tilde{V}\bar{V}_r \in \mathbb{R}^{p \times n}$$

definieren, erhalten wir durch

$$\begin{aligned} U^\top X_r V &= U_r^\top \tilde{U} X_r \tilde{V} \bar{V}_r \\ &= U_r^\top \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \bar{V}_r \\ &= \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} =: \Sigma \end{aligned}$$

eine erfolgreiche Zerlegung von X_r durch orthogonale Matrizen. □

0.3 Exact DMD

Ich weiß noch nicht wie ich dafür Sorge, dass meine Gleichungen nicht im Zeilenumbruch getrennt werden UND ich den Blocktext beibehalten kann.

In der Einleitung haben wir grob den DMD Algorithmus erklärt. Wir gehen hier jetzt aber auf die „exact DMD“ Variante ein, da sie im Gegensatz zur ursprünglichen Variante keine einheitlichen Zeitabstände zwischen den Messungen erfordert. Exact DMD erlaubt es uns Daten über mehrere Messungen die zeitlich unterschiedlich auseinanderliegen zusammenzutragen. Zu jeder Messung gehört dann ein Datenpaar $\{x(t_i), x(t'_i)\}$ mit $i = 1, \dots, n$ und $t'_i = t_i + \Delta t$. Fügen wir die Datenpaare in zwei Matrizen $X, X' \in \mathbb{R}^{p \times n}$ ein,

erhalten wir die Zustände des Systems zu n diskreten Zeitpunkten. Wir haben also

$$X = \begin{pmatrix} | & | & \dots & | \\ x(t_1) & x(t_2) & \dots & x(t_n) \\ | & | & \dots & | \end{pmatrix} \quad \text{und} \quad X' = \begin{pmatrix} | & | & \dots & | \\ x(t'_1) & x(t'_2) & \dots & x(t'_n) \\ | & | & \dots & | \end{pmatrix}.$$

Mit den Vorbereitungen abgeschlossen, gehen wir jetzt auf den Algorithmus ein.

Als Erstes bestimmen wir die Singulärwertzerlegung von X also

$$X = U \Sigma V^\top.$$

Um den Rechenaufwand zu minimieren, finden wir eine geeignete Rangreduzierung. Wir approximieren also mit $r < n$, $U_r \in \mathbb{R}^{p \times r}$, $\Sigma_r \in \mathbb{R}^{r \times r}$ und $V_r \in \mathbb{R}^{n \times r}$

$$X \approx U_r \Sigma_r V_r^\top.$$

Um den linearen Operator A zu finden, der

$$X' \approx AX$$

lösen benötigen wir die Pseudoinverse von X . Um eine eindeutige Inverse zu bekommen, benutzen wir die Moore-Penrose-Inverse aus dem folgenden Satz.

Satz 0.9 (Moore-Penrose-Inverse [1, S. 230]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix und $U, \hat{\Sigma}$ und V die Matrizen aus der Singulärwertzerlegung in Satz 0.4. Dann existiert genau eine Moore-Penrose-Inverse der Form

$$X^\dagger = V \begin{pmatrix} \hat{\Sigma}^{-1} & 0 \\ 0 & 0 \end{pmatrix} U^\top \in \mathbb{R}^{n \times p}.$$

Mit Satz 0.9 können wir A durch

$$A = X' V_r \Sigma_r^{-1} U_r^\top = X' X_r^\dagger$$

bestimmen. Das Ziel ist es die Spektralzerlegung von A zu finden, damit wir analysieren können wie sich das System über die Zeit entwickelt. Da A aber eine $p \times p$ große Matrix ist und p schnell sehr groß werden kann, können wir den Rechenaufwand minimieren, indem wir die Spektralzerlegung von einem A_r bestimmen, welches nur noch die für uns

relevante Dimension r hat. Wir bestimmen A_r durch

$$\begin{aligned} A_r &= U_r^\top A U_r \\ &= U_r^\top X' X_r^\dagger U_r \\ &= U_r^\top X' V_r \Sigma_r^{-1}. \end{aligned}$$

Sei W die Matrix aus Eigenvektoren von A_r und Λ eine Diagonalmatrix dessen Einträge die Eigenwerte λ_i von A_r sind, dann ist die Spektralzerlegung von A_r genau

$$A_r W = W \Lambda.$$

Sei Φ die Matrix, dessen Spalten die Eigenvektoren von A sind. Dann können wir Φ durch die reduzierten Eigenvektoren W mit

$$\Phi = X' V_r \Sigma_r^{-1} W$$

rekonstruieren.

Durch

$$\begin{aligned} A \Phi &= (X' V_r \Sigma_r^{-1} U_r^\top) (X' V_r \Sigma_r^{-1} W) \\ &= X' V_r \Sigma_r^{-1} A_r W \\ &= X' V_r \Sigma_r^{-1} W \Lambda \\ &= \Phi \Lambda \end{aligned}$$

kann sehen wir, dass die Spalten von Φ auch die Eigenvektoren zu den Eigenwerten von A_r sind. Damit können wir also die Spektralzerlegung von A mit der Spektralzerlegung von A_r bestimmen.

Muss noch irgendwas ans Ende.