

In diesem Kapitel wollen wir genauer auf den DMD Algorithmus beziehungsweise die „exact DMD“ Variante eingehen.

Aus der Einleitung wissen wir, dass die Singulärwertzerlegung und die Frobeniusnorm wichtige Werkzeuge des Algorithmus sind, weshalb wir sie hier konkret definieren.

0.1 Frobeniusnorm

Definition 0.1 (Frobeniusnorm). Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix und x_{ij} mit $i \in \{1, \dots, p\}$, $j \in \{1, \dots, n\}$ ihre Einträge. Die *Frobeniusnorm* von X ist definiert durch

$$\|X\|_F := \sqrt{\sum_{i=1}^p \sum_{j=1}^n |x_{ij}|^2}.$$

Eine weitere Möglichkeit, die Frobeniusnorm zu definieren, ist über die Spur einer Matrix.

Lemma 0.2. Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix. Dann gilt

$$\|X\|_F = \sqrt{\text{tr}(X^H X)}.$$

Beweis. Sei x_i der i -te Spaltenvektor von X und $\bar{x}_{ij}$ das komplex Konjugierte von x_{ij} . Dann ist

$$\begin{aligned} X^H X &= \begin{pmatrix} x_1 & \cdots & x_n \end{pmatrix}^H \begin{pmatrix} x_1 & \cdots & x_n \end{pmatrix} \\ &= \begin{pmatrix} \langle x_1, x_1 \rangle & & * \\ & \ddots & \\ * & & \langle x_p, x_p \rangle \end{pmatrix} = \begin{pmatrix} \sum_{j=1}^p \bar{x}_{1j} x_{1j} & & * \\ & \ddots & \\ * & & \sum_{j=1}^p \bar{x}_{nj} x_{nj} \end{pmatrix}. \end{aligned}$$

Mit $\bar{x}x = |x|^2$ erhalten wir

$$\text{tr}(X^H X) = \sum_{i=1}^n \sum_{j=1}^p \bar{x}_{ij} x_{ij} = \sum_{i=1}^n \sum_{j=1}^p |x_{ij}|^2 = \|X\|_F^2. \quad (0.1)$$

□

Die Frobeniusnorm wird im weiteren Verlauf aufgrund ihrer Invarianz bezüglich unitärer Transformation verwendet, welche wir durch folgendes Lemma zeigen.

Lemma 0.3. Sei $X \in \mathbb{C}^{p \times n}$ eine Matrix und $U \in \mathbb{C}^{p \times p}$ und $V \in \mathbb{C}^{n \times n}$ unitäre Matrizen. Dann gilt

1. $\|X\|_F = \|X^H\|_F$,
2. $\|UX\|_F = \|X\|_F$,
3. $\|XV\|_F = \|X\|_F$.

Beweis.

1. Aus Lemma 0.2 folgt

$$\|X\|_F^2 = \text{tr}(X^H X) = \sum_{i=1}^n \sum_{j=1}^p \bar{x}_{ij} x_{ij} = \sum_{j=1}^p \sum_{i=1}^n \bar{x}_{ij} x_{ij} = \text{tr}(X X^H) = \|X^H\|_F^2.$$

2. Es ist

$$\|UX\|_F^2 = \text{tr}(X^H U^H U X) = \text{tr}(X^H \mathbb{1} X) = \text{tr}(X^H X) = \|X\|_F^2.$$

3. Mit 1. und 2. folgt

$$\|XV\|_F = \|V^H X^H\|_F = \|X^H\|_F = \|X\|_F. \quad \square$$

0.2 Singulärwertzerlegung

Satz 0.4 (Singulärwertzerlegung [2, S. 228]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix und $r := \text{rang } X$ mit $r \leq \min(p, n)$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ und eine Diagonalmatrix $\hat{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_r) \in \mathbb{R}^{r \times r}$ mit $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U \Sigma V^T \quad \text{mit} \quad \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Wir nennen die Diagonalelemente von $\hat{\Sigma}$ Singulärwerte.

Der Beweis des Satzes 0.4 folgt später, da dafür noch die folgenden Lemmata benötigt werden. Wichtig zu erwähnen ist noch, dass unter den in Satz 0.4 genannten Voraussetzungen, $\hat{\Sigma}$ durch X eindeutig bestimmt ist [2, S. 229]. Die beiden orthogonalen Matrizen U und V hingegen sind nicht eindeutig.

Lemma 0.5. Seien $X \in \mathbb{R}^{p \times n}$ und $\sigma_i \in (0, \infty)$ die i -ten Singulärwerte von X mit den Voraussetzungen aus Satz 0.4. Seien weiter λ_i die Eigenwerte von $X^\top X$. Dann gilt

$$\sigma_i = \sqrt{\lambda_i}. \quad (0.2)$$

Beweis. Mit U und V aus Satz 0.4 wird durch

$$\begin{aligned} X^\top X &= (U \Sigma V^\top)^\top (U \Sigma V^\top) \\ &= V \Sigma^\top U^\top U \Sigma V^\top \\ &= V \Sigma^\top \Sigma V^\top \end{aligned}$$

deutlich, dass $X^\top X$ ähnlich zu $\Sigma^\top \Sigma$ ist. Also haben $X^\top X$ und $\Sigma^\top \Sigma$ auch die gleichen Eigenwerte. Damit sind auch die Wurzeln der Eigenwerte von $X^\top X$ gleich den Eigenwerten beziehungsweise Singulärwerten von Σ . $\square$

Lemma 0.6. Die aus der Singulärwertzerlegung in 0.4 entstehenden Singulärwerte sind invariant bezüglich der Transposition von X .

Beweis. Seien die Voraussetzungen aus Satz 0.4 gegeben, dann gilt

$$X^\top = (U \Sigma V^\top)^\top = V \Sigma^\top U^\top.$$

Da Σ nur auf der Hauptdiagonalen Einträge hat und sonst mit Nullen gefüllt ist, erhalten wir

$$\text{diag } \Sigma^\top = \{\sigma_1, \sigma_2, \dots, \sigma_m\} = \text{diag } \Sigma.$$

$\square$

Den Beweis von Satz 0.4 teilen wir auf. Wir betrachten dafür zum einen die Singulärwertzerlegung für den Fall, dass X vollen Rang besitzt, und zum anderen für den rangreduzierten Fall. Für den vollen Rang benutzen wir das folgende Lemma.

Lemma 0.7 ([2, S. 191]). Sei $X \in \mathbb{R}^{p \times p}$ eine symmetrische Matrix. Dann existiert eine orthogonale Matrix $U \in \mathbb{R}^{p \times p}$ und eine Diagonalmatrix $D \in \mathbb{R}^{p \times p}$ so, dass

$$U^\top X U = D$$

gilt.

Für den rangreduzierten Fall brauchen wir das folgende Lemma.

Lemma 0.8 ([2, S. 227]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix mit $\text{rang } X = r < n \leq p$. Dann existieren orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ sowie eine reguläre obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$ so, dass

$$U^\top X V = R \quad \text{mit} \quad R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt.

Für den Beweis der Singulärwertzerlegung, gehen wir durch Lemma 0.6 ohne Beschränkung der Allgemeinheit davon aus, dass $n < p$ gilt.

Beweis von Satz 0.4. Zunächst betrachten wir den Fall des vollen Ranges von X . Sei also der Rang von X durch $\text{rang } X = r = n$ gegeben. Bei vollem Rang ist $X^\top X \in \mathbb{R}^{n \times n}$ sowohl symmetrisch als auch positiv definit. Die Eigenwerte λ_i von $X^\top X$ sortieren wir nach ihrer Größe, also

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n > 0.$$

Mit Lemma 0.7 finden wir ein orthogonales $V \in \mathbb{R}^{n \times n}$ so, dass

$$V^\top X^\top X V = D = \text{diag}(\lambda_1, \dots, \lambda_n) \in \mathbb{R}^{n \times n}.$$

Weiter definieren wir

$$\hat{\Sigma} := \text{diag}(\sigma_1, \dots, \sigma_n)$$

mit $\sigma_i := \sqrt{\lambda_i} \in (0, \infty)$, für $i = 1, \dots, n$, und setzen

$$\hat{U} := X V \hat{\Sigma}^{-1} \in \mathbb{R}^{p \times n}.$$

Jetzt kann man durch Umformung von

$$\begin{aligned} \hat{U}^\top \hat{U} &= \hat{\Sigma}^{-\top} V^\top X^\top X V \hat{\Sigma}^{-1} \\ &= \hat{\Sigma}^{-1} D \hat{\Sigma}^{-1} \\ &= \hat{\Sigma}^{-1} \hat{\Sigma}^{-1} D \\ &= D^{-1} D \\ &= \mathbb{1} \end{aligned}$$

die Orthonormalität der Spalten von $\hat{U}$ sehen.

Da $\hat{U}$ in $\mathbb{R}^{p \times n}$ liegt und aus orthonormalen Spaltenvektoren besteht, finden wir ein

$Z \in \mathbb{R}^{p \times (p-n)}$, welches $\hat{U}$ so um $p - n$ orthonormale Spaltenvektoren ergänzt, dass

$$U = (\hat{U} \ Z) \in \mathbb{R}^{p \times p}$$

eine orthogonale Matrix ist. Es gilt also

$$\begin{aligned} Z^\top X V \hat{\Sigma}^{-1} &= Z^\top \hat{U} \\ &= 0 \in \mathbb{R}^{(p-n) \times p}. \end{aligned}$$

Da $\hat{\Sigma}^{-1} \hat{\Sigma} = \mathbb{1}$ ist, folgt auch direkt

$$Z^\top X V = 0.$$

Zusammengetragen haben wir dann

$$\begin{aligned} U^\top X V &= \begin{pmatrix} \hat{U}^\top \\ Z^\top \end{pmatrix} X V = \begin{pmatrix} \hat{\Sigma}^{-1} V^\top X^\top X V \\ Z^\top X V \end{pmatrix} \\ &= \begin{pmatrix} \hat{\Sigma}^{-1} D \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} \hat{\Sigma} \\ 0 \end{pmatrix}, \end{aligned}$$

womit wir den Fall des vollen Ranges bewiesen hätten.

Seien λ_i wie oben definiert wieder die Eigenwerte von $X^\top X$ und sei $X_r \in \mathbb{R}^{p \times n}$ eine Matrix mit $\text{rang } X_r = r < n$. Nach Lemma 0.8 gibt es zwei orthogonale Matrizen $\tilde{U} \in \mathbb{R}^{p \times p}$ und $\tilde{V} \in \mathbb{R}^{n \times n}$, sowie eine obere Dreiecksmatrix $\hat{R} \in \mathbb{R}^{r \times r}$ so, dass

$$\tilde{U}^\top X_r \tilde{V} = R \text{ mit } R = \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Nach obigem Fall mit vollem Rang, wissen wir, dass es orthogonale Matrizen $U_r \in \mathbb{R}^{p \times p}$ und $V_r \in \mathbb{R}^{r \times r}$ mit

$$U_r^\top \begin{pmatrix} \hat{R} \\ 0 \end{pmatrix} V_r = \begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{p \times r}$$

gibt. Dabei ist $\hat{\Sigma}_r := \text{diag}(\sigma_1, \dots, \sigma_r)$ mit $\sigma_i = \sqrt{\lambda_i}$. Im Folgenden erweitern wir

$$\begin{pmatrix} \hat{\Sigma}_r \\ 0 \end{pmatrix} \in \mathbb{R}^{p \times r} \quad \text{zu} \quad \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} = \Sigma \in \mathbb{R}^{p \times n}$$

und finden eine orthogonale Fortsetzung für V_r zu

$$\bar{V}_r = \begin{pmatrix} V_r & 0 \\ 0 & \mathbb{1} \end{pmatrix} \in \mathbb{R}^{n \times n}.$$

Wenn wir uns jetzt die orthogonalen Matrizen

$$U := \tilde{U}U_r \in \mathbb{R}^{p \times p} \quad \text{und} \quad V := \tilde{V}\bar{V}_r \in \mathbb{R}^{n \times n}$$

definieren, erhalten wir durch

$$\begin{aligned} U^\top X_r V &= U_r^\top \tilde{U} X_r \tilde{V} \bar{V}_r \\ &= U_r^\top \begin{pmatrix} \hat{R} & 0 \\ 0 & 0 \end{pmatrix} \bar{V}_r \\ &= \begin{pmatrix} \hat{\Sigma}_r & 0 \\ 0 & 0 \end{pmatrix} =: \Sigma \end{aligned}$$

eine erfolgreiche Zerlegung von X_r durch orthogonale Matrizen. □

0.3 Exact DMD

In der Einleitung haben wir grob den DMD Algorithmus erklärt. Wir gehen hier jetzt aber auf die „exact DMD“ Variante ein, da sie im Gegensatz zur ursprünglichen Variante keine einheitlichen Zeitabstände zwischen den Messungen erfordert. Dieses Kapitel beruht auf dem Buch „Data-Driven Science and Engineering“ [1].

Exact DMD erlaubt es uns, Daten über mehrere Messungen, die zeitlich unterschiedlich auseinanderliegen, zusammenzutragen. Zu jeder Messung gehört dann ein Datenpaar $\{x(t_i), x(t'_i)\}$ mit $i = 1, \dots, n$ und $t'_i = t_i + \Delta t$. Dabei ist x die Messung zum Zeitpunkt t_i beziehungsweise t'_i . Fügen wir die Datenpaare wie in (0.3) in zwei Matrizen $X, X' \in \mathbb{R}^{p \times n}$

ein, erhalten wir die Zustände des Systems zu n diskreten Zeitpunkten. Wir erhalten also

$$X = \begin{pmatrix} | & | & & | \\ x(t_1) & x(t_2) & \dots & x(t_n) \\ | & | & & | \end{pmatrix} \quad \text{und} \quad X' = \begin{pmatrix} | & | & & | \\ x(t'_1) & x(t'_2) & \dots & x(t'_n) \\ | & | & & | \end{pmatrix}. \quad (0.3)$$

Mit den Vorbereitungen abgeschlossen, gehen wir jetzt auf den Algorithmus ein.

Als Erstes bestimmen wir die Singulärwertzerlegung von X , also

$$X = U \Sigma V^\top.$$

Um den Rechenaufwand zu minimieren, finden wir eine geeignete Rangreduzierung. Wir finden also ein $r \in \mathbb{N}$ mit $r < n$ so, dass wir mit $U_r \in \mathbb{R}^{p \times r}$, $\Sigma_r \in \mathbb{R}^{r \times r}$ und $V_r \in \mathbb{R}^{n \times r}$

$$X \approx U_r \Sigma_r V_r^\top =: X_r$$

approximieren. Um den diagonalisierbaren, linearen Operator A zu finden, der

$$X' \approx AX$$

löst, benötigen wir die Pseudoinverse von X . Um eine eindeutige Inverse zu bekommen, benutzen wir die Moore–Penrose–Inverse aus dem folgenden Satz.

Satz 0.9 (Moore–Penrose–Inverse [2, S. 230]). Sei $X \in \mathbb{R}^{p \times n}$ eine Matrix und $U, \hat{\Sigma}$ und V die Matrizen aus der Singulärwertzerlegung in Satz 0.4. Dann existiert genau eine Moore–Penrose–Inverse der Form

$$X^\dagger = V \begin{pmatrix} \hat{\Sigma}^{-1} & 0 \\ 0 & 0 \end{pmatrix} U^\top \in \mathbb{R}^{n \times p}.$$

Mit Satz 0.9 können wir A durch

$$A = X' V_r \Sigma_r^{-1} U_r^\top = X' X_r^\dagger$$

bestimmen. Das Ziel ist es, die Spektralzerlegung von A zu finden, damit wir analysieren können, wie sich das System mit der Zeit entwickelt. Da A aber eine $p \times p$ Matrix ist und p schnell sehr groß wird, können wir den Rechenaufwand minimieren, indem wir die Spektralzerlegung von einem $A_r \in \mathbb{R}^{r \times r}$ bestimmen, welches nur noch die für uns

relevante Dimension r hat. Wir bestimmen A_r durch

$$\begin{aligned} A_r &= U_r^\top A U_r \\ &= U_r^\top X' X_r^\dagger U_r \\ &= U_r^\top X' V_r \Sigma_r^{-1}. \end{aligned} \tag{0.4}$$

Sei $W \in \mathbb{R}^{r \times r}$ die Matrix aus Eigenvektoren von A_r und $\Lambda \in \mathbb{R}^{r \times r}$ eine Diagonalmatrix, deren Einträge die Eigenwerte λ_i der zugehörigen Eigenvektoren von A_r sind, dann ist die Spektralzerlegung von A_r genau

$$A_r W = W \Lambda. \tag{0.5}$$

Sei $\Phi \in \mathbb{R}^{p \times p}$ die Matrix, deren Spalten die Eigenvektoren von A sind. Dann können wir Φ durch die reduzierten Eigenvektoren W mit

$$\Phi = X' V_r \Sigma_r^{-1} W$$

rekonstruieren.

Durch

$$\begin{aligned} A\Phi &= (X' V_r \Sigma_r^{-1} U_r^\top)(X' V_r \Sigma_r^{-1} W) \\ &\stackrel{(0.4)}{=} X' V_r \Sigma_r^{-1} A_r W \\ &\stackrel{(0.5)}{=} X' V_r \Sigma_r^{-1} W \Lambda \\ &= \Phi \Lambda \end{aligned}$$

können wir sehen, dass die Spalten von Φ auch die Eigenvektoren zu den Eigenwerten von A_r sind. Damit können wir also die Spektralzerlegung von A mit der Spektralzerlegung von A_r bestimmen.