

Bei der Rangreduzierung handelt es sich um das Approximieren einer Matrix durch eine andere Matrix eines niedrigeren Ranges. Sie ist ein wichtiges Werkzeug im Umgang mit großen Datenmengen welche als Matrix vorliegen, um den Rechenaufwand, bei dem Verarbeiten der Daten aufkommt, zu minimieren.

Ein Beispiel das wir in diesem Zusammenhang betrachten ist der Dynamic Mode Decomposition Algorithmus kurz DMD aus [1]. DMD ist ein datengetriebener Algorithmus, der ursprünglich im Forschungsgebiet der Strömungsdynamik entwickelt wurde. Grundsätzlich dient der Algorithmus der Analyse von Messdaten eines dynamischen Systems mittels Singulärwertzerlegung von großen Datenmatrizen. DMD kann anhand von Messdaten mehrerer Zeitpunkte die Dynamik eines Systems approximieren. Die Genauigkeit hängt unter anderem davon ab, wie viele Informationen in Form von Messdaten über das System zur Verfügung stehen und wie groß die Messfehler, also das Rauschen der Daten, ist. Dabei ist DMD gut im Erkennen von Mustern, wie im Falle der Strömungsdynamik zum Beispiel Wirbelungen. Probleme treten jedoch auf, wenn man DMD außerhalb von Simulationen verwendet und echte Messungen analysieren will. Bei echten Messungen hat man immer ein Rauschen in den Daten, welches das Ergebnis verfälscht. Dadurch kommt es durch Fehlerfortpflanzung schnell zu größeren Ungenauigkeiten. Im Laufe der letzten Jahre wurden eine Vielzahl von Varianten des DMD Algorithmus entwickelt, um unterschiedliche Schwächen des Algorithmus auszugleichen.

Das klassische DMD benötigt Messdaten aus k Messungen in einheitlichen Zeitabständen. Für jeden Zeitpunkt i werden die jeweiligen Messdaten in die i -te Spalte einer Datenmatrix X eingetragen. Zusätzlich legen wir eine zweite Datenmatrix X' so an, dass wir in X die Messungen $(x_1, \dots, x_{k-1})$ und in X' die Messungen $(x_2, \dots, x_k)$ sammeln. Bei den Datenmatrizen handelt es sich um $p \times n$ Matrizen, wobei p die Dimension des Systems bzw. die Anzahl der Messdaten zum i -ten Zeitpunkt ist und $n = k - 1$ ist die Anzahl der Messungen. In der Regel haben die Datenmatrizen deutlich mehr Zeilen als Spalten also gilt $p \gg n$. Häufig sind die Systeme, die betrachtet werden, hochgradig nicht-linear. Durch das Aneinanderreihen der Messdaten in den Datenmatrizen wird die Dimension p des Systems erhöht. Dadurch lässt sich das System näherungsweise linear beschreiben. Das Ziel von DMD ist es einen linearen Operator A bzw. seine Spektralzerlegung zu finden, für den

$$X' \approx AX$$

so gut wie möglich gilt. Der Operator A muss diagonalisierbar sein. Der dafür am besten

passende Operator A lässt sich durch

$$A = \arg \min_{A \in \text{GL}(p, \mathbb{R})} \|X' - AX\|_F = X'X^\dagger$$

bestimmen. Dabei sind $\|\cdot\|_F$ die Frobeniusnorm und $X^\dagger$ die Moore-Penrose-Inverse, welche wir in Kapitel ?? und ?? noch genauer beschreiben werden. Die Moore-Penrose-Inverse lässt sich dann mittels Singulärwertzerlegung (SWZ) der Datenmatrix X bestimmen. Die SWZ beschreiben wir in Kapitel ?? nochmal genauer, liefern aber für einen ersten Überblick eine vereinfachte Beschreibung. Bei der SWZ finden wir für eine Matrix $X \in \mathbb{R}^{p \times n}$ zwei orthogonale Matrizen $U \in \mathbb{R}^{p \times p}$ und $V \in \mathbb{R}^{n \times n}$ und $\hat{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_r)$ mit $r \leq \min(p, n)$ und $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ so, dass

$$X = U\Sigma V^\top \quad \text{mit} \quad \Sigma = \begin{pmatrix} \hat{\Sigma} & 0 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{p \times n}$$

gilt. Bei der Bestimmung von A wird der Rechenaufwand schnell zu groß, weshalb der DMD Algorithmus eine Dimensionsreduktion durchführt. Als Dimensionsreduktion bezeichnen wir eine Methode, bei der die Dimension einer Matrix, beispielsweise auf ihren Rang, reduziert wird. Damit kann man eine Spektralzerlegung von A machen, ohne A direkt zu benutzen. Durch die oben genannte Form der Datenmatrizen kann man direkt sehen, dass X maximal von Rang n sein kann. Es gibt also maximal $r \leq n$ Singulärwerte, die nicht Null sind. Reduzieren wir also unser Σ aus der SWZ auf eine $r \times r$ große Matrix also $\hat{\Sigma}$ und entfernen alle Spalten außer die ersten r von U und V , erhalten wir mit den reduzierten Matrizen U_r , Σ_r und V_r ,

$$X_r = U_r \Sigma_r V_r^\top = U_r \hat{\Sigma} V_r^\top.$$

Nach dem Eckart-Young-Theorem [1, S. 9] lässt sich durch

$$\|X_r\|_F^2 = \sum_{i=1}^r \sigma_i^2$$

zeigen, dass X_r die beste Rang r -Approximation von X bezüglich der Frobeniusnorm ist. Die Spektralzerlegung von A können wir damit über die kleinere Matrix

$$\tilde{A} = U_r^\top A U_r$$

bestimmen. Diese Methode der Dimensionsreduktion für SWZ ist als *ökonomische SWZ*

bekannt.

Eine weitere Methode der Rangreduzierung, welche im Paper [2] von Matan Gavish und David L. Donoho behandelt wird, ist das „singular value hard thresholding“ (SVHD). Dies ist eine Rangreduzierung für Datenmatrizen, in der alle Singulärwerte, die unter einem definierten Schwellenwert τ liegen auf 0 gesetzt werden und die Dimensionen wie bei der ökonomischen SWZ angepasst werden. Gavish und Donoho definieren eine Rahmenstruktur, in der statt der Datenmatrix X eine Folge an Datenmatrix $\{X_\eta\}_{\eta \in \mathbb{N}}$ der Form

$$X_\eta := X_\eta^{\text{echt}} + \gamma X_\eta^{\text{rauschen}}$$

betrachtet wird, für die mit $\eta \rightarrow \infty$ die Dimensionen p und n gegen unendlich laufen. Dabei gilt für das Dimensions-Stichproben-Verhältnis $y = \frac{p}{n} \in (0, 1]$, dass es nicht divergiert. Wir haben also X_η in einen echten Teil und einem durch $\gamma \in \mathbb{R}$ skalierten Fehleranteil aufgeteilt. Die Einträge der Fehlermatrix sind dabei unabhängig und identisch verteilte Zufallsvariablen mit Erwartungswert $\mathbb{E}(X_\eta^{\text{rauschen}}) = 0$ und Varianz $\text{Var}(X_\eta^{\text{rauschen}}) = 1$. Zusätzlich werden die Singulärwerte von X_η^{echt} fixiert. Sei also r der Rang von X^{echt} und $\sigma_1^{\text{echt}}, \dots, \sigma_r^{\text{echt}}$ ihre Singulärwerte, dann ist die Singulärwertzerlegung von X_η^{echt} für alle η von der Form

$$X_\eta^{\text{echt}} = U_\eta \text{diag}(\sigma_1^{\text{echt}}, \dots, \sigma_r^{\text{echt}}, 0, \dots, 0) V_\eta^\top \quad (0.1)$$

mit passenden U_η und V_η .

Innerhalb dieser Rahmenstruktur haben Gavish und Donoho herausgefunden, dass für bekanntes Rauschen γ und bekanntem Dimensions-Stichproben-Verhältnis, der optimale Schwellenwert τ_* für Singulärwerte bei

$$\tau_* = \lambda_*(y) \gamma \sqrt{n} \quad \text{mit} \quad \lambda_*(y) := \sqrt{2(y+1) + \frac{8y}{(y+1) + \sqrt{y^2 + 14y + 1}}}$$

liegt. Bei quadratischen Matrizen ist $\lambda_* = \frac{4}{\sqrt{3}}$.

Wenn das Rauschen aber nicht bekannt ist, muss γ geschätzt werden. Das Ziel ist es also einen Schwellenwert $\hat{\tau}_*$ zu finden, ab dem davon ausgegangen werden kann, dass die Singulärwerte, die größer oder gleich diesem Schwellenwert sind, nur zu einem vernachlässigbaren Anteil aus Rauschen bestehen. Im Zusammenhang mit Singulärwerten von Zufallsmatrizen spielt die Marčenko-Pastur-Verteilung eine zentrale Rolle. Sie sagt aus, wie die quadrierten Singulärwerte von bestimmten Zufallsmatrizen verteilt sind.

Für unbekanntes Rauschen haben Gavish und Donoho dann mit dem Median der Sin-

gulärwerte $\sigma_{\text{med},\eta}$ von X_η und dem Median der Marčenko-Pastur-Verteilung μ_y , den Rausch-Schätzer

$$\hat{\gamma}(X) := \frac{\sigma_{\text{med},\eta}}{\sqrt{n\mu_y}}$$

definiert. Also mit $a = (1 - \sqrt{y})^2$, $b = (1 + \sqrt{y})^2$ und $a \leq \mu_y \leq b$ so, dass

$$\int_a^{\mu_y} \frac{1}{2\pi xy} \sqrt{(b-x)(x-a)} \, dx = \frac{1}{2}$$

gilt.

Mit $\hat{\gamma}$ haben Gavish und Donoho dann den Schwellenwert für Singulärwerte durch

$$\hat{\tau}_*(y, X) := \lambda_*(y) \hat{\gamma}(X) \sqrt{n} = \lambda_*(y) \frac{\sigma_{\text{med},\eta}}{\sqrt{\mu_y}}$$

definiert.

In dieser Arbeit konzentrieren wir uns zum Einen auf den DMD Algorithmus, und zum Anderen auf die Herleitung der Marčenko-Pastur-Verteilung, da diese wie gerade beschrieben ein wesentlicher Bestandteil der Dimensionsreduktion ist.