

Dieses Kapitel ist noch seeeehr work in progress also ich hab erstmal grob Gedanken aufgeschrieben.

## 0.1 paper [1]

## 0.2 Idee

Wir betrachten die gemessene Datenmatrix

$$X = X^{\text{true}} + \gamma X^{\text{noise}} \quad (0.1)$$

mit  $X \in \mathbb{R}^{n \times m}$ ,  $X^{\text{true}}$  als *echte* Datenmatrix und **approximately of low rank** und  $X^{\text{noise}}$  als Messfehlermatrix welche Unabhängig und identisch verteilte Zufallsvariablen enthält **vielleicht noch definieren**.

Hier benutzen wir die *truncated* Singulärwertzerlegung also

$$X = \sum_{i=1}^n \sigma_i u_i v_i' . \quad (0.2)$$

Schätzen kann man die *truncation* jetzt mit

$$\hat{X}_r = \sum_{i=1}^r \sigma_i u_i v_i' . \quad (0.3)$$

mit  $r = \text{rang}(X^{\text{true}})$  und den Singulärwerten wieder nach größe absteigend sortiert.

Da aber der Rang von  $X^{\text{true}}$  nicht unbedingt bekannt ist kann man versuchen, anhand der Größe, der Singulärwerte zu Kürzen. Dafür bauen wir mithilfe einer Indikatorfunktion  $\eta_H(\sigma_i; \tau) = \sigma \chi_{\{\sigma \geq \tau\}}$  die gekürzte Matrix

$$\hat{X}_\tau = \sum_{i=1}^r \eta_H(\sigma_i; \tau) u_i v_i' . \quad (0.4)$$

Jetzt gilt es aber herauszufinden wie wir dieses  $\tau$  wählen damit wir immernoch sinnvolle Ergebnisse erhalten, aber gleichzeitig zu viel rechenaufwand spaaren wie möglich.

### 0.3 Setting

**Definition 0.1** (denoiser). Ein *Denoiser* reduziert eine Matrix auf nur noch *relevante* Ränge mit der Form

$$\hat{X}: \sum_{i=1}^n \sigma_i u_i v_i' \rightarrow \sum_{i=1}^n \eta(\sigma_i; \lambda) u_i v_i' \quad (0.5)$$

**Definition 0.2** (Mean Square Error (MSE)). Mit dem MSE wird der Fehler der beim *denoising* Prozess entsteht, durch

$$\left\| \hat{X}(X) - X^{\text{true}} \right\|_F^2 = \sum_{i,j} \left( \hat{X}(X)_{i,j} - X_{i,j}^{\text{true}} \right)^2 \quad (0.6)$$

quantifiziert.

Wir betrachten eine Folge an denoising Problemen, die immer größer werden.

$$X_k = X_k^{\text{true}} + \gamma X_k^{\text{noise}} \quad (0.7)$$

mit  $X_k^{\text{true}}, X_k^{\text{noise}} \in M_{n_k, m}$ .

Jedes  $X_k^{\text{noise}}$  erfüllt die Eigenschaften von  $X^{\text{noise}}$ . Gegeben sei ein fixer Vektor  $\mathbf{x} \in \mathbb{R}^r$ , mit  $r > 0$ , den Einträgen  $\mathbf{x} = (x_1, \dots, x_r)$  und  $x_i \geq x_{i+1} > 0$ . Für alle  $k$  gilt

$$X_k^{\text{true}} = U_k \text{diag}(x_1, \dots, x_r, 0, \dots, 0) V_k'. \quad (0.8)$$

**Definition 0.3** (Asymptotic Mean Square Error (AMSE)). lalala